

CONHECIMENTOS ESPECÍFICOS

Data Mining



Presidente: Gabriel Granjeiro

Vice-Presidente: Rodrigo Calado

Diretor Pedagógico: Erico Teixeira

Diretora de Produção Educacional: Vivian Higashi

Gerência de Produção de Conteúdo: Magno Coimbra

Coordenadora Pedagógica: Élica Lopes

Todo o material desta apostila (incluindo textos e imagens) está protegido por direitos autorais do Gran Cursos Online. Será proibida toda forma de plágio, cópia, reprodução ou qualquer outra forma de uso, não autorizada expressamente, seja ela onerosa ou não, sujeitando-se o transgressor às penalidades previstas civil e criminalmente.

CÓDIGO:

230227518837



PATRÍCIA QUINTÃO

Mestre em Engenharia de Sistemas e computação pela COPPE/UFRJ, Especialista em Gerência de Informática e Bacharel em Informática pela UFV. Atualmente é professora no Gran Cursos Online; Analista Legislativo (Área de Governança de TI), na Assembleia Legislativa de MG; Escritora e Personal & Professional Coach.

Atua como professora de Cursinhos e Faculdades, na área de Tecnologia da Informação, desde 2008. É membro: da Sociedade Brasileira de Coaching, do PMI, da ISACA, da Comissão de Estudo de Técnicas de Segurança (CE-21:027.00) da ABNT, responsável pela elaboração das normas brasileiras sobre gestão da Segurança da Informação.

Autora dos livros: Informática FCC – Questões comentadas e organizadas por assunto, 3ª. edição e 1001 questões comentadas de informática (Cespe/UnB), 2ª. edição, pela Editora Gen/Método.

Foi aprovada nos seguintes concursos: Analista Legislativo, na especialidade de Administração de Rede, na Assembleia Legislativa do Estado de MG; Professora titular do Departamento de Ciência da Computação do Instituto Federal de Educação, Ciência e Tecnologia; Professora substituta do DCC da UFJF; Analista de TI/Suporte, PRODABEL; Analista do Ministério Público MG; Analista de Sistemas, DATAPREV, Segurança da Informação; Analista de Sistemas, INFRAERO; Analista – TIC, PRODEMGE; Analista de Sistemas, Prefeitura de Juiz de Fora; Analista de Sistemas, SERPRO; Analista Judiciário (Informática), TRF 2ª Região RJ/ES, etc.

Redes Sociais: @coachpatriciaquintao (Instagram) / profapatriciaquintao (YouTube) / @plquintao (Twitter) / t.me/coachpatriciaquintao (Telegram)

SUMÁRIO

Apresentação	5
Data Mining	6
1. O Contexto Atual	6
2. Motivos que Potencializam o Uso da Mineração de Dados	7
3. Definições	9
4. Quando a Mineração de Dados é Mais Indicada?	11
5. Processo de Descoberta de Conhecimento	12
6. Técnicas para Pré-Processamento de Dados	19
7. Fases da Mineração de Dados com Foco no Modelo CRISP-DM	19
7.1 Entendimento do Negócio (Business Understanding)	20
7.2. Seleção dos Dados (Data Understanding)	21
7.3. Limpeza dos Dados (Data Preparation)	21
7.4. Modelagem dos Dados (Modeling)	21
7.5. Avaliação do Processo (Evaluation)	22
7.6. Execução (Deployment)	22
8. Funcionalidades, Tarefas (ou Técnicas) Gerais de Mineração e Algoritmos	25
8.1. Tarefas de Descrição (ou Descritivas)	28
8.2. Tarefas de Predição (Preditivas ou de Previsão)	28
9. Principais Tarefas (ou Técnicas) de Mineração de Dados	31
9.1. Classificação	31
9.2. Análise de Clusters (Análise de Agrupamentos, Análise de Aglomerações ou Análise de Partições)	33
9.3. Detecção de Anomalias (Detecção de Desvios ou Mineração de Exceções) ..	35
9.4. Regras de Associação	36
9.5. Análise de Regressão	39
9.6. Árvores de Decisão	39
9.7. Métodos Bayesianos	41
9.8. Regras de Indução	41

9.9. Redes Neurais Artificiais	42
9.10. Lógica Nebulosa (Fuzzy Logic)	42
10. Métodos para Identificar Padrões em Dados	42
11. OLAP e Data Mining	43
12. Características dos Conjuntos de Dados	44
13. Mineração de Texto (Text Mining)	44
Mapa Mental	46
Questões Comentadas em Aula	51
Exercícios	55
Gabarito	64
Gabarito Comentado	65
Referências	87

APRESENTAÇÃO

Olá, querido(a) amigo(a)!

Seja você quem for, seja qual for a posição social que você tenha na vida, a mais alta ou a mais baixa, tenha sempre como meta muita força, muita determinação e sempre faça tudo com muito amor e com muita fé em Deus, que um dia você chega lá. De alguma maneira você chega lá.

Ayrton Senna

Saber o que te limita a lutar pelos seus sonhos é fundamental para dar o primeiro passo.

Acredite na sua capacidade e supere os desafios! 😊

Rumo então à aula sobre **Mineração de Dados**, com tópicos importantes para entendimento da disciplina.

Espero que esteja aproveitando todo o curso!

Grande abraço!

DATA MINING

1. O CONTEXTO ATUAL

De 1990 em diante o volume de informações armazenadas em meio eletrônico cresceu aceleradamente. Estudos mostram que **a quantidade de informação no mundo dobra a cada 20 meses**, e, como consequência, o tamanho e a quantidade de banco de dados espalhados pelo mundo cresce ainda mais aceleradamente.

E que valor tem esses dados armazenados? Por que tanta informação precisa ser mantida de modo cumulativo e não é simplesmente descartada pouco tempo depois do seu uso?

O fato é que nesse meio há um amontoado de dados que estão gravados nos bancos de dados e, também, há muita informação não explorada, que poderia ser de grande valia para o **suporte às decisões** nas grandes corporações, governos, universidades e outros.

Há nesse “enxame” de dados, tidos como desnecessários por alguns, **padrões e tendências que se descobertos podem ser úteis** para entender e otimizar os processos de negócio em empresas, ajudar a entender melhor os resultados de experiências científicas, colaborar com a medicina no entendimento e tratamento de casos de epidemias, e muitos outros.

É justamente nesse cenário que entra em cena o **Data Mining (Mineração de Dados)**. Pode ser entendido como **um campo de estudo que procura encontrar informações que estão implícitas**, ou seja, **procura padrões e tendências ocultas em base de dados**.

Um exemplo de *Data Mining* muito comum são as previsões meteorológicas, em que é utilizado como forma de prever as alterações climáticas. Para tanto, são analisados os registros climáticos dos últimos 10 a 20 anos e procura-se identificar os **padrões de alterações climáticas** nesses períodos, a fim de se conseguir **prever as próximas alterações**. Assim, **o Data Mining exerce a função de identificar padrões e tendências meteorológicas**.

Esse novo campo de estudos que é o **Data Mining** é tido como crítico para os negócios das grandes empresas e **continua a crescer**, uma vez que o uso das informações obtidas por meio de mineração de dados tornou-se imprescindível para a sustentação da competitividade no ambiente comercial dos dias de hoje.

Em geral, **o valor da informação para apoiar a tomada de decisão aumenta a partir da base da pirâmide** ilustrada na figura destacada a seguir (AMORIM, 2006).




Figura. Evolução do Valor Estratégico de Bases de Dados. (Baseado em [Navega, 2002])

Uma decisão baseada em dados nas camadas mais baixas, em que há tipicamente milhões de registros de dados, não possui muito valor agregado; no entanto aquela apoiada em dados altamente resumidos nas camadas superiores da pirâmide tem probabilidade de **alto valor estratégico** (AMORIM, 2006).


E também, alia-se a isso, o fato de que com o armazenamento de grandes quantidades de dados num local comum e, também, o contínuo avanço da capacidade de processamento dos computadores, os empresários passaram a procurar por **tecnologias para extração de informação útil em meio aos infindáveis amontoados de dados**.

2. MOTIVOS QUE POTENCIALIZAM O USO DA MINERAÇÃO DE DADOS

- O **volume de dados** disponível atualmente é **enorme**.
- Os **dados** estão sendo **organizados**.
- Os **recursos computacionais** estão cada vez mais **potentes**.
- A **competição empresarial** exige técnicas mais modernas de decisão.
- Programas comerciais de mineração de dados já podem ser adquiridos.

TAN et. al (2009, p. 05) destaca alguns **aspectos motivadores da Mineração de Dados**:

- **escalabilidade**: devido aos avanços na geração e coleta, conjuntos de dados com tamanhos em gigabytes, terabytes e petabytes, por exemplo, estão se tornando **comuns**;



- **alta dimensionalidade:** é comum encontrarmos conjuntos de dados com centenas ou milhares de atributos ao invés do punhado comum de uma década atrás;
- **dados complexos e heterogêneos:** diversificação de tipos de atributos e relacionamentos entre eles;
- **propriedade e distribuição dos dados:** os dados utilizados para análise nem sempre estão mais num mesmo local e pertencem a múltiplas instâncias organizacionais;
- **análises não tradicionais:** novas técnicas para validação de hipóteses têm surgido atualmente.

DIRETO DO CONCURSO

001. (ESAF/CGU/ANALISTA DE FINANÇAS E CONTROLE/AUDITORIA E FISCALIZAÇÃO/GERAL/2012) São aspectos motivadores da Mineração de Dados:

- Escalabilidade. Dimensionalidade moderada. Dados homogêneos. Propriedade e centralização dos dados.
- Extensibilidade. Alta paridade. Dados complexos e heterogêneos. Concorrência e distribuição dos dados.
- Escalabilidade. Alta dimensionalidade. Dados complexos e heterogêneos. Propriedade e distribuição de dados.
- Escalabilidade. Dimensionalidade variável. Dados compatíveis e acoplados. Adequação da distribuição de dados.
- Especialidade. Alta dimensionalidade de verificação. Dados complexos e complementares. Propriedade e consistência de dados.



A banca retirou os aspectos de TAN *et. al* (2009, p. 05) e todos os que foram listados na

assertiva C estão corretos: escalabilidade, alta dimensionalidade, dados complexos e

O conteúdo deste livro eletrônico é licenciado para ALEXANDRE LINS DE ALMEIDA SILVA ALFOLIM, 0495308641, sendo vedada a reprodução, a sua reprodução, cópia, divulgação ou distribuição, sujeitando-se aos infratores à responsabilização civil e criminal.

heterogêneos; propriedade e distribuição de dados. Um aspecto abordado no livro e não mencionado na questão é o de “**Análises não tradicionais**”.

- **Escalabilidade:** devido aos avanços na geração e coleta, conjuntos de dados com tamanhos em gigabytes, terabytes e mesmo petabytes estão se tornando comuns;
- **Alta dimensionalidade:** é comum encontrarmos conjuntos de dados com centenas ou milhares de atributos ao invés do punhado comum de uma década atrás;
- **Dados complexos e heterogêneos:** diversificação de tipos de atributos e relacionamentos entre eles;
- **Propriedade e distribuição dos dados:** os dados utilizados para análise nem sempre estão mais num mesmo local e pertencem a múltiplas instâncias organizacionais;
- **Análises não tradicionais:** novas técnicas para validação de hipóteses têm surgido atualmente.

Letra c.

3. DEFINIÇÕES

Nos seus primeiros anos o **Data Mining (Mineração de Dados)** foi popularmente tratado como sinônimo de **Descoberta de Conhecimento em Base de Dados** (da sigla em inglês **KDD – Knowledge Discovery in Databases**).

Mas na visão de muitos pesquisadores **Data Mining** deve ser entendido como **um passo da descoberta de conhecimento, independentemente se será sobre uma base de dados ou sobre quaisquer outros repositórios de conhecimento.**

O **Data Mining** é entendido como o **processo de identificar informações relevantes**, tais como padrões, associações, mudanças, anomalias e estruturas, **em grandes conglomerados de dados** que estejam em banco de dados ou outros repositórios de informações.

A **mineração de dados** é um campo interdisciplinar que reúne técnicas de **aprendizado de máquina, reconhecimento de padrões, estatísticas, banco de dados e visualização** para abordar a questão da extração de informações a partir de grandes bases de dados (*Evangelos Simoudis, citado em Daniel T. Larose, Discovering Knowledge in Data – An Introduction to Data Mining*).



Figura. Disciplinas envolvidas com Mineração de Dados (HAN & KAMBER, 2006)

Fayyad et al. (1996) sintetiza **Data Mining** como “o **processo não trivial de identificar, em dados, padrões válidos, novos, potencialmente úteis e ultimamente compreensíveis**”.

Obs.: Mineração de Dados (ou Data Mining)

Etapas do processo de KDD. Corresponde à execução de um algoritmo particular que, sob algumas limitações aceitáveis de eficiência computacional, encontra padrões ou modelos nos dados.

É o processo de análise de conjuntos de dados que tem por objetivo a descoberta de padrões interessantes e que possam representar informações úteis.

Um conceito já cobrado em prova foi proposto na edição antiga do livro “Data Mining Techniques: For Marketing, Sales, and Customer Support”, listada a seguir: “a **mineração de dados** é a exploração e análise, por **meios automáticos ou semiautomáticos, de grandes quantidades de dados a fim de descobrir padrões e regras significativas** (1997).

Na edição mais atual do livro o conceito é o seguinte:

Obs.: A mineração de dados é um processo de negócio que permite explorar grandes quantidades de dados para descobrir padrões e regras significativas (2011).

Laudon & Laudon (2014) afirmam que a **mineração de dados** fornece *insights* em dados corporativos que não podem ser obtidos com OLAP, **ao encontrar padrões escondidos e relacionamentos em grandes bancos de dados e inferindo regras a partir deles, de modo a prever comportamento futuro**.

SAS, empresa pioneira em sistemas analíticos, destaca que a **mineração de dados** é o **processo de encontrar anomalias, padrões e correlações em grandes conjuntos de dados** [...].

Obs.: O Data Mining apoia o conhecimento indutivo, que descobre novas regras e padrões nos dados fornecidos (ELMASRI, NAVATHE, 2005)

DIRETO DO CONCURSO



002. (CESPE/EBSERH/ANALISTA DE TECNOLOGIA DA INFORMAÇÃO/2018) Julgue o item que se segue, a respeito de arquitetura e tecnologias de sistemas de informação.

A descoberta de novas regras e padrões em conjuntos de dados fornecidos, ou aquisição de conhecimento indutivo, é um dos objetivos de data mining.



O conhecimento é classificado em **indutivo** e **dedutivo**. O conhecimento dedutivo deduz novas informações baseadas na aplicação de regras lógicas predefinidas de dedução sobre dados existentes. **O Data Mining apoia o conhecimento indutivo**, que descobre novas regras e padrões nos dados fornecidos. (ELMASRI, NAVATHE, 2005).

Certo.

4. QUANDO A MINERAÇÃO DE DADOS É MAIS INDICADA?

Hoje praticamente não existe nenhuma área de conhecimento em que técnicas de *Data Mining* não possam ser usadas. Entretanto **existem áreas nas quais o uso tem sido mais frequente**, como por exemplo:

- **Marketing:** redução dos custos com o envio de correspondências por meio de sistemas de mala direta a partir da identificação de grupos de clientes potenciais;
- **Deteção de fraude:** reclamações indevidas de seguro, chamadas clonadas de telefones celulares, compras fraudulentas com cartão de crédito.
 - Atualmente, em telecomunicações, existe uma explosão de crimes contra a telefonia celular, dentre os quais, a clonagem. Técnicas de *data mining* podem ser utilizadas para detectar hábitos dos usuários de celulares. Quando um telefonema for feito e considerado pelo sistema como uma exceção, o programa faz uma chamada para confirmar se foi ou não uma tentativa de fraude.
- **Produção:** empresas desenvolvem sistemas para detectar e diagnosticar erros na fabricação de produtos. Estas falhas são normalmente agrupadas por técnicas de

Análise de Agrupamentos

- **Previsões meteorológicas:** utilizado como forma de prever as alterações climáticas. Para tanto, são analisados os registros climáticos dos últimos 10 a 20 anos e procura-se identificar os **padrões de alterações climáticas** nesses períodos, a fim de se conseguir **prever as próximas alterações**. Assim, o *Data Mining* exerce a função de **identificar padrões e tendências meteorológicas**.

As áreas em que as aplicações de mineração de dados são bem-sucedidas possuem estas **características**:

- exigem **decisões baseadas em conhecimento**;
- possuem **um ambiente em mudança constante**;
- possuem **dados acessíveis, suficientes e relevantes**;
- fornecem um **retorno significativo para decisões corretas**.

DIRETO DO CONCURSO

003. (CESPE/TCU/AUDITOR FEDERAL DE CONTROLE EXTERNO/CONHECIMENTOS GERAIS/2015) No que concerne a data mining (mineração de dados) e big data, julgue o seguinte item. No ambiente organizacional, devido à grande quantidade de dados, não é recomendado o emprego de data mining para atividades ligadas a *marketing*.



Conforme visto, nos dias atuais praticamente não existe nenhuma área de conhecimento em que técnicas de *Data Mining* não possam ser usadas. Entretanto **existem áreas nas quais o uso tem sido mais frequente**, como a área de **Marketing**, sendo utilizada na redução dos custos com o envio de correspondências por meio de sistemas de mala direta a partir da identificação de grupos de clientes potenciais, etc.

Errado.

5. PROCESSO DE DESCOBERTA DE CONHECIMENTO

Vamos então as principais considerações sobre o processo de **Descoberta de Conhecimento em Base de Dados (KDD - Knowledge Discovery in Databases)**:

- “é o processo não trivial de identificação de **padrões/modelos** em dados que sejam **válidos, novos, potencialmente úteis e compreensíveis**”;
- “é uma tarefa cujo uso de conhecimento é intensivo, consistindo de complexas interações, prolongadas no tempo, entre uma pessoa e um banco de dados, possivelmente suportada por um conjunto heterogêneo de ferramentas”.

KDD é **pluridisciplinar**, pois envolve **banco de dados**, **técnicas de estatísticas**, redes neurais, de aprendizado de máquinas, **de reconhecimento de padrões** e de **visualização de dados**.

A figura seguinte ilustra o processo de **KDD** proposto por Usama Fayyad, Gregory Piatetsky-Shapiro e Padhraic Smyth (1996).




Figura. Processo de KDD. Adaptação da proposta realizada por Usama Fayyad, Gregory Piatetsky-Shapiro e Padhraic Smyth (1996)

O **processo de KDD** é iterativo (pois o usuário pode intervir e controlar o curso das atividades) e iterativo (por ser uma sequência finita de operações em que o resultado de cada uma é dependente dos resultados das que a precedem), com os passos listados a seguir:

- **entendimento do domínio da aplicação e identificação do objetivo do processo de KDD;**
- **seleção:** criação de um conjunto-alvo de dados;
- **pré-processamento:** limpeza de dados e operações básicas como remoção de ruído, tratamento para a falta de dados, etc. É o passo mais trabalhoso e demorado do processo de KDD.

Algumas **técnicas de pré-processamento** conhecidas são:

- **análise de outliers (registros que apresentam grande discrepância em relação à maioria dos registros).** A figura seguinte identifica visualmente a presença de *outliers*, em que os pontos externos aos polígonos são valores fora dos padrões da população observada.




Figura. Detecção de Outliers utilizando uma abordagem visual. Fonte: Cortês et. al., 2002

- remoção de ruídos ou dados espúrios (**dados medidos errados**);
- estimativa de dados faltantes por modelagem;
- formatação dos dados para a ferramenta específica;
- criação de atributos derivados e de novos registros;
- integração de tabelas;
- discretização de dados numéricos;
- **transformação**: encontrar características úteis para representar os dados, conforme o objetivo definido e realizar a redução ou transformação da dimensionalidade;
- **mineração de dados (Data Mining)**: casar os objetivos do processo de KDD com um método particular de mineração de dados e realizar a análise exploratória e seleção de modelo e hipótese, buscando **padrões** de interesse;
- **interpretação**: interpretar e avaliar os padrões minerados, podendo retornar a passos anteriores caso seja necessário; **agir a partir do conhecimento descoberto**.

DIRETO DO CONCURSO



004. (FCC/INFRAERO/ANALISTA DE SISTEMAS/ADMINISTRADOR DE BANCO DE DADOS/2011)

Funcionalidade cujo objetivo é encontrar conjuntos de dados que não obedecem ao comportamento ou modelo dos dados. Uma vez encontrados, podem ser tratados ou descartados para utilização em mining. Trata-se de

- a) descrição.
- b) agrupamento.
- c) visualização.
- d) análise de *outliers*.
- e) análise de associações.



Esta questão merece atenção por tratar de uma atividade em **Data Mining** chamada de **Análise de Outliers**. Na busca de padrões e associações em banco de dados, é comum identificarmos numa **amostra de dados alguns registros que fogem aos padrões identificados**, ou seja, num grupo de registros é muito comum alguns registros apresentarem grande discrepância em relação à maioria dos registros. E esses registros que apresentam grande discrepância são chamados de **Outliers**.

É necessário em um processo de *Data Mining* eliminar os *outliers*, pois a presença de alguns raros registros com grandes discrepâncias na amostra pode induzir a tendências, médias estatísticas e padrões distorcidos. Por isso, a atividade de Análise de *Outliers* consiste em procurar os *outliers*, e eliminá-los antes da apuração dos padrões e associações durante o *Data Mining*.

Letra d.

Fayyad *et al.* (1996) destaca o processo de **descoberta de conhecimento** de forma mais simplificada, baseada em três etapas: **Preparação, Data Mining e Análise de Dados**.

Processo de Descoberta de Conhecimento




Figura. Etapas do Processo de Descoberta de Conhecimento

Vejamos cada uma delas:

- **Preparação:** é a etapa que **trata de preparar os dados antes de serem submetidos às técnicas de Data Mining**. Nessa etapa, os dados são selecionados (Quais dados

são importantes?), purificados (retirar as inconsistências e incompletude de dados) e pré-processados (reapresentá-los de uma forma adequada para o processo de *Data Mining*).

Esse passo é executado sob a supervisão de um especialista, pois é necessária a colaboração de uma pessoa apta para definir quais dados são relevantes e também para definir o que fazer com os dados antes de utilizá-los no *Data Mining*.

- **Data Mining:** é a etapa em que os dados preparados são processados, em que se faz a mineração dos dados propriamente dita.

O principal objetivo desse passo é transformar os dados de uma maneira que permita a identificação mais fácil de informações importantes.

O que se tenta fazer nessa etapa é **identificar padrões de comportamento**, por exemplo, pode ser verificado que 75% dos clientes de um supermercado que compram um produto X também compram um produto Y. Essa informação pode levar as empresas a criarem novos planos de marketing em cima dos produtos X e Y.

Portanto, esses padrões e associações, vão compor o conhecimento da empresa sobre o negócio em que atua, ajudando-a a obter maiores lucros e aumentar a satisfação de seus clientes.

Obs.: O Data Mining é uma etapa do KDD em que são aplicadas técnicas para identificação de padrões sobre os dados disponíveis. Tais dados estão disponíveis em meios digitais, e comumente são trabalhados os dados que estão em bases de dados.

Esse processo como um todo tem o intuito de trabalhar os dados registrados ao longo do tempo de vida de um negócio a fim de se identificar **padrões** que representam alguma informação sobre o comportamento do negócio. E em função dessas informações busca-se identificar conhecimento que possa conduzir a melhores decisões sobre o negócio. Esse processo de Descoberta de Conhecimento sendo repetido continuamente resultará em sabedoria sobre o domínio de negócio para os tomadores de decisões.

- **Análise de Dados:** aqui **o resultado do Data Mining é avaliado**, com o objetivo de determinar se algum conhecimento adicional foi descoberto, assim como definir a importância dos fatos gerados.

Nessa etapa, várias formas de análise podem ser utilizadas, por exemplo: o resultado do *Data Mining* pode ser expresso em um gráfico, em que análise dos dados passa a ser uma análise do comportamento do gráfico.

O **processo de KDD** segundo outros autores, como Terra (2000) pode ser visto a seguir:



Figura. Proposta de processo de KDD (TERRA, 2000)

Em outra visão (CAVALCANTI, 2012), tem-se a figura seguinte.




Figura. Fonte: Cavalcanti (2012)

DIRETO DO CONCURSO

005. (FCC/CNMP/ANALISTA DO CNMP/DESENVOLVIMENTO DE SISTEMAS/2015) Em relação às ferramentas de Data Discovery e os fundamentos de Data Mining, é correto afirmar:

a) *Data Mining* é o processo de descobrir conhecimento em banco de dados, que envolve várias etapas. O KDD Knowledge Discovery in Database é uma destas etapas, portanto, a mineração de dados é um conceito que abrange o KDD.

b) A etapa de KDD do Data Mining consiste em aplicar técnicas que auxiliem na busca de relações entre os dados. De forma geral, existem três tipos de técnicas: Estatísticas,

Exploratórias e Intuitivas. Todas são devidamente experimentadas e validadas para o processo de mineração.

c) Os dados podem ser não estruturados (bancos de dados, CRM, ERP), estruturados (texto, documentos, arquivos, mídias sociais, cloud) ou uma mistura de ambos (emails, SOA/web services, RSS). As ferramentas de Data Discovery mais completas possuem conectividade para todas essas origens de dados de forma segura e controlada.

d) Estima-se que, atualmente, em média, 80% de todos os dados disponíveis são do tipo estruturado. Existem diversas ferramentas open source e comerciais de Data Discovery. Dentre as open source está a InfoSphere Data Explorer e entre as comerciais está a Vivisimo da IBM.

e) As ferramentas de *Data Mining* permitem ao usuário avaliar tendências e padrões não conhecidos entre os dados. Esses tipos de ferramentas podem utilizar técnicas avançadas de computação como redes neurais, algoritmos genéticos e lógica nebulosa, dentre outras.



Vamos analisar cada um dos itens:

a) Errada. O Processo de Descoberta de Conhecimento em Base de Dados (KDD - *Knowledge Discovery in Databases*) abrange a mineração de dados! Como exemplo, Fayyad et al. (1996) destaca o processo de descoberta de conhecimento de forma mais simplificada, baseada em **três etapas: Preparação, Data Mining e Análise de Dados**. O Data Mining é uma etapa do KDD em que são aplicadas técnicas para identificação de padrões sobre os dados disponíveis.

b) Errada. A etapa de *Data Mining* do KDD consiste em aplicar técnicas que auxiliem na busca de relações entre os dados.

c) Errada. Os dados podem ser estruturados (bancos de dados, CRM, ERP), não-estruturados (Ex.: arquivos de mídias sociais, etc.) ou uma mistura de ambos. As ferramentas de *Data Mining* mais completas possuem conectividade para todas essas origens de dados de forma segura e controlada.

d) Errada. Estima-se que, atualmente, em média, 80% de todos os dados disponíveis são do tipo não estruturado. Existem diversas ferramentas open source e comerciais de *Data Discovery*. Dentre as open source podemos citar **Weka** (um projeto open source que significa Waikato Environment for Knowledge Analysis – Ambiente para Análise de Conhecimento Waikato) e entre as comerciais está a **Vivisimo** e **InfoSphere Data Explorer** da IBM.

e) Certa. As ferramentas de **Mineração de Dados (Data Mining)** permitem ao usuário avaliar **tendências e padrões** não conhecidos entre os dados. Esses tipos de ferramentas podem utilizar técnicas avançadas de computação como redes neurais, árvores de decisão, algoritmos genéticos (AGs) e lógica nebulosa (*Fuzzy logic* – teoria matemática que permite

uma modelagem do modo aproximado de raciocínio, imitando a habilidade humana de tomar uma decisão).

decisões em ambientes de incertezas e imprecisão. Com isso, pode-se construir sistemas inteligentes de controle e suporte à decisão), estatística, etc.

Letra e.

6. TÉCNICAS PARA PRÉ-PROCESSAMENTO DE DADOS

A seguir, são destacadas inúmeras **técnicas de pré-processamento**, voltadas para **preparação dos dados de forma que estes sejam submetidos à Mineração de Dados**.

Essas técnicas buscam melhorar a qualidade dos dados e, conseqüentemente, a eficiência e resultados do *Data Mining*.

Técnicas de Pré-Processamento	Descrição
Agregação	Combinar dois ou mais objetos em um único.
Amostragem	Selecionar um subconjunto dos objetos de dados a serem analisados.
Redução de dimensionalidade	Diminuir o número de atributos para facilitar a análise (uso de técnicas de álgebra linear).
Seleção de subconjuntos de recursos	Eliminar características irrelevantes ou redundantes (senso comum).
Criação de recursos (características)	Criar, a partir dos originais, um novo conjunto de atributos que capture as informações importantes em um conjunto de dados muito mais eficazmente (extrair faces de uma foto).
Discretização e binarização	Categorizar atributos para facilitar o uso de algoritmos de classificação.
Transformação de variáveis	Transformar atributos ou variáveis , por exemplo, uso do valor absoluto.

7. FASES DA MINERAÇÃO DE DADOS COM FOCO NO MODELO CRISP-DM

Em 1996, um conjunto de três empresas especializadas no mercado de *Data Mining*, desenvolveram um **modelo de processos genéricos**, com o intuito de padronizar as etapas do processo de mineração de dados, dando início ao **projeto CRISP-DM (CROSS Industry Standard Process for Data Mining - Processo Padrão Inter-Indústrias para Mineração de Dados)** (The CRISP-DM Consortium, 2000).

Esse **modelo de processo de mineração de dados industrial e livre de ferramenta** **propõe uma visão geral do ciclo de vida de um projeto de mineração de dados**. Ele contém as **fases** correspondentes de um projeto, suas respectivas **tarefas** e **relacionamentos** entre essas tarefas.

Na figura seguinte é mostrado o **ciclo de vida de um projeto de mineração de dados**, que consiste de **06 (seis) fases**.




Figura - Fases do CRISP-DM Process Model (Baseado em [The CRISP-DM Consortium, 2000])

A **sequência** dessas fases **NÃO** é obrigatória, ocorrendo a transição para diferentes fases, dependendo do resultado de cada fase, e que etapa particular de cada fase precisa ser executada em seguida. **As setas indicam as mais importantes e mais frequentes dependências entre as fases.**

O ciclo externo na figura simboliza o ciclo natural da mineração de dados. Um processo de mineração de dados continua após a solução ter sido desenvolvida. Processos subsequentes se beneficiarão das experiências de processos anteriores.

Obs.: As setas interiores, indicam as dependências mais importantes e frequentes entre as diversas fases.

A seguir, destacamos uma síntese das **etapas pertencentes ao modelo CRISP** (The CRISPDM Consortium, 2000):

7.1 ENTENDIMENTO DO NEGÓCIO (BUSINESS UNDERSTANDING)

Essa fase inicial tem o **foco no entendimento do negócio** que **visa obter conhecimento sobre os objetivos do negócio e seus requisitos**, e então converter esse conhecimento em

uma definição de um problema de mineração de dados, e um plano preliminar designado para alcançar esses objetivos.

7.2. SELEÇÃO DOS DADOS (DATA UNDERSTANDING)

Consiste no entendimento dos dados, que visa à familiarização com o banco de dados pelo grupo de projeto, utilizando-se de conjuntos de dados “modelo”.

Uma vez definido o **domínio** sobre o qual se pretende executar o processo de descoberta, o próximo passo é selecionar e coletar o conjunto de dados ou variáveis necessárias. Essa fase se inicia com uma coleta inicial de dados, e com procedimentos e atividades visando a familiarização com os dados, para identificar possíveis problemas de qualidade, ou detectar subconjuntos interessantes para formar hipóteses.

7.3. LIMPEZA DOS DADOS (DATA PREPARATION)

A fase de limpeza dos dados consiste na **preparação dos dados** que visa **a limpeza, transformação, integração e formatação dos dados da etapa anterior**. É a atividade na qual os ruídos, dados estranhos ou inconsistentes são tratados.

Essa fase abrange todas as atividades para construir o conjunto de dados final (dados que serão alimentados nas ferramentas de mineração), a partir do conjunto de dados inicial.

A utilização de *Data Warehouses* facilita muito esta etapa do processo de mineração de dados, que costuma ser a fase que exige mais esforço, correspondendo geralmente a mais de 50% do trabalho. Por isso, é muito importante que a organização possua em seus processos habituais boas práticas da administração de dados, como o *Data Cleansing*, que é uma parte fundamental da cadeia da administração da informação, responsável pelas etapas de detecção, validação e correção de erros em bases de dados (Chapman, 2005).

7.4. MODELAGEM DOS DADOS (MODELING)

Fase que consiste na **modelagem dos dados**, **a qual visa a aplicação de técnicas de modelagem sobre o conjunto de dados preparado na etapa anterior**. Nessa fase, várias técnicas de modelagem são selecionadas e aplicadas, e seus parâmetros são calibrados para se obter valores otimizados. **Geralmente, existem várias técnicas para o mesmo tipo de problema de mineração.**

Algumas técnicas possuem requerimentos específicos na forma dos dados. Consequentemente, voltar para a etapa de preparação de dados é frequentemente necessário. A maioria das técnicas de mineração de dados são baseadas em conceitos de aprendizagem de máquina, reconhecimento de padrões, estatística, classificação e clusterização.

7.5. AVALIAÇÃO DO PROCESSO (EVALUATION)

A avaliação do processo **visa garantir que o modelo gerado atenda às expectativas da organização**. Os resultados do processo de descoberta do conhecimento podem ser mostrados de diversas formas. Porém, estas formas devem possibilitar uma análise criteriosa para identificar a necessidade de retornar a qualquer um dos estágios anteriores do processo de mineração.

Nesta etapa se construiu um modelo que parece de alta qualidade, de uma perspectiva da análise de dados. Antes de prosseguir, é importante avaliar mais detalhadamente o modelo, e rever as etapas executadas para construir o modelo, para se certificar de que ele conseguirá alcançar os objetivos de negócio. Deve se determinar se houve algum importante objetivo do negócio que não foi suficientemente alcançado. No fim desta fase, uma decisão sobre o uso dos resultados da mineração deve ser tomada.

7.6. EXECUÇÃO (DEPLOYMENT)

Esta fase consiste na **definição das fases de implantação do projeto de Mineração de Dados**. A criação do modelo não é o fim do projeto. Mesmo se a finalidade do modelo for apenas aumentar o conhecimento dos dados, o conhecimento ganho necessitará ser organizado e apresentado em uma maneira que o cliente possa usar.

Dependendo das exigências, a fase de execução pode ser tão simples quanto a geração de um relatório, ou tão complexo quanto executar processos de mineração de dados repetidamente. Em muitos casos será o cliente, não o analista dos dados, que realizará as etapas da execução. Entretanto, mesmo se o analista não se encarregar da execução é importante que ele faça o cliente compreender que medidas deverão ser tomadas a fim de empregar efetivamente os modelos criados.

Obs.: CRISP-DM: modelo de processo de Mineração de Dados, não proprietário, com o objetivo de guiar os esforços de *Data Mining* nas organizações.

O **processo do CRISP-DM** é organizado em um conjunto de **6 etapas (fases)**: entendimento do negócio, seleção dos dados, limpeza ou preparação dos dados, modelagem dos dados, avaliação do processo e execução.

Essas etapas são executadas de forma **interativa e iterativa**. Assim, **a sequência da execução pode ser alterada em função das entradas e saídas fornecidas**. O encadeamento das ações, dependendo do objetivo e de como as informações se encontram, permite o retrocesso a passos já realizados.

DIRETO DO CONCURSO

006. (CESPE/TCE-PE/AUDITOR DE OBRAS PÚBLICAS/2017) Julgue o item que se refere a CRISP-DM (Cross Industry Standard Process for Data Mining).

Durante a fase de entendimento do negócio, busca-se descrever claramente o problema, fazer a identificação dos dados e verificar se as variáveis relevantes para o projeto não são interdependentes.



Destacamos na tabela seguinte uma visão geral das fases do CRISP-DM, para melhor fixação desse assunto! Vamos lá!

(1) Entendimento do Negócio (Business Understanding)	Foco no entendimento do negócio que visa obter conhecimento sobre os objetivos do negócio e seus requisitos.
(2) Seleção dos Dados (Data Understanding)	Consiste no entendimento dos dados , que visa à familiarização com o banco de dados pelo grupo de projeto, utilizando-se de conjuntos de dados “modelo”.
(3) Limpeza dos Dados ou Preparação dos Dados (Data Preparation)	Fase de preparação de dados , buscando a limpeza, a transformação, a integração e a formatação dos dados da etapa anterior.
(4) Modelagem dos Dados (Modeling)	Fase que consiste na modelagem dos dados, a qual visa à aplicação de técnicas de modelagem sobre o conjunto de dados preparado na etapa anterior . Técnicas são baseadas em conceitos de: aprendizagem de máquina; reconhecimento de padrões; estatística; clusterização, etc.
(5) Avaliação do processo (Evaluation)	Visa garantir que o modelo gerado atenda às expectativas da organização . Os resultados do processo de descoberta do conhecimento podem ser mostrados de diversas formas.
(6) Execução (Deployment)	Esta fase consiste na definição das fases de implantação do projeto de Mineração de Dados .

Figura – Visão Geral das Fases do CRISP-DM Process Model (Elaboração Própria)

Observe que a banca misturou conceitos das fases 1 e 2 no enunciado da questão. **Durante a fase de entendimento do negócio, busca-se descrever claramente o problema, e na fase de seleção de dados é possível fazer a identificação dos dados e verificar se as variáveis relevantes para o projeto não são interdependentes.** Portanto, a assertiva está errada. **Letra e.**

Como uma metodologia, **CRISP-DM inclui descrições de fases típicas de um projeto, as tarefas envolvidas em cada fase e uma explicação dos relacionamentos entre essas tarefas**; como um modelo de processos, **provê uma visão do ciclo de vida do Data Mining**.

O ciclo de vida consiste em **6 (seis) fases** com setas indicando as dependências mais importantes e frequentes entre fases. **A sequência entre as fases não é restrita**.

O conteúdo das provas, questões e demais materiais publicados em nosso site são de propriedade intelectual da Gran Cursos Online e não podem ser reproduzidos ou utilizados de qualquer forma sem a autorização expressa da Gran Cursos Online. A reprodução, cópia, divulgação ou distribuição, sujeitando-se aos infratores à responsabilização civil e criminal.

A **metodologia CRISP-DM** é descrita como um modelo de processo hierárquico constituído por **um conjunto de tarefas** descritas em **quatro níveis de abstração**.

Obs.: **CRISP-DM**, essencialmente, é um **modelo de quatro níveis**, movendo-se do mais genérico (as **fases**), passando por **tarefas genéricas**, realizando o mapeamento em **tarefas especializadas** e instâncias de processo.

No seu nível mais elevado são definidas **6 fases**.

Cada fase é composta por um número de **tarefas genéricas** concebidas com a finalidade de cobrir todas as possíveis situações de *Data Mining*.

Cada tarefa genérica é subdividida em **tarefas especializadas** que serão ou não executadas de acordo com o tipo do problema que se pretende resolver. Neste nível, pretende-se descrever de que forma terão lugar as ações que fazem parte de uma tarefa genérica numa determinada situação.

O último nível diz respeito ao **instanciamento do processo**, por meio do registro das ações, decisões e resultados de um trabalho de *Data Mining*.




Figura. CRISP Process Model

8. FUNCIONALIDADES, TAREFAS (OU TÉCNICAS) GERAIS DE MINERAÇÃO E ALGORITMOS

A figura seguinte, ilustra, em camadas, as **interações** entre **funcionalidades**, **técnicas da mineração de dados e algoritmos**, com o objetivo de esclarecer a interatividade do **objetivo** da mineração de dados com as **técnicas** a serem empregadas.




Figura. Interatividade entre as funcionalidades e técnicas da mineração de dados.

Fonte: Cortês et. al., 2002

Uma das vantagens de se focar nas funcionalidades da mineração de dados diz respeito às facilidades que podem ser obtidas quando surge uma nova necessidade de análise de dados. Neste caso, **basta identificar a que resultado se deseja chegar** e imediatamente **partir para identificação de qual técnica aplicar**.

Diversos autores tratam as **funcionalidades da mineração de dados de forma diferenciada (não se tem um consenso ainda quanto à nomenclatura a ser utilizada)**.

Vejamos **algumas opções**:

- Descoberta de conhecimento e predição;
- Classificação, Estimção, Predição, Afinidade em grupos, Agrupamentos (*clustering*) e Descrição.
- Classificação, Detecção de sequência, Análise de dependência de dados e Análise de desvio.
- **Descrição e Predição.**
- **Previsão, Identificação, Classificação e Otimização.**

DIRETO DO CONCURSO

007. (ESAF/ANAC/ANALISTA ADMINISTRATIVO/ANÁLISE DE SISTEMAS/2016) São objetivos da Mineração de Dados:

- Distribuição, Identificação, Organização e Otimização
- Previsão, Priorização, Classificação e Alocação
- Previsão, Identificação, Classificação e Otimização
- Mapeamento, Identificação, Classificação e Atribuição
- Planejamento, Redirecionamento, Classificação e Otimização



Como já vimos, diversos autores tratam os objetivos da mineração de dados de forma diferenciada. Nessa questão, a banca cobrou a classificação proposta por Navathe. De acordo com esse autor, de um modo geral, esses objetivos se encontram nas seguintes classes:

Previsão (ou Prognóstico)	A mineração de dados pode mostrar como certos atributos dos dados se comportarão no futuro . Um de seus objetivos é prever comportamentos futuros baseado em comportamentos passados . Ex.: Análise de compras passadas para realizar a previsão de compras futuras sob certos descontos.
Identificação	Padrões de dados podem ser usados para identificar a existência de um item, um evento ou uma atividade . Ex.: intrusos tentando quebrar um sistema podem ser identificados tendo-se em vista os programas por eles executados.
Classificação	A mineração de dados pode particionar os dados de modo que diferentes classes ou categorias possam ser identificadas tomando-se como base combinações de parâmetros. Ex.: segmentação de clientes em um supermercado.
Otimização	Um objetivo relevante da mineração de dados pode ser otimizar o uso de recursos limitados , como tempo, espaço, dinheiro ou materiais e maximizar variáveis de saída como vendas ou lucros sob determinadas restrições. Ex.: a execução de um projeto que deve respeitar completamente o orçamento/escopo e cronogramas contratados, de forma a maximizar os resultados.

Conforme visto, a letra C é a que apresenta corretamente objetivos da Mineração de Dados.

Letra c

008. (FCC/TCE-SP/AGENTE DA FISCALIZAÇÃO FINANCEIRA/INFORMÁTICA/PRODUÇÃO E BANCO DE DADOS/2010) NÃO é um objetivo da mineração de dados (data mining), na visão dos diversos autores,

- a) garantir a não redundância nos bancos transacionais.
- b) conhecer o comportamento de certos atributos no futuro.
- c) possibilitar a análise de determinados padrões de eventos.
- d) categorizar perfis individuais ou coletivos de interesse comercial.
- e) apoiar a otimização do uso de recursos limitados e/ou maximizar variáveis de resultado para a empresa.



Vamos analisar cada um dos itens:

- a) Errada. Os **bancos de dados transacionais** são os bancos de dados que estão por trás da operação dos sistemas comerciais, em que são registradas todas as transações do dia-a-dia de uma empresa. O **processo de Descoberta de Conhecimento em Bases de Dados** tem uma etapa chamada de Preparação de Dados que antecede o *Data Mining*. Essa etapa tem a função de coletar os dados originais das bases de dados e purificá-los, **removendo redundâncias (ou seja, duplicações de dados)**, a fim de tornar estes dados adequados para o processo de *Data Mining*.
- b) Certa. O *Data Mining* também permite, a partir de tendências e análises temporais, a previsão do estado futuro de atributos (características) do negócio (**Objetivo relacionado: previsão ou prognóstico**).
- c) Certa. O *Data Mining* tem entre seus **objetivos a descoberta de padrões e tendências e associações em conglomerados de dados (Objetivo relacionado: identificação)**.
- d) Certa. Estudamos também que uma das técnicas de *Data Mining* é a Classificação, que permite a organização dos registros em classes (**Objetivo relacionado: classificação**).
- e) Certa. A partir do conhecimento adquirido ao minerar as bases de dados espera-se que seja possível à gestão das empresas **otimizar** o uso de recursos e aumentar os resultados do negócio (**Objetivo relacionado: otimização**).

Letra a.

Uma vez definidas as funcionalidades (resultados) a que se deseja chegar com o processo de mineração de dados, cabe agora escolher que **técnicas/tarefas** devemos utilizar, que sejam mais aderentes para a obtenção dos resultados, com uma melhor precisão.

As tarefas básicas de mineração de dados podem ser classificadas, de uma forma geral, em

8.1. TAREFAS DE DESCRIÇÃO (OU DESCRITIVAS)

- Caracterizam as **propriedades gerais dos dados** em um banco de dados.
- O **objetivo** dessas tarefas é **derivar padrões (correlações, tendências, grupos, trajetórias e anomalias)** que resumem os relacionamentos subjacentes nos dados.
- As tarefas descritivas da mineração são muitas **vezes exploratórias em sua natureza e frequentemente requerem técnicas de pós-processamento para validar e explicar resultados.**

8.2. TAREFAS DE PREDIÇÃO (PREDITIVAS OU DE PREVISÃO)

- Realizam **inferências sobre os dados atuais** para fazer previsões.
- O objetivo dessas tarefas é prever o **valor de um determinado atributo** baseado nos valores de outros atributos.
- O **atributo a ser predito** é comumente conhecido como a **variável dependente ou alvo**, enquanto que os **outros atributos usados para fazer a previsão (ou predição)** são conhecidos como as **variáveis independentes (explicativas ou preditoras).**

Obs.: A **modelagem preditiva** é uma **técnica estatística para modelar e encontrar padrões**, que **utiliza dados históricos para realizar previsões de tendências, padrões de comportamento ou eventos futuros.**

A **modelagem preditiva** utiliza de estatísticas e modelos matemáticos para **prever resultados futuros.**

DIRETO DO CONCURSO

009. (CESPE/TCE-RJ/2021) Com relação a noções de mineração de dados e Big Data, julgue o item que se segue. Na mineração de dados preditiva, ocorre a geração de um conhecimento obtido de experiências anteriores para ser aplicado em situações futuras.



A **mineração de dados preditiva** busca **prever comportamentos futuros e tendências com base nos dados conhecidos** (ENAP, 2020).




Figura. Tipos de Análises (QUINTÃO, 2021)

Certo.

Obs.: A divisão apresentada para as **tarefas básicas de mineração de dados** facilita o entendimento do principal objetivo de cada tarefa.

No entanto, nem sempre é fácil classificar uma tarefa como preditiva ou descritiva, pois alguns modelos preditivos podem ser descritivos, por serem compreensíveis, e vice-versa.

Veja uma diferenciação apontada na literatura para **análise descritiva x prognóstico**:




Figura. Funcionalidades (resultados) da mineração de dados. Fonte: Cortês et. al., 2002

- **Análise Descritiva:** representa a área de investigação nos dados que **busca tanto descrever fatos relevantes, não triviais e desconhecidos dos usuários, como analisar a base de dados**, principalmente pelo seu aspecto de qualidade, para validar todo o processo da mineração e seus resultados, ou seja, o conhecimento encontrado.




Figura. Sub-funcionalidades da análise prévia e do descobrimento. Fonte: Cortês et. al., 2002

- **Análise de Prognóstico:** representa a área de investigação nos dados que **busca inferir resultados a partir dos padrões encontrados na análise descritiva**, ou seja, **prognosticar o comportamento de um novo conjunto de dados**.

DIRETO DO CONCURSO

010. (CESPE/TCE-SC/AUDITOR FISCAL DE CONTROLE EXTERNO/2016) Para a realização de prognósticos por meio de técnicas de mineração de dados, parte-se de uma série de valores existentes obtidos de dados históricos bem como de suposições controladas a respeito das condições futuras, para prever outros valores e situações que ocorrerão e, assim, planejar e preparar as ações organizacionais.



A mineração de dados pode mostrar como certos atributos dos dados se comportarão no futuro. A **análise de prognóstico (ou previsão)** representa a área de investigação de dados que **busca inferir resultados a partir dos padrões encontrados na análise descritiva, ou seja, prognosticar o comportamento de um novo conjunto de dados**. Parte de uma série de valores obtidos de dados históricos bem como de suposições controladas a respeito das condições futuras, para **prever** outros valores e situações que ocorrerão e, assim, planejar e preparar as ações organizacionais. Por exemplo um prognóstico pode descobrir padrões nos dados que ajudam os gerentes a estimar o valor futuro de variáveis com números de vendas.

Obs.: Referência: https://pt.wikipedia.org/wiki/Minera%C3%A7%C3%A3o_de_dados.

Certo.

9. PRINCIPAIS TAREFAS (OU TÉCNICAS) DE MINERAÇÃO DE DADOS

A seguir, são apresentados os conceitos a serem aprendidos referentes às principais **tarefas de mineração de dados**. Já vi alguns autores as chamarem de **técnicas de mineração de dados** (Inclusive temos questões da banca que tratam dessa forma).

9.1. CLASSIFICAÇÃO

- **Muito utilizada** na mineração de dados.
- O ser humano está sempre classificando o que percebe a sua volta, criando classes de relações humanas diferentes (colegas de trabalho, amigos, familiares, etc.) e dando

a cada classe uma forma diferente de tratamento.

Obs.: **Classificar um novo objeto** é determinar com que grupo (ou classe) de objetos, já classificados anteriormente, esse novo objeto apresenta mais semelhança.

- A classificação pode ser sintetizada por **um processo de discriminação de unidades em classes ou categorias**. Assim, classificam-se sabores, amigos, clientes, eventos, entre outros, em categorias, tais como: doce/salgado/neutro e legal/ilegal.
- Em um processo de mineração de dados, a **classificação** está especificamente voltada à **atribuição de uma das classes predefinidas pelo analista a novos fatos ou objetos submetidos à classificação**.

Obs.: Cespe (2014) destacou que com o **uso da classificação como técnica de Data Mining**, busca-se a identificação de uma classe por meio de múltiplos atributos.

- Essa técnica **pode ser utilizada tanto para entender dados existentes quanto para prever como novos dados irão se comportar** (EURIDITIONHOME, 2004) e também **pode ser usada em conjunto com outras técnicas de mineração de dados**.
- Na mineração de dados são comuns as tarefas de classificação de clientes em baixo, médio ou alto risco de empréstimo bancário; de clientes potencialmente consumidores de um determinado produto a julgar pelo seu perfil; de transações financeiras como legais, ilegais ou suspeitas em sistemas de fiscalização do 24 mercado financeiro; de ações da bolsa de valores com lucros potenciais baixos, médios e altos, etc.
- A **classificação** é um exemplo de um processo de aprendizado supervisionado. **A tarefa de classificação é supervisionada (supervised learning)**, pois os **dados de treinamento (conjunto de treinamento) são fornecidos com suas classes reais, previamente definidas**. O conjunto de treinamento corresponde à base de dados submetida ao **algoritmo de classificação**, a partir da qual serão obtidos os padrões de classificação.
- A qualidade de uma descrição estrutural de classificação pode ser avaliada com a utilização de novos dados, com classes já conhecidas: os chamados **dados de teste (ou conjunto de teste)**. Tem-se, então, o conjunto de treinamento para obter os padrões de classificação e o conjunto de teste para validar os padrões obtidos. É comum, a partir de uma base de dados a ser minerada, que seja separado um conjunto de instâncias para o treinamento e o restante é utilizado como conjunto de teste.
- A taxa de sucesso nos dados de teste pode fornecer uma medida objetiva da qualidade do conceito aprendido. Entretanto, em muitas situações práticas o sucesso é medido subjetivamente.

EXEMPLO

Exemplo de aplicações para a tarefa de classificação: prever se deve haver jogo ou não, com base em dados sobre o tempo.

9.2. ANÁLISE DE CLUSTERS (ANÁLISE DE AGRUPAMENTOS, ANÁLISE DE AGLOMERAÇÕES OU ANÁLISE DE PARTIÇÕES)

Também chamada de **segmentação de dados ou Clusterização (Clustering)**, diz respeito a agrupar ou segmentar uma coleção de objetos em subconjuntos, chamados de **clusters**.


Os **objetos dentro de um mesmo cluster são mais próximos entre si** do que com qualquer outro objeto alocado em outro *cluster*.

Um *cluster* é um subconjunto de todos os possíveis subconjuntos distintos da população (DINIZ e LOUZADA NETO, 2000).

Obs.: Agrupar é, baseado em medidas de semelhança, definir quantas e quais classes existem em um conjunto de entidades.

Um **exemplo** de clusterização é o agrupamento de clientes que corresponde à descoberta de grupos de clientes de acordo com seus atributos. Assim, pode-se obter o perfil de cada grupo de clientes identificado.

A figura a seguir apresenta um exemplo de clusterização de instâncias que possuem os atributos X e Y, do tipo numérico.



O problema da tarefa de **Clusterização** é encontrar **grupos de instâncias** (como por exemplo registros em uma base de dados) de acordo com as **similaridades** entre estas instâncias.

- **A clusterização é considerada como um aprendizado não supervisionado (*unsupervised learning*) pois nenhuma classe (ou grupo) é conhecida previamente.**
 - Um **agrupamento** é uma coleção de registros similares entre si, mas diferentes dos outros registros nos demais agrupamentos. **Essa tarefa difere da classificação** uma vez não necessita que os registros sejam previamente categorizados – trata-se de um **aprendizado não supervisionado**. Também, ela não tem a pretensão de

classificar, estimar ou prever o valor de uma variável, ela apenas identifica os grupos de dados similares.

- O sucesso da clusterização é medido de forma subjetiva.
- A análise de *clusters* pode ser baseada em métodos estatísticos como o ***k-means* (média), k-modes (moda), k-medoids (mediana** - valor mais ao centro do conjunto de dados), etc.
- O **método de clustering k-means** objetiva particionar “n” observações entre “k” grupos; cada observação pertence ao grupo mais próximo da **média**.

DIRETO DO CONCURSO

011. (CESPE/SEDF/ANALISTA DE GESTÃO EDUCACIONAL/TECNOLOGIA DA INFORMACÃO/2017)

Com relação a data mining e data warehouse, julgue o item que se segue.

Agrupar registros em grupos, de modo que os registros em um grupo sejam semelhantes entre si e diferentes dos registros em outros grupos é uma maneira de descrever conhecimento descoberto durante processos de mineração de dados.



A questão descreve corretamente a tarefa de **clusterização** ou **análise de agrupamentos**, que permite agrupar registros em grupos ou *clusters*, de modo que os registros em um grupo sejam semelhantes entre si e diferentes dos registros em outros grupos.


Certo.

012. (CESPE/SERPRO/ANALISTA/NEGÓCIOS EM TECNOLOGIA DA INFORMAÇÃO/2013)

Clusterização é a tarefa preditiva relativa à identificação de um conjunto finito de categorias empregadas para descrever uma informação. Essas categorias nunca poderão ser mutuamente exclusivas.



Clusterização é a tarefa de **análise descritiva** relativa à identificação de um conjunto finito de categorias empregadas para descrever uma informação. As categorias levantadas **podem ser mutuamente exclusivas**, e a assertiva está errada.



Errado.

013. (CESPE/TCE-PE/ANALISTA DE CONTROLE EXTERNO/AUDITORIA DE CONTAS PÚBLICAS/2017) Em relação à análise de agrupamentos (clusterização) em mineração de dados, julgue o item seguinte.

O método de clustering k-means objetiva particionar 'n' observações entre 'k' grupos; cada observação pertence ao grupo mais próximo da média.




Conceito extraído do Wikipedia: em mineração de dados, agrupamento **k-means (k média)** é um método de *Clustering* que objetiva particionar n observações dentre k grupos; cada observação pertence ao grupo mais próximo da média.

Certo.

9.3. DETECÇÃO DE ANOMALIAS (DETECÇÃO DE DESVIOS OU MINERAÇÃO DE EXCEÇÕES)

É a **tarefa de identificar observações cujas características sejam significativamente diferentes do resto dos dados.**

Tan et al. (2009, p.777) destaca que na **deteção de anomalias** o **objetivo é encontrar objetos que sejam diferentes da maioria dos outros objetos**. Segundo os autores, muitas vezes, objetos anômalos são conhecidos como **fatores elementos estranhos**, já que, em um desenho disperso dos dados, eles ficam longe dos outros pontos de dados. Veja a figura seguinte como exemplo.



A detecção de anomalias também é conhecida como **detecção de desvios** (Tan et al., 2009), porque **objetos anômalos** têm atributos que se desviam significativamente dos valores de atributos esperados ou típicos ou, como **mineração de exceções**, porque as anomalias são excepcionais em algum sentido.

Cabe destacar que, embora objetos ou eventos **diferentes** sejam, por definição, relativamente raros, **isto não significa que eles não ocorram com frequência em termos absolutos**. Por exemplo, um evento que seja “um em um milhão” pode ocorrer milhões de vezes quando bilhões de eventos são considerados (Tan et al., 2009).

Os exemplos a seguir, retirados de Tan et al. (2009), ilustram aplicações para a quais as anomalias são de considerável interesse:

EXEMPLO

- detecção de fraudes; detecção de intrusão; distúrbios no Ecosistema;
- saúde pública. Ex.: se todas as crianças de uma cidade forem vacinadas contra uma determinada doença, como sarampo, então a ocorrência de alguns casos espalhados por diversos hospitais da cidade é um evento anômalo, que poderá indicar um problema com os programas de vacinação da cidade.

9.4. REGRAS DE ASSOCIAÇÃO

A tarefa de **obtenção de regras de associação** corresponde a **descobrir qualquer estrutura de associação entre os dados**.

No *Data Mining*, uma regra de associação relaciona a presença de um conjunto de itens com outra faixa de valores de um outro conjunto de variáveis.

A associação pode ser aplicada caso nenhuma classe tenha sido especificada.

O conteúdo deste livro eletrônico é protegido por direitos autorais. É proibida a reprodução, a distribuição, a divulgação ou a utilização em qualquer forma e a qualquer título, sem a autorização expressa do autor, sujeitando-se aos infratores à responsabilização civil e criminal.

- **Duas medidas nos informam a qualidade da regra de associação (ou grau de certeza):** suporte e confiança.
 - O **suporte** trata da quantidade de ocorrências da regra em relação à quantidade de transações ou eventos como um todo;
 - a **confiança** trata da quantidade de ocorrências da regra, dado que a ação antecedente ocorreu. A confiança é a quantidade de vezes que a regra é verificada, dado que o evento antecedente ocorre.

O **fator de suporte** e o **fator de confiança** são dois índices utilizados para definir o **grau de certeza** de uma regra de associação.

As **regras de associação** permitem a identificação de grupos de dados que apresentam coocorrência entre si (**Ocorrência simultânea de duas coisas, fatos**, etc. Por exemplo, em uma cesta de compras, pessoas que compraram o item X também compraram o Y.).

- **Market Basket Analysis (MBA)** ou, em português, **análise de cesta de compras** (ou **análise de cesta de mercado**), é uma técnica de *Data Mining* que faz uso de regras de associação para identificar os hábitos de compra dos clientes, fornecendo uma visão da combinação de produtos dentro das cestas de compras dos clientes analisados. Conhecer o perfil de compra do público-alvo é muito importante para aumentar o potencial de recomendação, ajudando a incrementar as vendas.

DIRETO DO CONCURSO

014. (CESPE/CEBRASPE/MINISTÉRIO DA ECONOMIA/TECNOLOGIA DA INFORMAÇÃO/CIÊNCIA DE DADOS/2020) No que se refere à mineração de dados, julgue o item a seguir.

A técnica de associação é utilizada para indicar um grau de afinidade entre registros de eventos diferentes, para permitir o processo de data mining.



As **regras de associação** buscam descobrir padrões de ocorrência entre diferentes elementos em um grande conjunto de dados.

Em outras palavras, a técnica de associação tem como objetivo **realizar uma análise de afinidade entre duas características ou atributos**.

Um exemplo clássico é o de um supermercado que foi observado e em um determinado dia da semana, vários clientes que compravam fraldas também compravam cervejas.

Certo.

015. (CESPE/TCE/RJ/2021) A respeito de mineração de dados, julgue o item que se segue. O fator de suporte e o fator de confiança são dois índices utilizados para definir o grau de certeza de uma regra de associação.



Duas medidas nos informam a qualidade da regra de associação (ou grau de certeza):

- o **suporte** trata da quantidade de ocorrências da regra em relação à quantidade de transações ou eventos como um todo;
- a **confiança** trata da quantidade de ocorrências da regra, dado que a ação antecedente ocorreu.

Certo.

016. (FCC/AL-MS/TÉCNICO DE INFORMÁTICA/2016) Um famoso site de vendas sempre envia ao cliente que acabou de comprar um item X, ou o está analisando, a seguinte frase: Pessoas que compraram o item X também compraram o Y. Para isso, o site deve estar aplicando a técnica de Data Mining denominada

- a) profiling.
- b) coocorrência.
- c) regressão múltipla.
- d) regressão logística.
- e) classificação.



A **coocorrência** é a **ocorrência simultânea de dois eventos**. Por exemplo, em uma cesta de compras, pessoas que compraram o item X também compraram o Y. Na verdade, a técnica de Mineração de Dados que está mais associada a esse conceito se refere às **regras de associação**.

Letra b.

- **Diferenças da tarefa de Associação em relação à Classificação:**

- associação pode prever qualquer atributo (não só a classe);
- associação pode prever os valores de mais de um atributo.

Exemplos de regras de associação obtidas a partir da base de dados sobre o **tempo** (com atributos **nominais**).

(temperatura=fria) $\Rightarrow$ (umidade=normal)
 (umidade=normal) e (vento=falso) $\Rightarrow$ (jogar=sim)
 (tempo=claro) e (jogar=não) $\Rightarrow$ (umidade=alta)
 (vento=falso) e (jogar=não) $\Rightarrow$ (tempo=claro) e (umidade=alta)

Utilizando-se uma base de dados de **compras** em um supermercado, pode-se obter quais itens são comprados juntos com uma certa frequência, conforme visto a seguir.

fralda ⇒ cerveja
cereal ⇒ leite

Devido às diferenças apontadas entre as tarefas de Associação e Classificação, **normalmente obtém-se muito mais regras de associação do que regras de classificação.**

9.5. ANÁLISE DE REGRESSÃO

Busca explicar uma ou várias variáveis de interesse (sempre contínuas ou binárias) em função de outras. Uma vez construído o modelo (que é uma equação matemática), **ele pode ser usado para realizar previsões ou calcular probabilidades.**

A tarefa de regressão é predizer um valor numérico a partir de um conjunto de atributos fornecidos. A regressão pode ser considerada uma variação da classificação, pois prevê um valor numérico contínuo ao invés de um valor categórico (ou nominal).

A **regressão** é considerada como um aprendizado supervisionado (*supervised learning*) pois a base de dados de treinamento já possui valores numéricos previamente definidos para o atributo a ser previsto nas novas instâncias.

O sucesso da regressão pode ser medido por meio de dados de teste, ou subjetivamente.

A figura a seguir apresenta um exemplo de base de dados de treinamento com um atributo numérico a ser utilizado para previsão por meio da **Regressão**. Assim, a partir da obtenção da equação de regressão com base nestes dados fornecidos, será possível **prever** a duração de um novo jogo a partir dos demais atributos fornecidos.

Tempo	Temperatura	Umidade	Vento	Dur. Jogo
Claro	Quente	Alta	Falso	5 min
Claro	Quente	Alta	Verdadeiro	0 min
Nublado	Quente	Alta	Falso	55 min
Chuvoso	Amena	Normal	Falso	40 min
...	...	...	...	...

9.6. ÁRVORES DE DECISÃO

É um **modelo preditivo** que pode ser visualizado na forma de uma **árvore**, daí seu nome. Cada **ramo** da árvore é uma questão de classificação e cada **folha** é uma partição do conjunto de dados com sua classificação.

A forma de execução é simples: dado um conjunto de dados cabe ao usuário escolher uma das variáveis como objeto de saída. A partir daí, o algoritmo encontra o fator mais importante correlacionado com a variável de saída e seta-o como o primeiro ramo (chamado de **raiz**), os demais fatores são subsequentemente classificados como nós até que se chegue ao último nível, a **folha**.

Desta forma, a árvore de decisão utiliza a estratégia de **dividir para conquistar**, um problema complexo é decomposto em subproblemas mais simples e recursivamente a mesma estratégia é aplicada a cada subproblema.

Obs.: A abordagem “**divisão e conquista**” produz uma árvore em que cada nó refere-se ao teste de um atributo particular.

Em *Data Mining*, as árvores de decisão podem ser usadas com sistemas de classificação para atribuir informação de tipo. Na técnica de árvore de decisão em *Data Mining*, é empregada a abordagem denominada **estratificação**, permitindo separar os **dados** levantados em grupos distintos, como por exemplo, **estratificação** por local, por data, por tipo, etc.

As árvores de decisão (*vide exemplo na figura seguinte*) têm sido muito utilizadas pelos softwares de mineração de dados. Isto é justificado pelo fato delas possuírem uma representação intuitiva, que torna o modelo de classificação fácil de ser interpretado.

A árvore de decisão apresentada a seguir indica se uma pessoa é rica ou não com base nos seus outros atributos, os atributos **preditivos**.




Figura. Árvore de decisão Fonte: <https://www.devmedia.com.br/extracao-de-arvores-de-decisao-com-a-ferramenta-de-data-mining-weka/3388>

DIRETO DO CONCURSO



017. (CESPE/TCE-MG/ANALISTA DE CONTROLE EXTERNO/CIÊNCIA DA COMPUTAÇÃO/2018)

Na técnica de árvore de decisão em data mining, é empregada a abordagem denominada

a) análise de volumetria.

b) combinação de variáveis.

- c) estratificação.
- d) avaliação de dados.
- e) percepção.



As **árvores de decisão** classificam os dados em um número finito de **classes com base nos valores das variáveis de entrada**. Tratam-se essencialmente de **uma hierarquia de declarações se-então, e são mais apropriadas para dados categorizados e intervalos de dados**.

Na técnica de árvore de decisão em *data mining*, é empregada a abordagem denominada **estratificação**, permitindo separar os **dados** levantados em grupos distintos, como por exemplo, **estratificação** por local, por data, por tipo, etc.

Letra c.

9.7. MÉTODOS BAYESIANOS

O filtro bayesiano utiliza uma **abordagem probabilística**, tendo como base o Teorema de Bayes. Nesse caso, um item que precisa ser classificado tem uma série de atributos.

Então, ele **calcula a probabilidade de o item pertencer a cada classe**, dados aqueles atributos que ele tem. Dessa forma, a classe que alcançar a maior probabilidade é aquela na qual o item vai ser classificado.

9.8. REGRAS DE INDUÇÃO

- A técnica de Regras de Indução é altamente automatizada e, possivelmente, é a **melhor técnica de Data Mining para expor todas as possibilidades de padrões existentes em um banco de dados** (BERSON et al., 1999).
- Consiste em uma expressão condicional do tipo:
 - **se** <condição> **então** <consequência>, ou, em outras palavras:
 - **se** <isto> **então** <aquilo>.

Por exemplo:

- **se** comprou cereal **então** comprou também leite
- **se** comprou queijo e presunto **então** comprou também pão
- Após a formação das regras, constrói-se uma tabela com o percentual de **precisão** (com que frequência a regra está correta?) e de **cobertura** (com que frequência a regra pode ser usada?). Quando maior o percentual, melhor a regra.

9.9. REDES NEURAIS ARTIFICIAIS

São técnicas que **procuram reproduzir de maneira simplificada as conexões do sistema biológico neural**. Estruturalmente, consistem em um número de elementos interconectados, chamados **neurônios**, organizados em camadas que aprendem pela modificação de suas conexões. Tipicamente, tem-se uma camada de entrada ligada a uma ou mais camadas intermediárias que são ligadas a uma camada de saída (BERRY e LINOFF, 1997).

A partir de um conjunto de treinamento, procura-se aprender padrões gerais que possam ser aplicados à classificação ou à predição de dados. A função básica de cada neurônio é avaliar valores de entrada, calcular o total para valores de entrada combinados, comparar o total com um valor limiar e determinar o valor de saída.

9.10. LÓGICA NEBULOSA (FUZZY LOGIC)


Uma **teoria matemática que permite uma modelagem do modo aproximado de raciocínio**, imitando a habilidade humana de tomar decisões em ambientes de incertezas e imprecisão. Com isso, pode-se construir sistemas inteligentes de controle e suporte à decisão.

A **fase de modelagem de um Data Mining agrega a seleção e aplicação das técnicas sobre os dados selecionados**. Inúmeras técnicas podem ser empregadas para obtenção de padrões úteis, como por exemplo, a **PMML** (*predictive model mark-up language*), que objetiva, via schemas XML, a definição para modelos encontrados em associações, modelos de regressão e *clustering* (CESPE/2013).

10. MÉTODOS PARA IDENTIFICAR PADRÕES EM DADOS

Um *Data Mining* inteligente descobre informações em *Data Warehouses* nos casos em que consultas e relatórios não conseguem revelá-las. Ferramentas de *Data Mining* encontram **padrões** em dados e podem até **deduzir regras a partir deles**.

De acordo com Turban, são usados **três métodos para identificar padrões em dados**, destacados a seguir:



11. OLAP E DATA MINING

OLAP é uma ferramenta de consulta em bases de dados analíticas, que visa extrair informações por meio de *queries* e utiliza as operações sobre os cubos de dados.

Data Mining (Mineração de Dados) é bem mais complexo que OLAP, uma vez que **busca padrões em grandes volumes de dados por meio de técnicas estatísticas e de algoritmos de inteligência artificial**, por exemplo. Com o uso da Mineração de dados (*Data Mining*), é possível descobrir informações relacionadas a **associações, sequências, classificação, aglomeração e prognósticos**. Conforme destaca WIKIPEDIA (2016):

- **Associações:** são **ocorrências ligadas a um único evento**. Por exemplo: um estudo de modelos de compra em supermercados pode revelar que, na compra de salgadinhos de milho, compra-se também um refrigerante tipo Coca-Cola em 65% das vezes: mas, quando há uma promoção, o refrigerante é comprado em 85% das vezes. Com essas informações, os gerentes podem tomar decisões mais acertadas pois aprenderam a respeito da rentabilidade de uma promoção.
- **Sequências:** aqui os **eventos estão ligados ao longo do tempo**. Pode-se descobrir, por exemplo, que quando se compra uma casa, em 65% as vezes se adquire uma nova geladeira no período de duas semanas; e que em 45% das vezes, um fogão também é comprado um mês após a compra da residência.
- **Classificação:** **reconhece modelos que descrevem o grupo ao qual o item pertence por meio do exame dos itens já classificados e pela inferência de um conjunto de regras**. Exemplo: empresas de operadoras de cartões de crédito e companhias telefônicas preocupam-se com a perda de clientes regulares, a classificação pode ajudar a descobrir as características de clientes que provavelmente virão abandoná-las e oferecer um modelo para ajudar os gerentes a prever quem são, de modo que se elabore antecipadamente campanhas especiais para reter esses clientes.

Aglomerção (clustering): funciona de maneira semelhante à classificação quando ainda não foram definidos grupos. Uma ferramenta de *Data Mining* **descobrirá diferentes agrupamentos dentro da massa de dados**. Por exemplo ao encontrar grupos de afinidades para cartões bancários ou ao dividir o banco de dados em categorias de clientes com base na demografia e em investimentos pessoais.

- **Prognóstico:** embora todas essas aplicações envolvam previsões, os prognósticos as utilizam de modo diferente. **Parte-se de uma série de valores existentes obtidos de dados históricos bem como de suposições controladas a respeito das condições futuras, para prever outros valores e situações que ocorrerão e, assim, planejar e preparar as ações organizacionais**. Por exemplo um prognóstico pode descobrir padrões nos dados que ajudam os gerentes a **estimar o valor futuro** de variáveis com números de vendas.

12. CARACTERÍSTICAS DOS CONJUNTOS DE DADOS

TAN et. al (2009, p. 35) destaca **três características** que são aplicadas a muitos conjuntos de dados e que possuem um impacto significativo sobre as técnicas de mineração de dados, que são: **dimensão**, **dispersão** e **resolução**.




Figura. Características dos Conjuntos de Dados. Fonte: TAN et. al (2009, p. 35)

13. MINERAÇÃO DE TEXTO (TEXT MINING)

Turbam et al. (2009) destacam que a **mineração de texto (Text Mining)** é a aplicação de **Data Mining em arquivos de texto não estruturados ou menos estruturados**.

O *Data Mining* aproveita-se da infraestrutura de dados armazenados para extrair informações adicionais úteis. Por exemplo, ao aplicar *Data Mining* a um banco de dados de clientes, um analista pode descobrir que qualquer pessoa que compra o produto A também compra os produtos B e C seis horas depois.

O **Text Mining funciona com informações menos estruturadas**. Raramente os documentos têm uma estrutura interna sólida, e quando têm, frequentemente está focada no formato do documento ao invés do conteúdo do documento.

- O **Text Mining** ajuda as empresas a (Turbam et al, 2009):
 - encontrar o conteúdo “escondido” dos documentos, incluindo informações adicionais úteis;
 - **relacionar documentos** ao longo de prévias divisões despercebidas (Ex.: descobrir que os clientes de duas divisões distintas de produto têm as mesmas características);
 - **agrupar documentos** usando temas em comum (Ex.: encontrar todos os clientes de uma companhia de seguro que têm reclamações parecidas e cancelam suas apólices)

Text Mining envolve a criação de índices numéricos a partir de dados não estruturados e, então, a aplicação dos algoritmos de *Data Mining* a esses índices.

Text Mining **não** é a mesma coisa que mecanismos de busca na web. Em uma busca, estamos tentando encontrar o que os outros prepararam. Com *Text Mining* queremos descobrir novos padrões, pedaços de informação que podem não ser óbvios ou conhecidos.

- São **componentes de um sistema de *Text Mining***:
 - um **sistema para o manuseio de documentos** em diversos formatos (txt, pdf, etc.), provenientes de diferentes fontes (*e-mail*, web, Twitter, etc.);
 - **componentes para processar esses documentos** e criar arquivos de dados que possam, então, ser explorados (resumidores, classe gramatical das palavras, etc.);
 - **ferramentas de *Data Mining***.

Já existem algumas ferramentas proprietárias para mineração de textos que estejam contidos em conteúdos da web, livros, comentários de *blogs*, etc. Exemplos: Apache Mahout, SAS Text Miner e demais relacionadas com a linguagem R, porém não são aplicáveis diretamente a NoSQL (*Not only Structured Query Language*).

Obs.: Os novos modelos de bases de dados **NoSQL** não possuem uma estrutura formal, não fornecem acesso via SQL, são distribuídos e prometem maior escalabilidade e desempenho. Ao se popularizarem criaram uma lacuna em termos de análise de dados, já que as **ferramentas de mineração de dados**, por exemplo, **usualmente foram desenvolvidas para serem aplicadas a modelos relacionais**, não a dados sem estrutura ou semi-estruturados.

MAPA MENTAL




Figura. Data Mining (Mineração de Dados). Fonte: Quintão (2023)




Figura. Características dos Conjuntos de Dados. Fonte: Quintão (2023)




Figura. Mineração de Texto (Text Mining). Fonte: Quintão (2023)




Figura. Fases do CRISP-DM Process Model (Baseado em The Crisp-DM Consortium, 2000)




Figura. Fases do CRISP-DM Process Model. Fonte: Quintão (2023)




Figura. Técnicas e Tarefas de Mineração de Dados. Fonte: Quintão (2023)




Figura. Técnicas e Tarefas de Mineração de Dados. Fonte: Quintão (2022)

QUESTÕES COMENTADAS EM AULA

001. (ESAF/CGU/ANALISTA DE FINANÇAS E CONTROLE/AUDITORIA E FISCALIZAÇÃO/GERAL/2012) São aspectos motivadores da Mineração de Dados:

- a) Escalabilidade. Dimensionalidade moderada. Dados homogêneos. Propriedade e centralização dos dados.
- b) Extensibilidade. Alta paridade. Dados complexos e heterogêneos. Concorrência e distribuição dos dados.
- c) Escalabilidade. Alta dimensionalidade. Dados complexos e heterogêneos. Propriedade e distribuição de dados.
- d) Escalabilidade. Dimensionalidade variável. Dados compatíveis e acoplados. Adequação da distribuição de dados.
- e) Especialidade. Alta dimensionalidade de verificação. Dados complexos e complementares. Propriedade e consistência de dados.

002. (CESPE/EBSERH/ANALISTA DE TECNOLOGIA DA INFORMAÇÃO/2018) Julgue o item que se segue, a respeito de arquitetura e tecnologias de sistemas de informação.

A descoberta de novas regras e padrões em conjuntos de dados fornecidos, ou aquisição de conhecimento indutivo, é um dos objetivos de data mining.

003. (CESPE/TCU/AUDITOR FEDERAL DE CONTROLE EXTERNO/CONHECIMENTOS GERAIS/2015)

No que concerne a data mining (mineração de dados) e big data, julgue o seguinte item.

No ambiente organizacional, devido à grande quantidade de dados, não é recomendado o emprego de data mining para atividades ligadas a marketing.

004. (FCC/INFRAERO/ANALISTA DE SISTEMAS - ADMINISTRADOR DE BANCO DE DADOS/2011)

Funcionalidade cujo objetivo é encontrar conjuntos de dados que não obedecem ao comportamento ou modelo dos dados. Uma vez encontrados, podem ser tratados ou descartados para utilização em mining. Trata-se de

- a) descrição.
- b) agrupamento.
- c) visualização.
- d) análise de outliers.
- e) análise de associações.

005. (FCC/CNMP/ANALISTA DO CNMP/DESENVOLVIMENTO DE SISTEMAS/2015) Em relação às ferramentas de Data Discovery e os fundamentos de Data Mining, é correto afirmar:

O conteúdo deste material é de propriedade da Grancursos Online. É proibida a reprodução, cópia, divulgação ou distribuição, sujeitando-se aos infratores à responsabilização civil e criminal.

- a) *Data Mining* é o processo de descobrir conhecimento em banco de dados, que envolve várias etapas. O KDD *Knowledge Discovery in Database* é uma destas etapas, portanto, a mineração de dados é um conceito que abrange o KDD.
- b) A etapa de KDD do *Data Mining* consiste em aplicar técnicas que auxiliem na busca de relações entre os dados. De forma geral, existem três tipos de técnicas: Estatísticas, Exploratórias e Intuitivas. Todas são devidamente experimentadas e validadas para o processo de mineração.
- c) Os dados podem ser não estruturados (bancos de dados, CRM, ERP), estruturados (texto, documentos, arquivos, mídias sociais, cloud) ou uma mistura de ambos (emails, SOA/web services, RSS). As ferramentas de Data Discovery mais completas possuem conectividade para todas essas origens de dados de forma segura e controlada.
- d) Estima-se que, atualmente, em média, 80% de todos os dados disponíveis são do tipo estruturado. Existem diversas ferramentas open source e comerciais de Data Discovery. Dentre as open source está a InfoSphere Data Explorer e entre as comerciais está a Vivisimo da IBM.
- e) As ferramentas de *Data Mining* permitem ao usuário avaliar tendências e padrões não conhecidos entre os dados. Esses tipos de ferramentas podem utilizar técnicas avançadas de computação como redes neurais, algoritmos genéticos e lógica nebulosa, dentre outras.

006. (CESPE/TCE-PE/AUDITOR DE OBRAS PÚBLICAS/2017) Julgue o item que se refere a CRISP-DM (Cross Industry Standard Process for Data Mining).

Durante a fase de entendimento do negócio, busca-se descrever claramente o problema, fazer a identificação dos dados e verificar se as variáveis relevantes para o projeto não são interdependentes.

007. (ESAF/ANAC/ANALISTA ADMINISTRATIVO/ANÁLISE DE SISTEMAS/2016) São objetivos da Mineração de Dados:

- a) Distribuição, Identificação, Organização e Otimização
- b) Previsão, Priorização, Classificação e Alocação
- c) Previsão, Identificação, Classificação e Otimização
- d) Mapeamento, Identificação, Classificação e Atribuição
- e) Planejamento, Redirecionamento, Classificação e Otimização

008. (FCC/TCE-SP/AGENTE DA FISCALIZAÇÃO FINANCEIRA/INFORMÁTICA - PRODUÇÃO E BANCO DE DADOS/2010) NÃO é um objetivo da mineração de dados (data mining), na visão dos diversos autores,

- a) garantir a não redundância nos bancos transacionais.

b) conhecer o comportamento de certos atributos no futuro.

- c) possibilitar a análise de determinados padrões de eventos.
- d) categorizar perfis individuais ou coletivos de interesse comercial.
- e) apoiar a otimização do uso de recursos limitados e/ou maximizar variáveis de resultado para a empresa.

009. (CESPE/TCE-RJ/2021) Com relação a noções de mineração de dados e *Big Data*, julgue o item que se segue. Na mineração de dados preditiva, ocorre a geração de um conhecimento obtido de experiências anteriores para ser aplicado em situações futuras.

010. (CESPE/TCE-SC/AUDITOR FISCAL DE CONTROLE EXTERNO/2016) Para a realização de prognósticos por meio de técnicas de mineração de dados, parte-se de uma série de valores existentes obtidos de dados históricos bem como de suposições controladas a respeito das condições futuras, para prever outros valores e situações que ocorrerão e, assim, planejar e preparar as ações organizacionais.

011. (CESPE/SEDf/ANALISTA DE GESTÃO EDUCACIONAL/TECNOLOGIA DA INFORMAÇÃO/2017) Com relação a *data mining* e *data warehouse*, julgue o item que se segue.

Agrupar registros em grupos, de modo que os registros em um grupo sejam semelhantes entre si e diferentes dos registros em outros grupos é uma maneira de descrever conhecimento descoberto durante processos de mineração de dados.

012. (CESPE/SERPRO/ANALISTA/NEGÓCIOS EM TECNOLOGIA DA INFORMAÇÃO/2013) Clusterização é a tarefa preditiva relativa à identificação de um conjunto finito de categorias empregadas para descrever uma informação. Essas categorias nunca poderão ser mutuamente exclusivas.

013. (CESPE/TCE-PE/ANALISTA DE CONTROLE EXTERNO/AUDITORIA DE CONTAS PÚBLICAS/2017) Em relação à análise de agrupamentos (clusterização) em mineração de dados, julgue o item seguinte.

O método de clustering k-means objetiva particionar 'n' observações entre 'k' grupos; cada observação pertence ao grupo mais próximo da média.

014. (CESPE/CEBRASPE/MINISTÉRIO DA ECONOMIA/ TECNOLOGIA DA INFORMAÇÃO/CIÊNCIA DE DADOS/2020) No que se refere à mineração de dados, julgue o item a seguir.

A técnica de associação é utilizada para indicar um grau de afinidade entre registros de eventos diferentes, para permitir o processo de *data mining*.

015. (CESPE/TCE/RJ/2021) A respeito de mineração de dados, julgue o item que se segue. O fator de suporte e o fator de confiança são dois índices utilizados para definir o grau de certeza de uma regra de associação.

016. (FCC/AL-MS/TÉCNICO DE INFORMÁTICA/2016) Um famoso site de vendas sempre envia ao cliente que acabou de comprar um item X, ou o está analisando, a seguinte frase: Pessoas que compraram o item X também compraram o Y. Para isso, o site deve estar aplicando a técnica de *Data Mining* denominada

- a) profiling.
- b) coocorrência.
- c) regressão múltipla.
- d) regressão logística.
- e) classificação.

017. (CESPE/TCE-MG/ANALISTA DE CONTROLE EXTERNO/CIÊNCIA DA COMPUTAÇÃO/2018) Na técnica de árvore de decisão em *data mining*, é empregada a abordagem denominada

- a) análise de volumetria.
- b) combinação de variáveis.
- c) estratificação.
- d) avaliação de dados.
- e) percepção.

EXERCÍCIOS

018. (FGV/SENADO/2018) Considerando as diferentes técnicas de mineração de dados, não é correto afirmar que:

- a) em Regras de Associação, confiança refere-se a quantas vezes uma regra de associação se verifica no conjunto de dados analisado.
- b) correlação canônica e análise múltipla de discriminante são técnicas utilizadas para análise multivariada.
- c) na análise de agrupamentos, medidas de correlação, medidas de distância e medidas de associação são alguns dos métodos utilizados para medir a semelhança entre objetos.
- d) a classificação é considerada um exemplo de aprendizado supervisionado, enquanto o agrupamento é considerado exemplo de aprendizado não supervisionado.
- e) regressão é uma aplicação especial da regra de classificação, onde a regra é considerada uma função sobre variáveis, mapeando-as em uma classe destino.

019. (FGV/DETRAN-RN/ASSESSOR TÉCNICO/ADMINISTRAÇÃO DE BANCO DE DADOS/2010) Sobre Data Mining, pode-se afirmar que:

- a) Refere-se à implementação de banco de dados paralelos.
- b) Consiste em armazenar o banco de dados em diversos computadores.
- c) Relaciona-se à capacidade de processar grande volume de tarefas em um mesmo intervalo de tempo.
- d) Permite-se distinguir várias entidades de um conjunto.
- e) Refere-se à busca de informações relevantes a partir de um grande volume de dados.

020. (FGV/SEFAZ-RJ/FISCAL DE RENDAS/2007) *DataWarehouse* e *DataMining* são recursos utilizados por muitas organizações para facilitar e agilizar o processamento, a análise e a consulta de dados. Sobre esses recursos, é correto afirmar que:

- a) um *DataMining* armazena dados extraídos de bancos de dados de diferentes organizações.
- b) um *DataWarehouse* armazena dados por períodos não superiores a três meses, o que dificulta previsões e análises de tendência.
- c) um *DataWarehouse* é repositório de dados históricos orientados a assunto, organizados para serem acessíveis para atividades de processamento analítico.
- d) *DataMining* é uma técnica de análise de dados exclusiva para aplicação em um *DataWarehouse*.
- e) num *DataWarehouse*, os usuários finais necessitam conhecer linguagem de programação para acessar dados.

021. (CESPE/CEBRASPE/MINISTÉRIO DA ECONOMIA/TECNOLOGIA DA INFORMAÇÃO/CIÊNCIA DE DADOS/2020) No que se refere à mineração de dados, julgue o item a seguir.

O conteúdo deste documento é de propriedade da GRAN Concursos e não pode ser reproduzido, copiado, divulgado ou distribuído, sob qualquer forma e a qualquer título, sem a autorização expressa da GRAN Concursos. A violação desta política sujeita o infrator à responsabilidade civil e criminal.

Modelagem preditiva é utilizada para antecipar comportamentos futuros, por meio do estudo da relação entre duas ou mais variáveis.

022. (CESPE/CEBRASPE/MINISTÉRIO DA ECONOMIA/TECNOLOGIA DA INFORMAÇÃO/CIÊNCIA DE DADOS/2020) Julgue o seguinte item, a respeito de big data. Aprendizagem de máquina pode ajudar a clusterização na identificação de *outliers*, que são objetos completamente diferentes do padrão da amostra.

023. (CESPE/POLÍCIA FEDERAL/AGENTE DE POLÍCIA FEDERAL/2018) Julgue o item que segue, relativo a noções de mineração de dados, big data e aprendizado de máquina. Pode-se definir mineração de dados como o processo de identificar, em dados, padrões válidos, novos, potencialmente úteis e, ao final, compreensíveis.

024. (CESPE/TCU/AUDITOR FEDERAL DE CONTROLE EXTERNO/2015) O uso prático de data mining envolve o emprego de processos, ferramentas, técnicas e métodos oriundos da matemática, da estatística e da computação, inclusive de inteligência artificial.

025. (CESPE/FUB/TÉCNICO DE TECNOLOGIA DA INFORMAÇÃO/2018) Julgue o item a seguir, a respeito de data mining e OLAP. No *data mining*, uma regra de associação relaciona a presença de um conjunto de itens com outra faixa de valores de um outro conjunto de variáveis.

026. (INÉDITA/2021) O ciclo de vida de um projeto de mineração de dados, segundo a abordagem CRISP-DM, consiste de 5 (cinco) fases. A sequência dessas fases NÃO é obrigatória.

027. (FCC/ANÁLISE DE INFORMAÇÕES/TCE-RS/2018) O modelo de referência CRISP-DM tem seu ciclo de vida estruturado nas seguintes 6 fases:

- a) Estruturação do Negócio, Limpeza dos Dados, Indicação das Métricas, Modelagem, Estimativa e Exportação dos Dados.
- b) Otimização do Negócio, Redução dos Dados, Replicação dos Dados, Modelagem, Importação dos Dados e Backup.
- c) Entendimento do Negócio, Entendimento dos Dados, Preparação dos Dados, Modelagem, Avaliação e Implantação.
- d) Preparação do Negócio, Replicação dos Dados, Indexação dos Dados, Diagramação do Negócio, Estimativa e Organização.
- e) Otimização do Negócio, Entendimento dos Dados, Indexação dos Dados, Exportação dos Dados, Organização e Importação dos Dados.

028. (FCC/SABESP/ANALISTA DE GESTÃO/PUBLICIDADE E PROPAGANDA/2018) O conceito de Data Mining descreve

- a) o uso de teorias, métodos, processos e tecnologias para organizar uma grande quantidade de dados brutos para identificar padrões de comportamentos em determinados públicos.
- b) o conjunto de métodos, tecnologias e estratégias para atração voluntária de visitantes, buscando a conversão consistente de leads em clientes (realização de compra).
- c) as atividades coordenadas de modo sistemático por uma determinada organização para relacionamento com os seus distintos públicos, bem como com outras organizações, sejam públicas, privadas ou não governamentais.
- d) o conjunto de tarefas e processos, organizados e sistematizados, normalmente como uso de uma plataforma tecnológica (hardware e software, ou até mesmo em *cloud computing*) para a gestão do relacionamento com clientes.
- e) o trabalho de produzir levantamento sobre os hábitos de consumo de mídia de um determinado público, identificando horários, tempo gasto etc., associando ao perfil socioeconômico, potencial de consumo, persuasão etc.

029. (FCC/SEFAZ-SC/AUDITOR-FISCAL DA RECEITA ESTADUAL/AUDITORIA E FISCALIZAÇÃO/2018) Atenção: Para responder à questão, considere o seguinte caso hipotético: Um Auditor da Receita Estadual pretende descobrir, após denúncia, elementos que possam caracterizar e fundamentar a possível existência de fraudes, tipificadas como sonegação tributária, que vêm ocorrendo sistematicamente na arrecadação do ICMS. A denúncia é que, frequentemente, caminhões das empresas Org1, Org2 e Org3 não são adequadamente fiscalizados nos postos de fronteiras. Inobservâncias de procedimentos podem ser avaliadas pelo curto período de permanência dos caminhões dessas empresas na operação de pesagem, em relação ao período médio registrado para demais caminhões.

Para caracterizar e fundamentar a existência de possíveis fraudes, o Auditor deverá coletar os registros diários dos postos por, pelo menos, 1 ano e elaborar demonstrativos para análises mensais, trimestrais e anuais.

A aplicação de técnicas de mineração de dados (data mining) pode ser de grande valia para o Auditor. No caso das pesagens, por exemplo, uma ação típica de mining, que é passível de ser tomada com o auxílio de instrumentos preditivos, é

- a) quantificar as ocorrências de possíveis pesagens fraudulentas ocorridas durante todo o trimestre que antecede a data da análise, em alguns postos selecionados, mediante parâmetros comparativos preestabelecidos.
- b) analisar o percentual de ocorrências das menores permanências de caminhões nos postos, no último ano, em relação ao movimento total.
- c) relacionar os postos onde ocorreram, nos últimos seis meses, as menores permanências das empresas suspeitas e informar o escalão superior para a tomada de decisão.
- d) realizar uma abordagem surpresa em determinado posto, com probabilidade significativa de constatar ocorrência fraudulenta.
- e) reportar ao escalão superior as características gerais das pesagens e permanências de todos os caminhões, nos cinco maiores postos do Estado, no mês que antecede a data de análise.

030. (FCC/TRT-11/TÉCNICO JUDICIÁRIO DE TI/2017) Sistemas do tipo I e do tipo II realizam tarefas diferentes, porém complementares. O tipo I é adequado para atividades como indexação de dados, alocação de custos, análises de séries temporais e análises “*what-if*”. Porém, a maioria dos sistemas do tipo I não tem a capacidade de realizar inferências indutivas, processo que permite chegar a conclusões genéricas a partir de exemplos específicos, que são uma característica nativa de sistemas do tipo II.

Sistemas do tipo I fornecem uma visão multidimensional de dados, incluindo suporte a hierarquias. Essa visão de dados é uma forma natural de analisar negócios e organizações. Sistemas do tipo II, por outro lado, podem ajudar a detectar tendências, encontrar padrões e relações entre as informações disponíveis em bancos de dados.

Os sistemas do tipo II podem encontrar informações ocultas nos dados disponíveis, mas é o gestor quem deve atribuir o valor de cada uma dessas descobertas para a organização.

Os sistemas do tipo I e II são, correta e respectivamente,

- a) OLAP e *Data Warehouse*.
- b) *Data Warehouse* e *Data Mining*.
- c) Banco de Dados Multidimensional e Banco de Dados Relacional.
- d) *Data Mining* e *Data Warehouse*.
- e) OLAP e *Data Mining*.

031. (FCC/TRF 3ª REGIÃO/ANALISTA JUDICIÁRIO/INFORMÁTICA/BANCO DE DADOS/2014)

Mineração de dados é a investigação de relações e padrões globais que existem em grandes bancos de dados, mas que estão ocultos no grande volume de dados. Com base nas funções que executam, há diferentes técnicas para a mineração de dados, dentre as quais estão:

I – identificar afinidades existentes entre um conjunto de itens em um dado grupo de registros. Por exemplo: 75% dos envolvidos em processos judiciais ligados a ataques maliciosos a servidores de dados também estão envolvidos em processos ligados a roubo de dados sigilosos.

II – identificar sequências que ocorrem em determinados registros. Por exemplo: 32% de pessoas do sexo feminino após ajuizarem uma causa contra o INSS solicitando nova perícia médica ajuízam uma causa contra o INSS solicitando ressarcimento monetário.

III – as categorias são definidas antes da análise dos dados. Pode ser utilizada para identificar os atributos de um determinado grupo que fazem a discriminação entre 3 tipos diferentes, por exemplo, os tipos de processos judiciais podem ser categorizados como infrequentes, ocasionais e frequentes.

Os tipos de técnicas referenciados em I, II e III, respectivamente, são:

- a) I – Padrões sequenciais
- II – Redes Neurais

III – Árvore de decisão

- b) I – Redes Neurais
II – Árvore de decisão
III – Padrões sequenciais
- c) I – Associação
II – Padrões sequenciais
III – Classificação
- d) I – Classificação
II – Associação
III – Previsão
- e) I – Árvore de decisão
II – Classificação
III – Associação

032. (FCC/TRF-4/ANALISTA JUDICIÁRIO-INFORMÁTICA/2010) Sobre data mining, é correto afirmar:

- a) Não requer interação com analistas humanos, pois os algoritmos utilizados conseguem determinar de forma completa e eficiente o valor dos padrões encontrados.
- b) Na mineração de dados, encontrar padrões requer que os dados brutos sejam sistematicamente “simplificados”, de forma a desconsiderar aquilo que é genérico e privilegiar aquilo que é específico.
- c) É um grande banco de dados voltado para dar suporte necessário nas decisões de usuários finais, geralmente gerentes e analistas de negócios.
- d) O processo de descobrimento realizado pelo data mining só pode ser utilizado a partir de um data warehouse, onde os dados já estão sem erros, sem duplicidade, são consistentes e habilitam descobertas abrangentes e precisas.
- e) É o processo de descoberta de novas correlações, padrões e tendências entre as informações de uma empresa, por meio da análise de grandes quantidades de dados armazenados em bancos de dados usando técnicas de reconhecimento de padrões, estatísticas e matemáticas.

033. (UFF/UFF/2009) O conjunto de técnicas que, envolvendo métodos matemáticos e estatísticos, algoritmos e princípios de inteligência artificial, tem o objetivo de descobrir relacionamentos significativos entre dados armazenados em repositórios de grandes volumes e concluir sobre padrões de comportamento de clientes de uma organização é conhecido como:

- a) Datawarehouse;
- b) Metadados;
- c) Data Mart;
- d) *Data Mining*;
- e) *Sistemas Transacionais*.

034. (FMP-RS/TCE-RS/AUDITOR PÚBLICO EXTERNO/ADMINISTRAÇÃO/2011) Mineração de dados consiste em

- a) explorar um conjunto de dados visando a extrair ou a ajudar a evidenciar padrões, como regras de associação ou sequências temporais, para detectar relacionamentos entre estes.
- b) acessar um banco de dados para realizar consultas de forma genérica, buscando recuperar informações (registros) que atendam um mesmo critério de pesquisa.
- c) recuperar informações de um banco de dados específico, voltado a representar e armazenar dados relacionados com companhias de exploração petrolífera e de recursos mineralógicos.
- d) um banco de dados específico voltado à gestão de negócios usando tecnologia de informação (TI) como, por exemplo, a área de BI (*Business Intelligence*).
- e) representar informações de um banco de dados mediante vários modelos hierárquicos como, por exemplo, o de entidade-relacionamento (ER).

035. (INÉDITA/2021) O resultado da Mineração de Dados pode descobrir os seguintes tipos de informação “nova”: regras de associação, padrões Sequenciais e regras de Classificação.

036. (ESAF/CVM/2010) Mineração de Dados é

- a) o processo de atualizar de maneira semi-automática grandes bancos de dados para encontrar versões úteis.
- b) o processo de analisar de maneira semi-automática grandes bancos de dados para encontrar padrões úteis.
- c) o processo de segmentar de maneira semi-automática bancos de dados qualitativos e corrigir padrões de especificação.
- d) o programa que depura de maneira automática bancos de dados corporativos para mostrar padrões de análise.
- e) o processo de automatizar a definição de bancos de dados de médio porte de maior utilidade para os usuários externos de rotinas de mineração.

037. (ESAF/CGU/ANALISTA DE FINANÇAS E CONTROLE/AUDITORIA E FISCALIZAÇÃO/GERAL/2012) São características gerais de conjuntos de dados:

- a) disposição, dispersão e renderização.
- b) dimensão, posicionamento e homogeneidade.
- c) compatibilidade, dispersão e interação.
- d) dimensão, dispersão e resolução.
- e) portabilidade, concentração e resolução.

038. (CESPE/TCE-PA/AUDITOR DE CONTROLE EXTERNO/INFORMÁTICA/ANALISTA DE SISTEMA/2016) Julgue o item a seguir em relação a data warehouse e data mining.

O conteúdo deste material é de propriedade intelectual da GRAN Concursos. É proibida a reprodução, cópia, divulgação ou distribuição, sujeitando-se aos infratores à responsabilização civil e criminal.

No contexto de data mining, o processo de descoberta de conhecimento em base de dados consiste na extração não trivial de conhecimento previamente desconhecido e potencialmente útil.

039. (CESPE/MEC/ADMINISTRADOR DE DADOS/2015) Acerca de data warehouse (DW), Business Intelligence (BI) e data mining, julgue o item que se segue.

Situação hipotética: Após o período de inscrição para o vestibular de determinada universidade pública, foram reunidas informações acerca do perfil dos candidatos, cursos inscritos e concorrências. Ademais, que, por meio das soluções de BI e DW que integram outros sistemas, foram realizadas análises para a detecção de relacionamentos sistemáticos entre as informações registradas.

Assertiva: Nessa situação, tais análises podem ser consideradas como *data mining*, pois agregam valor às decisões do MEC e sugerem tendências, como, por exemplo, o aumento no número de escolas privadas e a escolha de determinado curso superior.

040. (CESPE/TRT-08/ANALISTA DE TI/2016) Acerca de data mining, assinale a opção correta.

a) A fase de preparação para implementação de um projeto de data mining consiste, entre outras tarefas, em coletar os dados que serão garimpados, que devem estar exclusivamente em um data warehouse interno da empresa.

b) As redes neurais são um recurso matemático/computacional usado na aplicação de técnicas estatísticas nos processos de data mining e consistem em utilizar uma massa de dados para criar e organizar regras de classificação e decisão em formato de diagrama de árvore, que vão classificar seu comportamento ou estimar resultados futuros.

c) As aplicações de data mining utilizam diversas técnicas de natureza estatística, como a análise de conglomerados (cluster analysis), que tem como objetivo agrupar, em diferentes conjuntos de dados, os elementos identificados como semelhantes entre si, com base nas características analisadas.

d) As séries temporais correspondem a técnicas estatísticas utilizadas no cálculo de previsão de um conjunto de informações, analisando-se seus valores ao longo de determinado período. Nesse caso, para se obter uma previsão mais precisa, devem ser descartadas eventuais sazonalidades no conjunto de informações.

e) Os processos de data mining e OLAP têm os mesmos objetivos: trabalhar os dados existentes no data warehouse e realizar inferências, buscando reconhecer correlações não explícitas nos dados do data warehouse.

041. (CESPE/TCDF/ANALISTA DE ADMINISTRAÇÃO PÚBLICA/SISTEMAS DE TI/2014) Com o uso da classificação como técnica de *Data Mining*, busca-se a identificação de uma classe por meio de múltiplos atributos. Essa técnica também pode ser usada em conjunto com outras técnicas de mineração de dados.

042. (CESPE/CRPM/ANALISTA EM GEOCIÊNCIAS/SISTEMAS/2013) A fase de modelagem de um data mining agrega a seleção e aplicação das técnicas sobre os dados selecionados. Inúmeras técnicas podem ser empregadas para obtenção de padrões úteis, como por exemplo, a PMML (predictive model mark-up language), que objetiva, via schemas XML, a definição para modelos encontrados em associações, modelos de regressão e clustering.

043. (CESPE/TRT-21ª REGIÃO/ANALISTA JUDICIÁRIO/TECNOLOGIA DA INFORMAÇÃO/2010) O *data mining* é um processo automático de descoberta de padrões, de conhecimento em bases de dados, que utiliza, entre outros, árvores de decisão e métodos bayesianos como técnicas para classificação de dados.

044. (VUNESP/TJ-PA/ANALISTA JUDICIÁRIO/ANÁLISE DE SISTEMA/DESENVOLVIMENTO/2014) Uma das tarefas implementadas por uma ferramenta de Data Mining consiste em realizar a determinação de um valor futuro de determinada característica ou atributo de um registro ou conjunto de registros. Tal tarefa corresponde à

- a) normalização.
- b) indexação.
- c) análise de afinidade.
- d) predição.
- e) análise de equivalência

045. (VUNESP/PRODEST-ES/ANALISTA DE TECNOLOGIA DA INFORMAÇÃO/DESENVOLVIMENTO DE SISTEMAS/2014) No data mining, uma das formas de se obter conhecimento é por meio das Regras de Associação, que buscam eventuais associações entre 2 determinados produtos, um denominado antecedente e o outro, consequente. Uma medida utilizada nesse tipo de regra é denominada 'suporte', que representa

- a) a fração da população-alvo que satisfaz o antecedente e o consequente.
- b) a razão entre o produto antecedente e o consequente
- c) a razão entre o produto consequente e o precedente.
- d) o número absoluto da população-alvo que satisfaz o antecedente e o consequente
- e) o número absoluto de produtos do tipo antecedente.

046. (FCC/TCE-SP/AGENTE DA FISCALIZAÇÃO FINANCEIRA/INFORMÁTICA/PRODUÇÃO E BANCO DE DADOS/2010) No âmbito dos algoritmos associados ao mining, se houver um banco de dados com um número potencial pequeno de conjuntos de itens grandes, isto é, uns poucos milhares, então o suporte para todos eles pode ser testado em uma passagem usando a técnica específica de

- a) hierarquização.

- b) partição

- c) amostragem.
- d) árvore de padrão frequente.
- e) séries temporais.

047. (CESPE/TCU/AUDITOR FEDERAL DE CONTROLE EXTERNO/2015) A finalidade do uso do data mining em uma organização é subsidiar a produção de afirmações conclusivas acerca do padrão de comportamento exibido por agentes de interesse dessa organização.

048. (CESPE/MEC/ADMINISTRADOR DE BANCO DE DADOS/2015) Julgue o item seguinte, referente a *data mining*. A predição em algoritmos de data mining objetiva modelar funções sobre valores para apresentar o comportamento futuro de determinados atributos.

049. (CESPE/MEC/ADMINISTRADOR DE BANCO DE DADOS/2015) Julgue o item seguinte, referente a data mining.

Selecionar uma amostra e determinar os conjuntos de itens frequentes dessa amostra para formar a lista de previsão de subconjunto são as principais características do algoritmo de previsão.

050. (CESPE/TJ-DFT/TÉCNICO JUDICIÁRIO/PROGRAMAÇÃO DE SISTEMAS/2015) Julgue o item a seguir, a respeito de datawarehouse e de data mining.

Em um processo de mineração, durante a etapa de preparação dos dados, são analisados os requisitos de negócio para consolidar os dados.

GABARITO

- | | |
|-------|-------|
| 1. c | 37. d |
| 2. C | 38. C |
| 3. E | 39. C |
| 4. d | 40. c |
| 5. e | 41. C |
| 6. E | 42. C |
| 7. c | 43. C |
| 8. a | 44. d |
| 9. C | 45. a |
| 10. C | 46. b |
| 11. C | 47. C |
| 12. E | 48. C |
| 13. C | 49. E |
| 14. C | 50. E |
| 15. C | |
| 16. b | |
| 17. c | |
| 18. a | |
| 19. e | |
| 20. c | |
| 21. C | |
| 22. C | |
| 23. C | |
| 24. C | |
| 25. C | |
| 26. E | |
| 27. c | |
| 28. a | |
| 29. d | |
| 30. e | |
| 31. c | |
| 32. e | |
| 33. d | |
| 34. a | |
| 35. C | |
| 36. b | |

GABARITO COMENTADO

018. (FGV/SENADO/2018) Considerando as diferentes técnicas de mineração de dados, não é correto afirmar que:

- a) em Regras de Associação, confiança refere-se a quantas vezes uma regra de associação se verifica no conjunto de dados analisado.
- b) correlação canônica e análise múltipla de discriminante são técnicas utilizadas para análise multivariada.
- c) na análise de agrupamentos, medidas de correlação, medidas de distância e medidas de associação são alguns dos métodos utilizados para medir a semelhança entre objetos.
- d) a classificação é considerada um exemplo de aprendizado supervisionado, enquanto o agrupamento é considerado exemplo de aprendizado não supervisionado.
- e) regressão é uma aplicação especial da regra de classificação, onde a regra é considerada uma função sobre variáveis, mapeando-as em uma classe destino.



- a) Errada. Essa assertiva menciona o **suporte**, que trata da quantidade de ocorrências da regra em relação à quantidade de transações ou eventos como um todo. A **confiança** trata da quantidade de ocorrências da regra, dado que a ação antecedente ocorreu.
- b) Certa. Correlação canônica e análise múltipla de discriminante são técnicas utilizadas para análise multivariada.

Análise multivariada é tipo de análise estatística que pode ser empregada na **mineração de dados**, para que se possa analisar o comportamento de mais de uma variável de resultado.

- c) Certa. Na **análise de agrupamentos (análise de clusters)** vários métodos distintos para se medir a semelhança entre os itens, de modo a agrupá-los, podem ser utilizados, como por exemplo: medidas de correlação, medidas de distância e medidas de associação.
- d) Certa. **A tarefa de classificação é supervisionada (supervised learning)**, pois os **dados de treinamento (conjunto de treinamento) são fornecidos com suas classes reais, previamente definidas**. Já na **análise de clusters** (análise de agrupamentos) não há classes predefinidas nem conjunto de treinamento - o algoritmo irá determinar quais dados devem ser colocados em grupos iguais ou diferentes.
- e) Certa. De acordo com Elmasri e Navathe, **regressão** é uma aplicação especial da regra de classificação, em que a regra é considerada uma função sobre variáveis, mapeando-as em uma classe destino.

Letra a.

019. (FGV/DETRAN-RN/ASSESSOR TÉCNICO/ADMINISTRAÇÃO DE BANCO DE DADOS/2010)

Sobre Data Mining, pode-se afirmar que:

O conteúdo deste material é de propriedade da GRAN CONCURSOS, sendo vedada a reprodução, cópia, divulgação ou distribuição, sujeitando-se aos infratores à responsabilização civil e criminal.

- a) Refere-se à implementação de banco de dados paralelos.
- b) Consiste em armazenar o banco de dados em diversos computadores.
- c) Relaciona-se à capacidade de processar grande volume de tarefas em um mesmo intervalo de tempo.
- d) Permite-se distinguir várias entidades de um conjunto.
- e) Refere-se à busca de informações relevantes a partir de um grande volume de dados.



O processo de **Data Mining** tem o objetivo de buscar informações relevantes num conglomerado de dados. Essas informações relevantes são **padrões, tendências e associações** que quando analisadas serão úteis para produção de conhecimento sobre um dado domínio de negócio. Portanto, a opção correta é a letra E.

Letra e.

020. (FGV/SEFAZ-RJ/FISCAL DE RENDAS/2007) *DataWarehouse* e *DataMining* são recursos utilizados por muitas organizações para facilitar e agilizar o processamento, a análise e a consulta de dados. Sobre esses recursos, é correto afirmar que:

- a) um *DataMining* armazena dados extraídos de bancos de dados de diferentes organizações.
- b) um *DataWarehouse* armazena dados por períodos não superiores a três meses, o que dificulta previsões e análises de tendência.
- c) um *DataWarehouse* é repositório de dados históricos orientados a assunto, organizados para serem acessíveis para atividades de processamento analítico.
- d) *DataMining* é uma técnica de análise de dados exclusiva para aplicação em um *DataWarehouse*.
- e) num *DataWarehouse*, os usuários finais necessitam conhecer linguagem de programação para acessar dados.



Bill Inmon destaca que o “*Data Warehouse* é uma coleção de dados orientados por assuntos, integrados, variáveis com o tempo e não voláteis, para dar suporte ao processo de tomada de decisão.

A principal ideia do **Data Warehouse** é construir um depósito no qual será mantida a **memória histórica dos dados**, possibilitando a utilização desses dados para consulta e análise estratégica para a tomada de decisão!

Data Mart é um **banco de dados multidimensional de escopo departamental** (ou seja, abrange apenas um determinado departamento). Trata-se de “um subconjunto lógico do *Data Warehouse*, geralmente visto como um *data warehouse* setorial” (Kimball).

As diferenças entre o *Data Mart* e o *Data Warehouse* são apenas com relação ao tamanho e ao escopo do problema a ser resolvido.

Data Mining (ou **Mineração de dados**) define uma série de procedimentos, técnicas e ferramentas para recuperar e analisar dados de um *Data Warehouse* ou *Data Mart* à procura de padrões e tendências a respeito dos dados armazenados.

Letra c.

021. (CESPE/CEBRASPE/MINISTÉRIO DA ECONOMIA/TECNOLOGIA DA INFORMAÇÃO/CIÊNCIA DE DADOS/2020) No que se refere à mineração de dados, julgue o item a seguir.

Modelagem preditiva é utilizada para antecipar comportamentos futuros, por meio do estudo da relação entre duas ou mais variáveis.



A modelagem preditiva é uma técnica estatística para modelar e encontrar padrões, que utiliza dados históricos para realizar previsões de tendências, padrões de comportamento ou eventos futuros.

Certo.

022. (CESPE/CEBRASPE/MINISTÉRIO DA ECONOMIA/TECNOLOGIA DA INFORMAÇÃO/CIÊNCIA DE DADOS/2020) Julgue o seguinte item, a respeito de big data. Aprendizagem de máquina pode ajudar a clusterização na identificação de *outliers*, que são objetos completamente diferentes do padrão da amostra.



Os *outliers* são dados que não apresentam o mesmo comportamento padrão da maioria, ou seja, são objetos completamente diferentes do padrão da amostra.

Aprendizagem de máquina pode ajudar a clusterização na identificação de outliers, sendo bastante usado em:

- Detecção de fraudes.
- Resultados de pesquisa na Web.
- Anúncios em tempo real em páginas da web e dispositivos móveis, etc.

Certo.

023. (CESPE/POLÍCIA FEDERAL/AGENTE DE POLÍCIA FEDERAL/2018) Julgue o item que segue, relativo a noções de mineração de dados, big data e aprendizado de máquina.

Pode-se definir mineração de dados como o processo de identificar, em dados, padrões válidos, novos, potencialmente úteis e, ao final, compreensíveis.



Trata-se de um processo não trivial de identificação de **padrões/modelos** em **dados** que sejam **válidos, novos, potencialmente úteis e compreensíveis**”.

Certo.


024. (CESPE/TCU/AUDITOR FEDERAL DE CONTROLE EXTERNO/2015) O uso prático de data mining envolve o emprego de processos, ferramentas, técnicas e métodos oriundos da matemática, da estatística e da computação, inclusive de inteligência artificial.



Data Mining é a etapa do KDD (*Knowledge Discovery in Databases* - Descoberta de Conhecimento em Bases de Dados) em que os dados preparados são processados, ou seja, é onde se faz a mineração dos dados propriamente dita.

Nesse contexto, são aplicadas **técnicas** para identificação de padrões sobre os dados disponíveis. Esse processo tem o intuito de trabalhar os dados registrados ao longo do tempo de vida de um negócio a fim de se identificar **padrões** que representam alguma informação sobre o comportamento do negócio.

A figura a seguir apresenta um esquema que descreve o KDD.



O processo de KDD envolve os seguintes passos:

- **entendimento do domínio da aplicação** e identificação do objetivo do processo de KDD;
- **seleção**: criação de um conjunto-alvo de dados;
- **pré-processamento**: limpeza de dados e operações básicas como remoção de ruído, tratamento para a falta de dados, etc.;
- **transformação**: encontrar características úteis para representar os dados, conforme o objetivo definido e realizar a redução ou transformação da dimensionalidade;

- mineração de dados: **casar os objetivos do processo de KDD com um método particular de mineração de dados e realizar a análise exploratória e seleção de modelo e hipótese, buscando padrões de interesse;**
- **interpretação**: interpretar e avaliar os padrões minerados, podendo retornar a passos anteriores caso seja necessário;
- **agir a partir do conhecimento descoberto.**

No **Data Mining** são aplicadas **técnicas** e ferramentas **matemáticas, estatísticas e computacionais** visando a extração de informações implícitas, **previamente desconhecidas**, e potencialmente **úteis**, a partir de dados. Para isso é necessário um programa de computador para detectar padrões e regularidades nos dados. Os termos destacados na questão estão de acordo com essa teoria, e a assertiva é correta.

Certo.

025. (CESPE/FUB/TÉCNICO DE TECNOLOGIA DA INFORMAÇÃO/2018) Julgue o item a seguir, a respeito de data mining e OLAP.

No *data mining*, uma regra de associação relaciona a presença de um conjunto de itens com outra faixa de valores de um outro conjunto de variáveis.



Uma regra de associação é um padrão da forma $X \rightarrow Y$, onde X e Y são **conjuntos de valores**.

Certo.

026. (INÉDITA/2021) O ciclo de vida de um projeto de mineração de dados, segundo a abordagem CRISP-DM, consiste de 5 (cinco) fases. A sequência dessas fases NÃO é obrigatória.



Na figura seguinte é mostrado o **ciclo de vida de um projeto de mineração de dados, que consiste de 6 (seis) fases**. A sequência dessas fases **NÃO** é obrigatória, ocorrendo a transição para diferentes fases, dependendo do resultado de cada fase, e que etapa particular de cada fase precisa ser executada em seguida. As setas indicam as mais importantes e mais frequentes dependências entre as fases.

O ciclo externo na figura simboliza o ciclo natural da mineração de dados. Um processo de mineração de dados continua após a solução ter sido desenvolvida. Processos subsequentes se beneficiarão das experiências de processos anteriores.




Figura - Fases do CRISP-DM Process Model (Baseado em [The CRISP-DM Consortium, 2000])

Errado.

027. (FCC/ANÁLISE DE INFORMAÇÕES/TCE-RS/2018) O modelo de referência CRISP-DM tem seu ciclo de vida estruturado nas seguintes 6 fases:

- Estruturação do Negócio, Limpeza dos Dados, Indicação das Métricas, Modelagem, Estimativa e Exportação dos Dados.
- Otimização do Negócio, Redução dos Dados, Replicação dos Dados, Modelagem, Importação dos Dados e Backup.
- Entendimento do Negócio, Entendimento dos Dados, Preparação dos Dados, Modelagem, Avaliação e Implantação.
- Preparação do Negócio, Replicação dos Dados, Indexação dos Dados, Diagramação do Negócio, Estimativa e Organização.
- Otimização do Negócio, Entendimento dos Dados, Indexação dos Dados, Exportação dos Dados, Organização e Importação dos Dados.



Na figura seguinte é mostrado o **ciclo de vida de um projeto de mineração de dados**, que consiste de **6 (seis) fases**. A **seqüência** dessas fases **NÃO** é obrigatória, ocorrendo a transição para diferentes fases, dependendo do resultado de cada fase, e que etapa particular de cada fase precisa ser executada em seguida. As setas indicam as mais importantes e mais frequentes dependências entre as fases.

O ciclo externo na figura simboliza o **ciclo natural da mineração de dados**. Um processo de mineração de dados continua após a solução ter sido desenvolvida. Processos subsequentes se beneficiarão das experiências de processos anteriores.




Figura - Fases do CRISP-DM Process Model (Baseado em [The CRISP-DM Consortium, 2000])

A melhor resposta é a letra C, com as fases: Entendimento do Negócio, Entendimento dos Dados, Preparação dos Dados, Modelagem, Avaliação e Implantação.

Letra c.

028. (FCC/SABESP/ANALISTA DE GESTÃO/PUBLICIDADE E PROPAGANDA/2018) O conceito de *Data Mining* descreve

a) o uso de teorias, métodos, processos e tecnologias para organizar uma grande quantidade de dados brutos para identificar padrões de comportamentos em determinados públicos.

- b) o conjunto de métodos, tecnologias e estratégias para atração voluntária de visitantes, buscando a conversão consistente de leads em clientes (realização de compra).
- c) as atividades coordenadas de modo sistemático por uma determinada organização para relacionamento com os seus distintos públicos, bem como com outras organizações, sejam públicas, privadas ou não governamentais.
- d) o conjunto de tarefas e processos, organizados e sistematizados, normalmente como uso de uma plataforma tecnológica (hardware e software, ou até mesmo em *cloud computing*) para a gestão do relacionamento com clientes.
- e) o trabalho de produzir levantamento sobre os hábitos de consumo de mídia de um determinado público, identificando horários, tempo gasto etc., associando ao perfil socioeconômico, potencial de consumo, persuasão etc.



Data Mining (ou Mineração de dados) define uma série de **procedimentos, técnicas e ferramentas** para recuperar e analisar dados de um *Data Warehouse* ou *Data Mart*, à procura de padrões e tendências a respeito dos dados armazenados.

Letra a.

029. (FCC/SEFAZ-SC/AUDITOR-FISCAL DA RECEITA ESTADUAL/AUDITORIA E FISCALIZAÇÃO/2018) Atenção: Para responder à questão, considere o seguinte caso hipotético: Um Auditor da Receita Estadual pretende descobrir, após denúncia, elementos que possam caracterizar e fundamentar a possível existência de fraudes, tipificadas como sonegação tributária, que vêm ocorrendo sistematicamente na arrecadação do ICMS. A denúncia é que, frequentemente, caminhões das empresas Org1, Org2 e Org3 não são adequadamente fiscalizados nos postos de fronteiras. Inobservâncias de procedimentos podem ser avaliadas pelo curto período de permanência dos caminhões dessas empresas na operação de pesagem, em relação ao período médio registrado para demais caminhões.

Para caracterizar e fundamentar a existência de possíveis fraudes, o Auditor deverá coletar os registros diários dos postos por, pelo menos, 1 ano e elaborar demonstrativos para análises mensais, trimestrais e anuais.

A aplicação de técnicas de mineração de dados (data mining) pode ser de grande valia para o Auditor. No caso das pesagens, por exemplo, uma ação típica de mining, que é passível de ser tomada com o auxílio de instrumentos preditivos, é

- a) quantificar as ocorrências de possíveis pesagens fraudulentas ocorridas durante todo o trimestre que antecede a data da análise, em alguns postos selecionados, mediante parâmetros comparativos preestabelecidos.
- b) analisar o percentual de ocorrências das menores permanências de caminhões nos postos, no último ano, em relação ao movimento total.

- c) relacionar os postos onde ocorreram, nos últimos seis meses, as menores permanências das empresas suspeitas e informar o escalão superior para a tomada de decisão.
- d) realizar uma abordagem surpresa em determinado posto, com probabilidade significativa de constatar ocorrência fraudulenta.
- e) reportar ao escalão superior as características gerais das pesagens e permanências de todos os caminhões, nos cinco maiores postos do Estado, no mês que antecede a data de análise.



Na Mineração de Dados (*Data Mining*) há uma série de conceitos que vão desde a preparação/ transformação dos dados, aplicação de algoritmos e aprendizagem de máquina até a validação estatística dos resultados. Quem realiza esta tarefa é o analista de dados contratado para esta função.

O processo de mineração de dados não pode ser resumido em simples contagens e cálculos de percentuais. Há inteligência de máquina e dados estatísticos codificados nos diversos algoritmos propostos para esta área do conhecimento.

Nesse sentido, as **tarefas preditivas ou de previsão realizam inferências sobre os dados atuais para fazer previsões**. O objetivo dessas tarefas é prever o valor de um determinado atributo baseado nos valores de outros atributos. Assim, fazem uso de **estatísticas e modelos matemáticos para prever resultados futuros**.

A única alternativa que menciona conceitos estatísticos, como “**probabilidade significativa**” é a letra D, que é a resposta.

Letra d.

030. (FCC/TRT-11/TÉCNICO JUDICIÁRIO DE TI/2017) Sistemas do tipo I e do tipo II realizam tarefas diferentes, porém complementares. O tipo I é adequado para atividades como indexação de dados, alocação de custos, análises de séries temporais e análises “*what-if*”. Porém, a maioria dos sistemas do tipo I não tem a capacidade de realizar inferências indutivas, processo que permite chegar a conclusões genéricas a partir de exemplos específicos, que são uma característica nativa de sistemas do tipo II.

Sistemas do tipo I fornecem uma visão multidimensional de dados, incluindo suporte a hierarquias. Essa visão de dados é uma forma natural de analisar negócios e organizações. Sistemas do tipo II, por outro lado, podem ajudar a detectar tendências, encontrar padrões e relações entre as informações disponíveis em bancos de dados.

Os sistemas do tipo II podem encontrar informações ocultas nos dados disponíveis, mas é o gestor quem deve atribuir o valor de cada uma dessas descobertas para a organização.

Os sistemas do tipo I e II são, correta e respectivamente,

a) OLAP e *Data Warehouse*.

b) *Data Warehouse* e *Data Mining*.

- c) Banco de Dados Multidimensional e Banco de Dados Relacional.
d) *Data Mining* e *Data Warehouse*.
e) OLAP e *Data Mining*.



Obs.: A seguir, criei um resumo do que foi destacado em <http://www.bigdatabusiness.com.br/veja-como-a-mineracao-de-dados-pode-deixa-lo-a-frente-dos-concorrentes/>.

Sistema do Tipo I: OLAP	Sistema do Tipo II: <i>Data Mining</i>
OLAP é adequado para atividades como indexação de dados, alocação de custos, análises de séries temporais e análises “what-if” (usuário final introduz mudanças nas variáveis ou nas relações entre variáveis e observa as mudanças resultantes nos valores de outras variáveis). Porém, a maioria dos sistemas de OLAP <u>não</u> têm a capacidade de realizar inferências indutivas além das análises preditivas limitadas a esses fatores.	A inferência indutiva , processo que permite chegar a conclusões genéricas a partir de exemplos específicos, é uma característica nativa de data mining . Minerar dados, por outro lado, normalmente <u>não</u> conta com os conceitos de dimensões e hierarquias.
Sistemas de OLAP fornecem uma visão multidimensional de dados, incluindo suporte total a hierarquias. Essa visão de dados é uma forma natural de analisar negócios e organizações.	Data Mining pode ajudar a detectar tendências (como “propensão de uma pessoa a comprar” e “propensão de um cliente a interromper a assinatura do serviço”), e encontrar padrões e relações entre as informações disponíveis em banco de dados.

Letra e.

031. (FCC/TRF 3ª REGIÃO/ANALISTA JUDICIÁRIO/INFORMÁTICA/BANCO DE DADOS/2014)
Mineração de dados é a investigação de relações e padrões globais que existem em grandes bancos de dados, mas que estão ocultos no grande volume de dados. Com base nas funções que executam, há diferentes técnicas para a mineração de dados, dentre as quais estão:
I – identificar afinidades existentes entre um conjunto de itens em um dado grupo de registros. Por exemplo: 75% dos envolvidos em processos judiciais ligados a ataques maliciosos a servidores de dados também estão envolvidos em processos ligados a roubo de dados sigilosos.
II – identificar sequências que ocorrem em determinados registros. Por exemplo: 32% de pessoas do sexo feminino após ajuizarem uma causa contra o INSS solicitando nova perícia médica ajuízam uma causa contra o INSS solicitando ressarcimento monetário.
III – as categorias são definidas antes da análise dos dados. Pode ser utilizada para identificar os atributos de um determinado grupo que fazem a discriminação entre 3 tipos diferentes, por exemplo, os tipos de processos judiciais podem ser categorizados como infrequentes, ocasionais e frequentes.

Os tipos de técnicas referenciados em I, II e III respectivamente são:

- a) I – Padrões sequenciais
II – Redes Neurais
III – Árvore de decisão
- b) I – Redes Neurais
II – Árvore de decisão
III – Padrões sequenciais
- c) I – Associação
II – Padrões sequenciais
III – Classificação
- d) I – Classificação
II – Associação
III – Previsão
- e) I – Árvore de decisão
II – Classificação
III – Associação



I – Associação	I – Identificar afinidades existentes entre um conjunto de itens em um dado grupo de registros. Por exemplo: 75% dos envolvidos em processos judiciais ligados a ataques maliciosos a servidores de dados também estão envolvidos em processos ligados a roubo de dados sigilosos.
II – Padrões sequenciais	II – Identificar sequências que ocorrem em determinados registros. Por exemplo: 32% de pessoas do sexo feminino após ajuizarem uma causa contra o INSS solicitando nova perícia médica ajuízam uma causa contra o INSS solicitando ressarcimento monetário.
III – Classificação	III – As categorias são definidas antes da análise dos dados. Pode ser utilizada para identificar os atributos de um determinado grupo que fazem a discriminação entre 3 tipos diferentes, por exemplo, os tipos de processos judiciais podem ser categorizados como infrequentes, ocasionais e frequentes.

Letra c.

032. (FCC/TRF-4/ANALISTA JUDICIÁRIO-INFORMÁTICA/2010) Sobre data mining, é correto afirmar:

- a) Não requer interação com analistas humanos, pois os algoritmos utilizados conseguem determinar de forma completa e eficiente o valor dos padrões encontrados.
- b) Na mineração de dados, encontrar padrões requer que os dados brutos sejam sistematicamente “simplificados”, de forma a desconsiderar aquilo que é genérico e privilegiar aquilo que é específico.
- c) É um grande banco de dados voltado para dar suporte necessário nas decisões de usuários finais geralmente gerentes e analistas de negócios.

d) O processo de descobrimento realizado pelo data mining só pode ser utilizado a partir de um data warehouse, onde os dados já estão sem erros, sem duplicidade, são consistentes e habilitam descobertas abrangentes e precisas.

e) É o processo de descoberta de novas correlações, padrões e tendências entre as informações de uma empresa, por meio da análise de grandes quantidades de dados armazenados em bancos de dados usando técnicas de reconhecimento de padrões, estatísticas e matemáticas.



A **mineração de dados** (ou **Data Mining**) é o nome dado ao conjunto de técnicas que permite a extração de conhecimentos a partir de grandes volumes de dados. Em outras palavras, é o processo de descoberta de novas correlações, padrões e tendências entre as informações úteis em grandes depósitos de dados. A letra E é a resposta dessa questão.

Letra e.

033. (UFF/UFF/2009) O conjunto de técnicas que, envolvendo métodos matemáticos e estatísticos, algoritmos e princípios de inteligência artificial, tem o objetivo de descobrir relacionamentos significativos entre dados armazenados em repositórios de grandes volumes e concluir sobre padrões de comportamento de clientes de uma organização é conhecido como:

- a) Datawarehouse;
- b) Metadados;
- c) Data Mart;
- d) *Data Mining*;
- e) Sistemas Transacionais.



Vamos aos comentários das diversas opções:

a) Errada. Uma das atividades de uma empresa que pretende trabalhar com **Data Mining** é justamente coletar os registros das bases de dados transacionais e organizá-los em bases de dados agrupadas por assunto e destinadas a análises. Cada base de dados organizada por assunto dá-se o nome de **Data Mart**, e ao conjunto de *Data Marts* dá-se o nome de **Data Warehouse**. Essa organização dos dados é importante e muito válida, pois tende a facilitar em muito o trabalho de mineração de dados.

b) Errada. **Metadados** são **dados com a finalidade de descrever outros dados**. É como se fosse um dicionário, trata-se de um grupo específico de registros em banco de dados cuja finalidade é permitir melhor entendimento dos dados a que se referem.

c) Errada. **Data Mart** é uma base de dados em que os dados já estão organizados por assunto. Assim, numa grande empresa seria comum encontrar um Data Mart de Vendas (tratando de registros sobre vendas), um Data Mart de Recursos de Humanos, ou outro sobre Compras da Empresa, etc.

d) Certa. O enunciado da questão dá fortes indicações de que a questão trata de **Data Mining**. O texto diz: “**descobrir relacionamentos significativos**” e também “**concluir sobre padrões de comportamento de clientes de uma organização**”, tudo isso faz parte da descrição de *Data Mining*.

e) Errada. **Sistemas Transacionais** são os sistemas da empresa de um modo geral. Pode ser tanto a loja virtual da empresa, como pode ser o sistema de gerenciamento de vendas ou de recursos humanos. Esses sistemas são caracterizados inclusive por **realizarem contínuas operações de consulta, inserção, alteração e exclusão em banco de dados transacionais**. Chamamos de banco de dados transacionais os bancos de dados preparados para se comportarem em transações (inserção, exclusão e alteração). Esses bancos de dados são chamados de **OLTP** (*On-line Transaction Processing*).

Letra d.

034. (FMP-RS/TCE-RS/AUDITOR PÚBLICO EXTERNO/ADMINISTRAÇÃO/2011) Mineração de dados consiste em

- a) explorar um conjunto de dados visando a extrair ou a ajudar a evidenciar padrões, como regras de associação ou sequências temporais, para detectar relacionamentos entre estes.
- b) acessar um banco de dados para realizar consultas de forma genérica, buscando recuperar informações (registros) que atendam um mesmo critério de pesquisa.
- c) recuperar informações de um banco de dados específico, voltado a representar e armazenar dados relacionados com companhias de exploração petrolífera e de recursos mineralógicos.
- d) um banco de dados específico voltado à gestão de negócios usando tecnologia de informação (TI) como, por exemplo, a área de BI (*Business Intelligence*).
- e) representar informações de um banco de dados mediante vários modelos hierárquicos como, por exemplo, o de entidade-relacionamento (ER).



Vamos aos comentários de cada uma das assertivas:

- a) Certa. **Data Mining** refere-se à busca de **informações relevantes** a partir de um grande volume de dados.
- b) Errada. **Data Mining** é um processo “**de identificar informações relevantes, tais como padrões, associações, mudanças, anomalias e estruturas, em grandes conglomerados de dados que estejam em banco de dados ou outros repositórios de informações**”. Portanto não se trata apenas de “acessar um banco de dados para realizar consultas genéricas” como diz a letra B.
- c) Errada. O processo de **Data Mining** pode atuar sobre **diversas bases de dados** e não somente sobre um banco de dados específico.

d) Errada. **Data Mining** não é um banco de dados, trata-se de um **processo** que busca **identificar informações relevantes, em grandes conglomerados de dados que estejam em banco de dados ou outros repositórios de informações.**

e) Errada. **Data Mining** é um processo de busca de padrões e associações, entre outros.

Letra a.

035. (INÉDITA/2021) O resultado da Mineração de Dados pode descobrir os seguintes tipos de informação “nova”: regras de associação, padrões Sequenciais e regras de Classificação.



Perfeito! Veja exemplos a seguir.

Regras de associação	Permite identificar afinidades existentes entre um conjunto de itens em um dado grupo de registros. Por exemplo, se um cliente compra uma máquina fotográfica, pode querer comprar também um cartão de memória.
Padrões sequenciais	Permite identificar sequências que ocorrem em determinados registros. Por exemplo, determinado cliente pega um empréstimo para comprar um carro. Depois da quarta parcela, começa a atrasar o pagamento. Depois de um ano, deixa de pagar. Isso pode se repetir de forma mais ou menos igual para diversos clientes, e pode definir um padrão. Assim, quando o cliente começa a atrasar muito, a empresa já pode se preparar para ele deixar de pagar a dívida.
Regras de classificação	As categorias são definidas antes da análise dos dados. Por exemplo, clientes podem ser classificados por frequência de visitas, por tipo de financiamento utilizado, por quantidade comprada, por afinidades com alguns itens e assim sucessivamente. Algumas estatísticas reveladoras podem ser geradas para cada classe de clientes.

Certo.

036. (ESAF/CVM/2010) Mineração de Dados é

a) o processo de atualizar de maneira semi-automática grandes bancos de dados para encontrar versões úteis.

b) o processo de analisar de maneira semi-automática grandes bancos de dados para encontrar padrões úteis.

c) o processo de segmentar de maneira semi- automática bancos de dados qualitativos e corrigir padrões de especificação.

d) o programa que depura de maneira automática bancos de dados corporativos para mostrar padrões de análise.

e) o processo de automatizar a definição de bancos de dados de médio porte de maior utilidade para os usuários externos de rotinas de mineração.



Conforme visto o **Data Mining** é um processo de procura de padrões e regras de associações em conglomerados de dados

Esse processo é realizado com o uso de softwares com algoritmos que implementam as técnicas de **Data Mining** conhecidas e também com a supervisão de um especialista no domínio de negócio em estudo. Por isso, podemos dizer que **Data Mining** é também semiautomático. Portanto, somente a letra B está correta.

Letra b.

037. (ESAF/CGU/ANALISTA DE FINANÇAS E CONTROLE/AUDITORIA E FISCALIZAÇÃO/GERAL/2012) São características gerais de conjuntos de dados:

- a) disposição, dispersão e renderização.
- b) dimensão, posicionamento e homogeneidade.
- c) compatibilidade, dispersão e interação.
- d) dimensão, dispersão e resolução.
- e) portabilidade, concentração e resolução.



Mais uma questão retirada de TAN et. al (2009, p. 35), que destaca **três características aplicadas a muitos conjuntos de dados** e que possuem um impacto significativo sobre as técnicas de mineração de dados: **dimensão, dispersão e resolução**.

Dimensão	• Relacionada à quantidade de atributos de um conjunto de dados .
Resolução	• Está relacionada à granularidade dos dados .
Dispersão	• Um conjunto de dados é muito disperso quando para um atributo relevante, a maioria dos valores é NULL (desconhecido) ou um valor padrão.

Portanto, a assertiva D é a resposta da questão.

Letra d.

038. (CESPE/TCE-PA/AUDITOR DE CONTROLE EXTERNO/INFORMÁTICA/ANALISTA DE SISTEMA/2016) Julgue o item a seguir, em relação a data warehouse e data mining.

No contexto de data mining, o processo de descoberta de conhecimento em base de dados consiste na extração não trivial de conhecimento previamente desconhecido e potencialmente útil.



A **mineração de dados (data mining)** refere-se à **mineração ou descoberta de novas informações em termos de padrões ou regras com base em grandes quantidades de dados**. Trata-se do **processo não trivial de identificar padrões válidos, novos, potencialmente úteis e, em última instância, compreensíveis** em dados armazenados em bancos de dados estruturados.

Certo.

039. (CESPE/MEC/ADMINISTRADOR DE DADOS/2015) Acerca de data warehouse (DW), Business Intelligence (BI) e data mining, julgue o item que se segue.

Situação hipotética: Após o período de inscrição para o vestibular de determinada universidade pública, foram reunidas informações acerca do perfil dos candidatos, cursos inscritos e concorrências. Ademais, que, por meio das soluções de BI e DW que integram outros sistemas, foram realizadas análises para a detecção de relacionamentos sistemáticos entre as informações registradas.

Assertiva: Nessa situação, tais análises podem ser consideradas como *data mining*, pois agregam valor às decisões do MEC e sugerem tendências, como, por exemplo, o aumento no número de escolas privadas e a escolha de determinado curso superior.



A questão destaca a detecção de relacionamentos sistemáticos (ou seja, os padrões) entre as informações registradas. Nesse sentido, o **Data Mining (Mineração de Dados)** é entendido como o **processo de identificar informações relevantes, tais como padrões, associações, mudanças, anomalias e estruturas, em grandes conglomerados de dados que estejam em banco de dados ou outros repositórios de informações**. Portanto, está correta a assertiva.

Certo.

040. (CESPE/TRT-08/ANALISTA DE TI/2016) Acerca de data mining, assinale a opção correta.

a) A fase de preparação para implementação de um projeto de data mining consiste, entre outras tarefas, em coletar os dados que serão garimpados, que devem estar exclusivamente em um data warehouse interno da empresa.

b) As redes neurais são um recurso matemático/computacional usado na aplicação de técnicas estatísticas nos processos de data mining e consistem em utilizar uma massa de dados para criar e organizar regras de classificação e decisão em formato de diagrama de árvore, que vão classificar seu comportamento ou estimar resultados futuros.

c) As aplicações de data mining utilizam diversas técnicas de natureza estatística, como a **análise de conglomerados (cluster analysis)**, que tem como objetivo agrupar em diferentes

conjuntos de dados, os elementos identificados como semelhantes entre si, com base nas características analisadas.

d) As séries temporais correspondem a técnicas estatísticas utilizadas no cálculo de previsão de um conjunto de informações, analisando-se seus valores ao longo de determinado período. Nesse caso, para se obter uma previsão mais precisa, devem ser descartadas eventuais sazonalidades no conjunto de informações.

e) Os processos de data mining e OLAP têm os mesmos objetivos: trabalhar os dados existentes no data warehouse e realizar inferências, buscando reconhecer correlações não explícitas nos dados do data warehouse.



Vamos aos comentários de cada uma das assertivas:

a) Errada. Cita que os dados a serem garimpados devem estar exclusivamente em um Data Warehouse interno da empresa, contudo a fonte de dados pode ser qualquer uma: os dados podem estar em arquivos de texto no file system ou em outro repositório, em banco de dados, em Data Warehouse, enfim, a mineração ocorre em qualquer tipo de arquivo de dados e o mesmo pode estar em qualquer tipo de repositório.

b) Errada. Diversos conceitos foram misturados nessa assertiva, o que a tornou bastante confusa.

Redes neurais são soluções computacionais que utilizam estruturas matemáticas de maneira a ser desenvolvido um programa de computador com a habilidade de aprender padrões e auxiliar no processo de predição de eventos.

Entretanto redes neurais não representam a descrição em formato de diagrama de árvore. As árvores de decisão é que realizam este tipo de representação de conhecimento.

Cada técnica de mineração é usada com um propósito específico, como exemplo, a classificação vai permitir que você classifique novas entradas de acordo com um conjunto predeterminado de saídas, que foram construídos em uma etapa anterior do processo.

c) Certa. Definição bem completa para a abordagem aqui apresentada.

d) Errada. Tendo-se em vista o fato de seu resultado ser uma análise de seus valores de saída ao longo de determinado período, faz-se necessária a análise dos efeitos sazonais e até a análise dos efeitos cíclicos contidos na série.

e) Errada. Os processos de OLAP e Data Mining são distintos! OLAP é uma ferramenta de consulta em bases de dados analíticas, que visa extrair informações por meio de queries e utiliza as operações sobre os cubos de dados. *Data Mining* (Mineração de Dados) é bem mais complexo que OLAP, uma vez que busca padrões em grandes volumes de dados por meio de técnicas estatísticas e de **algoritmos** de inteligência artificial, por exemplo.

041. (CESPE/TCDF/ANALISTA DE ADMINISTRAÇÃO PÚBLICA/SISTEMAS DE TI/2014) Com o uso da classificação como técnica de *Data Mining*, busca-se a identificação de uma classe por meio de múltiplos atributos. Essa técnica também pode ser usada em conjunto com outras técnicas de mineração de dados.



Classificar um novo objeto é determinar com que grupo (ou classe) de objetos, já classificados anteriormente, esse novo objeto apresenta mais semelhança. Outras técnicas podem ser utilizadas em conjunto com a classificação, para otimizar a descoberta de conhecimento em bases de dados.

Certo.

042. (CESPE/CRPM/ANALISTA EM GEOCIÊNCIAS/SISTEMAS/2013) A fase de modelagem de um data mining agrega a seleção e aplicação das técnicas sobre os dados selecionados. Inúmeras técnicas podem ser empregadas para obtenção de padrões úteis, como por exemplo, a PMML (predictive model mark-up language), que objetiva, via schemas XML, a definição para modelos encontrados em associações, modelos de regressão e clustering.



A PMML (predictive *model mark-up language*) é a linguagem padrão de fato utilizada para representar os modelos de analítica preditiva. Trata-se de uma linguagem baseada em XML para a descrição de modelos encontrados em *Data Mining*.

Obs.: Veja mais: <http://www.ibm.com/developerworks/br/industry/library/ind-PMML1/>

Certo.

043. (CESPE/TRT-21ª REGIÃO/ANALISTA JUDICIÁRIO/TECNOLOGIA DA INFORMAÇÃO/2010) O *data mining* é um processo automático de descoberta de padrões, de conhecimento em bases de dados, que utiliza, entre outros, árvores de decisão e métodos bayesianos como técnicas para classificação de dados.



Um conceito aqui explorado foi proposto na edição antiga do livro "*Data Mining Techniques: For Marketing, Sales, and Customer Support*", listada a seguir:

A **mineração de dados** é a exploração e análise, por **meios automáticos ou semiautomáticos**, de grandes quantidades de dados a fim de descobrir **padrões e regras significativas** (1997).

A questão citou **duas técnicas de classificação de dados** corretamente, a saber: árvores de decisão e métodos bayesianos. Cabe destacar que **não** existe uma técnica que resolva todos

os problemas de *Data Mining*. **Diferentes técnicas servem para diferentes propósitos, cada uma oferecendo vantagens e desvantagens. A escolha da técnica está fortemente relacionada com o tipo de conhecimento que se deseja extrair ou com o tipo de dado no qual ela será aplicada.**

Certo.

044. (VUNESP/TJ-PA/ANALISTA JUDICIÁRIO/ANÁLISE DE SISTEMA/DESENVOLVIMENTO/2014)

Uma das tarefas implementadas por uma ferramenta de Data Mining consiste em realizar a determinação de um valor futuro de determinada característica ou atributo de um registro ou conjunto de registros. Tal tarefa corresponde à

- a) normalização.
- b) indexação.
- c) análise de afinidade.
- d) predição.
- e) análise de equivalência



Tal tarefa corresponde à **predição (ou previsão) que busca descrever a natureza de ocorrências futuras de certos eventos com base nos acontecimentos passados.**

A **predição difere da adivinhação**, pois leva em consideração as experiências, opiniões e outras informações relevantes na condução da previsão. Dependendo da natureza da predição, podemos falar em **classificação** ou **regressão**.

Letra d.

045. (VUNESP/PRODEST-ES/ANALISTA DE TECNOLOGIA DA INFORMAÇÃO/DESENVOLVIMENTO

DE SISTEMAS/2014) No data mining, uma das formas de se obter conhecimento é por meio das Regras de Associação, que buscam eventuais associações entre 2 determinados produtos, um denominado antecedente e o outro, consequente. Uma medida utilizada nesse tipo de regra é denominada 'suporte', que representa

- a) a fração da população-alvo que satisfaz o antecedente e o consequente.
- b) a razão entre o produto antecedente e o consequente
- c) a razão entre o produto consequente e o precedente.
- d) o número absoluto da população-alvo que satisfaz o antecedente e o consequente
- e) o número absoluto de produtos do tipo antecedente.



A **tarefa de associação** tem como premissa básica encontrar relacionamentos ou padrões frequentes entre conjuntos de dados.

Tipicamente, **regras de associação representam padrões existentes em transações armazenadas**. O termo transação indica quais itens foram consultados em uma determinada operação de consulta.

Como exemplo, a partir de uma base de dados, na qual registram-se os itens adquiridos por clientes, uma estratégia de mineração, com o uso de regras de associação, poderia gerar a seguinte regra: {cinto, bolsa} $\Rightarrow$ {sapato}, a qual indica que o cliente que compra cinto e bolsa, com um determinado grau de certeza, compra também sapato. Este grau de certeza de uma regra é definido por dois índices: o **fator de suporte** e o **fator de confiança**.

- **Suporte:** é a porcentagem da população que satisfaz à regra. Em outras palavras, a fração da população-alvo que satisfaz o antecedente e o consequente.
- **Confiança:** dadas duas regras, antecedente e consequente, é a porcentagem em que a regra consequente ocorre.

Letra a.

046. (FCC/TCE-SP/AGENTE DA FISCALIZAÇÃO FINANCEIRA/INFORMÁTICA/PRODUÇÃO E BANCO DE DADOS/2010) No âmbito dos algoritmos associados ao mining, se houver um banco de dados com um número potencial pequeno de conjuntos de itens grandes, isto é, uns poucos milhares, então o suporte para todos eles pode ser testado em uma passagem usando a técnica específica de

- hierarquização.
- partição.
- amostragem.
- árvore de padrão frequente.
- séries temporais.



A **análise de agrupamentos** (também conhecida como **clusterização** ou **análise de aglomerações** ou **análise de partições**) busca **classificar casos** (por exemplo, pessoas, coisas, eventos) **em grupos ou clusters, de modo que o grau de associação seja forte entre os membros do mesmo cluster e fraco entre os membros de diferentes clusters**. Cada *cluster* descreve a classe a que seus membros pertencem.

Letra b.

047. (CESPE/TCU/AUDITOR FEDERAL DE CONTROLE EXTERNO/2015) A finalidade do uso do data mining em uma organização é subsidiar a produção de afirmações conclusivas acerca do padrão de comportamento exibido por agentes de interesse dessa organização.



A **mineração de dados (Data Mining)** pode ser utilizada para encontrar novos padrões, visando:

- **predição:** o sistema encontra padrões para prever (prever) o comportamento futuro de algumas entidades;
- **descrição:** o sistema encontra padrões relevantes sobre os dados, em uma forma compreensível para o usuário.

A mineração de dados **envolve o ajuste de modelos aos dados observados ou a determinação de padrões a partir destes dados**. Os modelos ajustados fazem o papel do conhecimento inferido, sobre o qual o julgamento humano subjetivo é exigido na verificação se os modelos refletem conhecimento útil ou interessante.

Certo.

048. (CESPE/MEC/ADMINISTRADOR DE BANCO DE DADOS/2015) Julgue o item seguinte, referente a *data mining*. A predição em algoritmos de data mining objetiva modelar funções sobre valores para apresentar o comportamento futuro de determinados atributos.



Isso! A **predição (ou previsão)** em algoritmos de *Data Mining* possibilita ao sistema encontrar padrões para **prever (prever) o comportamento futuro** de algumas entidades.

Certo.

049. (CESPE/MEC/ADMINISTRADOR DE BANCO DE DADOS/2015) Julgue o item seguinte, referente a data mining.

Selecionar uma amostra e determinar os conjuntos de itens frequentes dessa amostra para formar a lista de previsão de subconjunto são as principais características do algoritmo de previsão.



Conforme destaca Soares (2019), a assertiva apresenta o **algoritmo de amostragem** utilizado nas regras de associação. Navathe cita que a ideia principal do algoritmo de amostragem é selecionar uma amostra pequena e determinar os conjuntos de dados frequentes com base na amostra.

Errado.


050. (CESPE/TJ-DFT/TÉCNICO JUDICIÁRIO/PROGRAMAÇÃO DE SISTEMAS/2015) Julgue o item a seguir, a respeito de dataware house e de data mining.

O conteúdo intelectual aqui contido é de propriedade intelectual da GRAN CONCURSOS, inscrita no CNPJ nº 16.045.812/0001-612, vedada, por quaisquer meios e a qualquer título, a sua reprodução, cópia, divulgação ou distribuição, sujeitando-se aos infratores à responsabilização civil e criminal.

Em um processo de mineração, durante a etapa de preparação dos dados, são analisados os requisitos de negócio para consolidar os dados.



Em um processo de mineração, durante a etapa de entendimento do negócio, são analisados os requisitos de negócio para consolidar os dados.



Esta fase inicial de **entendimento do negócio** se concentra, portanto, na **compreensão das necessidades gerenciais e dos objetivos e requisitos de negócio que devem ser atendidos pela mineração de dados**. Em seguida, **um plano de projeto para busca de conhecimentos** é desenvolvido, especificando as pessoas responsáveis por coletar, analisar e reportar dados. Nesta fase inicial, um orçamento para apoiar o estudo também deve ser estabelecido, pelo menos em alto nível com valores aproximados.

O propósito da fase de **preparação dos dados** é **carregar os dados identificados e prepará-los para análise** por métodos de mineração de dados. A fase de preparação de dados abrange todas as **atividades para construir o conjunto de dados final** (dados que serão alimentados na ferramenta de modelagem) **a partir dos dados brutos iniciais**.

Errado.

REFERÊNCIAS

AMORIM, T. **Conceitos, técnicas, ferramentas e aplicações de Mineração de Dados para gerar conhecimento a partir de bases de dados**. 2006. Disponível em: <<http://www.cin.ufpe.br/~tg/2006-2/tmas.pdf>>. Acesso em: 22 jul. 2019.

BERRY, M. J. A.; LONOFF, G.. **Data Mining Techniques: for Marketing, Sales and Customer Support**. New York: John Wiley & Sons, Inc., 1997.

BERSON, Alex; SMITH, Stephen; THEARLING, Kurt. **Building Data Mining Applications for CRM**. USA, New York: MacGrawHill, 1999.

CORTÊS, S. da C.; PORCARO, R. M.; LIFSCHITZ, S. **Mineração de Dados – Funcionalidades, técnicas e abordagens**. 2002. Disponível em: <ftp://obaluae.inf.puc-rio.br/pub/docs/techreports/02_10_cortes.pdf>.

DIEGO, E. **As melhores ferramentas do mercado para Business Intelligence**. 2014. Disponível em: <<http://corporate.canaltech.com.br/noticia/business-intelligence/As-melhores-ferramentas-do-mercado-para-Business-Intelligence/>>.

DINIZ, Carlos Alberto; LOUZADA NETO, Francisco. **Data Mining: uma introdução**. São Paulo: ABE, 2000.

ELMASRI, R.; NAVATHE, S. B. **Sistemas de Banco de Dados**. 4. ed. Pearson. 2006.

FAYYAD U. M., PIATETSKY-SHAPIO, G. & SMITH, P., **"From Data Mining to Knowledge Discovery: An Overview"**. In: Advances in Knowledge Discovery and Data Mining, FAYYAD, U.M. et alii (eds.), AAAI/MIT Press, pp. 1-36, 1995.

FAYYAD U.M., PIATETSKY-SHAPIO, G. & SMITH, P., **"From Data Mining to Knowledge Discovery in Databases"**. AI Magazine, Vol. 17, No. 3, pp. 37-54, 1996.

FAYYAD, Usama; PIATETSKI-SHAPIO, Gregory; SMYTH, Padhraic (1996) **"The KDD Process for Extracting Useful Knowledge from Volumes of Data"**. In: Communications of the ACM, pp.27-34, Nov.1996.

FERNANDES, A. A.; DE ABREU, V. F. **Implantando a Governança de TI: Da estratégia à Gestão de Processos e Serviços**. Brasport, 2014.

HAN, J.; KAMBER, M.. **Data Mining: concepts and techniques**. Morgan Kaufman Publishers, San Francisco, CA., 2001.

IBM. **IBM Completes Acquisition of Vivisimo**. 2012. Disponível em: <<https://www-03.ibm.com/press/us/en/pressrelease/37833.wss>>. Acesso em: 27 jul. 2020.

IMASTERS. **10 ferramentas e bibliotecas para trabalhar com data mining e Big Data – Parte 02**. 2017. Disponível em: <<https://imasters.com.br/data/10-ferramentas-e-bibliotecas-para-trabalhar-com-data-mining-e-big-data-parte-02>>.

IBM. **IBM SPSS Modeler CRISP-DM Guide**. 2011. Disponível em: <ftp://public.dhe.ibm.com/software/analytics/spss/documentation/modeler/14.2/en/CRISP_DM.pdf>. Acesso em: 27 jul. 2020.

Laudon, K. C., & Laudon, J. P. **Management Information Systems**. Harlow: Pearson. 2014.

NAVEGA, S. **Princípios Essenciais do Data Mining**. São Paulo: Cenadem, 2002.

PRASS, Fernando Sarturi. KKD: **Processo de descoberta de conhecimento em bancos de dados**. Grupo de Interesse Em Engenharia de Software, Florianópolis, v. 1, p. 10-14, 2004.

SOARES, I. B. **Mineração de dados**. 2019. Disponível em: <https://www.cin.ufpe.br/~in940/Mineracao_de_dados_Isadora.pdf>. Acesso em: 27 jul. 2020.

TAN, Pang – Ning; STEINBACH, Michael; KUMAR, Vipin. **Introdução ao DATAMINING Mineração de Dados**. Rio de Janeiro: Editora Ciência Moderna Ltda, 2009.

TURBAM, E. et al. **Business Intelligence: um Enfoque Gerencial para a Inteligência do Negócio**. Bookman, 2009.

WITTEN I.; FRANK E. **Data Mining**. Morgan Kauffmann, 2000. <http://www.scielo.br/pdf/pci/v11n3/a05v11n3>

SMART VISION. Disponível em: <<http://www.sv-europe.com/crisp-dm-methodology/>>. Acesso em: 21 jul. 2019.

WITTEN, I., FRANK, E. **Data Mining: Pratical Machine Learning Tools and Techniques with Java Implementations**. San Diego, California: Academic Press.2000.

Abra



caminhos



crie

futuros

gran.com.br

