

TECNOLOGIA DA INFORMAÇÃO

Business Intelligence e Pipeline de Dados – Parte I



Presidente: Gabriel Granjeiro

Vice-Presidente: Rodrigo Calado

Diretor Pedagógico: Erico Teixeira

Diretora de Produção Educacional: Vivian Higashi

Gerência de Produção de Conteúdo: Magno Coimbra

Coordenadora Pedagógica: Élica Lopes

Todo o material desta apostila (incluindo textos e imagens) está protegido por direitos autorais do Gran Cursos Online. Será proibida toda forma de plágio, cópia, reprodução ou qualquer outra forma de uso, não autorizada expressamente, seja ela onerosa ou não, sujeitando-se o transgressor às penalidades previstas civil e criminalmente.

CÓDIGO:

230313106852



PATRÍCIA QUINTÃO

Mestre em Engenharia de Sistemas e computação pela COPPE/UFRJ, Especialista em Gerência de Informática e Bacharel em Informática pela UFV. Atualmente é professora no Gran Cursos Online; Analista Legislativo (Área de Governança de TI), na Assembleia Legislativa de MG; Escritora e Personal & Professional Coach. Atua como professora de Cursinhos e Faculdades, na área de Tecnologia da Informação, desde 2008. É membro: da Sociedade Brasileira de Coaching, do PMI, da ISACA, da Comissão de Estudo de Técnicas de Segurança (CE-21:027.00) da ABNT, responsável pela elaboração das normas brasileiras sobre gestão da Segurança da Informação. Autora dos livros: Informática FCC – Questões comentadas e organizadas por assunto, 3ª. edição e 1001 questões comentadas de informática (Cespe/UnB), 2ª. edição, pela Editora Gen/Método. Foi aprovada nos seguintes concursos: Analista Legislativo, na especialidade de Administração de Rede, na Assembleia Legislativa do Estado de MG; Professora titular do Departamento de Ciência da Computação do Instituto Federal de Educação, Ciência e Tecnologia; Professora substituta do DCC da UFJF; Analista de TI/Suporte, PRODABEL; Analista do Ministério Público MG; Analista de Sistemas, DATAPREV, Segurança da Informação; Analista de Sistemas, INFRAERO; Analista - TIC, PRODEMGE; Analista de Sistemas, Prefeitura de Juiz de Fora; Analista de Sistemas, SERPRO; Analista Judiciário (Informática), TRF 2ª Região RJ/ES, etc.

GRAN
CONCURSOS

SUMÁRIO

Apresentação	4
Business Intelligence e Pipeline de Dados – Parte I	5
Conceitos Principais	5
Data Warehouse	5
Processo de Data Warehousing	12
Data Warehouse (DW) x Visões	13
Data Mart (DM)	16
Data Mining (Mineração de Dados)	17
Data Storage (Armazenamento de Dados)	17
Abordagens para o Projeto de DW	18
Pipeline de Dados	22
ETL (Extract, Transform, Load – Extração, Transformação e Carga de Dados) em DW	23
ELT (Extract, Load, Transform – Extração, Carga e Transformação) de Dados em DW	25
Coleta, Tratamento, Armazenamento, Integração, Recuperação e Descarte de Dados	31
Projeto do Data Warehouse	35
Visão Geral	35
Esquemas Multidimensionais	51
Esquema Estrela x Esquema Floco de Neve	58
Constelação de Fatos	59
Sete Passos para Construir um DW	60
Resumo	68
Questões Comentadas em Aula	80
Gabarito	87
Referências	88

APRESENTAÇÃO

Vamos lá, querido(a) amigo(a)!

Para chegar até a pontinha do *iceberg* chamada “sucesso” é preciso enfrentar a longa jornada.

Todo merecimento é fruto de várias tentativas e motivação para não desistir dos nossos sonhos. Lembre-se que **você é capaz de chegar lá!**

Vamos então à primeira parte da aula de **Business Intelligence e Pipeline de Dados**.

Em caso de dúvidas, acesse o fórum do curso ou entre em contato.

Força nos estudos! ✨ 📖

BUSINESS INTELLIGENCE E PIPELINE DE DADOS – PARTE I

CONCEITOS PRINCIPAIS

DATA WAREHOUSE

Um **Data Warehouse** (armazém de dados, ou ainda depósito de dados), é um repositório de informações colhidas de várias origens, armazenadas sob um esquema unificado, em um único local, **que propõe sustentar a tomada de decisão com dados**.



Figura. Armazém de dados.

Assim, uma das características fundamentais de um ambiente de data warehouse está em proporcionar um ambiente que permita realizar análise dos negócios de uma empresa com base nos dados por ela armazenados.

Para que serve?

- Para criar uma **visão única** e centralizada dos dados que estavam dispersos em diversos Bancos de Dados;
- Permite que usuários finais executem consultas, gerem relatórios e façam **análises**.

A seguir, listamos as principais Características de um **Data Warehouse**:

Obs.: O **Data Warehouse** pode ser considerado **uma coleção de dados orientada por assunto, integrada, não volátil, variante no tempo**, que dá apoio às decisões da administração.




Figura. Características do Data Warehouse. Fonte: Elaborada pela autora.

- **Orientado a assunto:** refere-se ao fato do Data Warehouse (DW) ser **organizado conforme diferentes visões de negócio**, ou seja, armazena informações sobre temas específicos importantes para o negócio da empresa. Exemplo: Vendas, Compras etc.



Figura. Visões de Negócio

- **Integrado a partir de fontes de dados heterogêneas:** refere-se à consistência de nomes, das unidades, das variáveis etc., no sentido de que os dados foram transformados até um estado uniforme. Por exemplo, considere sexo como um elemento de dado. Uma aplicação pode codificar sexo como M/F, outra como 1/0 e uma terceira como H/M.

Assim, **conforme os dados são inseridos no Data Warehouse, eles são convertidos para um mesmo padrão**. Sexo é codificado apenas de uma forma. Da mesma maneira, se um elemento de dado é medido em centímetros em uma aplicação, em polegadas em outra, ele será convertido para uma representação **única** ao ser colocado no Data Warehouse.




Figura. Exemplo de Integração de Dados de Fontes Heterogêneas.

- **Não volátil:** os dados são sempre inseridos, nunca excluídos. Isso significa que **em um DW não existem alterações de dados, somente a carga inicial e as consultas posteriores**. No ambiente operacional, ao contrário, os dados são, em geral, **atualizados** registro a registro, em múltiplas transações.

Obs.: Por definição, **os dados em um Data Warehouse não são voláteis**, ou seja, eles **não** mudam, salvo quando é necessário fazer correções de dados previamente carregados. Os dados estão disponíveis somente para leitura e não podem ser alterados.




Figura. Carregamento e Acesso a Dados no Data Warehouse.

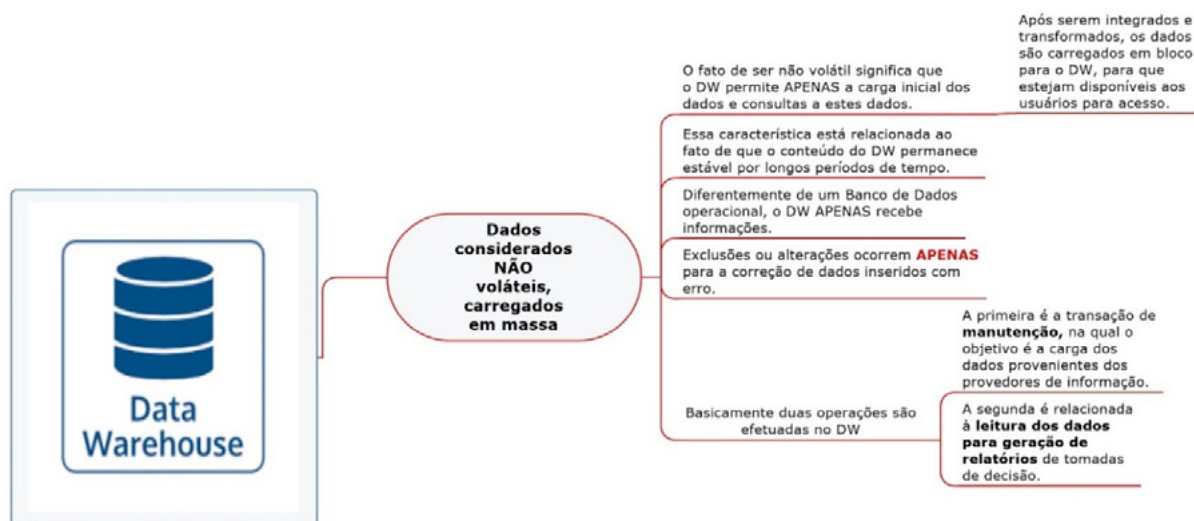


Figura. Dados não Voláteis.

- **Variante no tempo:** posições históricas das atividades no tempo.
- Refere-se ao fato de o dado em um *Data Warehouse* referir-se a algum momento específico, significando que ele NÃO É ATUALIZÁVEL.

Enquanto o **dado de produção é atualizado de acordo com mudanças de estado do objeto em questão**, refletindo, em geral, o estado do objeto no momento do acesso. Em um *Data Warehouse*, a cada ocorrência de uma mudança, uma nova entrada é criada, para marcar esta mudança.






Figura. Variação de Preços no Tempo.

- **Granularidade de dados:** refere-se ao **nível de sumarização dos elementos e de detalhes disponíveis nos dados**, sendo considerado o mais importante aspecto do projeto de um *Data Warehouse*.

Um Data Warehouse é recomendado para armazenar **dados sumarizados** de toda a empresa para apoio à decisão e utilização de ferramentas **OLAP** (*On Line Analytical Processing*).

DIRETO DO CONCURSO

001. (CESGRANRIO/BANCO DA AMAZÔNIA/TÉCNICO CIENTÍFICO/TECNOLOGIA DA INFORMAÇÃO/2018) Um Data Warehouse é recomendado para armazenar dados

- sumarizados de um departamento.
- sumarizados de toda a empresa para apoio à decisão e utilização de ferramentas OLAP.
- detalhados de toda a empresa para apoio à decisão e utilização de ferramentas OLAP.
- detalhados gerados por sistemas de informação transacionais.
- históricos detalhados de todas as transações realizadas em um determinado período de tempo.




O Data Warehouse (DW), na definição de Barbieri (2001, p. 49), é:

(...) um banco de dados, destinado a sistemas de **apoio à tomada de decisão** e cujos dados foram armazenados em estruturas lógicas dimensionais, possibilitando o seu processamento analítico por ferramentas especiais (OLAP e Mining).


A partir desta interpretação, pode-se afirmar que o DW é a fonte para a exploração dos dados, enquanto o **OLAP (On-line Transaction Processing)** e o data mining são as **técnicas** utilizadas para explorar e investigar os dados. Um Data Warehouse é recomendado para armazenar dados **sumarizados** de toda a empresa para apoio à decisão e utilização de ferramentas OLAP.

Letra b.

Obs.: Quanto menor a granularidade, mais detalhada é a informação disponível.



Definir a **granularidade** adequada é vital para que o DW atenda seus objetivos.



Para evitar que se perca informação são criados **vários níveis de granularidade**.



**Em um
nível
de
granula
ridade
muito
alto**

o **espaço em disco** e o **número de índices** necessários se tornam **bem menores**;

há, porém, uma **diminuição** da **possibilidade de utilização dos dados** para atender a consultas detalhadas.

O **Data Warehouse** é um **armazém centralizado de dados**, ou seja, **um banco de dados ou um agrupamento de bases de dados que contêm dados sobre os negócios organizados por assunto**.

Por exemplo, uma indústria automotiva poderia ter um *Data Warehouse* com uma base de dados destinada a armazenar registros inerentes ao setor de Vendas. Poderia haver também outra base de dados que contivesse dados inerentes ao departamento de Produção de Automóveis.

A cada uma dessas bases de dados dá-se o nome de **Data Mart**, e ao agrupamento de todos esses Data Marts damos o nome de

Data Warehouse.

Conforme visto, **Data Warehouse** é o processo de integração dos dados corporativos de uma empresa em um único repositório.

É um **ambiente de suporte à decisão** que alavanca dados armazenados em diferentes fontes e os organiza e entrega aos tomadores de decisões. Resumindo, é uma tecnologia de gestão e análise de dados.

DIRETO DO CONCURSO



002. (CESPE/DEPEN/AGENTE PENITENCIÁRIO FEDERAL/TECNOLOGIA DA INFORMAÇÃO/2015)

Acerca de datawarehouse e datamining, julgue o item subsequente:

O datawarehouse possibilita a análise de grandes volumes de dados, que, por sua vez, permitem a realização de uma melhor análise de eventos futuros.



Um **Data Warehouse**, também chamado de **armazém de dados**, é um **repositório de informações colhidas de várias origens, armazenadas sob um esquema unificado, em um único local**.

Quando reunidos, os dados são armazenados por muito tempo, permitindo o acesso a dados históricos. Ainda, o desenho da base de dados favorece os relatórios, a análise de grandes volumes de dados e a obtenção de informações estratégicas que podem **facilitar a tomada de decisão**.

O **Data Warehouse possibilita a análise de grandes volumes de dados**, coletados dos **sistemas transacionais (OLTP – On-line Transaction Processing)**. São as chamadas **séries históricas** que possibilitam uma melhor **análise de eventos passados**, oferecendo **suporte às tomadas de decisões presentes e a previsão de eventos futuros**.

Errado.

PROCESSO DE DATA WAREHOUSING

O termo **Data Warehousing** pode ser descrito como uma **coleção de tecnologias de suporte à decisão, objetivando capacitar o trabalhador do conhecimento** (executivo, gerente, analista) **a tomar decisões melhores e mais rápidas**.

A figura seguinte apresenta uma arquitetura típica de *Data Warehousing*, mostrando todo o processo envolvido.




Figura. Arquitetura de Data Warehousing. Fonte: Chaudhuri e Dayal (1997).

Essa **arquitetura** inclui ferramentas para:

- **extração de dados de múltiplas bases de dados operacionais e de fontes externas** (por exemplo, perfil dos clientes fornecida por consultores externos) usando *gateways* ou interfaces externas padrão suportadas pelo SGBD de suporte;
- **limpeza** dos dados para minimizar erros e preencher informações ausentes, quando possível;
- **transformação** para reconciliar erros semânticos;
- **integração** desses dados;
- **carga** dos dados no DW, que consiste na materialização das visões e no seu armazenamento no *Data Warehouse*; e para periodicamente executar o **refresh** do *Data Warehouse*, para que esse reflita as atualizações sofridas pela base operacional.

Além do *Data Warehouse* principal, podem existir diversos **Data Marts** (subconjuntos específicos focados em assuntos selecionados) **departamentais**.

Os dados contidos no *Data Warehouse* e nos *Data Marts* são armazenados e gerenciados por um ou mais **servidores de Data Warehouse**, que oferecem visões multidimensionais dos dados para uma variedade de ferramentas *front-end*: ferramentas de **consulta**, geradores de **relatórios**, ferramentas de **análises** específicas e ferramentas de **Data Mining**.

Finalmente, há um repositório para armazenamento e gerenciamento de dados de *log* e ferramentas para monitoramento e administração do sistema total.

DATA WAREHOUSE (DW) X VISÕES

Os *Data warehouses* têm sido considerados por algumas pessoas como sendo uma extensão de funções e visões do banco de dados. No entanto, **visões fornecem somente um subconjunto das capacidades de Data Warehouses**.

Visões e Data Warehouses são similares nos seguintes aspectos:

- ambos têm dados extraídos de bancos de dados;
- são orientados ao assunto.

Data Warehouses são distintos de visões nos seguintes pontos:

- DW existem como **armazenamento persistente** ao invés de ser materializado sob demanda;
- DW não são usualmente relacionais, mas sim **multidimensionais**. Visões de um banco de dados relacional são relacionais.
- DW **podem ser indexados** para otimizar performance. Visões não podem ser indexadas independente dos bancos de dados utilizados.
- DW fornecem suporte específico de funcionalidade, visões não;
- DW fornecem **grande quantidade de dados integrados e frequentemente temporais**, geralmente mais do que está contido em um banco de dados, enquanto as visões são um extrato de um banco de dados.

DIRETO DO CONCURSO

003. (ESAF/MPOG/2008/ADAPTADA) Algumas pessoas têm considerado que os Data Warehouses são uma extensão de visões de banco de dados. Porém, as visões fornecem apenas um subconjunto das funções e das capacidades dos data warehouses. Com relação às diferenças e similaridades entre as visões e os data warehouses, é correto afirmar que tanto os data warehouses quanto as visões fornecem, frequentemente, grandes quantidades de dados integrados e temporais, geralmente mais do que é contido em um banco de dados.



Uma **View (Visão)** é uma tabela lógica, baseada em uma tabela ou em outra visão. Ela não possui dados próprios, é somente uma interface para a manipulação de um conjunto de dados. Ela pode ser utilizada para restringir o acesso a dados em uma tabela, facilitar consultas complexas e também otimizar o tempo dos desenvolvedores.

A *View* é uma maneira alternativa de observação de dados de uma ou mais tabelas, que compõem uma base de dados. Pode ser considerada uma tabela virtual ou uma consulta armazenada. Como exemplo de utilização de *view*, cita-se a restrição usuário x domínio controlando o acesso de um usuário específico a colunas de uma tabela.

Alguns benefícios da utilização das *Views*: economia de tempo com retrabalho; velocidade de acesso às informações; mascara a complexidade do banco de dados; organiza dados a serem exportados para outros aplicativos.

Um **Data warehouse** (ou armazém de dados) é um sistema de computação utilizado para armazenar informação relativa às atividades de uma organização em banco de dados, de forma consolidada. Ele possibilita a análise de grandes volumes de dados, coletados dos sistemas transacionais. Por definição, os dados em um Data Warehouse não são voláteis, ou seja, eles não mudam, são somente para leitura e não podem ser alterados.

Os *Data Warehouses* surgiram como conceito acadêmico na década de 80. Com o amadurecimento dos sistemas de informação empresariais, as necessidades de análise dos dados cresceram paralelamente. Como os sistemas transacionais não conseguiam cumprir a tarefa de análise com a simples geração de relatórios, os *Data Warehouses* são atualmente o núcleo dos sistemas de informações gerenciais e apoio a decisão das principais soluções de *Business Intelligence* do mercado, devido **a sua capacidade de sumarizar grandes volumes de dados** e de possibilitar análises.

As ferramentas **OLAP (Online Analytical Processing)** têm como função a navegação nos dados de um *Data Warehouse*, possuindo uma estrutura adequada tanto para as pesquisas como para a apresentação das informações.

A assertiva, portanto, é falsa, tendo-se em vista que a **View** não tem como objetivo fornecer frequentemente grandes quantidades de dados integrados, e sim **fornecer um subconjunto dinâmico de dados (tabela virtual) a partir de uma ou mais tabelas**.

Observem ainda que o item afirma indevidamente que a quantidade de dados ofertada é maior do que em todo o banco de dados. Uma **View** não possui quantidade de dados maior do que o próprio banco de dados em que ela está inserida.

Errado.

DATA MART (DM)

O **Data Mart (DM)** nada mais é que um subconjunto de dados de um Data Warehouse, em que tipicamente desempenham o papel de um DW departamental, regional ou funcional.

- Segundo Ralph Kimball (2002)
 - Um Data Mart é um subconjunto lógico do Data Warehouse, normalmente visto como um Data Warehouse setorial.




Figura. Data Warehouse e Data Marts.

Alguns autores e especialistas dizem que o DW é uma evolução do DM que começou localizado e cresceu para atender um escopo maior.



DATA MINING (MINERAÇÃO DE DADOS)

É o processo de **análise de conjuntos de dados** que tem por objetivo a **descoberta de padrões interessantes** e que possam representar informações úteis.

A **mineração de dados** é um **processo de negócio** utilizado para explorar grandes quantidades de **dados** em busca de **padrões** e **regras significativas**.

O **Data Mining** apoia o **conhecimento indutivo**, que descobre novas regras e padrões nos dados fornecidos (ELMASRI, NAVATHE, 2005).

Um **exemplo** clássico de utilização do *Data Mining* na área de *marketing* é o das **fraldas próximas das cervejas**. Uma das maiores redes de varejo dos Estados Unidos detectou, em seu gigantesco armazém de dados, que a venda de fraldas descartáveis estava associada à de cerveja. De uma maneira geral, os compradores eram homens, que saíam à noite para comprar fraldas e aproveitavam para levar algumas latinhas para casa. Os produtos foram postos lado a lado. **Resultado: a venda de fraldas e cervejas disparou.**

Veja mais: <http://exame.abril.com.br/revista-exame/edicoes/633/noticias/o-que-cerveja-tem-a-ver-com-fraldas-m0053931>.

Outro exemplo de *Data Mining*: imagine o histórico de vendas de uma empresa que está no mercado há muitos anos. Suponhamos que essa empresa desejasse saber qual a **tendência de vendas de um produto X para os próximos 10 anos**. O Data Mining possui uma série de etapas e técnicas apropriadas para responder essa questão.

Obs.: Os processos de *Data Mining* são muito facilitados quando a empresa já possui seu **Data Warehouse** bem estruturado, **por isso esses dois termos Data Warehouse e Data Mining** caminham tão juntos.

As empresas comumente irão primeiramente amadurecer seus processos de organização dos dados sobre o negócio e agrupá-los por assunto, formando seus **Data Marts**. Em seguida, irão compor seu **Data Warehouse**, para, após, iniciar os **processos de Data Mining** com a finalidade de encontrar algum conhecimento de valor em meio aos dados sobre o negócio.

DATA STORAGE (ARMAZENAMENTO DE DADOS)

O **Data Warehouse** (Armazém de Dados) é o repositório de dados centrais, em que fica a informação. Para a criação do *Data Warehouse*, podemos usar bancos de dados relacionais, como PostgreSQL, Oracle Database, SQL Server e Teradata.

ABORDAGENS PARA O PROJETO DE DW

No que se refere aos **métodos** de construção de **Data Warehouse (DW)**, existem formalmente **dois**:



Nesse caso é realizada a **modelagem integral do DW**, seguida pelas extrações de dados.

Considera que se deve desenvolver um DW completo e centralizado antes que partes dele, sumarizadas, possam ser derivadas na forma de Data Marts.

A principal **vantagem** é a criação de um **modelo único**.

O **revés** fica por conta do **maior tempo de projeto**.



O **foco é em uma área por vez**, com o **crescimento gradual do DW**.

Considera que um DW possa ser composto a partir de Data Marts previamente desenvolvidos.

A **vantagem** é a obtenção de resultados a intervalos mais curtos, garantindo muitas vezes sustentação ao projeto.

A **desvantagem** é a **maior dificuldade de se consolidar informações entre as diversas áreas**.

Podem-se visualizar pela imagem seguinte as **duas formas de construção**, uma na qual o DW gera os DM (Data Mart) e outra em que os DM geram o DW.




Figura. Abordagens Bottom-up e Top-Down. Fonte: <https://canaltech.com.br/infra/a-abordagem-top-down-e-bottom-up-no-data-warehouse-21108/>.




Figura. Exemplos das Duas Formas de Construção de um Data Warehouse.

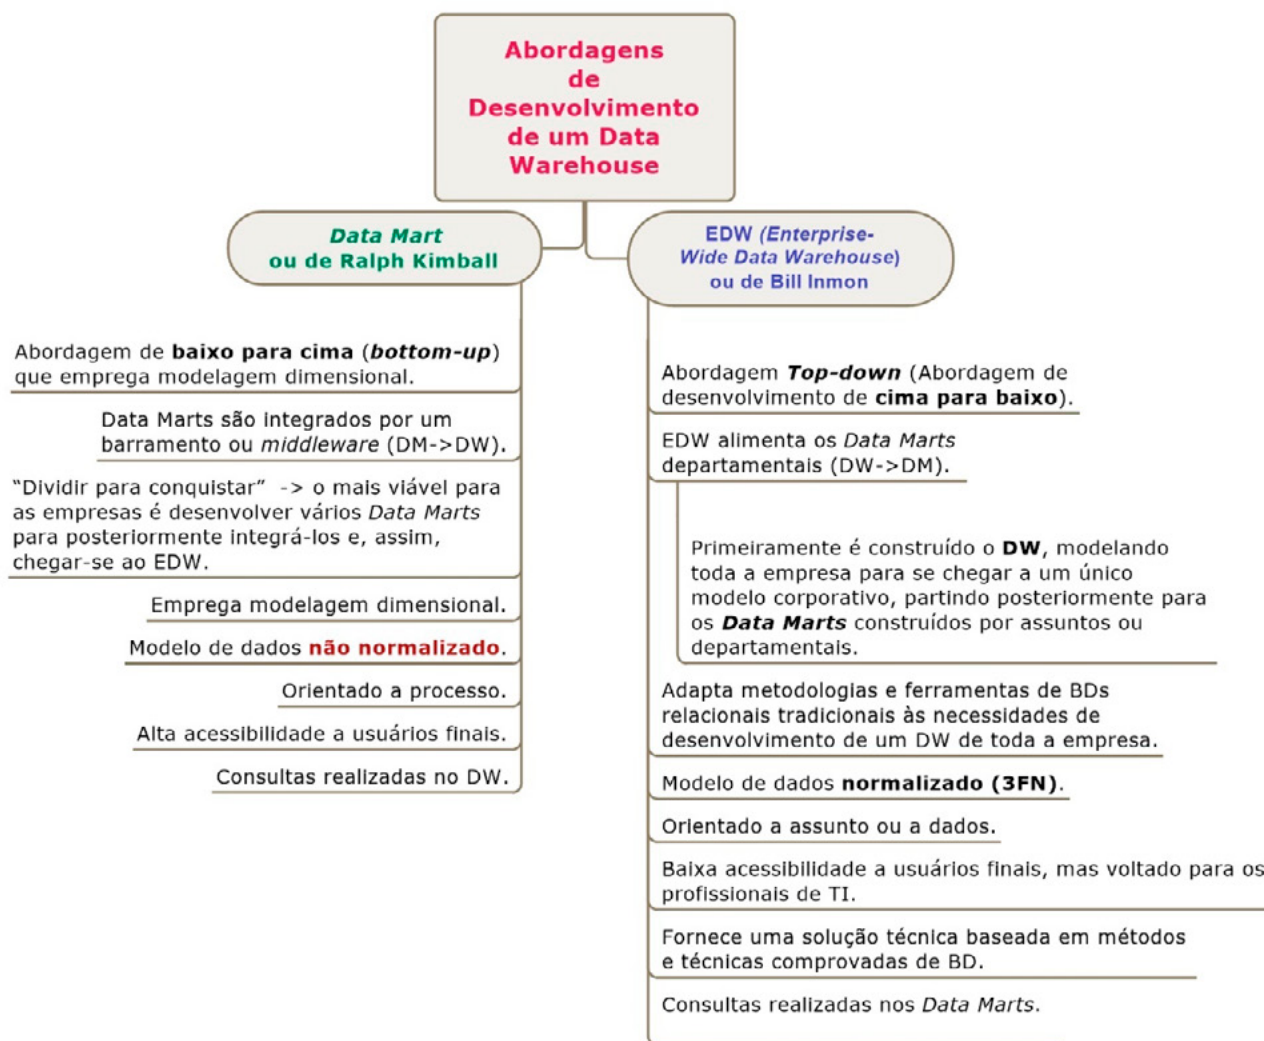


Figura. Abordagens de Desenvolvimento de um DW. Fonte: Elaborada pela autora.

Kimball concebeu uma arquitetura chamada **matriz de barramento** para auxiliar no desenvolvimento de um *Data Warehouse*.

De acordo com o autor, a matriz de barramento é uma matriz de relação cruzada entre **os processos de negócio** e **suas dimensões**, possibilitando visualizar aquelas dimensões que são compartilhadas entre os vários processos de negócio.

Observe pelo diagrama seguinte que, nas **linhas** são destacados os **processos de negócio** da organização. Já nas **colunas**, são dispostas as **dimensões** comuns a esses processos.

BUSINESS PROCESSES	COMMON DIMENSIONS						
	Date	Product	Warehouse	Store	Promotion	Customer	Employee
Issue Purchase Orders	X	X	X				
Receive Warehouse Deliveries	X	X	X				X
Warehouse Inventory	X	X	X				
Receive Store Deliveries	X	X	X	X			X
Store Inventory	X	X		X			
Retail Sales	X	X		X	X	X	X
Retail Sales Forecast	X	X		X			
Retail Promotion Tracking	X	X		X	X		
Customer Returns	X	X		X	X	X	X
Returns to Vendor	X	X		X			X
Frequent Shopper Sign-Ups	X			X		X	X

Fonte: Kimball (Group).

DIRETO DO CONCURSO



004. (VUNESP/TJ-SP/2012) Uma das técnicas utilizadas no projeto de um data warehouse corporativo consiste no uso da chamada matriz de barramento, na qual as linhas e colunas representam, respectivamente,

- a) cubos e medições.
- b) data staging e cubos.
- c) cardinalidades e hierarquias.
- d) dimensões e cardinalidades.
- e) processos de negócio e dimensões.



A matriz de barramento, proposta por Kimball, é uma matriz de relação cruzada entre **os processos de negócio** e **suas dimensões**, possibilitando visualizar aquelas dimensões que são compartilhadas entre os vários processos de negócio.

Essa matriz de barramento dispõe, nas suas **linhas**, os **processos de negócio** da organização e em suas **colunas** as **dimensões comuns**.

Letra e.

Para os processos de construção de um Data Warehouse (DW) é altamente importante a compreensão do negócio que envolve a empresa ou instituição em que se está desenvolvendo o trabalho.

PIPELINE DE DADOS

Pipeline de dados refere-se a um **conjunto de processos e etapas que são usados para coletar, transformar, integrar e mover dados de várias fontes para um destino final**. Os *pipelines* são fundamentais para organizar e automatizar o fluxo de dados em uma empresa, permitindo a análise e tomada de decisões baseadas em informações precisas e atualizadas.

Dsacademy (2020) cita que:

(...) os pipelines de dados consistem em três elementos principais, que são: **uma fonte, uma ou mais etapas de processamento e um destino**. Em alguns pipelines de dados, o destino pode ser chamado de **coletor**. Os pipelines de dados permitem o fluxo de dados de um aplicativo para um Data Warehouse, de um Data Lake para um banco de dados analítico ou para um sistema de processamento de pagamentos, por exemplo. Os pipelines de dados também podem ter a mesma fonte e coletor, de modo que o pipeline seja apenas para modificar o conjunto de dados. Sempre que os dados são processados entre o ponto A e o ponto B (ou pontos B, C e D), há um pipeline de dados entre esses pontos.

Fundamentos do Pipeline de Dados:

1) Coleta de dados: o pipeline começa com a coleta de dados a partir de várias fontes (Ex.: bancos de dados, aplicativos, arquivos de log, dispositivos IoT e fontes de terceiros);

2) Transformação de dados: uma vez coletados, os dados geralmente precisam passar por um processo de transformação para limpeza, enriquecimento, padronização ou agregação. Essa etapa garante que os dados estejam prontos para análise e sejam consistentes;

3) Integração de dados: os dados de diferentes fontes podem ser heterogêneos e armazenados em formatos diferentes. A integração envolve combinar e unificar esses dados em um formato consistente, permitindo a análise e o processamento eficientes;

4) Movimentação de dados: após a transformação e integração, os dados precisam ser movidos para um destino final, como um *data warehouse*, um *data lake* ou um sistema de análise em tempo real;

5) Processamento de dados: dependendo das necessidades da empresa, pode ser necessário realizar processamentos adicionais nos dados, como aplicar algoritmos de *machine learning*, executar análises estatísticas ou extrair *insights* específicos.

ORQUESTRAÇÃO DE PIPELINES DE DADOS

A **orquestração** refere-se à **coordenação e gerenciamento dos diferentes componentes do pipeline de dados**. Envolve a definição de fluxos de trabalho, programação de tarefas, monitoramento e escalonamento de recursos.

As ferramentas de orquestração de pipelines de dados mais populares incluem Apache Airflow, Apache NiFi, Luigi e AWS Step Functions.

ETL (Extract, Transform, Load) e ELT (Extract, Load, Transform): termos usados para descrever as etapas de um pipeline de dados.




Figura. (DATASCIENCEACADEMY, 2022)

ETL (EXTRACT, TRANSFORM, LOAD – EXTRAÇÃO, TRANSFORMAÇÃO E CARGA DE DADOS) EM DW

O processo de **ETL** (do inglês **Extract Transform and Load**) é usado na criação do **DW** (**Data Warehouse**).


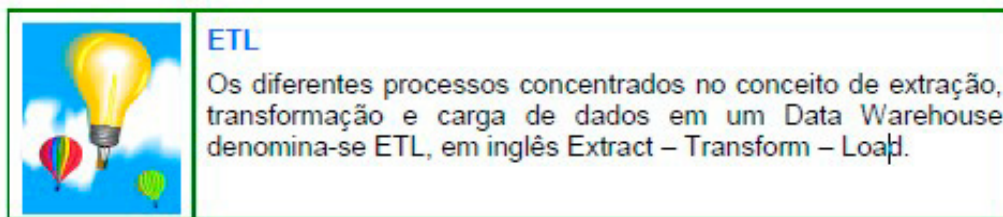



Figura. ETL. Fonte: http://laudosweb.hospitalorione.com.br/manual_html/etl_v4.1.0_painel.png.



- O processo inicial faz a **extração (extract)** de dados das bases de dados transacionais, dados de sistemas ERP, dados locais, externos ou dados da Web. Conforme visto, busca obter os dados das diferentes fontes de dados para posterior transformação. Geralmente essa etapa envolve a conexão e acessos aos dados a partir de fontes como arquivos texto, XML, bancos de dados relacionais, *logs* e outros formatos.
- **Transformação (Transform):** tem como objetivo transformar os dados modificando-os de modo que eles sejam adequados para o armazenamento no destino. O tipo de operação de transformação pode ser a validação, complementação, remoção, mudança de formato, consolidação ou outro tipo qualquer de manipulação de dados;



- **Load (Carga):** basicamente armazena os dados transformados em uma fonte de dados de destino de acordo com um modelo que indicará como eles serão disponibilizados para as aplicações de um projeto de BI (*Business Intelligence*).

Na etapa de **extração**, os dados relevantes ou de interesse são capturados de uma base de dados estruturada, ou fontes diversas (exemplo redes sociais).

Em seguida, na etapa de **transformação**, os dados são processados ou moldados para compor a informação na base do DW. Este processamento inclui atividades como normalização e geração de chave que identifica o registro na base.

Por fim, a etapa de **carga** consiste na inserção dos dados na base do Data Warehouse ou Data Mart.

As ferramentas de software ETL têm como função a **extração** de dados de diversos sistemas, a **transformação** desses dados de acordo com as regras de negócio e a **carga** dos dados em um Data Mart ou um DW.

Algumas das **ferramentas** conhecidas de ETL (*Extract – Transform – Load*) são:

- IBM InfoSphere DataStage;
- Informática Power Center;
- Business Objects Data Integrator;
- Data Transformation Services;
- Pentaho Data Integration;
- Oracle Data Integrator (ODI);
- SSIS (SQL Server Integration Services) etc.

Obs.: O ETL é um processo no qual os dados são **extraídos** de várias fontes, **transformados** em um formato adequado e **carregados** em um sistema de destino. **A transformação ocorre ANTES do carregamento** e geralmente é realizada em um servidor dedicado antes de enviar os dados para o destino final.

ELT (EXTRACT, LOAD, TRANSFORM – EXTRAÇÃO, CARGA E TRANSFORMAÇÃO) DE DADOS EM DW

Ao contrário do ETL, o **ELT** é um processo mais **ágil** para o carregamento e o processamento de dados, pois inverte a ordem das etapas de transformação de dados da **abordagem tradicional de ETL**. No processo de ELT, as fases seguem a seguinte ordem:

- **extração:** coleta e extração de dados brutos de uma ou diversas fontes para posterior integração em um repositório de dados único.
- **carregamento:** carregamento dos dados coletados em um *data warehouse* ou repositório de dados.
- **transformação:** transformação dos dados brutos em dados modelados dentro de um *data warehouse* para a aplicação de *business intelligence*, análise de dados e *advanced analytics*.

Obs.: Na abordagem de **ELT**, ao contrário da abordagem de ETL, a transformação de dados ocorre logo APÓS a coleta e o carregamento das informações em um repositório de dados centralizado, e **não** antes.

O ELT segue uma abordagem ligeiramente diferente, na qual **os dados extraídos são carregados no sistema de destino primeiro e, em seguida, a transformação é aplicada diretamente nesses dados armazenados**. Essa abordagem é viável quando há recursos de processamento suficientes no sistema de destino, como um *data warehouse*.

FERRAMENTAS DE PIPELINES DE DADOS

Existem várias ferramentas disponíveis para auxiliar na construção e gerenciamento de pipelines de dados. Algumas das mais populares incluem:

- **Apache Kafka:** uma plataforma de *streaming* distribuída usada para ingestão de dados em tempo real;
- **Apache Spark:** um motor de processamento distribuído que oferece recursos de processamento em lote e em tempo real;
- **Apache NiFi:** uma ferramenta para mover e transformar dados em tempo real, com uma interface gráfica de arrastar e soltar;
- **Apache Airflow:** uma plataforma de orquestração de *pipelines* de dados que permite programar, monitorar e gerenciar fluxos de trabalho complexos;
- **AWS Glue:** um serviço de ETL gerenciado pela Amazon Web Services que facilita a preparação e carregamento de dados para análise;
- **Microsoft Azure Data Factory:** uma ferramenta de orquestração de dados baseada em nuvem, que permite criar, agendar e gerenciar pipelines de dados.

Nessa seção elencamos apenas algumas das muitas ferramentas disponíveis, e a escolha da melhor ferramenta depende dos requisitos específicos do projeto e da infraestrutura tecnológica existente.

DIRETO DO CONCURSO



005. (FUNCAB/MDA-MINISTÉRIO DO DESENVOLVIMENTO AGRÁRIO/ANALISTA DE BUSINESS INTELLIGENCE/2014)




Figura. Modelo de organização para as próximas 3 questões.

A principal atividade de EXTRAÇÃO é:

- a) considerar logs de eventos e arquivos de controle.
- b) coletar dados das fontes externas transferindo-os para o ambiente de DW.
- c) carregar as dimensões considerando os tipos de hierarquias estáticas.
- d) tratar as inconsistências de dados resultantes da transcrição de dados.
- e) executar conversões de formatos para códigos geográficos dos países.



- a) Errada. Considerar logs de eventos e arquivos de controle faz parte da etapa de **Extração**, mas não podemos considerá-lo como a principal atividade desta etapa.
- b) Certa. A figura apresentada na questão destaca um modelo geral de como os dados são processados e armazenados em um *Data Warehouse* e em um *Data Mart*. Lembre-se de que este processo é conhecido como **ETL** (do inglês **E**xtract **T**ransform and **L**oad), cujas etapas são as seguintes:

- O processo inicial é a **extração** de dados das bases de dados transacionais, dados de sistemas ERP, dados locais, de fontes externas ou web.
- Após a extração, os dados devem ser **transformados** para que seja possível a **carga dos dados** em um *Data Warehouse* ou *Data Mart*, dependendo do método de construção adotado.

Baseado nas etapas de **Extração, Transformação e Carga**, aqui apresentadas, tem-se que a alternativa B é a resposta, pois é a que melhor descreve a principal atividade realizada durante a etapa da **Extração**.

- c) Errada. Retrata uma atividade realizada na etapa de **Carga**.
- d) Errada. Está relacionado a atividades da etapa de **Transformação**.
- e) Errada. Está relacionado a atividades da etapa de **Transformação**.

Letra b.

006. (FUNCAB/MDA-MINISTÉRIO DO DESENVOLVIMENTO AGRÁRIO/ANALISTA DE BUSINESS INTELLIGENCE/2014) A principal atividade de TRANSFORMAÇÃO é:

- a) aplicar regras aos dados extraídos para ajustá-los antes de serem carregados.
- b) analisar impactos das alternativas do código de aplicação no sistema fonte.
- c) avaliar aspectos de performance por meio do uso de paralelismo.
- d) obter dados de natureza estruturada e não estruturada.
- e) carregar tabelas Fato e fazer mapeamento das chaves.



O processo **ETL** (do inglês **E**xtract **T**ransform and **L**oad) consiste na **extração** (leitura de dados de uma ou mais bases de dados), **transformação** (conversão dos dados extraídos de sua forma anterior para a forma em que precisa estar para que possa ser colocado em um *Data Warehouse* ou simplesmente em outro banco de dados), e **carga** (colocar os dados no *Data Warehouse*).

Vamos aos comentários das assertivas:

- a) Certa. No processo **ETL**, a etapa de **Transformação** manipulará os dados para que eles fiquem prontos para serem carregados na fonte de dados de destino. Para isso, faz uso de regras predefinidas de formatação, validação ou alteração de dados para ajustar os dados antes de serem carregados.
- b) Errada. A análise de impacto e alternativas de código de aplicação, como apresentado nessa assertiva, não está definida em nenhuma das etapas do processo ETL.
- c) Errada. Também, a avaliação de aspectos de performance com paralelismo, indicada nessa assertiva, não faz parte das etapas do ETL.
- d) Errada. A obtenção de dados de natureza estruturada e não estruturada é realizada na etapa de **Extração**.
- e) Errada. A atividade de carregar tabelas Fato e fazer mapeamento das chaves é conduzida durante a etapa de **Carga**.

Letra a.

007. (FUNCAB/MDA-MINISTÉRIO DO DESENVOLVIMENTO AGRÁRIO/ANALISTA DE BUSINESS INTELLIGENCE/2014) A principal atividade de CARGA é:

- a) realizar a limpeza dos dados extraídos para melhorar a qualidade dos dados.
- b) definir a periodicidade da transcrição dos dados a serem coletados.
- c) otimizar a qualidade dos dados por meio da conversão de formatos.
- d) separar e concatenar dados visando eliminar inconsistências nos dados.
- e) estruturar e carregar os dados para o DW seguindo o modelo dimensional.



O processo **ETL** (do inglês **Extract Transform and Load**): processo de extração, tratamento e limpeza dos dados para inserção no DW.

- a) Errada. As atividades aqui elencadas são realizadas na etapa de **Transformação**.
- b) Errada. A definição da periodicidade de dados geralmente é associada com a etapa de **Extração**.
- c) Errada. As atividades aqui elencadas são realizadas na etapa de **Transformação**.
- d) Errada. As atividades aqui elencadas são realizadas na etapa de **Transformação**.
- e) Certa. A etapa de **Carga** é a última do processo e sua responsabilidade é garantir que os dados já transformados serão armazenados corretamente no modelo indicado na fonte de dados de destino. Diferentes tipos de modelos podem ser utilizados para armazenar os dados durante a etapa de Carga, porém o modelo multidimensional é o mais comum em sistemas de (*Business Intelligence*).

Letra e.

OPERATIONAL DATA STORAGE (ODS) OU STAGING AREA (SA)

Staging Area representa a área de armazenamento intermediário criada a partir do processo de ETL. Auxilia na transição dos dados das fontes OLTP para o destino final no *Data Warehouse*.




Figura. Arquitetura Geral de um Sistema de BI, com Destaque para Staging Area.

No âmbito dos DWs, **Staging Area** representa um **armazenamento intermediário dos dados**, que facilita a integração dos dados do ambiente operacional antes de sua atualização no DW. Atualmente, alguns autores passaram a denominá-lo **Dynamic Data Storage (DDS)**.

Esse banco de dados intermediário é considerado uma **área de transição** em que se pode inserir os dados oriundos da extração e realizar as transformações necessárias, tudo isso antes de carregá-los no DW, que será o destino dos dados.

O uso dessa área de transição é útil para **não sobrecarregar** o ambiente de produção (os sistemas operacionais da empresa) e nem o próprio DW com as operações de transformação.





Figura. Staging Area.

DIRETO DO CONCURSO

008. (FCC/AL-MS/TÉCNICO DE INFORMÁTICA/2016) Considere a figura abaixo.



No processo de ETL mostrado na figura, I e II correspondem, respectivamente, a

- a) OLTP e Data Warehouse.
- b) OLTP e Staging Area.
- c) Data Mart e Staging Area.
- d) Staging Area e OLTP.
- e) Staging Area e Data Warehouse.



O **processo ETL** (do inglês **Extract Transform and Load**) consiste na **extração** (leitura de dados de uma ou mais bases de dados), **transformação** (conversão dos dados extraídos de sua forma anterior para a forma em que precisa estar para que possa ser colocado em um DW ou simplesmente outro banco de dados), e **carga** (colocar os dados no DW).

Os dados são carregados para uma área de preparação (conhecida como *Staging Area* (ou *Operational Data Storage – ODS*) antes de serem transformados e carregados para o DW. Assim, no processo de ETL mostrado na figura, I e II correspondem, respectivamente, a *Staging Area* (ou *Operational Data Storage – ODS*) e *Data Warehouse*.




Figura. Ambiente de Data Warehouse

Letra e.

COLETA, TRATAMENTO, ARMAZENAMENTO, INTEGRAÇÃO, RECUPERAÇÃO E DESCARTE DE DADOS

Conforme vimos, o processo de **ETL** (do inglês **Extract Transform and Load**) envolve **coleta** (ou **extração**), **transformação** (nessa etapa, os dados são **tratados** para que se tornem mais corretos ou relevantes para os propósitos do BI) e **armazenamento** dos dados.

A **integração** é um processo de **combinação de dados de diversas fontes em uma base de dados unificada**. Esse processo já se inicia durante a coleta, com o planejamento das diferentes fontes de dados que vão compor o conjunto final, passando pelas etapas subsequentes até que se chegue na base de dados final.

Os dados já coletados, tratados, armazenados e integrados devem ser tornar acessíveis de modo a torná-los úteis à tomada de decisão. Nesse ponto, a literatura destaca dois sentidos para a etapa de **recuperação ou extração de dados**.

- Ao tratar o **ciclo de vida dos dados**, a recuperação refere-se ao **acesso aos dados, por meio da consulta e visualização**, para subsidiar o processo de tomada de decisão.
- Outra abordagem encontra na literatura envolve o **uso de um conjunto de técnicas e procedimentos para a extração de informações em dispositivos de armazenamento digital** (HD, Storages, dentre outros), **que não podem ser acessados de modo convencional pelo usuário ou pelo sistema** (Por exemplo, quando um dispositivo de armazenamento apresenta falhas. Diante desse fato, para recuperar os arquivos do dispositivo é preciso utilizar métodos não convencionais. Esses métodos não convencionais são conhecidos pelo termo **recuperação de dados** (ou **data recovery**, em inglês).

A fase de **descarte** trata da reflexão sobre descarte de dados **que não são mais necessários ou que estejam acima da capacidade de tratá-los com eficiência para o sistema como um todo**.

Esquematizando:

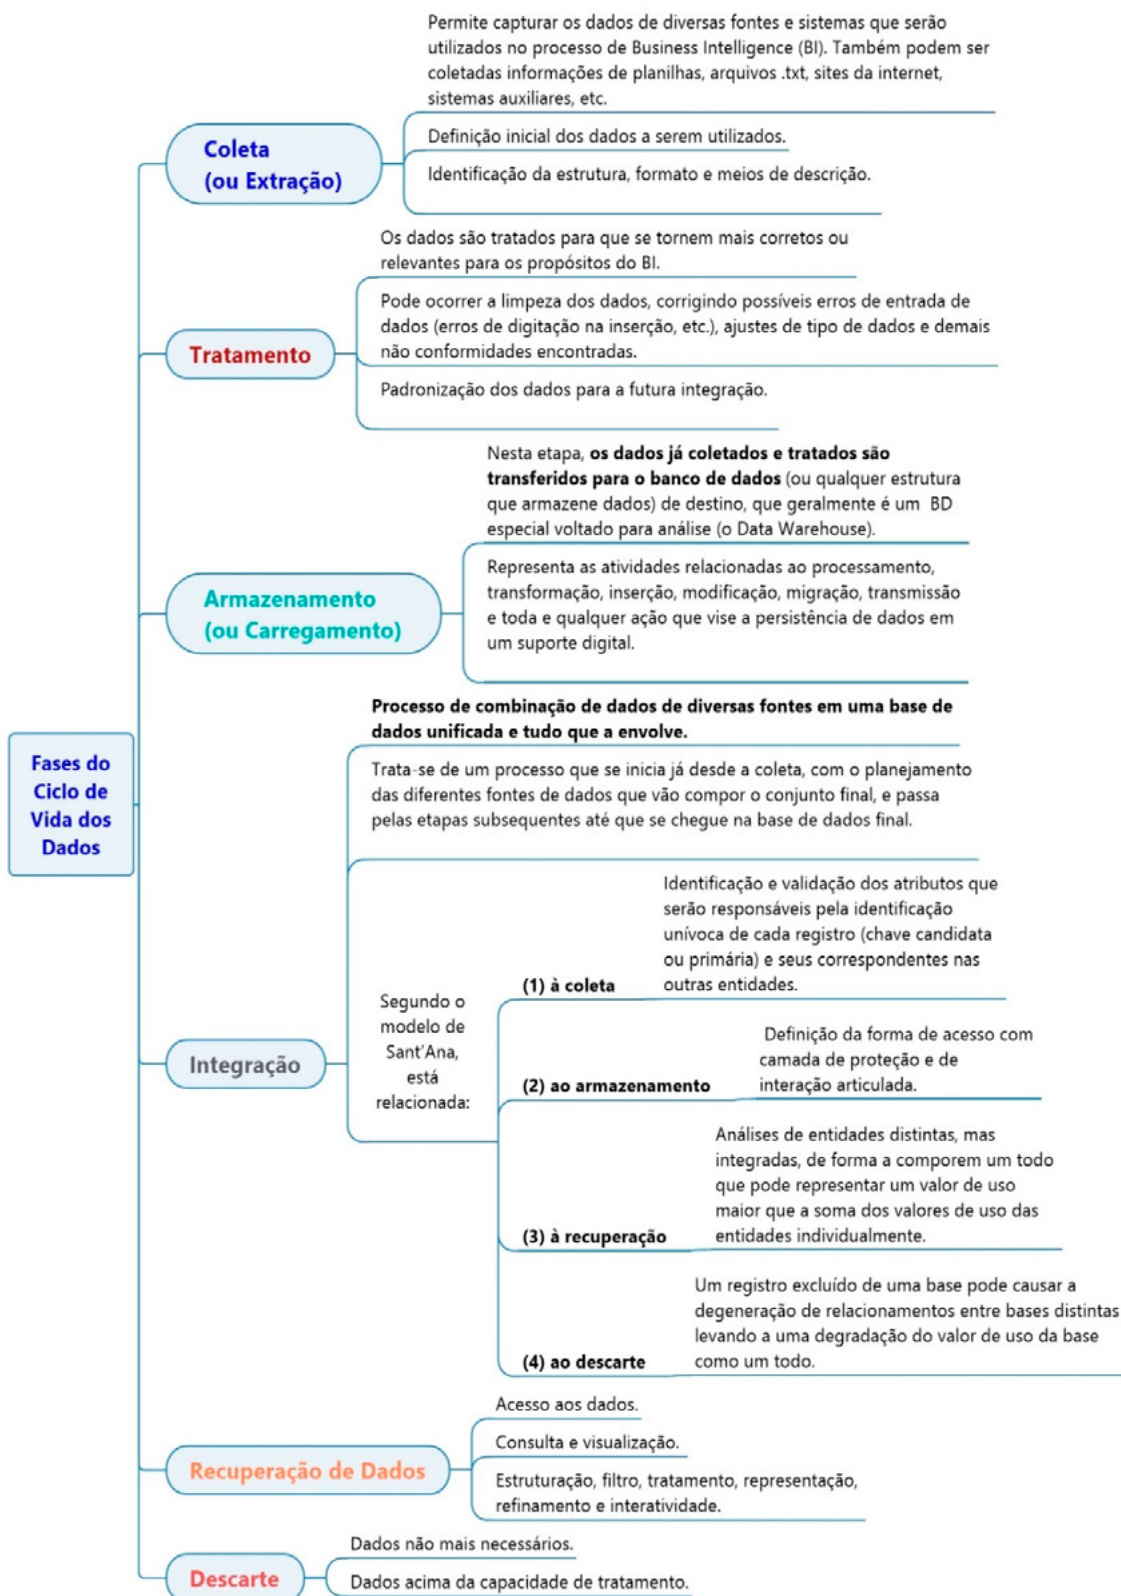


Figura. Fases do Ciclo de Vida dos Dados. Fonte: Elaborada pela autora.

DIRETO DO CONCURSO



- 009.** (IADES/METRÔ-DF/TÉCNICO EM ELETRÔNICA/2014) É o conjunto de técnicas e procedimentos para a extração de informações em dispositivos de armazenamento digital, que não podem ser acessados de modo convencional pelo usuário ou pelo sistema. Com base no exposto, é correto afirmar que essas informações apresentam o conceito de
- a) recuperação de dados.
 - b) backup corrompido.
 - c) mineração de dados.
 - d) backup interrompido.
 - e) recuperação de dispositivos.



A **mineração de dados (Data Mining)** corresponde a processos usados para **explorar e analisar grandes volumes de dados, visando identificar padrões, previsões, erros e associações etc.** Esse conceito, geralmente, está associado ao **aprendizado de máquina**, que é uma área da inteligência artificial que desenvolve algoritmos capazes de fazer com que o computador **aprenda** a partir do passado, usando dados de eventos que já aconteceram. Este aprendizado é capaz de identificar padrões que dificilmente seriam identificados através de técnicas triviais de análise de dados, como filtros, junções, pivôs ou agrupamentos.

O conceito de **recuperação de dados** (Ou **Data Recovery**, em inglês) envolve o **uso de um conjunto de técnicas e procedimentos para a extração de informações em dispositivos de armazenamento digital** (HD, Storages, dentre outros), **que não podem ser acessados de modo convencional pelo usuário ou pelo sistema** (Por exemplo, quando um dispositivo de armazenamento apresenta falhas. Diante desse fato, para recuperar os arquivos do dispositivo é preciso utilizar métodos não convencionais. Esses métodos não convencionais são conhecidos pelo termo recuperação de dados).

Letra a.

PROJETO DO DATA WAREHOUSE

VISÃO GERAL

A **modelagem multidimensional** (alguns autores a chamam de **modelagem dimensional**) **é a técnica de projeto mais frequentemente utilizada para a construção de um Data Warehouse.**

O objetivo é buscar um **padrão de apresentação de dados** que seja facilmente visualizado pelo usuário final e que possua um bom desempenho para consultas.

Quando falamos em modelagem multidimensional, estamos nos referindo à definição de um **modelo que se destina à análise de dados.**

No que diz respeito à **análise de dados**, o que se espera do modelo de dados encontra-se listado a seguir:

- seja uma **representação simples** do modelo de negócios estudado;
- seja um **modelo físico de fácil interpretação**, de modo que usuários sem treinamento formal em Tecnologia da Informação (TI) possam entendê-lo;
- **facilite a implementação física do modelo** de modo a maximizar performance das consultas aos dados.

Portanto, **no modelo multidimensional**, deixamos de focar na **coleta de dados** para nos ocuparmos com a **consulta aos dados**. **E esta é uma mudança radical de foco!**

DIRETO DO CONCURSO

010. (COPEVE UFAL/MPE-AL/ANALISTA DO MINISTÉRIO PÚBLICO/2012) Um modelo de banco de dados multidimensional está mais fortemente relacionado com:

- data warehouse.
- modelo relacional.
- bancos hierárquicos.
- modelo em 3 camadas.
- banco de dados distribuídos.



O modelo de dados denominado “multidimensional” está mais fortemente relacionado com o **Data Warehouse**, uma coleção de dados orientados por **assuntos, integrados, variáveis com o tempo e não voláteis**, para dar suporte ao processo de tomada de decisão com dados.

Letra a.

011. (FUNCAB/MDA/ADMINISTRADOR DE BANCO DE DADOS/2014) O modelo de dados denominado “multidimensional” se aplica para banco de dados com a tecnologia:

- relacional.
- hierárquica.
- datamining.
- distribuída
- data warehouse.



O modelo de banco de dados multidimensional se aplica para banco de dados com a tecnologia: **Data Warehouse (DW)**.

A modelagem dimensional oferece diversas maneiras de realizar consultas de dados em um DW.

Letra e.

012. (CESPE/SEDF/ANALISTA DE GESTÃO EDUCACIONAL/TECNOLOGIA DA INFORMAÇÃO/2017)
Com relação aos conceitos de modelagem multidimensional de dados para inteligência computacional, julgue o seguinte item.

Diferentemente da estrutura relacional, a estrutura multidimensional oferece baixa redundância de dados e suporte a normalização até a segunda forma normal.



A estrutura multidimensional oferece alta redundância.

Modelagem Multidimensional

• **Desnormalizado -> Alta redundância.**

Modelagem Relacional

• **Normalizado -> Baixa redundância.**

Errado.

A finalidade de bases de dados multidimensionais, conforme destaca Nardi (2007), é fornecer subsídio para realização de análises. Para tanto, sua arquitetura e até mesmo a terminologia empregada são distintas das utilizadas para bancos de dados transacionais.

Assim, o fato de existirem diversas informações a serem cruzadas (**dimensões**) permite a realização de pesquisas tais como a ilustrada na figura seguinte:




Figura. Exemplo de Pesquisa Multidimensional. Fonte: Nardi (2007).

Alguns **conceitos importantes** dentro da modelagem multidimensional estão listados a seguir:

TABELA DE FATOS

A **tabela de fatos** é a tabela primária do modelo dimensional e contém os valores do negócio que deseja analisar. **Cada tabela de fatos contém** as **chaves externas** que se relacionam com suas respectivas **tabelas de dimensões** e as colunas com os valores que serão analisados.



Exemplos de Fatos

- ✓ Em um hospital: admissão de pacientes
- ✓ Em uma operadora telefônica: Tráfego telefônico



Um **fato** é um conceito de interesse primário para o processo de tomada de decisões e corresponde aos eventos que ocorrem de forma dinâmica no negócio da empresa.

Fonte: Microsoft (2011).





Figura. Componentes de Modelagem Dimensional. Fonte: <https://slideplayer.com.br/slide/14585808/>.

As **tabelas fatos** indicam o **nível de granularidade das tabelas dimensões**. Elas orientam a criação das **tabelas dimensão**. Contudo, observe que os dados devem ser inseridos primeiramente nas **dimensões** para, em seguida, serem inseridos na **tabela fato**. Isso garantirá a integridade referencial dos dados na **tabela fato**.

Cada atributo que compõe a chave primária da tabela fato também é uma chave estrangeira para uma das tabelas dimensão.

A **tabela fato** contém uma chave primária composta. Essa é formada pela composição de atributos que são chaves estrangeiras, cada um apontando para sua respectiva **tabela dimensão**.

Veja essa figura:



Fonte: http://2.bp.blogspot.com/-6sMFtOxK3Cw/Ty6UHI5Zi9I/AAAAAAAAAJU/71TfY-TiDio/s1600/Modelo_estrela.png.

“Em uma **tabela de fatos**, uma linha corresponde a uma **medição**. **Todas as medições em uma tabela de fatos devem estar alinhadas na mesma granularidade**” (KIMBALL; ROSS, 2002, p. 21).

DIRETO DO CONCURSO

013. (FAURGS/HCPA/ANALISTA DE TI/BANCO DE DADOS/2016) Em um modelo dimensional, a tabela fatos armazena:

- a) estatísticas sobre os metadados.
- b) as restrições de domínio do negócio.
- c) descrições textuais das dimensões.
- d) medições numéricas do negócio.
- e) o tempo de processamento das transações.



Em um modelo dimensional, a **tabela fatos** armazena medições numéricas de negócio.

Letra d.

Esquematizando:

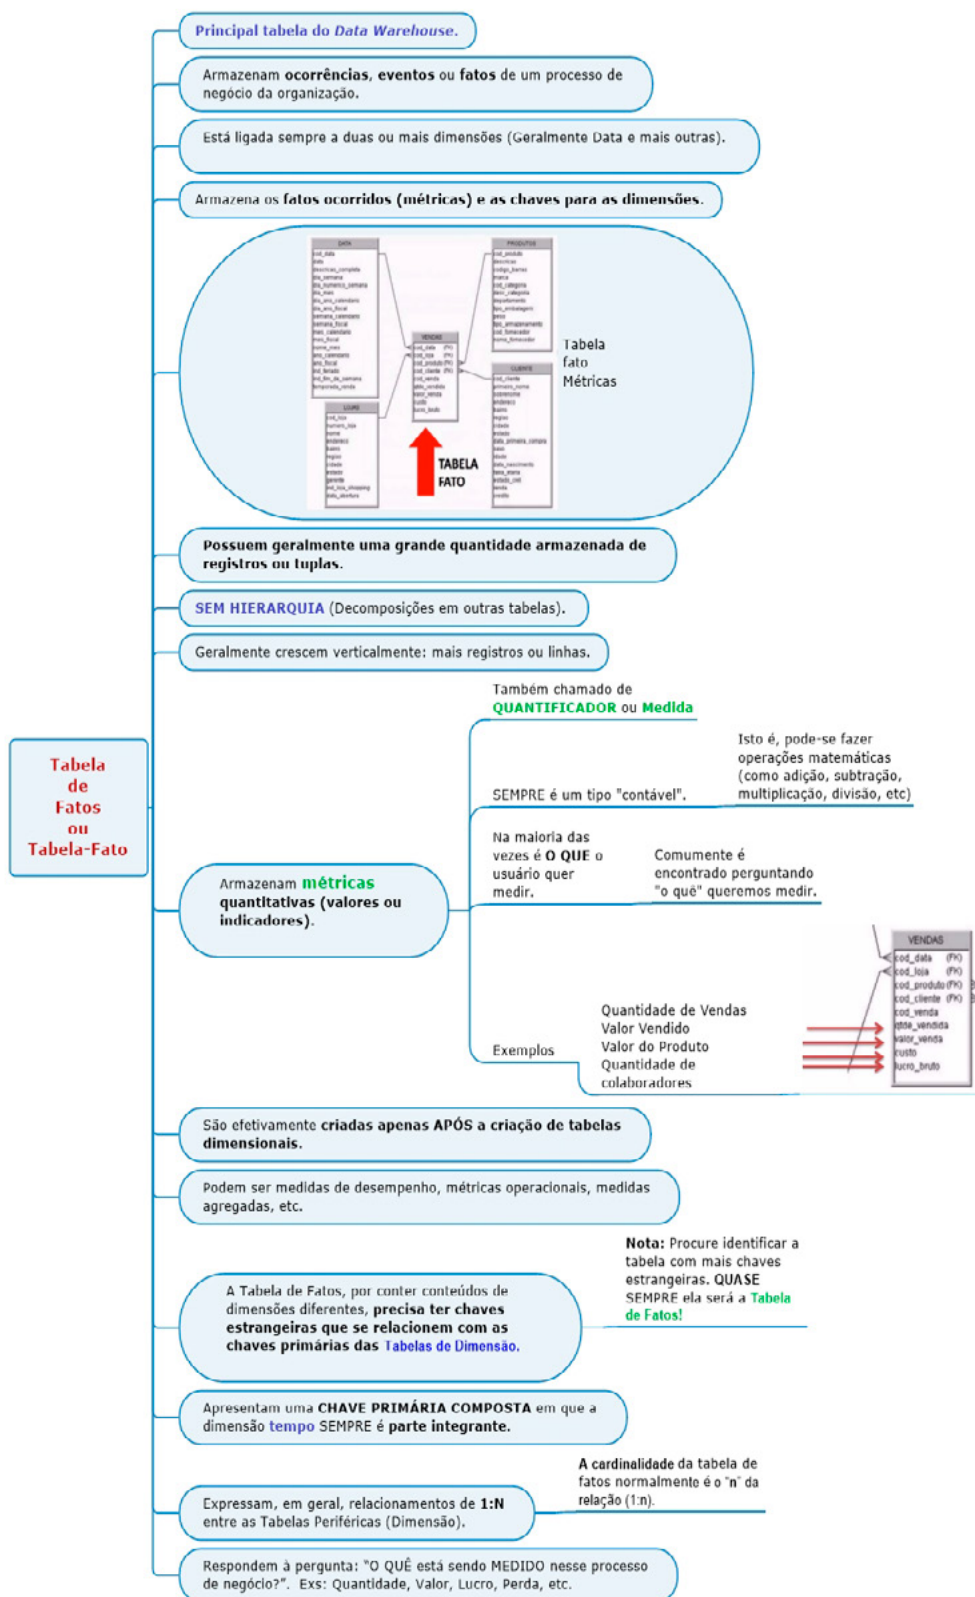


Figura. Tabela de Fatos. Fonte: Elaborada pela autora.

Um aspecto importante é que a tabela de fatos deve representar uma unidade do processo do negócio, **não** devendo misturar assuntos diferentes numa mesma tabela de fatos.

Os atributos mais comuns em uma tabela de fatos são valores numéricos. Estes valores são, em sua maioria, aditivos.

- As **métricas aditivas** são as que permitem operações como adição, subtração e média de valores por todas as dimensões, em quaisquer combinações de registros, como “total de itens vendidos” por combinação de data, produto e loja. Métricas aditivas são importantes porque normalmente as aplicações de Data Warehouse não retornam uma linha da tabela de fatos, mas sim centenas, milhares e até milhões (HOKAMA et al., 2004, p. 36).
- As **métricas não aditivas** são valores que **não** podem ser manipulados livremente, como valores percentuais ou relativos. Exemplos de métricas não aditivas são preço de custo e preço de venda de um produto em uma venda.
- Já as **métricas semiaditivas** são valores que **não** podem ser somados em todas as dimensões. Por exemplo: numa tabela com o registro diário do saldo bancário dos clientes de uma agência, não faz sentido somar os saldos bancários diários de um cliente durante um mês, mas pode-se somar os saldos de todos os clientes de uma agência em determinada data.

CLASSIFICAÇÃO DE FATOS

Os **fatos** podem ser classificados em **transações individuais**, em **snapshots** e em **linhas de itens** (KIMBALL et al., 1998).

- As **transações individuais** representam uma transação completa, normalmente, apresentam uma estrutura muito simples, possuem um campo acumulado que contém o valor total de uma transação.
- Os **fatos snapshots** representam medidas de atividades extraídas em tempo determinado, como, por exemplo, final do dia ou final do mês, com medições acumuladas durante esse período.
- Os **fatos do tipo linhas de itens** são aqueles que **representam exatamente uma linha de item**, são armazenados no nível mais detalhado dos fatos, como, por exemplo, itens de pedido, itens de entrega e itens de apólice de seguro.

Vamos agora falar dos tipos de tabelas fatos. Existem na literatura **seis tipos de fatos**:

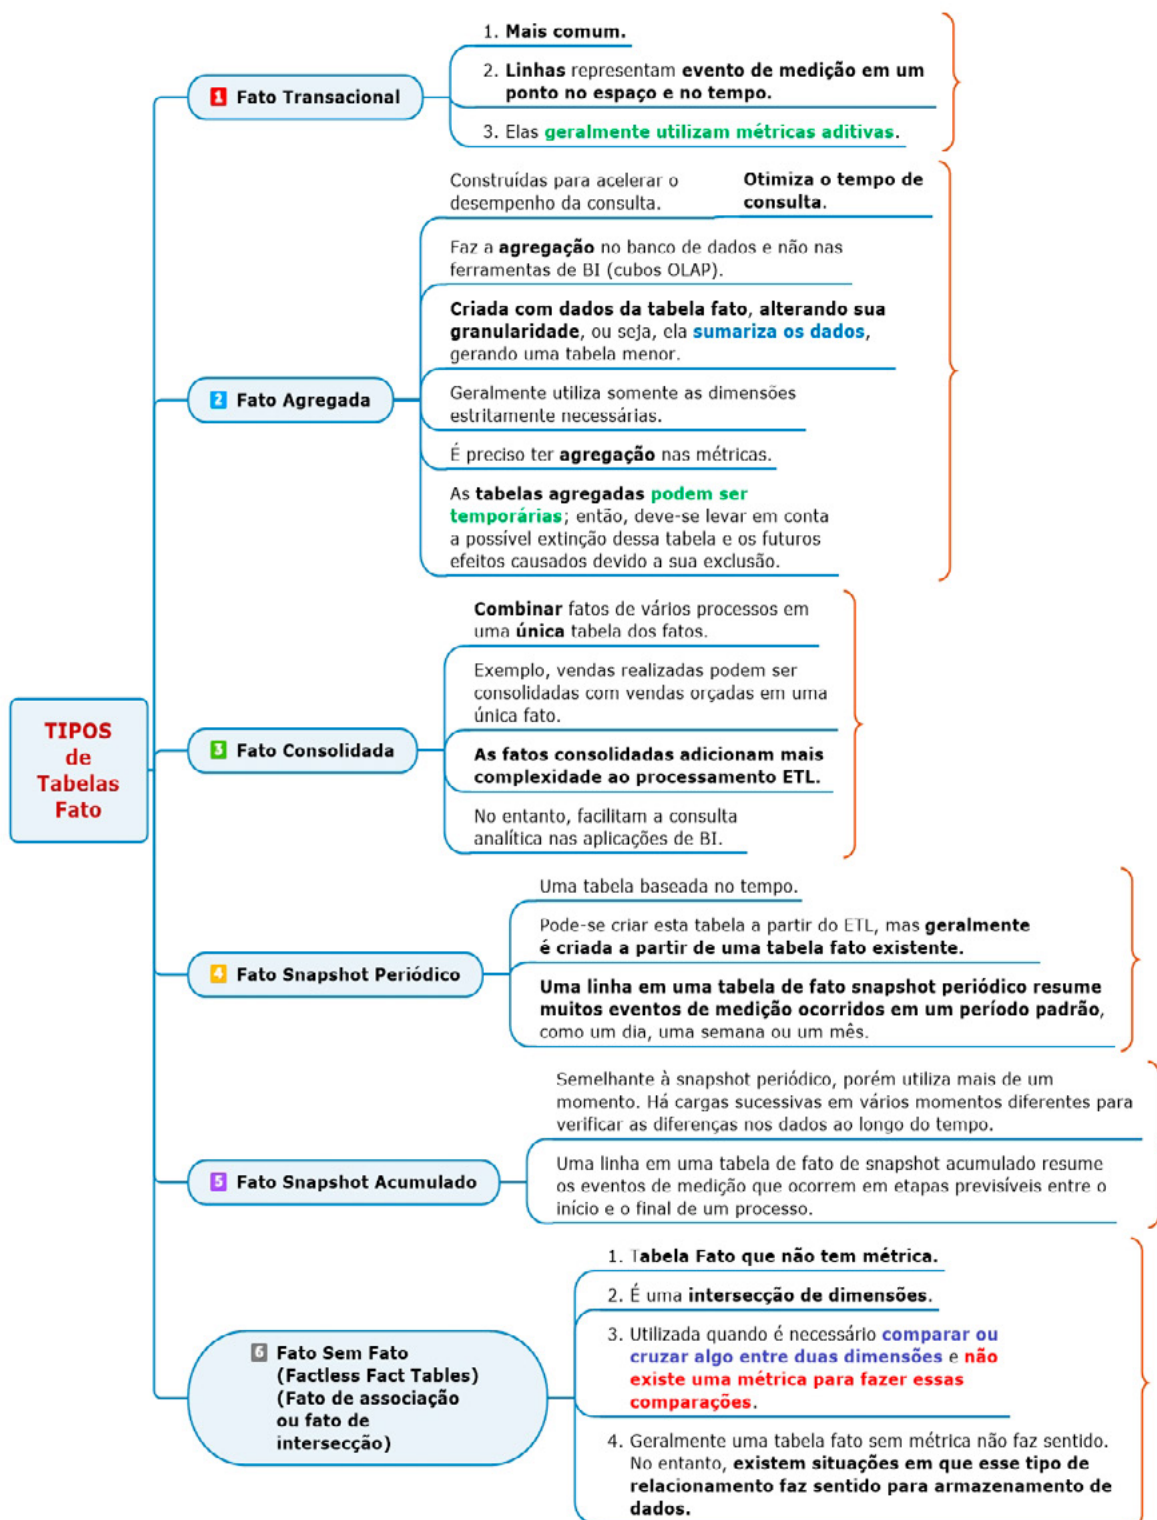


Figura. Tipos de Tabelas Fato. Fonte: Elaborada pela autora.

CUBO DE DADOS

O **modelo dimensional** é formado por uma **tabela central (tabela de fatos)** e várias outras a ela interligadas (**tabelas de dimensões**), sempre por meio de **chaves especiais, que associam o fato a uma dimensão do cubo**.




Figura. Cubo. Fonte: Microsoft (2011)

Cubo é uma estrutura multidimensional de dados que expressa a forma na qual os tipos de informações se relacionam entre si.

O cubo de uma forma genérica armazena todas as informações relacionadas a um determinado assunto, de maneira a permitir que sejam montadas várias combinações entre elas, resultando na extração de várias visões sobre o mesmo tema (Hokama et al., 2004).

Esquematizando:

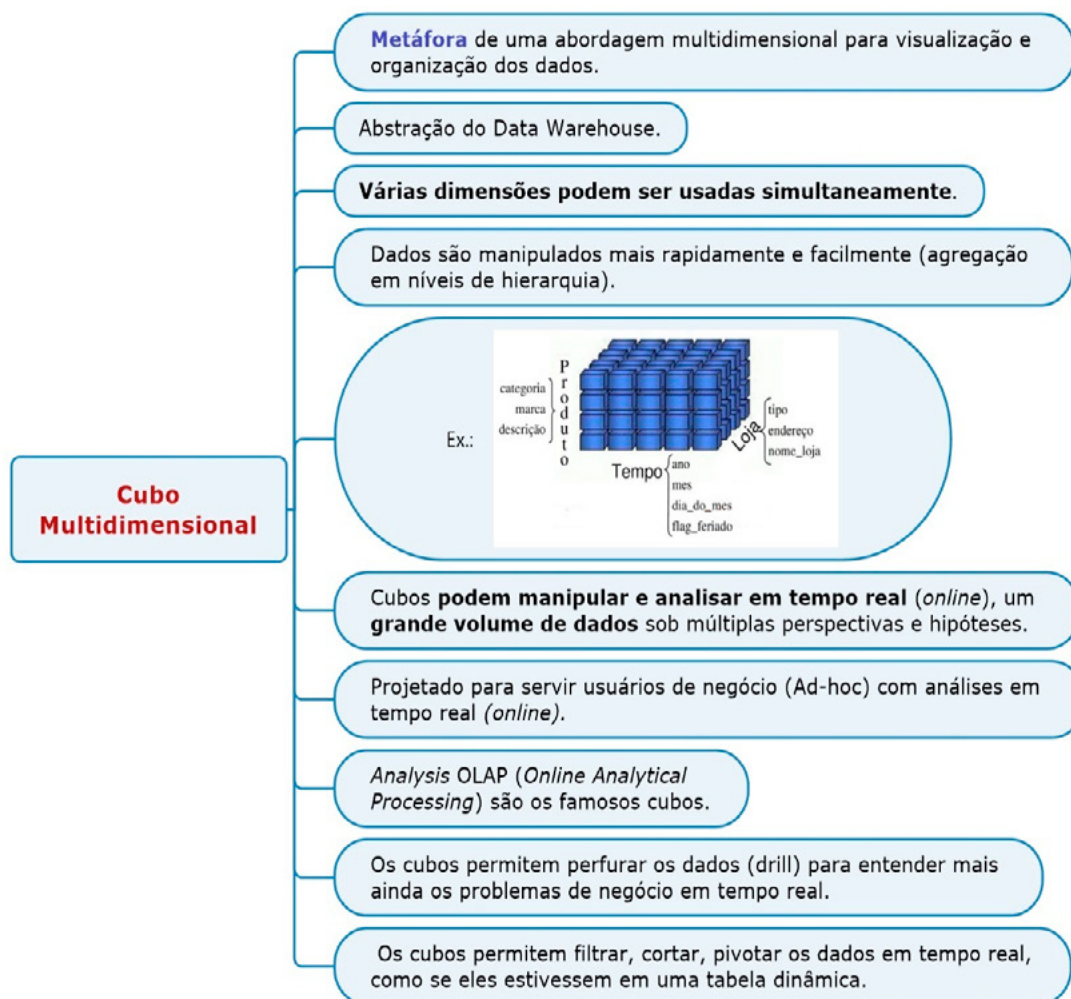


Figura. Cubo Multidimensional. Fonte: Elaborada pela autora.

DIRETO DO CONCURSO

014. (COSEAC/DATAPREV/ANALISTA DE TECNOLOGIA DA INFORMAÇÃO/2009/ADAPTADA)

Sobre modelagem multidimensional, o cubo:

I – é uma representação intuitiva, pois todas as dimensões coexistem para todo ponto no cubo e são independentes umas das outras;

II – é, de fato, apenas uma metáfora visual;


III – serve para descrever requisitos funcionais.

Acerca dos itens acima mencionados, apenas;

- a) I e III estão corretos;
- b) Somente I está correto;
- c) I e II estão corretos;
- d) II e III estão corretos;
- e) III está correto.



I – Certa. Os **cubos** são massas de dados que retornam das consultas feitas ao banco de dados e podem ser manipulados e visualizados por inúmeros ângulos e diferentes níveis de agregação. É uma **representação intuitiva do fato** porque **todas as dimensões coexistem para todo ponto no cubo e são independentes uma das outras**.



- O cubo é, de fato, apenas uma metáfora visual.
- É uma representação intuitiva do fato porque todas as dimensões coexistem para todo ponto no cubo e são independentes umas das outras.

Figura. Visão Multidimensional. Volume de Vendas. Fonte: <https://pt.slideshare.net/wbillacox/dicas-de-modelagem-dimENSIONAL>

II – Certa. O **cubo** é, de fato, apenas uma representação conceitual ou uma metáfora visual.

III – Errada. A análise multidimensional é uma das grandes utilidades da tecnologia OLAP (**Online Analytical Processing**), consistindo em ver determinados **cubos de informações** de diferentes ângulos (perspectivas) para análise e de vários níveis de agregação.

Portanto, I e II estão corretos.

Letra c.

015. (CESGRANRIO/PETROBRAS/ANALISTA DE SISTEMAS JÚNIOR) Em um banco de dados multidimensional, os dados estão conceitualmente armazenados e organizados em:

- a) classes e objetos.
- b) cubos e hipercubos.
- c) partições e índices.
- d) consultas materializadas e sumários.
- e) estrelas e constelações.



Um **cubo de dados** é a **representação multidimensional de dados agregados**. A figura seguinte ilustra um **cubo** que organiza dados de venda de produto por data e regiões de venda. Cada célula representa a venda de um produto específico, em um período específico (ano, trimestre, mês,...) em um local específico.




Figura. Cubo de dados de vendas

Adicionando outras dimensões, teremos um hipercubo. Os dados podem ser consultados diretamente em qualquer combinação de dimensões, permitindo que consultas complexas no banco de dados original sejam realizadas de forma mais direta e com maior desempenho. Existem ferramentas que permitem a visualização dos dados de acordo com a escolha de dimensões do usuário.

Assim, em um banco de dados multidimensional, os dados estão conceitualmente armazenados e organizados em **cubos** e **hipercubos**.

Letra b.

016. (CESPE/MPE-PI/ANALISTA MINISTERIAL/2012) Um cubo de dados é a representação multidimensional dos dados não agregados na qual é necessário que as dimensões tenham o mesmo tamanho.



Um **cubo de dados** é a **representação multidimensional de dados agregados**, mas **não** é necessário que as dimensões tenham o mesmo tamanho!

Errado.

TABELA DE DIMENSÃO

As **tabelas de dimensões** são as companheiras das tabelas de fatos. Cada dimensão é definida pela sua **chave primária**, que serve para manter a integridade referencial na tabela de fatos à qual está relacionada.

Um **cubo** requer a definição de **pelo menos uma dimensão** no seu esquema.

Esquematizando:




Figura. Tabela de Dimensão. Fonte: Elaborada pela autora.

MEDIDAS E DIMENSÕES

Cabe destacar que o modelo dimensional divide o mundo dos *dados* em dois grandes tipos: as **medidas** e as **dimensões** destas medidas.

- As **medidas** são sempre numéricas e são armazenadas nas **tabelas de fatos** e as **dimensões** contextuais são armazenadas nas **tabelas de dimensões**;
- As **dimensões** organizam os dados em função de uma área de interesse para os usuários. Cada dimensão descreve um aspecto do negócio e proporciona o acesso intuitivo e simples aos dados. Uma dimensão oferece ao usuário um grande número de combinações e intersecções para analisar dados.

DIRETO DO CONCURSO



017. (IDECAN/INMETRO/ANÁLISE E DESENVOLVIMENTO DE SISTEMAS/2015) A modelagem multidimensional é uma técnica de concepção e visualização de um modelo de dados de um conjunto de medidas que descrevem aspectos comuns de negócios. Um modelo multidimensional é formado por três elementos básicos. Assinale-os:

- Esquema, fatos e itens.
- Fatos, dimensões e itens.
- Medidas, esquema e fatos.
- Fatos, dimensões e medidas
- Dimensões, medidas e esquema.




Conforme visto, os **três elementos básicos** são:

Fatos	São os <u>dados a serem agrupados</u> , contendo os valores de cada medida para cada combinação das dimensões existentes. O tamanho da tabela que contém os fatos merece atenção especial do analista.
Dimensões	Estabelecem a organização dos dados, determinando possíveis consultas/cruzamentos. Por exemplo: região, tempo, canal de venda,... Cada dimensão pode ainda ter seus elementos, chamados membros , organizados em diferentes níveis hierárquicos. A dimensão tempo, por exemplo, pode possuir duas hierarquias: calendário gregoriano (com os níveis ano, mês e dia) e calendário fiscal (com os níveis ano, semana e dia).
Medidas	São os valores a serem analisados, como médias, totais e quantidades.

Letra d.

018. (FCC/TRT/4ª REGIÃO-RS/ANALISTA JUDICIÁRIO/TECNOLOGIA DA INFORMAÇÃO/2015)
Considere a arquitetura geral de um sistema de BI – Business Intelligence mostrada na figura abaixo.



Nesta arquitetura

- a) Data Marts representam áreas de armazenamento intermediário criadas a partir do processo de ETL. Auxiliam na transição dos dados das fontes OLTP para o destino final no Data Warehouse.
- b) OLAP é um subconjunto de informações extraído do Data Warehouse que pode ser identificado por assuntos ou departamentos específicos. Utiliza uma modelagem multidimensional conhecida como modelo estrela.
- c) os dados armazenados no Data Warehouse são integrados na base única mantendo as convenções de nomes, valores de variáveis e outros atributos físicos de dados como foram obtidos das bases de dados originais.
- d) o Data Warehouse não é volátil, permite apenas a carga inicial dos dados e consultas a estes dados. Além disso, os dados nele armazenados são precisos em relação ao tempo, não podendo ser atualizados.
- e) Data Mining se refere ao processo que, na construção do Data Warehouse, é utilizado para composição de análises e relatórios, armazenando dados descritivos e qualificando a respectiva métrica associada.



- a) Errada. **Staging Area** representa a área de armazenamento intermediário criada a partir do processo de ETL. Auxilia na transição dos dados das fontes OLTP para o destino final no *Data Warehouse*. **Data Mart** é um subconjunto de informações do DW que podem ser identificados por assuntos ou departamentos específicos.
- b) Errada. **Data Mart** é um subconjunto de informações extraído do *Data Warehouse* que pode ser identificado por assuntos ou departamentos específicos. Utiliza uma modelagem multidimensional conhecida como modelo estrela. **OLAP (On-line Analytical Processing)** são ferramentas com capacidade de análise em múltiplas perspectivas das informações armazenadas.

- c) Errada. Os dados armazenados no *Data Warehouse* são integrados na base única mantendo as convenções de nomes, valores de variáveis e outros atributos físicos de dados. O **processo ETL** (do inglês **Extract Transform and Load**) faz a extração, tratamento e limpeza dos dados para inserção no DW.
- d) Certa. O **Data Warehouse** não é volátil, permite apenas a carga inicial dos dados e consultas a estes dados. Além disso, os dados nele armazenados são precisos em relação ao tempo, não podendo ser atualizados.

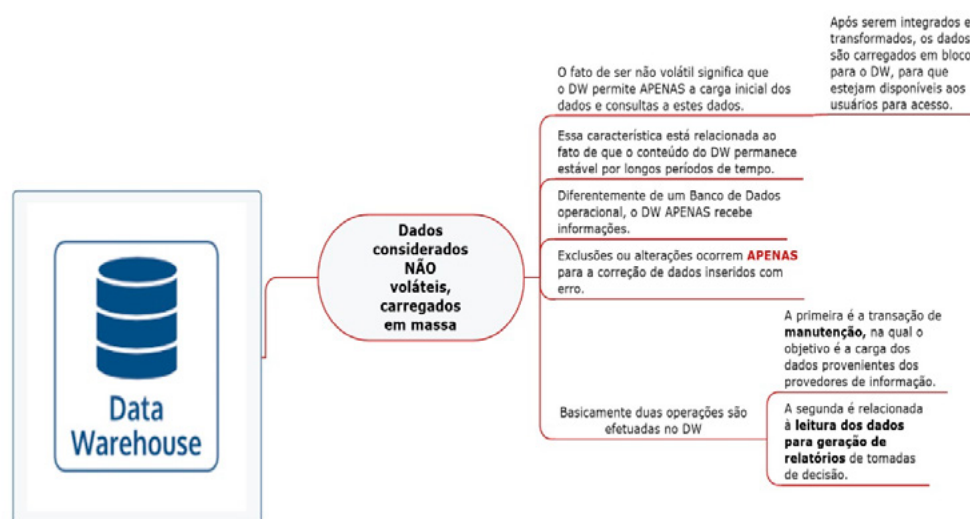


Figura. Dados não voláteis.

- e) Errada. **Dimensão** se refere à **tabela** que, na construção do *Data Warehouse*, é **utilizada** para composição de análises e relatórios, **armazenando dados descritivos e qualificando a respectiva métrica associada**.

Letra d.

ESQUEMAS MULTIDIMENSIONAIS

Dois esquemas multidimensionais comuns são o de **Estrela (Star Schema)** e o **Snow Flake (Floco de Neve)**.

ESQUEMA ESTRELA (STAR SCHEMA)

Esta estrutura está formada por uma **tabela central – tabela de fatos –** e um conjunto de tabelas organizadas ao redor dela, as **tabelas de dimensões**.



Figura. Esquema Estrela (Star Schema).

Segundo Elmasri e Navathe (2005, p. 651), uma **tabela de dimensão** consiste em *tuplas* de atributos da dimensão. Uma **tabela de fato** pode ser pensada como possuindo *tuplas*, uma por fato registrado.




Figura. Exemplo de Esquema Estrela (Star Schema). Fonte: Microsoft (2011).




Figura. Exemplo de Esquema Estrela (Star Schema).

Nas pontas da estrela estão as **tabelas de dimensões** que contêm os **atributos** das aberturas que interessam ao negócio e que podem ser utilizadas como critérios de filtro e são relativamente pequenas.

Cada **tabela de dimensão** está relacionada com a **tabela de fatos** por um identificador.




Figura. Representação da estrutura do Esquema Estrela. Fonte: <http://meusite.mackenzie.com.br/rogerio/tgi/2004ModelagemDW.pdf>.

As **características** de um **esquema de estrela** são:

- O centro da estrela é a **tabela de fatos**;
- As pontas da estrela são as **tabelas de dimensões**;
- Cada esquema está formado por apenas **UMA tabela de fatos**.

DIRETO DO CONCURSO



019. (FCC/TRT-MS/ANALISTA JUDICIÁRIO-TI/2017) Uma das formas de apresentação de um banco de dados multidimensional é através do modelo estrela. No centro de um modelo estrela encontra-se a tabela de:

- a) dimensão e, ao seu redor, as tabelas de fatos.
- b) dimensão, cuja chave primária deve ser composta.
- c) núcleo e, ao seu redor, as tabelas de nível.
- d) fatos, cuja chave primária deve ser simples.
- e) fatos e, ao seu redor, as tabelas de dimensões.



O modelo Estrela (*Star Schema*) é formado por uma tabela central – **tabela de fatos** – e um conjunto de tabelas organizadas ao redor dela, as **tabelas de dimensões**.

Letra e.

020. (FCC/SABESP/ANALISTA DE GESTÃO/SISTEMAS/2018) Um Analista está trabalhando em um Data Warehouse – DW que utiliza no centro do modelo uma única tabela que armazena as métricas e as chaves para as tabelas ao seu redor (que descrevem os dados que estão na tabela central) às quais está ligada. O esquema de modelagem utilizado pelo DW, a denominação da tabela central e a denominação das tabelas periféricas são, respectivamente,

- a) floco de neve, base, granulares.
- b) estrela, fato, dimensões.
- c) constelação, fato, granulares.
- d) atomic, base, branches.
- e) anel, base, dimensões.



O **modelo Estrela (Star)** é formado por uma tabela central – **tabela de fatos** – e um conjunto de tabelas organizadas ao redor dela, as **tabelas de dimensões**.

Nas pontas da estrela estão as **tabelas de dimensões** que contêm os **atributos** das aberturas que interessam ao negócio e que podem ser utilizadas como critérios de filtro e são relativamente pequenas. **Cada tabela de dimensão está relacionada com a tabela de fatos por um identificador.**

Letra b.

021. (FCC/TRT-AL/ANALISTA JUDICIÁRIO/TI/2011) O modelo estrela, como estrutura básica de um modelo de dados multidimensional, possui uma configuração típica composta de uma entidade central:

- a) mining e um conjunto de entidades fatos.
- b) mining e um conjunto de entidades dimensões.
- c) mining e um conjunto de entidades roll-up.
- d) dimensão e um conjunto de entidades fatos.
- e) fato e um conjunto de entidades dimensões.



O Esquema ou Modelo Estrela é basicamente uma Tabela de Fatos central conectada a várias Tabelas de Dimensão em um relacionamento 1:N, sendo uma única tabela para cada dimensão.



Figura. O Modelo Estrela (Star Schema).

Assim, o modelo estrela, como estrutura básica de um modelo de dados multidimensional, possui uma configuração típica composta de uma entidade central fato e um conjunto de entidades dimensões.

Letra e.

ESQUEMA FLOCO DE NEVE (SNOWFLAKE)

O **esquema floco de neve (Snowflake)** é uma **variação do esquema estrela em que alguma ponta da estrela explode em mais tabelas**.





Figura. Esquema floco de neve (Snowflake).

Neste esquema, as **tabelas de dimensão floco de neve** estão **padronizadas para eliminar redundância de dados**. Diferente do esquema estrela, neste esquema os dados das dimensões são distribuídos em **múltiplas tabelas**.



Como **vantagem** do esquema destaca-se a **economia de espaço no armazenamento em disco, porém com um aumento na quantidade de tabelas**.

As **características** a seguir são parte de um **esquema floco de neve**:

- a **dimensão** está **padronizada**;
- os diferentes níveis estão armazenados em tabelas separadas;
- verifica-se economia de espaço.

DIRETO DO CONCURSO

022. (UPENET/UPE/ANALISTA DE SISTEMAS/ENGENHARIA DE SOFTWARE/2017) O modelo dimensional de um data warehouse, no qual todas as tabelas relacionam-se diretamente com a tabela de fatos, de forma que as tabelas dimensionais devem conter todas as descrições que são necessárias para se definir uma classe, é denominado de:

- a) Floco de neve.
- b) Estrela.
- c) Barramento.
- d) Árvore.
- e) Anel.



No **modelo Estrela (Star Schema)** todas as tabelas relacionam-se diretamente com a **tabela de fatos**. Sendo assim, as **tabelas dimensionais** devem conter todas as descrições que são necessárias para definir uma classe.

No **modelo Floco de Neve (Snow Flake)**, as tabelas dimensionais relacionam-se com a tabela de fatos, mas algumas dimensões relacionam-se apenas entre elas.



Figura. Modelo Floco de Neve. Fonte: Machado (2004).

Letra b.

ESQUEMA ESTRELA X ESQUEMA FLOCO DE NEVE

Vamos a um **quadro resumido** sobre a diferença entre o Esquema Estrela (*Star Schema*) e o Esquema Floco de Neve (*Snow Flake*).

	Star Schema (Estrela)	Snow Flake (Flocos de Neve)
Clareza	Mais fácil	Mais difícil
Quantidade de Tabelas	Menor (<) Nesse esquema existe uma Tabela Fato central conectada a várias Tabelas-Dimensão .	Maior (>) Aqui tem-se também em uma Tabela Fato central (geralmente apenas uma) conectada a múltiplas dimensões , no entanto, estas Tabelas Dimensões são divididas em tabelas relacionadas . Essa divisão reduz a redundância dos dados, mas aumenta a complexidade do modelo.
Complexidade de Consultas	Consultas mais simples e fáceis de entender , pois há menor necessidade de junção de tabelas.	Consultas mais complexas e difíceis de entender , pois há necessidade de realizar muitas junções .
	Star Schema (Estrela)	Snow Flake (Flocos de Neve)
Desempenho de Consulta	Menos chaves estrangeiras, e consequentemente, menor tempo para as consultas (mais rápido). Melhora o desempenho .	Mais chaves estrangeiras , e consequentemente, mais tempo para as consultas (mais lento). Aumenta a quantidade de vínculos entre tabelas provocando redução do desempenho.
Tabelas-Dimensão	Somente uma para cada dimensão .	Mais que uma para cada dimensão .
Normalização	Recomenda a não normalização das tabelas dimensão . Tabelas de Dimensões são desnormalizadas .	Recomenda a normalização das Tabelas-Dimensão .
	Geralmente é um esquema totalmente não padronizado e pode estar parcialmente padronizado nas tabelas de dimensões.	(A normalização das dimensões também tem efeito negativo na velocidade de saída dos resultados). Todas as tabelas de dimensão são normalizadas, geralmente, até a 3FN.
Armazenamento	Aumenta o espaço .	Economiza espaço .
Joins	Poucos	Muitos . (Devido à Hierarquia das Tabelas-Dimensão). Este é outro fator que também torna mais lento .

Facilidade de Manutenção/Alteração	Como neste esquema o <u>foco</u> está nas consultas rápidas, pode existir redundância dos dados . As Tabelas-Dimensão deste esquema não são normalizadas (mais difícil de manter e alterar).	<u>Sem redundância</u> (mais fácil de manter e alterar). O fato de não haver redundância faz com que haja otimização dos dados .
Quando usar	Quando Tabelas-Dimensão são menores (têm menos linhas).	Quando Tabelas-Dimensão são maiores.

Tabela. Modelo Estrela x Modelo Floco de Neve.

CONSTELAÇÃO DE FATOS

Conforme destaca Elmasri e Navathe (2005, p. 651), uma **Constelação de Fatos** é um **conjunto de tabelas de fatos que compartilham algumas tabelas de dimensão**.

A figura seguinte mostra uma constelação de fatos com duas tabelas de fatos, intituladas “resultado vendas” e “previsão vendas”. Elas compartilham a tabela de dimensão chamada “**produto**”. As constelações de fatos limitam as possíveis consultas no *Data Warehouse*.




Figura. Uma constelação de fatos.

SETE PASSOS PARA CONSTRUIR UM DW

A seguir, destacamos os 7 passos para construir um *Data Warehouse* (DW), conforme destacado em Piton (2020).




Figura. 7 Passos para Construir um DW. Fonte: Elaborada pela autora.

PASSO 1 – ENTREVISTAR OS KEY USERS (USUÁRIOS PRINCIPAIS)

Embora o cliente deva saber o que ele quer, é preciso saber extrair as melhores respostas, então:

- use perguntas que os usuários principais (*Key Users*) estão acostumados a ver no dia a dia;
- **não** use termos técnicos **se não tiver necessidade**;
- o usuário de negócio não sabe o que são **fatos** ou **dimensões**, então é preciso induzir ele a dar as informações necessárias para a criação do DW. Use, por exemplo, a técnica 5W3H, que tem 9 perguntas simples para:
- levantar as informações necessárias para montar o Star Schema;
- falar a mesma língua dos usuários de negócio.

Qual fato aconteceu?




Figura. Técnica 5W3H.

Como os usuários principais (*key users*) podem não estar habituados com as terminologias de BI, explique o que se espera dessas perguntas. Dê exemplo de fatos, como:

- venda;
- transação;
- pedido;
- faturamento.

Piton (2017) cita como exemplo a venda, que é o mais comum.

Qual o fato que aconteceu? **Uma venda.**

Juntando todas as informações, é montada a história de como aquele **fato** aconteceu. As próximas perguntas fazem referência à resposta desta. Nelas tem-se também um *template* para deixar a pergunta mais fácil de entender.

#1 - What - o quê / do quê? Template: Aconteceu _____. Do quê?	Aconteceu uma venda. Do quê? De Coca-Cola Uma Coca-Cola foi vendida
#2 When - quando? Template: Aconteceu _____. Quando?	Aconteceu uma venda. Quando? 01/02/2017 Uma Coca-Cola foi vendida no dia 01/02/2017
#3 Where - onde? Template: Aconteceu _____. Onde?	Aconteceu uma venda. Onde? Na loja de São Paulo Uma Coca-Cola foi vendida, no dia 01/02/2017, em São Paulo
#4 Who - quem? "Quem" são as pessoas envolvidas com o fato, e o papel delas varia de acordo com o negócio. Template: Aconteceu _____. Para quem? Aconteceu _____. Quem entregou?	Para quem foi a venda? Para o Pedro Quem fez a venda? Joana Quem entregou? Transportadora Mercúrio Joana vendeu uma Coca-Cola para o Pedro, no dia 01/02/2017, em São Paulo e a entrega foi realizada pela Transportadora Mercúrio
#5 How - como? Template: Aconteceu _____. Como?	Aconteceu uma venda. Como? Com pagamento em cartão Joana vendeu uma Coca-Cola para o Pedro, que pagou com cartão, no dia 01/02/2017, em São Paulo e a entrega foi realizada pela Transportadora Mercúrio
#6 Why - por quê? Template: Aconteceu _____. Por quê?	Aconteceu uma venda. Por quê? Por causa de uma promoção de natal Joana vendeu uma Coca-Cola para o Pedro, que pagou com cartão, em uma promoção de natal, no dia 01/02/2017 e a entrega foi realizada pela Transportadora Mercúrio em São Paulo
#7 How often - com que frequência? Template: Com que frequência acontece _____?	Com que frequência acontece uma venda? A cada 3h
#8 How many - quanto / quantas? Template: Quantas _____ aconteceram? Quanto foi _____?	Quantas vendas aconteceram? 2 Quanto foi vendido? R\$200,00

PASSO 2 – IDENTIFICAR A FATO

Com a entrevista feita, é hora de organizar essas informações.

A **tabela fato** possui 2 elementos:

- **foreign keys**, que conectam a fato nas dimensões;
- **métricas**, que são sempre dados numéricos.

Essa parte é fácil. É só fazer a primeira pergunta corretamente para se obter a fato definida.

FATO VENDA				
FK DIM 1	FK DIM 2	FK DIM 3	FK DIM 4	MÉTRICAS

PASSO 3 – IDENTIFICAR AS MÉTRICAS

Depois de ter a fato definida, daremos prosseguimento à **identificação das métricas** dela.

E para isso, pode-se usar as respostas da pergunta #8 (*How many?* – quanto/quantas?), em que você tem a quantidade de vendas e o valor delas.

FATO VENDA				
FK DIM 1	FK DIM 2	FK DIM 3	FK DIM 4	MÉTRICAS
				Quantidade de venda
				Valor da venda


PASSO 4 – IDENTIFICAR AS DIMENSÕES

As **dimensões** possuem 3 elementos:


- **surrogate key**, que é a *primary key* da **dimensão**;
- **natural key**, que é a *primary key* da **origem**;
- **atributos**, que vão qualificar as **métricas** da **fato**.

As outras perguntas da entrevista vão definir suas dimensões.

Na frase final, já é possível identificar as **dimensões**:



E com esse levantamento foi possível **identificar 8 possíveis dimensões do Star Schema**.



PASSO 5 – DEFINIR A HIERARQUIA

Com as dimensões identificadas, iremos **definir a hierarquia e o grão de cada uma delas**.

Neste momento devemos entender exatamente o que o usuário principal (*key user*) quer ver com aquela informação e se certificar de qual é o menor nível que ele vai precisar ver.

Para essa parte, é fundamental que você entenda como funciona a **hierarquia de dimensões**.

Na dimensão produto, você teria a seguinte **hierarquia**:



PASSO 6 – IDENTIFICAR OS ATRIBUTOS

Com as dimensões definidas, é hora de identificar os atributos de cada uma delas.

Nesse momento, podemos fazer as perguntas para saber o que os usuários principais (*key users*) gostariam de analisar.

EXEMPLO

“Nessa primeira pergunta você respondeu Coca-Cola, que é um produto. O que você gostaria de analisar do produto?”


E entrevistando as pessoas envolvidas com o fato, **iremos identificar os atributos** necessários. Iremos obter informações como:

- Coca-Cola é o nome do produto;
- todo produto tem um código;
- o time de *marketing* vai dizer que precisa saber a marca do produto;
- o cara da logística vai precisar saber o peso do produto e a unidade de medida para planejar o caminhão;
- o pessoal do financeiro vai precisar saber o preço unitário do produto.

DIMENSÃO PRODUTO							
Surrogate Key (PK)	Natural Key	Atributo 1	Atributo 2	Atributo 3	Atributo 4	Atributo 5	Atributo 6
		Nome	Código	Marca	Peso	Unidade de medida	Preço unitário

PASSO 7 – DESENHAR O STAR SCHEMA

Nesse ponto já devemos ter todas as informações que devem constar no Star Schema levantadas e organizadas. Após analisá-las, **planeje as tabelas, defina seus atributos e hierarquia**, e teremos então a modelagem completa da primeira parte do Data Warehouse.




Com o desenho pronto, é só partir para a ferramenta de modelagem de banco de dados que preferir e o reproduzir, **fazer as conexões da fato com as dimensões** e colocar para funcionar.

Com o Star Schema criado, tem-se a primeira versão do Data Warehouse pronta para receber os dados do ETL.

NOTA:

- **Star Schema já te permite fazer análises;**
- A **Surrogate Key** nada mais é que o **campo de Primary Key** da dimensão:



- Ao invés de levar meses montando um DW gigante, entregue-o por partes e comece o quanto antes a apresentar os dados que os **key users** (usuários principais) precisam ver (PITON, 2020).

DIRETO DO CONCURSO

023. (CEBRASPE/CESPE/CGM JOÃO PESSOA/AUDITOR MUNICIPAL DE CONTROLE INTERNO/ TECNOLOGIA DA INFORMAÇÃO/DESENVOLVIMENTO DE SISTEMAS/2018) Com relação à modelagem dimensional e à otimização de bases de dados para business intelligence, julgue o item subsequente.

Na modelagem multidimensional utilizada em data warehouses para se prover melhor desempenho, a tabela fato central deve relacionar-se às suas dimensões por meio da chave primária oriunda da fonte de dados original. O valor dessa chave deve ser idêntico ao da fonte, para que tenha valor semântico e garanta que o histórico das transações seja mantido.



Na modelagem multidimensional utilizada em *data warehouses* para se prover melhor desempenho, a tabela fato central deve relacionar-se às suas dimensões por meio da **chave primária-oriunda-da-fonte-de-dados-original** **chave substituta** (ou **surrogate key**). O valor dessa chave deve ser **idêntico-ao-da-fonte,-para-que-tenha-valor-semântico** **numérico e autoincremental, não havendo valor semântico** e garanta que o histórico das transações seja mantido.

Errado.

RESUMO






Figura. Data Warehouse. Fonte: Elaborada pela autora.

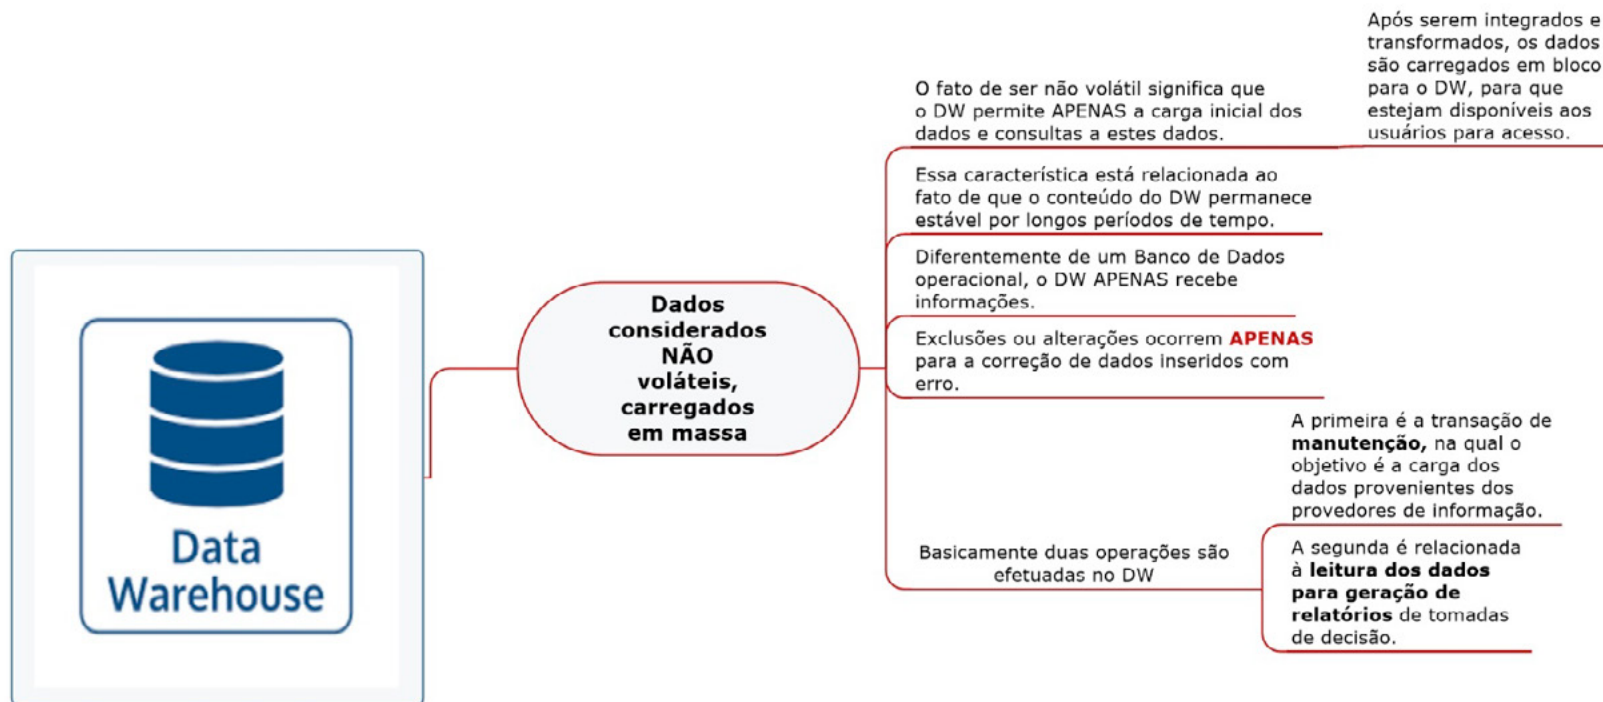


Figura. Dados Não Voláteis. Fonte: Elaborada pela autora.




Figura. Processo de Data Warehousing.

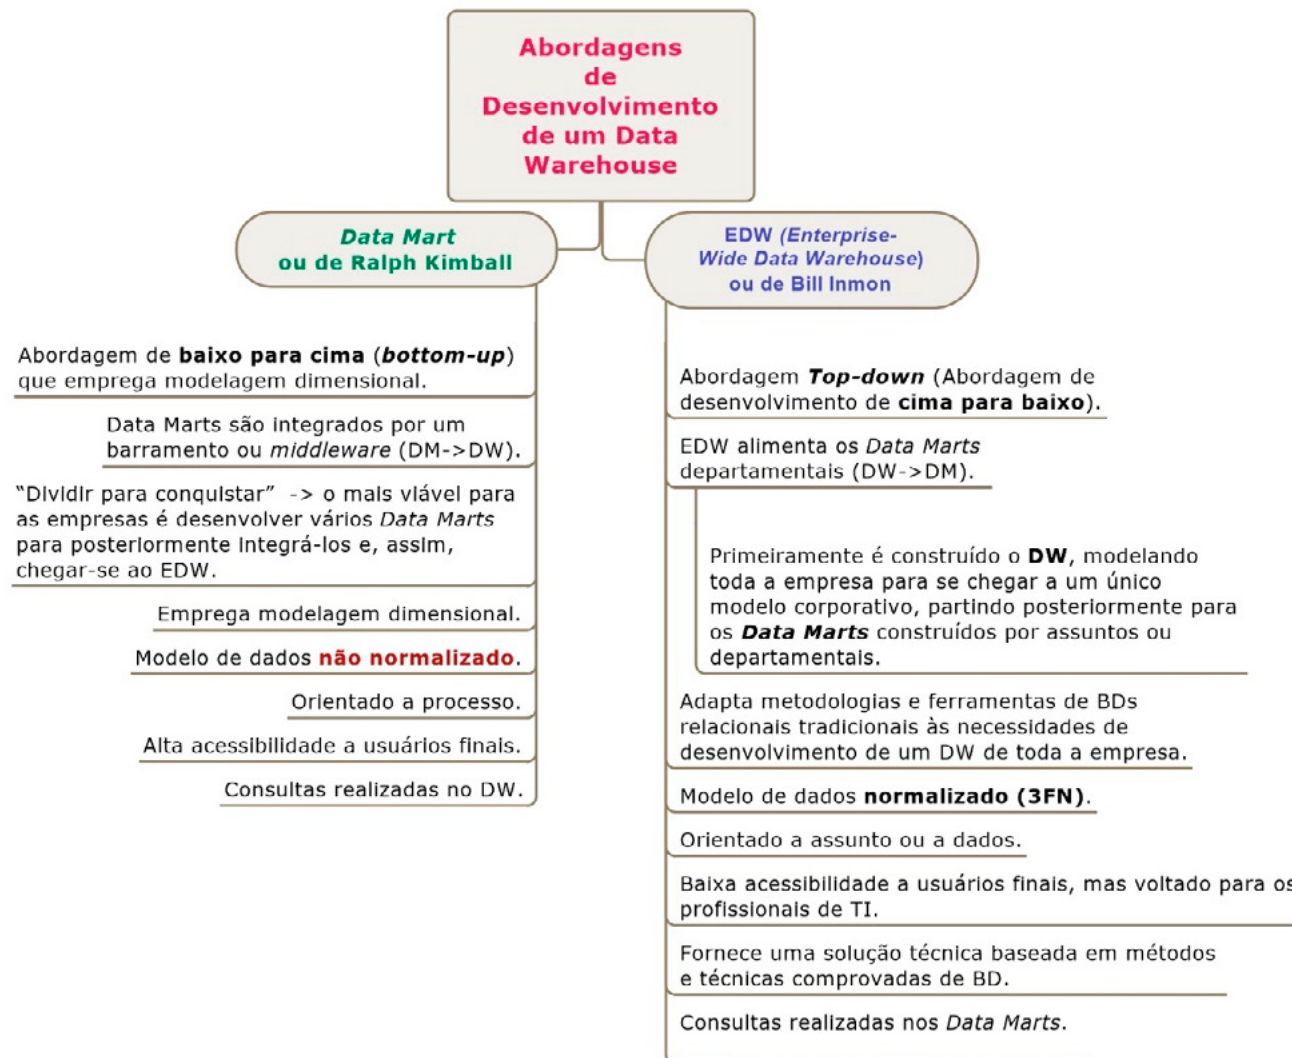


Figura. Abordagens de Desenvolvimento de um DW. Fonte: Elaborada pela autora.




Figura. Data Mart. Fonte: Elaborada pela autora.

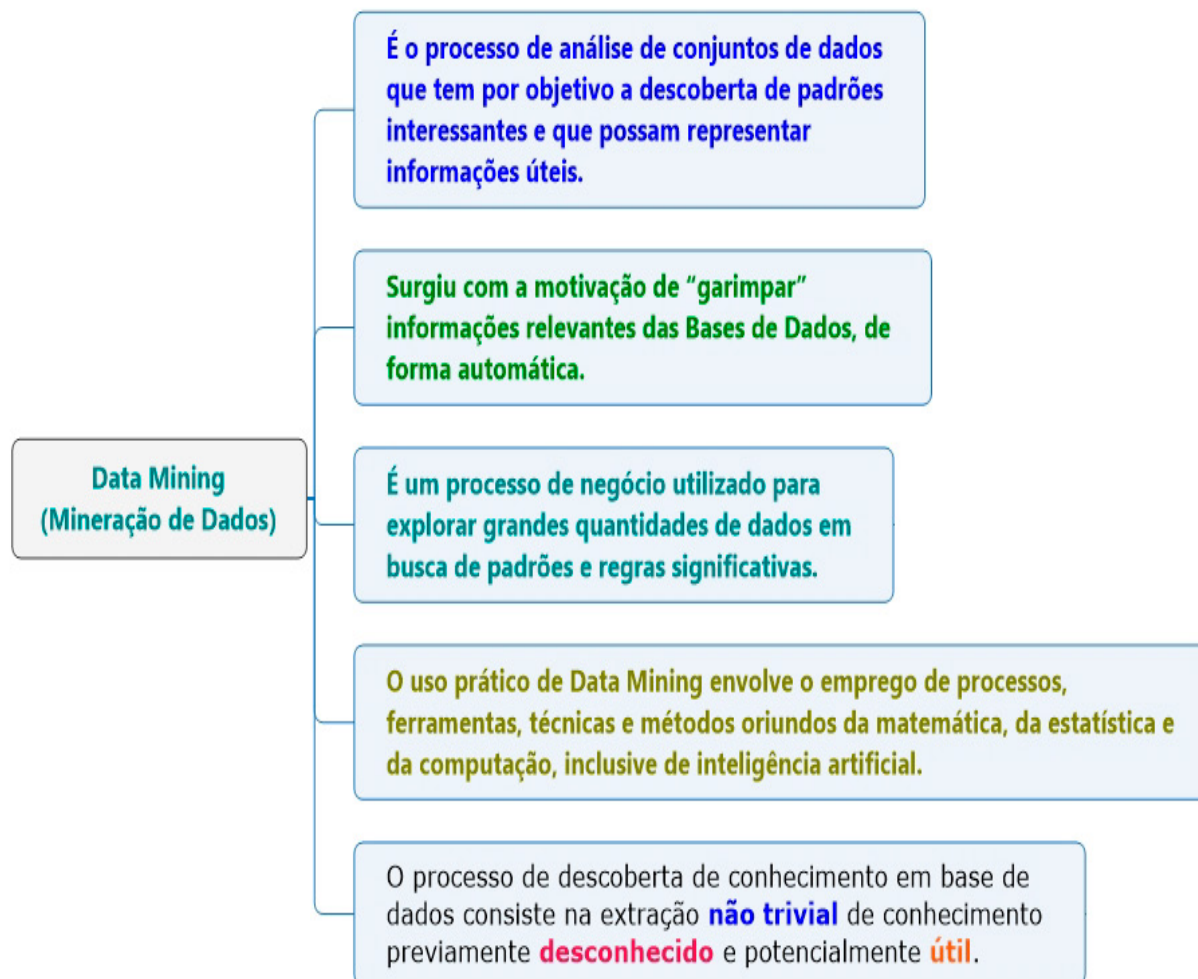


Figura. Data Mining. Fonte: Elaborada pela autora.

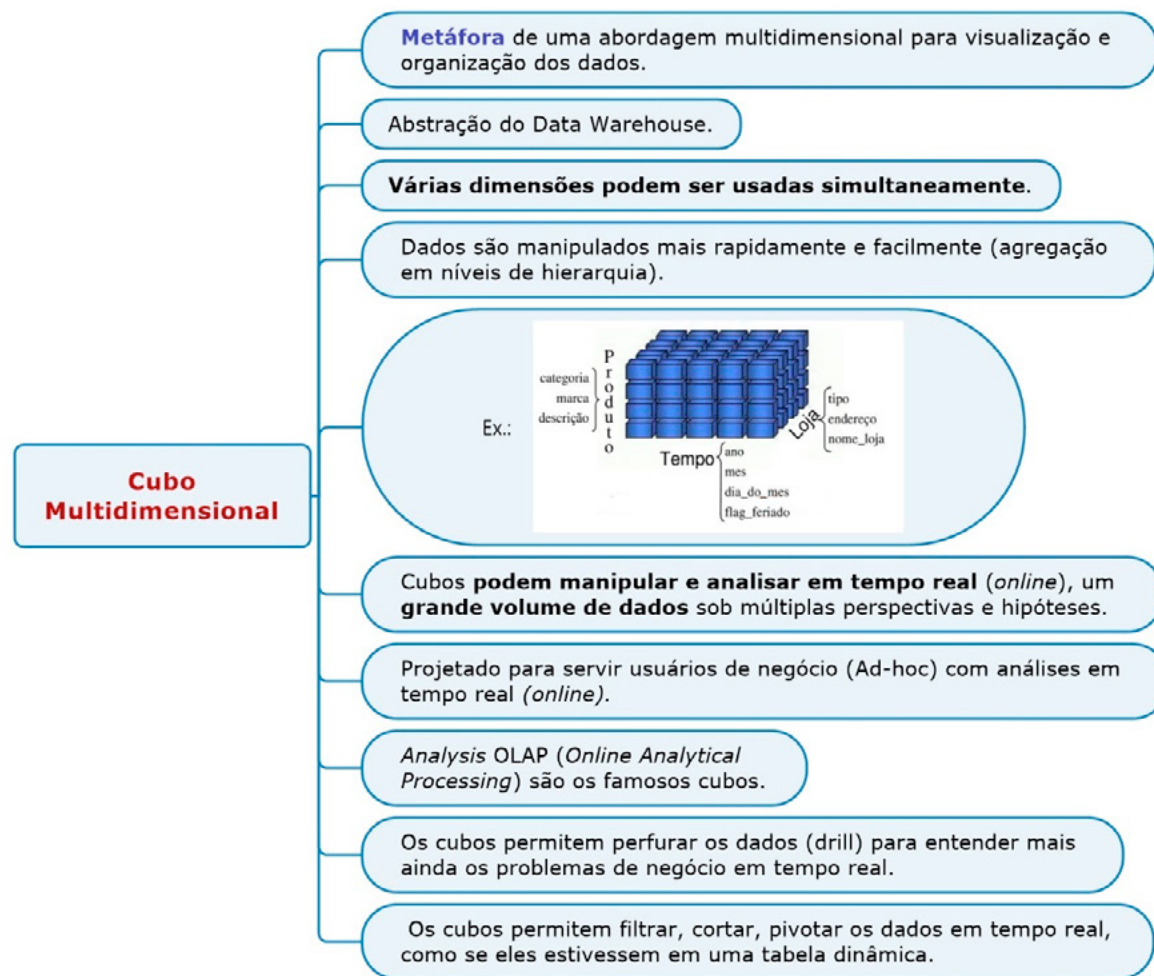


Figura. Cubo Multidimensional. Fonte: Elaborada pela autora.




Figura. Tipos de Tabelas de Fatos. Fonte: Elaborada pela autora.

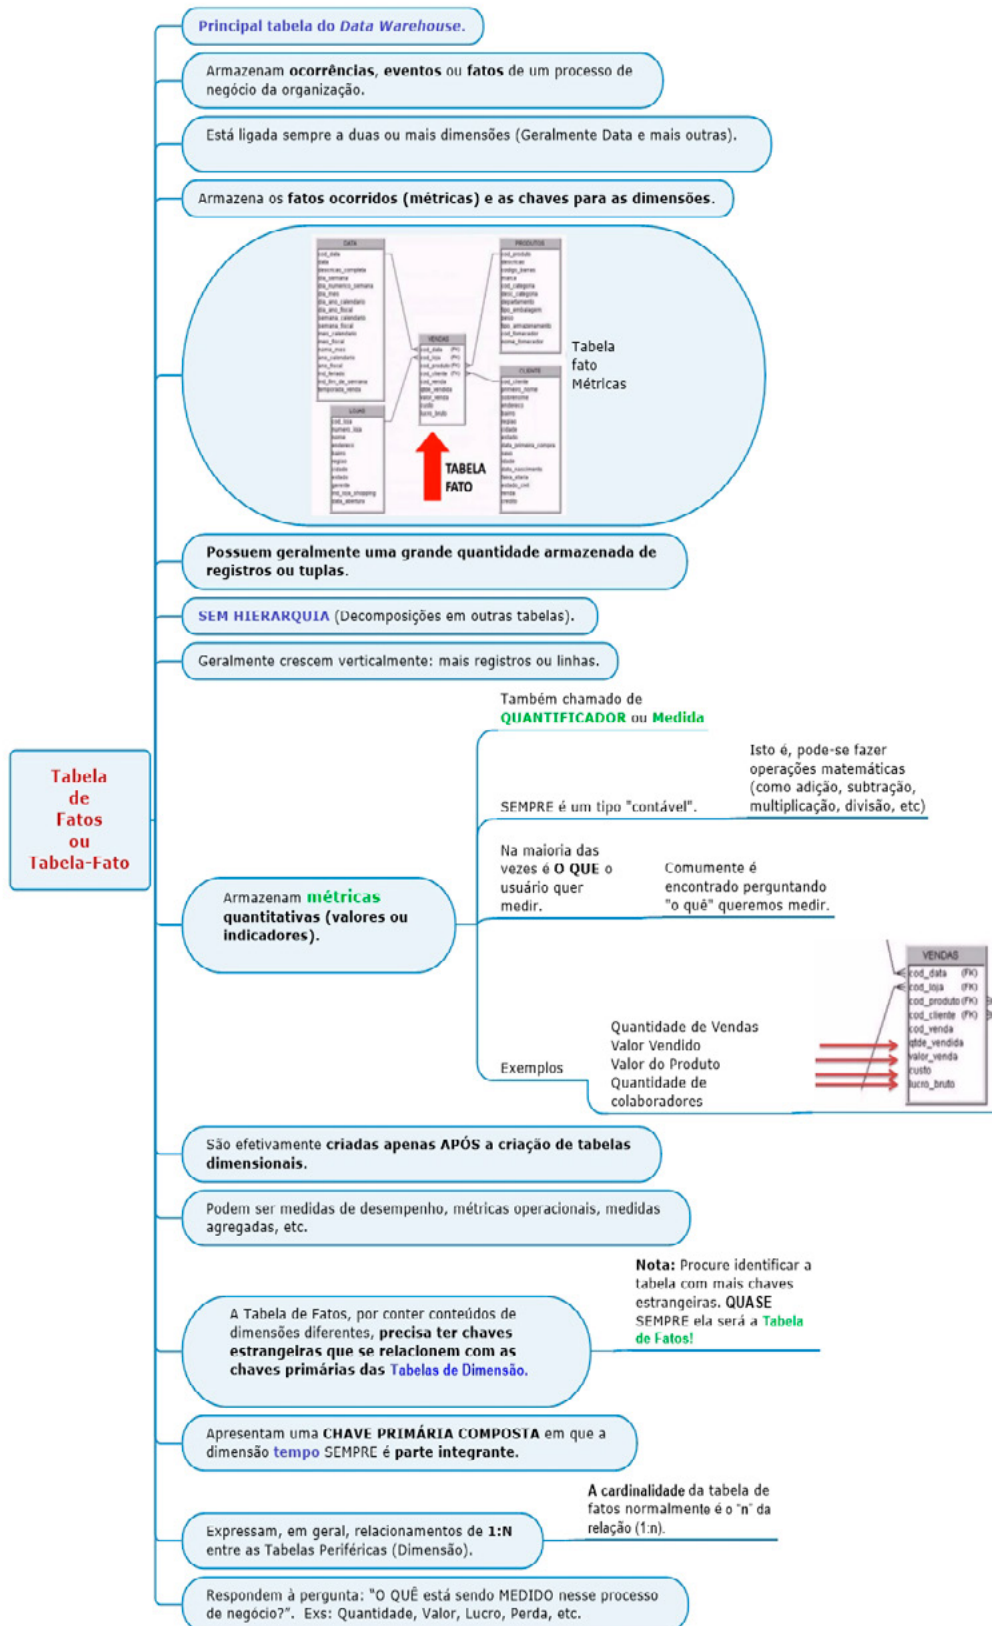


Figura. Tabela de Fatos. Fonte: Elaborada pela autora.

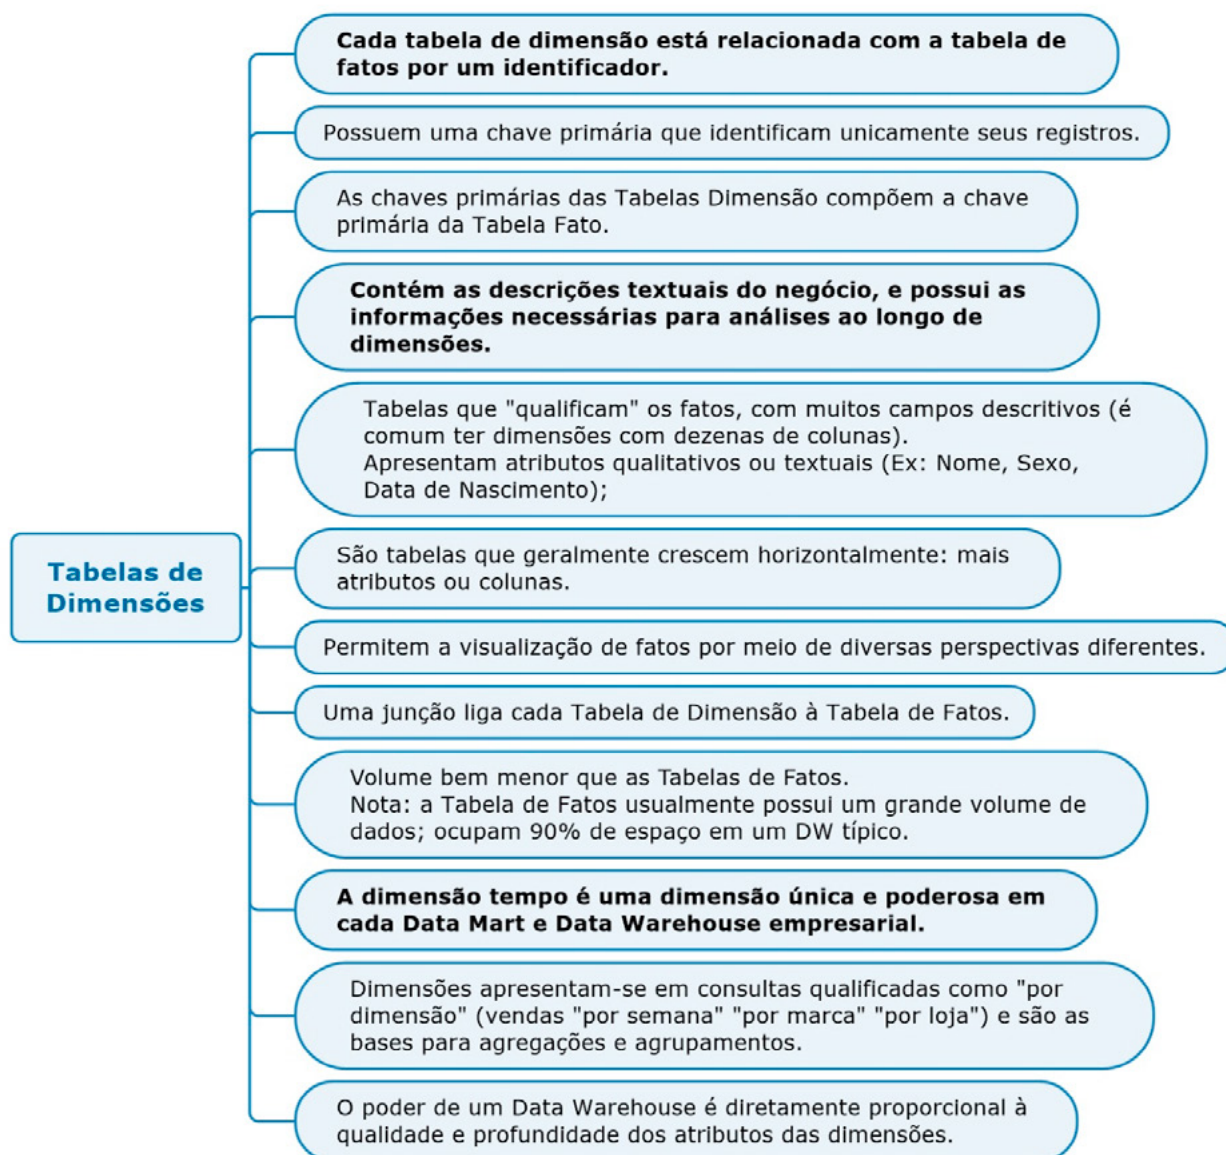


Figura. Tabelas de Dimensões. Fonte: Elaborada pela autora.

Granularidade refere-se ao nível de sumarização (**resumo**) dos elementos e de detalhes disponíveis. É considerado o aspecto mais importante de um DW.

Granularidade e **detalhamento** são grandezas **inversamente** proporcionais:

- Quanto mais detalhe, menor é a granularidade (Baixa granularidade = mais detalhado).
- Quanto menos detalhe, maior é a granularidade (Alta granularidade = menos detalhado).




Figura. Granularidade e Detalhamento.

Granularidade e **sumarização** são grandezas **diretamente** proporcionais:

- Quanto maior a sumarização, maior a granularidade;
- Quanto menor a sumarização, menor a granularidade.

QUESTÕES COMENTADAS EM AULA

001. (CESGRANRIO/BANCO DA AMAZÔNIA/TÉCNICO CIENTÍFICO/TECNOLOGIA DA INFORMAÇÃO/2018) Um Data Warehouse é recomendado para armazenar dados

- a) sumarizados de um departamento.
- b) sumarizados de toda a empresa para apoio à decisão e utilização de ferramentas OLAP.
- c) detalhados de toda a empresa para apoio à decisão e utilização de ferramentas OLAP.
- d) detalhados gerados por sistemas de informação transacionais.
- e) históricos detalhados de todas as transações realizadas em um determinado período de tempo.

002. (CESPE/DEPEN/AGENTE PENITENCIÁRIO FEDERAL/TECNOLOGIA DA INFORMAÇÃO/2015) Acerca de datawarehouse e datamining, julgue o item subsequente:

O datawarehouse possibilita a análise de grandes volumes de dados, que, por sua vez, permitem a realização de uma melhor análise de eventos futuros.

003. (ESAF/MPOG/2008/ADAPTADA) Algumas pessoas têm considerado que os Data Warehouses são uma extensão de visões de banco de dados. Porém, as visões fornecem apenas um subconjunto das funções e das capacidades dos data warehouses. Com relação às diferenças e similaridades entre as visões e os data warehouses, é correto afirmar que tanto os data warehouses quanto as visões fornecem, frequentemente, grandes quantidades de dados integrados e temporais, geralmente mais do que é contido em um banco de dados.

004. (VUNESP/TJ-SP/2012) Uma das técnicas utilizadas no projeto de um data warehouse corporativo consiste no uso da chamada matriz de barramento, na qual as linhas e colunas representam, respectivamente,

- a) cubos e medições.
- b) data staging e cubos.
- c) cardinalidades e hierarquias.
- d) dimensões e cardinalidades.
- e) processos de negócio e dimensões.

005. (FUNCAB/MDA-MINISTÉRIO DO DESENVOLVIMENTO AGRÁRIO/ANALISTA DE BUSINESS INTELLIGENCE/2014)




Figura. Modelo de organização para as próximas 3 questões.

A principal atividade de EXTRAÇÃO é:

- a) considerar logs de eventos e arquivos de controle.
- b) coletar dados das fontes externas transferindo-os para o ambiente de DW.
- c) carregar as dimensões considerando os tipos de hierarquias estáticas.
- d) tratar as inconsistências de dados resultantes da transcrição de dados.
- e) executar conversões de formatos para códigos geográficos dos países.


006. (FUNCAB/MDA-MINISTÉRIO DO DESENVOLVIMENTO AGRÁRIO/ANALISTA DE BUSINESS INTELLIGENCE/2014) A principal atividade de TRANSFORMAÇÃO é:

- a) aplicar regras aos dados extraídos para ajustá-los antes de serem carregados.
- b) analisar impactos das alternativas do código de aplicação no sistema fonte.
- c) avaliar aspectos de performance por meio do uso de paralelismo.
- d) obter dados de natureza estruturada e não estruturada.
- e) carregar tabelas Fato e fazer mapeamento das chaves.

007. (FUNCAB/MDA-MINISTÉRIO DO DESENVOLVIMENTO AGRÁRIO/ANALISTA DE BUSINESS INTELLIGENCE/2014) A principal atividade de CARGA é:

- a) realizar a limpeza dos dados extraídos para melhorar a qualidade dos dados.
- b) definir a periodicidade da transcrição dos dados a serem coletados.
- c) otimizar a qualidade dos dados por meio da conversão de formatos.
- d) separar e concatenar dados visando eliminar inconsistências nos dados.
- e) estruturar e carregar os dados para o DW seguindo o modelo dimensional.

008. (FCC/AL-MS/TÉCNICO DE INFORMÁTICA/2016) Considere a figura abaixo.



No processo de ETL mostrado na figura, I e II correspondem, respectivamente, a

- a) OLTP e Data Warehouse.
- b) OLTP e Staging Area.
- c) Data Mart e Staging Area.
- d) Staging Area e OLTP.
- e) Staging Area e Data Warehouse.

009. (IADES/METRÔ-DF/TÉCNICO EM ELETRÔNICA/2014) É o conjunto de técnicas e procedimentos para a extração de informações em dispositivos de armazenamento digital, que não podem ser acessados de modo convencional pelo usuário ou pelo sistema. Com base no exposto, é correto afirmar que essas informações apresentam o conceito de

- a) recuperação de dados.
- b) backup corrompido.
- c) mineração de dados.
- d) backup interrompido.
- e) recuperação de dispositivos.

010. (COPEVE UFAL/MPE-AL/ANALISTA DO MINISTÉRIO PÚBLICO/2012) Um modelo de banco de dados multidimensional está mais fortemente relacionado com:

- a) data warehouse.
- b) modelo relacional.
- c) bancos hierárquicos.
- d) modelo em 3 camadas.
- e) banco de dados distribuídos.

011. (FUNCAB/MDA/ADMINISTRADOR DE BANCO DE DADOS/2014) O modelo de dados denominado “multidimensional” se aplica para banco de dados com a tecnologia:

- a) relacional.
- b) hierárquica.
- c) datamining.
- d) distribuída
- e) data warehouse.

012. (CESPE/SEDF/ANALISTA DE GESTÃO EDUCACIONAL/TECNOLOGIA DA INFORMAÇÃO/2017) Com relação aos conceitos de modelagem multidimensional de dados para inteligência computacional, julgue o seguinte item. [Diferentemente da estrutura relacional, a estrutura multidimensional oferece baixa redundância de dados e suporte a normalização até a segunda forma normal].

013. (FAURGS/HCPA/ANALISTA DE TI/BANCO DE DADOS/2016) Em um modelo dimensional, a tabela fatos armazena:

- a) estatísticas sobre os metadados.
- b) as restrições de domínio do negócio.
- c) descrições textuais das dimensões.
- d) medições numéricas do negócio.
- e) o tempo de processamento das transações.

014. (COSEAC/DATAPREV/ANALISTA DE TECNOLOGIA DA INFORMAÇÃO/2009/ADAPTADA) Sobre modelagem multidimensional, o cubo:

I – é uma representação intuitiva, pois todas as dimensões coexistem para todo ponto no cubo e são independentes umas das outras;

II – é, de fato, apenas uma metáfora visual;

III – serve para descrever requisitos funcionais.

Acerca dos itens acima mencionados, apenas;

- a) I e III estão corretos;
- b) Somente I está correto;
- c) I e II estão corretos;
- d) II e III estão corretos;
- e) III está correto.

015. (CESGRANRIO/PETROBRAS/ANALISTA DE SISTEMAS JÚNIOR) Em um banco de dados multidimensional, os dados estão conceitualmente armazenados e organizados em:


- a) classes e objetos.
- b) cubos e hipercubos.
- c) partições e índices.
- d) consultas materializadas e sumários.
- e) estrelas e constelações.

016. (CESPE/MPE-PI/ANALISTA MINISTERIAL/2012) Um cubo de dados é a representação multidimensional dos dados não agregados na qual é necessário que as dimensões tenham o mesmo tamanho.

017. (IDECAN/INMETRO/ANÁLISE E DESENVOLVIMENTO DE SISTEMAS/2015) A modelagem multidimensional é uma técnica de concepção e visualização de um modelo de dados de um conjunto de medidas que descrevem aspectos comuns de negócios. Um modelo multidimensional é formado por três elementos básicos. Assinale-os:

- a) Esquema, fatos e itens.
- b) Fatos, dimensões e itens.
- c) Medidas, esquema e fatos.
- d) Fatos, dimensões e medidas
- e) Dimensões, medidas e esquema.

018. (FCC/TRT/4ª REGIÃO-RS/ANALISTA JUDICIÁRIO/TECNOLOGIA DA INFORMAÇÃO/2015) Considere a arquitetura geral de um sistema de BI- Business Intelligence mostrada na figura abaixo.



Nesta arquitetura

- a) Data Marts representam áreas de armazenamento intermediário criadas a partir do processo de ETL. Auxiliam na transição dos dados das fontes OLTP para o destino final no Data Warehouse.
- b) OLAP é um subconjunto de informações extraído do Data Warehouse que pode ser identificado por assuntos ou departamentos específicos. Utiliza uma modelagem multidimensional conhecida como modelo estrela.
- c) os dados armazenados no Data Warehouse são integrados na base única mantendo as convenções de nomes, valores de variáveis e outros atributos físicos de dados como foram obtidos das bases de dados originais.
- d) o Data Warehouse não é volátil, permite apenas a carga inicial dos dados e consultas a estes dados. Além disso, os dados nele armazenados são precisos em relação ao tempo, não podendo ser atualizados.
- e) Data Mining se refere ao processo que, na construção do Data Warehouse, é utilizado para composição de análises e relatórios, armazenando dados descritivos e qualificando a respectiva métrica associada.

019. (FCC/TRT-MS/ANALISTA JUDICIÁRIO-TI/2017) Uma das formas de apresentação de um banco de dados multidimensional é através do modelo estrela. No centro de um modelo estrela encontra-se a tabela de:

- a) dimensão e, ao seu redor, as tabelas de fatos.
- b) dimensão, cuja chave primária deve ser composta.
- c) núcleo e, ao seu redor, as tabelas de nível.
- d) fatos, cuja chave primária deve ser simples.
- e) fatos e, ao seu redor, as tabelas de dimensões.

020. (FCC/SABESP/ANALISTA DE GESTÃO/SISTEMAS/2018) Um Analista está trabalhando em um Data Warehouse – DW que utiliza no centro do modelo uma única tabela que armazena as métricas e as chaves para as tabelas ao seu redor (que descrevem os dados que estão na tabela central) às quais está ligada. O esquema de modelagem utilizado pelo DW, a denominação da tabela central e a denominação das tabelas periféricas são, respectivamente,

- a) floco de neve, base, granulares.
- b) estrela, fato, dimensões.
- c) constelação, fato, granulares.
- d) atomic, base, branches.
- e) anel, base, dimensões.

021. (FCC/TRT-AL/ANALISTA JUDICIÁRIO/TI/2011) O modelo estrela, como estrutura básica de um modelo de dados multidimensional, possui uma configuração típica composta de uma entidade central:

- a) mining e um conjunto de entidades fatos.
- b) mining e um conjunto de entidades dimensões.
- c) mining e um conjunto de entidades roll-up.
- d) dimensão e um conjunto de entidades fatos.
- e) fato e um conjunto de entidades dimensões.

022. (UPENET/UPE/ANALISTA DE SISTEMAS/ENGENHARIA DE SOFTWARE/2017) O modelo dimensional de um data warehouse, no qual todas as tabelas relacionam-se diretamente com a tabela de fatos, de forma que as tabelas dimensionais devem conter todas as descrições que são necessárias para se definir uma classe, é denominado de:

- a) Floco de neve.
- b) Estrela.
- c) Barramento.
- d) Árvore.
- e) Anel.

023. (CEBRASPE/CESPE/CGM JOÃO PESSOA/AUDITOR MUNICIPAL DE CONTROLE INTERNO/TECNOLOGIA DA INFORMAÇÃO/DESENVOLVIMENTO DE SISTEMAS/2018) Com relação à modelagem dimensional e à otimização de bases de dados para business intelligence, julgue o item subsequente.

Na modelagem multidimensional utilizada em data warehouses para se prover melhor desempenho, a tabela fato central deve relacionar-se às suas dimensões por meio da chave primária oriunda da fonte de dados original. O valor dessa chave deve ser idêntico ao da fonte, para que tenha valor semântico e garanta que o histórico das transações seja mantido.

GABARITO

1. b
2. E
3. E
4. e
5. b
6. a
7. e
8. e
9. a
10. a
11. e
12. E
13. d
14. c
15. b
16. E
17. d
18. d
19. e
20. b
21. e
22. b
23. E

REFERÊNCIAS

BEAL, Adriana. *Gestão estratégica da informação: como transformar a informação e a tecnologia da informação em fatores de crescimento e de alto desempenho nas organizações*. Atlas, 2012.

BIO, S. R. *Sistemas de informação: um enfoque gerencial*. São Paulo: Atlas.

CHAUDHURI, S., DAYAL, U. *An Overview of Data Warehousing and OLAP Technology*. ACM SIGMOD Record, v. 26, p. 65-74, 1997.

CLARO, Daniela Barreiro. *Dados da Web Atual*. Disponível em: < <http://walderson.com/site/wp-content/uploads/2017/02/CCI.Aula-04.Dados-da-Web-Atual.pdf> > Acesso em: 1 mar. 2020.

DSACADEMY. *Mas afinal, o que é pipeline de dados?* Disponível em: <<https://blog.dsacademy.com.br/mas-afinal-o-que-e-pipeline-de-dados/>>. 2020.

ELIAS, D. *As melhores ferramentas do mercado para Business Intelligence*. 2014. Disponível em: <<http://corporate.canaltech.com.br/noticia/business-intelligence/As-melhores-ferramentas-do-mercado-para-Business-Intelligence/>>. Acesso em: 20 set. 2020.

GARTNER. 2020. *Magic Quadrant for Analytics and Business Intelligence Platforms* Disponível em: <<https://www.gartner.com/doc/reprints?id=1-1YAE9AY1&ct=200206&st=sb&ref=lp&signin=d3bc9455788b4ae25dceff374a965001>>. Acesso em: 11 fev. 2020.

LOPES, Adriano; VILLA, Cláudia Regina. *A gestão da qualidade como facilitadora da gestão da informação e do conhecimento em ambiente jurídico*. XI Seminário Latinolberoamericano de Gestión Tecnológica. 2005.

HOSCO. *Recuperação de dados*. Disponível em: < <https://recuperacao-de-dados.eti.br> >. Acesso em: 30 set. 2017.

KIMBALL, R.; MARGY, R. *The Data Warehouse Toolkit: The Definitive Guide to Dimensional Modeling*. Wiley Publishing, 3rd edição, 2013.

MACHADO, F. N. R. *Tecnologia e projeto de Data Warehouse*. 2ª edição. São Paulo: Érica, 2004.

MELLO, Ronaldo dos Santos et al. *Dados semiestruturados*. XV Simpósio Brasileiro de Banco de Dados, 2000.

REZENDE, Denis Alcides. *Planejamento de sistemas de informação e informática: guia prático para planejar a tecnologia da informação integrada ao planejamento estratégico das organizações*. 5. ed. São Paulo: Atlas, 2016.

SANT'ANA, Ricardo César Gonçalves. Ciclo de vida dos dados: uma perspectiva a partir da ciência da informação. *Informação & Informação*, v. 21, n. 2, p. 116-142, 2016.

TAKEUCHI, Hirotaka; NONAKA, Ikujiro. *Gestão do conhecimento*. Bookman, 2009.

Abra



caminhos



crie

futuros

gran.com.br

