

INFORMÁTICA E DADOS

Big Data, Hadoop e Spark



Presidente: Gabriel Granjeiro

Vice-Presidente: Rodrigo Calado

Diretor Pedagógico: Erico Teixeira

Diretora de Produção Educacional: Vivian Higashi

Gerente de Produção Digital: Bárbara Guerra

Todo o material desta apostila (incluindo textos e imagens) está protegido por direitos autorais do Gran. Será proibida toda forma de plágio, cópia, reprodução ou qualquer outra forma de uso, não autorizada expressamente, seja ela onerosa ou não, sujeitando-se o transgressor às penalidades previstas civil e criminalmente.

CÓDIGO:

251021391448



PATRÍCIA QUINTÃO

Mestre em Engenharia de Sistemas e computação pela COPPE/UFRJ, Especialista em Gerência de Informática e Bacharel em Informática pela UFV. Atualmente é professora no Gran Cursos Online; Analista Legislativo (Área de Governança de TI), na Assembleia Legislativa de MG; Escritora e Personal & Professional Coach. Atua como professora de Cursinhos e Faculdades, na área de Tecnologia da Informação, desde 2008. É membro: da Sociedade Brasileira de Coaching, do PMI, da ISACA, da Comissão de Estudo de Técnicas de Segurança (CE-21:027.00) da ABNT, responsável pela elaboração das normas brasileiras sobre gestão da Segurança da Informação. Autora dos livros: Informática FCC - Questões comentadas e organizadas por assunto, 3ª. edição e 1001 questões comentadas de informática (Cespe/UnB), 2ª. edição, pela Editora Gen/Método. Foi aprovada nos seguintes concursos: Analista Legislativo, na especialidade de Administração de Rede, na Assembleia Legislativa do Estado de MG; Professora titular do Departamento de Ciência da Computação do Instituto Federal de Educação, Ciência e Tecnologia; Professora substituta do DCC da UFJF; Analista de TI/Suporte, PRODABEL; Analista do Ministério Público MG; Analista de Sistemas, DATAPREV, Segurança da Informação; Analista de Sistemas, INFRAERO; Analista - TIC, PRODEMGE; Analista de Sistemas, Prefeitura de Juiz de Fora; Analista de Sistemas, SERPRO; Analista Judiciário (Informática), TRF 2ª Região RJ/ES, etc.

GRAN
CONCURSOS

SUMÁRIO

Apresentação	5
Big Data, Hadoop e Spark.....	6
O Que É “Big Data”?	6
Objetivo do “Big Data”	9
Origem dos Dados.....	10
Dados Estruturados, Semiestruturados e Não Estruturados.....	11
Como Armazenar Big Data?.....	14
Big Data Analytics.....	20
Tipos de Análise	21
Riscos Principais	22
Mitos sobre o Big Data	23
Big Data x Small Data.....	24
O Que É (e Não É) Análise de Big Data	24
Dimensões do Big Data	25
Ingestão de Dados	33
Gerenciamento de Dados	34
Entrega de Dados	34
Análise de Dados.....	35
Arquitetura do Big Data.....	35
Arquitetura Lambda e Arquitetura Kappa.....	37
Arquitetura Lambda.....	38
Arquitetura Kappa	39
Camadas Lógicas de uma Solução de Big Data	42
Conceitos Fundamentais e Terminologia para Concursos.....	47
Apache Hadoop: O Ecossistema para Big Data	49
Apache Spark: Processamento Rápido e Versátil	57
Principais Plataformas de Computação em Nuvem para Big Data.....	58

Resumo	63
Questões Comentadas em Aula	70
Exercícios	73
Gabarito	81
Gabarito Comentado.....	82
Referências	112

APRESENTAÇÃO

Olá, querido amigo!

O momento perfeito não “surge”; ele é construído. Construa o seu.

Você tem suas próprias dificuldades, problemas, vitórias e soluções. Continue firme e, em breve, estará colhendo os frutos da vitória.

Rumo, então, à aula sobre **Big Data, Hadoop e Spark!**

Força nos estudos!

Grande abraço,

BIG DATA, HADOOP E SPARK

O QUE É “BIG DATA”?

Neste exato momento, uma enxurrada de dados, ou 2,5 quintilhões de bytes por dia, é gerada para nortear indivíduos, empresas e governos, e está dobrando a cada dois anos (DATASCIENCEACADEMY, 2022).

Big Data é uma coleção de conjuntos de dados grandes e complexos que não podem ser processados por bancos de dados ou aplicações de processamento tradicionais (DATASCIENCEACADEMY, 2022).

Siewert (2013) destaca que o termo **Big Data** é “definido genericamente como a captura, gerenciamento e análise de dados que vão além dos dados tipicamente estruturados, os quais podem ser consultados e pesquisados por meio de bancos de dados relacionais.”

Frequentemente, são dados obtidos de arquivos não estruturados, como vídeo digital, imagens, dados de sensores, arquivos de logs e qualquer tipo de dados não contidos em registros típicos com campos que podem ser pesquisados.

- Big Data tem dados estruturados e não estruturados!
- Big Data é o termo que descreve o imenso volume de dados – estruturados e não estruturados – que impactam os negócios no dia a dia.

De maneira geral, **Big Data** não se refere apenas aos dados, mas também às soluções tecnológicas criadas para lidar com dados em volume, variedade e velocidade significativos (CESPE/2018).

Segundo Siewert (2013), o **Big Data** possui variadas fontes de dados, como:

- dados gerados pelas máquinas (redes de sensores, logs);
- dispositivos móveis (vídeo, mensagens, fotografias);
- comunicação máquina a máquina, a “Internet das Coisas”;
- dados em bancos de dados relacionais oriundos das transações da organização;
- imagens de documentos, etc.

De acordo com Landim (2015), trata-se de um termo usado para descrever grandes e complexos conjuntos de dados que são muito difíceis de capturar, processar, armazenar, buscar e analisar com os sistemas de bancos de dados convencionais.

Veja a seguir as principais definições encontradas na literatura para o termo **Big Data**:

Kim, Trimi e Ji-Hyong	“Big Data é o termo geral para a enorme quantidade de dados digitais coletados a partir de todos os tipos de fontes.”
Davenport e Kwon	“Big Data são dados demasiadamente volumosos ou muito desestruturados para serem gerenciados e analisados através de meios tradicionais”.

DI MARTINO	"Big Data" se refere ao conjunto de dados cujo tamanho está além da habilidade de ferramentas típicas de banco de dados em capturar, gerenciar e analisar."
Gartner Group (2012)	"Big Data" , em geral, é definido como ativos de alto volume, velocidade e variedade de informação que exigem custo-benefício, de formas inovadoras de processamento de informações para maior visibilidade e tomada de decisão. "
GEORGE et al. (2014) (Academy of Management Journal)	"O Big Data é formado por uma crescente pluralidade de fontes de informação , entre elas cliques na web, transações em dispositivos móveis, conteúdo gerado por usuários, mídias sociais, bem como conteúdo gerado intencionalmente através de redes de sensores ou transações comerciais, tais como consultas de vendas e transações de compra."
International Data Corporation	"Big Data" é uma nova geração de tecnologias e arquiteturas, projetadas economicamente para extrair valor de volumes muito grandes e vastos de dados , permitindo alta velocidade de captura, descoberta e análise."
MCAFEE, A et al. (2012) (Harvard Business Review)	"Big Data" como uma forma essencial para melhorar a eficiência e a eficácia das organizações de vendas e marketing . Ao colocar Big Data no coração de vendas e marketing, os insights podem ser aproveitados para melhorar a tomada de decisão e inovar no modelo de vendas da empresa, o que pode envolver a utilização de dados para orientar ações em tempo real."
Dumbill e EDD	"Big Data" é o dado que excede a capacidade de processamento convencional dos sistemas de bancos de dados."
Mayer Schönberger e Cukier	"Big Data" é a habilidade da sociedade de aproveitar a informação por novas maneiras para produzir introspecção úteis ou bens e serviços de valor significativo".
Mahrt e Scharkow	"Big Data" denota um maior conjunto de dados ao longo do tempo , conjunto de dados estes que são grandes demais para serem manipulados por infraestruturas de armazenamento e processamento regulares."
Oxford English Dictionary	"Big Data" é um dado de grande tamanho, tipicamente ao nível que sua manipulação e gerenciamento apresenta desafios significativos a logística ".
RAJESH	"Big Data" são conjuntos de dados que são tão grandes que se tornam difíceis de trabalhar com o uso de ferramentas atualmente disponíveis".

Esquematizando!




Figura Visão Geral do Big Data e Seus Objetivos. Fonte: Quintão (2023)

DIRETO DO CONCURSO

001. (QUADRIX/CREF-11ª REGIÃO/AGENTE DE ORIENTAÇÃO E FISCALIZAÇÃO/2014) Trata-se de uma infinidade de informações não estruturadas que, quando usadas com inteligência, se tornam uma arma poderosa para empresas tomarem decisões cada vez melhores. As soluções tecnológicas que trabalham com esse conceito permitem analisar um enorme volume de dados de forma rápida e ainda oferecem total controle ao gestor das informações. E as fontes de dados são as mais diversas possíveis: de textos e fotos em rede sociais, passando

por imagens e vídeos, até jogadas específicas no esporte e até tratamentos na medicina.
(<http://olhardigital.uol.com.br/pro/video/39376/39376>)

O conceito definido no texto é:

- a) Governança de TI
- b) QoS.
- c) Big Data
- d) Data Center.
- e) ITIL.



A questão destaca de forma bem clara o conceito de Big Data; fácil, não é mesmo?

Letra c.

OBJETIVO DO “BIG DATA”

Obs.: O **objetivo do Big Data** é propiciar dados e informações que possam ser analisados, visando subsidiar a **tomada de decisão** (Fernandes e Abreu, 2014).

A tomada de decisão é possível em função não somente do **volume** de dados, da **velocidade de captura dessas informações**, **das fontes variadas de dados** e de **novos softwares para fins de modelagem dessas informações** (Fernandes e Abreu, 2014).

Por exemplo, observar uma tendência de crescimento nas vendas de um produto em função de comentários favoráveis no Facebook. Este tipo de análise é o que está sendo denominado **Data Analytics** (Fernandes e Abreu, 2014).

Em Brito (2019), o autor destaca o seguinte: “o objetivo principal do Big Data é **obter informação útil a partir de dados armazenados em tempo real (espontâneos)** e, por isso, esses dados **não são estruturados**, o que torna a aplicação de técnicas de extração de informação mais difícil.”

Assim, estamos falando de muitos dados que são gerados e consumidos rapidamente.

Obs.: É por isso que dizemos que as **características** mais marcantes do Big Data são:

- (i) quantidade e
- (ii) velocidade.

Então, no cenário do Comércio Eletrônico, a simples transação eletrônica é uma relação direta entre cliente e empresa, o que não é caracterizado como Big Data. Essa transação gera um pedido que representa um histórico sob a perspectiva de negócios da empresa.

Por outro lado, se a empresa tem **ferramentas para analisar o comportamento dos usuários enquanto navegam pela sua página de Comércio Eletrônico**, é possível exibir

ao usuário somente aqueles produtos que estejam alinhados ao seu perfil; assim, existe um potencial real de maximizar as vendas — **isso é Big Data**.

Outro exemplo de Big Data no mesmo contexto do comércio eletrônico e que se relaciona com a produção: se a empresa tem ferramentas para avaliar quais produtos estão sendo mais acessados em seu ambiente de comércio eletrônico em determinado momento, esse pode ser um indicativo de quais produtos devem ser priorizados no ambiente da produção. Então, repare que *os dados foram originados de maneira espontânea e as informações foram consumidas praticamente no mesmo tempo em que foram geradas*; por isso, essas informações não são estruturadas. Esse é outro exemplo de **Big Data**.

O que se apregoa é que de nada adianta armazenar uma montanha de dados se não se sabe como tirar proveito disso para o negócio!


ORIGEM DOS DADOS

O Big Data surge para analisar as *interações, transações e observações de comportamentos*, de forma a proporcionar entendimento dos dados e auxiliar na tomada de decisões. Assim, irá gerar mais experiência, produtividade, consumo e novos produtos e serviços.

Obs.: Big Data = Transações + Interações + Observações



Fonte: Big Data (MAFRA, 2013)



Fonte: Big Data (MAFRA, 2013)

DADOS ESTRUTURADOS, SEMIESTRUTURADOS E NÃO ESTRUTURADOS

Podemos classificar os dados, de acordo com sua estrutura, de três formas: **dados estruturados**, **dados semiestrutturados** e **dados não estruturados**.

- **Dados não estruturados:** são aqueles que **existem em seu estado original (bruto)**, ou seja, **no formato em que foram coletados**. Portanto, **estão em um formato que não possibilita o processamento que produz informações**.

Como exemplos de dados desse tipo, podemos citar textos, imagens, vídeos e documentos, entre outros. Ao contrário dos dados estruturados, os dados não estruturados **não possuem uma estrutura definida**.

- **Dados estruturados:** são o **resultado da obtenção de dados não estruturados e de sua formatação (estruturação)**, visando facilitar o armazenamento, a utilização e a geração de informações. A estrutura (formato) é aplicada com base no tipo de processamento que se deseja executar nos dados.

Os dados estruturados que **descrevem** e permitem **encontrar, gerenciar, compreender** e (ou) **preservar** documentos arquivísticos ao longo do tempo são conhecidos como **metadados**.

Obs.: Alguns dados podem não estar prontos (não estruturados) para determinados tipos de processamento, mas podem estar prontos (estruturados) para outros.

EXEMPLO

O valor de dados 37890 pode se referir a um CEP, a um valor de vendas ou a um código de produto. Se representar um CEP ou um código de produto e for armazenado como texto, não será possível executar cálculos matemáticos com ele. Por outro lado, se esse valor representar uma transação de vendas, será necessário formatá-lo como numérico.

Para ilustrar o conceito de **estrutura**, imagine uma pilha de faturas impressas em papel. Caso deseje simplesmente armazená-las como imagens para recuperação e exibição futura, é possível escaneá-las e salvá-las em formato gráfico. Por outro lado, se desejar obter informações como vendas mensais totais e médias, esse armazenamento gráfico não seria útil. Em vez disso, é possível armazenar os dados das faturas em um formato de planilha (estruturado), de modo a permitir a execução dos cálculos necessários. Na verdade, em sua maioria, os dados que encontramos são mais bem classificados como **semiestruturados**.



Figura. Dados Estruturados, SemiEstruturados e Não Estruturados (UNIVERSIDADE DA TECNOLOGIA, 2019)

Conforme visto na figura, alguns autores também abordam uma **terceira classificação**, conhecida como dados semiestruturados.

- **Dados semiestruturados** são aqueles que **já foram parcialmente processados**. Como o nome pode indicar, são dados que contêm **parte de sua estrutura rígida e outra parte não rígida**. Possuem uma **representação estrutural heterogênea**, não sendo nem completamente não estruturados nem estritamente tipados. Por exemplo, olhando-se uma página comum da web, os dados são apresentados em um formato pré-organizado para transmitir alguma informação.
- As corporações **não** se limitam ao uso de dados **estruturados**; também utilizam dados **semiestruturados** e **não** estruturados.

Esquematizando!

Dados **não** estruturados

Existem em seu estado original (bruto), **sem estrutura prévia definida**.

Maioria dos dados corporativos (cerca de 90%).

Busca e processamento **difícultados**.

Ex: relatórios, memorandos, documentos, imagens, músicas, vídeos, etc.

Dados **semi**estruturados

Representação estrutural heterogêna (não completamente desestruturados e nem fortemente tipados).

Auto-descritivo (esquema de representação está presente (de forma explícita ou implícita) junto com os dados).

Estrutura geralmente **implícita** nos próprios dados.

Ex.: RDF, OWL, XML, etc.

Dados **estruturados**

Esquema **rígido** e previamente planejado, e, portanto, os objetos de dados são conhecidos previamente.

Organização em blocos semânticos (**relações**) e definição de mesmas descrições para dados de um mesmo grupo (atributos).

Busca e processamento mais fáceis.

Ex: Banco de dados.

COMO ARMAZENAR BIG DATA?

Em linhas gerais, o armazenamento pode ser feito tomando-se como base a regra (DATASCIENCEACADEMY, 2022):

Os dados são estruturados ou podem ser estruturados antes do armazenamento? Usamos um data warehouse !	Os dados não são estruturados ou não podem ser estruturados antes do armazenamento? Usamos um Data Lake ou um Data Store !
--	---

- **Data Warehouse**

Um **Data Warehouse (DW)** é um **sistema de armazenamento que conecta e harmoniza grandes quantidades de dados de diversas formas.**




Figura. Data Warehouse (DATASCIENCEACADEMY, 2022)

Obs.: O **Data Warehouse** pode ser considerado uma **coleção de dados orientada por assunto, integrada, não volátil e variante no tempo**, que apoia as decisões da administração.





Figura. Características do Data Warehouse. Fonte: Quintão (2023)

Tem como objetivo **alimentar a inteligência de negócios (Business Intelligence), relatórios e análises, além de oferecer suporte aos requisitos de negócio**, para que as empresas possam transformar seus dados em insights e tomar decisões inteligentes baseadas em dados (DATASCIENCEACADEMY, 2022).

Os **DWs armazenam dados atuais e históricos** em um único lugar.



Os dados fluem para um DW a partir de sistemas transacionais (como ERP e CRM), bancos de dados e fontes externas, como sistemas de parceiros, dispositivos de IoT e aplicativos de mídia social — geralmente em uma cadência regular (DATASCIENCEACADEMY, 2022).

O surgimento da computação em nuvem causou uma mudança no cenário. Nos últimos anos, os locais de armazenamento de dados mudaram da infraestrutura local tradicional para vários ambientes, incluindo nuvens privadas e públicas (DATASCIENCEACADEMY, 2022).

A estrutura dos dados, ou *schema*, **deve** ser definida **antes** do processo de armazenamento.

DATASCIENCEACADEMY (2022) destaca que os DWs modernos são projetados para lidar com dados estruturados e não estruturados, como vídeos, arquivos de imagens e dados de sensores (**embora os Data Lakes ainda sejam opções melhores para dados não estruturados**).

Sem um DW, é muito difícil combinar dados de fontes heterogêneas, garantir que estejam no formato correto para análise e obter uma visão atual e de longo alcance dos dados ao longo do tempo.




Figura. Principais Benefícios do DW (QUINTÃO, 2023)

• Data Lake

O **Data Lake** é **um repositório centralizado que permite armazenar todos os dados estruturados e não estruturados em qualquer escala**. Pode-se armazenar os dados como estão na fonte, sem ter que primeiro estruturá-los e executar diferentes tipos de análises – de painéis e visualizações a processamento de Big Data, análises em tempo real e aprendizado de máquina para orientar melhores decisões (DATASCIENCEACADEMY, 2022).

Dependendo dos requisitos, uma empresa típica exigirá um Data Warehouse e um Data Lake, pois atendem a diferentes necessidades e casos de uso.

A estrutura dos dados, ou schema (esquema), não é definida quando os dados são capturados. Dessa forma, pode-se armazenar **todos os dados em formato bruto, sem a**

necessidade de saber quais perguntas de negócio deverão ser respondidas no futuro (DATASCIENCEACADEMY, 2022).




Figura. Data Lake (DATASCIENCEACADEMY, 2022)

Diferentes tipos de análises (ex.: consultas SQL, análises de Big Data, pesquisa de texto, análises em tempo real e aprendizado de máquina, por exemplo) podem ser usados para descobrir **insights**.

Data Lakes permitem que as empresas gerem diferentes tipos de percepções sobre os dados, desde relatórios de dados históricos até modelos preditivos criados com *Machine Learning*.




Figura. Data Lake (QUINTÃO, 2023)

Para o **DW**, normalmente utilizamos **ETL** (Extração, Transformação e Carga).

Para o **Data Lake**, normalmente usamos **ELT** (Extração, Carga e Transformação).

Data Lakes e **DWs** podem fazer parte de uma grande estrutura central de armazenamento, conhecida como **Data Hub**.

Para que um **Data Lake** torne os dados utilizáveis, ele precisa ter mecanismos definidos para catalogar e proteger os dados. Sem esses elementos, os dados não podem ser considerados confiáveis, resultando em um **Data Swamp** (**Pântano de Dados**). Atender às necessidades de públicos mais amplos exige que os **Data Lakes** tenham governança, gestão de metadados, consistência semântica e controles de acesso.

• Data Store

Um **Data Store** é um **repositório para armazenar e gerenciar de forma persistente coleções de dados** que incluem **não** apenas dados estruturados, mas também tipos variados de armazenamento, como documentos, dados no formato chave-valor, filas de mensagens e outros formatos de arquivo (DATASCIENCEACADEMY, 2022).




Figura. Data Store (QUINTÃO, 2023)

• Data Lakehouse

Cada vez mais, vemos a evolução de uma arquitetura híbrida que está sendo chamada de **Data Lakehouse** (DATASCIENCEACADEMY, 2022).

A ideia fundamental dessa arquitetura é **pegar os melhores conceitos dos modelos de Data Warehouse e Data Lake** e juntá-los, enquanto tenta eliminar os piores conceitos de ambos os modelos (DATASCIENCEACADEMY, 2022)!

Os **Data Lakehouses** permitem que estruturas e esquemas, como os usados em um **Data Warehouse**, sejam aplicados aos dados não estruturados do tipo que normalmente seriam armazenados em um **Data Lake**. Isso significa que os usuários de

dados podem acessar as informações mais rapidamente e começar a colocá-las em prática (DATASCIENCEACADEMY, 2022).




Figura. Data Lakehouse (DATASCIENCEACADEMY, 2022)

O **Data Lakehouse** será a evolução natural no amadurecimento da infraestrutura de dados de uma empresa (DATASCIENCEACADEMY, 2022).

BIG DATA ANALYTICS

- É o trabalho analítico e inteligente de grandes volumes de dados, **estruturados ou não estruturados**, que são coletados, armazenados e interpretados por softwares de altíssimo desempenho (SANTANA, 2018).
- É um termo que se refere à **análise desses conjuntos grandes e complexos de dados estruturados e não estruturados**. São utilizadas ferramentas e equipamentos de alta performance, muitas vezes com o auxílio de **computação distribuída** (utilizando várias máquinas em um trabalho coordenado).
- Geralmente envolve a utilização de algoritmos estatísticos avançados e **análise preditiva**, apontando o que está por vir no futuro e indicando tendências.
- Trata-se do cruzamento de uma infinidade de dados do **ambiente interno e externo**, gerando uma espécie de “**bússola gerencial**” para **tomadores de decisão**. Tudo isso, é claro, em um tempo de processamento extremamente reduzido (SANTANA, 2018).

Obs.: O termo ***Big Data Analytics*** refere-se aos poderosos ***softwares*** que **tratam dados estruturados e não estruturados** para **transformá-los em informações**

úteis às organizações, permitindo-lhes analisar dados como registros de **call center**, postagens de redes sociais, *blogs*, dados de CRM e demonstrativos de resultados.

A seguir, destacamos algumas das fontes usadas por um *software* de **Big Data Analytics** (SANTANA, 2018):

- Dados extraídos de ferramentas de Inteligência de Negócios (**Business Intelligence – BI**);
- Arquivos de *log* de servidores web;
- **Conteúdo de mídias sociais**;
- Relatórios empresariais;
- Textos de *e-mails* de consumidores à empresa;
- Indicadores macroeconômicos;
- Pesquisas de satisfação;
- Estatísticas de ligações celulares capturadas por sensores conectados à “**internet das coisas**”, etc.

Veja também alguns **exemplos de aplicação do Big Data Analytics** (DATASCIENCEACADEMY, 2022):

Uma rede de supermercados pode extrair, armazenar, processar e analisar dados de compras a fim de detectar padrões e organizar os produtos de forma a aumentar as vendas.
Uma companhia aérea pode extrair, armazenar, processar e analisar dados de viagens dos passageiros a fim de oferecer rotas com maior probabilidade de venda.
Uma rede de hotéis pode extrair, armazenar, processar e analisar dados de comentários de clientes em redes sociais para customizar seus serviços, aumentar as vendas e reduzir custos.
Uma rede de hospitais pode extrair, armazenar, processar e analisar dados de exames médicos a fim de personalizar e otimizar o atendimento dos pacientes.

TIPOS DE ANÁLISE

Quando se trata de Big Data, a literatura geralmente destaca **quatro tipos de análises** (VORHIES, 2014):

- **Descritiva**: **foca no presente**, visando descrever características dos dados e eventos correntes para subsidiar decisões de efeitos imediatos.
- **Diagnóstica**: busca **entender as relações de causa e efeito entre eventos**.
- **Preditiva**: tem como objetivo **prever comportamentos futuros** e tendências com base nos dados conhecidos.
- **Prescritiva**: parecida com a análise preditiva, mas **busca prever os efeitos futuros** dos eventos.




Figura. Tipos de Análises (QUINTÃO, 2023)

DIRETO DO CONCURSO

002. (CESPE/TCE-MG/2018) Uma empresa, ao implementar técnicas e softwares de big data, deu enfoque diferenciado à análise que tem como objetivo mostrar as consequências de determinado evento. Essa análise é do tipo

- a) preemptiva.
- b) perceptiva.
- c) prescritiva.
- d) preditiva.
- e) evolutiva.



Conforme visto, a análise **prescritiva** é aquela que **busca os efeitos dos eventos futuros**.
Letra c.

RISCOS PRINCIPAIS

ISACA (2013a) destaca as principais perguntas que devem ser feitas em relação ao *Big Data*, do ponto de vista dos **riscos**. São elas:

- **Onde** os dados serão armazenados?
- **Como** os dados serão protegidos?
- **Como utilizar** os dados de forma **segura** e legal?

Os principais **riscos** que devem ser gerenciados são (Fernandes e Abreu, 2014):

- riscos de **perda de dados** “tóxicos” armazenados como informações privadas ou de custódia, tais como contas de clientes, números de cartão de crédito, segredos industriais da empresa, etc.;
- o **uso de informações obtidas em redes sociais**, por exemplo, abrange **questões de privacidade e de falta de consenso jurídico** internacional, uma vez que cada país tem sua legislação específica;
- **questões de segurança da informação**;
- **qualidade dos dados** capturados para fins de análise;
- **disponibilidade e capacidade da infraestrutura tecnológica** que suporta o *Big Data*;
- **qualidade e capacidade do fornecedor de serviços** (se for o caso) que captura, armazena e/ou realiza análise de dados;
- **qualidade dos modelos de exploração** desenvolvidos para a análise dos dados;
- **pessoas com capacitação requerida** (cientista de dados) **para desenvolver modelos e analisar resultados**;
- **falha ao categorizar e mapear os dados**;
- **falta de governança de dados**, etc.

MITOS SOBRE O BIG DATA

A seguir, confira algumas informações que você já deve ter escutado em algum momento, mas que **NÃO** retratam a realidade.

Mito 01 – Big Data engloba somente dados não estruturados.

Com o crescimento do volume de dados nos últimos anos, o banco de dados relacional precisou ser complementado com outras estruturas. O que mudou, de fato, foi a **inclusão no Big Data de mais tipos de dados, além dos estruturados**.

Mito 02 – Big Data refere-se somente a soluções com petabytes de dados.

Embora o volume de dados seja o fator que impulsionou o Big Data, aplicações que utilizam conjuntos de dados em uma escala menor do que petabytes também podem se beneficiar das tecnologias de Big Data. Afinal, **o mais importante nessas aplicações é a capacidade de extrair valor dos dados**.

Mito 03 – Big Data pode prever o futuro.

Big Data e todas as suas ferramentas **não** podem prever o que vai acontecer no futuro.

É possível **analisar o que aconteceu no passado** e tentar desenhar as **tendências** entre as ações, os pontos de decisão e suas consequências, baseadas nos dados.

Podemos usar isso para **adivinhar** que, em **circunstâncias semelhantes**, se uma decisão similar for tomada, resultados semelhantes ocorrerão como consequência. Mas **não podemos prever o futuro**.

BIG DATA X SMALL DATA

Big Data Grandes volumes de dados, com muita variedade e gerados em alta velocidade.	Small Data Dados que estão disponíveis em quantidade mínima suficiente para a compreensão humana.
---	--

Fonte: (DATASCIENCEACADEMY, 2022)

O QUE É (E NÃO É) ANÁLISE DE BIG DATA

Análise de Big Data tem claramente a capacidade de mudar o jogo, permitindo que organizações ganhem **insights a partir de novas fontes de dados que não foram pesquisadas no passado** (INTEL IT Center, 2013).

Veja o que o INTEL IT Center (2013) relata sobre **o que é, ou não, a análise de Big Data**.

Análise de Big Data é...
Uma estratégia baseada em tecnologia que permite a coleta de insights mais profundos e relevantes dos clientes, parceiros e sobre o negócio — ganhando, assim, uma vantagem competitiva.
Trabalhar com conjuntos de dados cujo porte e variedade estão além da habilidade de captura, armazenamento e análise de softwares de banco de dados típicos .
Processamento de um fluxo contínuo de dados em tempo real , possibilitando a tomada de decisões sensíveis ao tempo mais rápido do que em qualquer outra época.
Distribuído na natureza , o processamento de análise vai aonde estão os dados para maior velocidade e eficiência.
Um novo paradigma no qual a Tecnologia da Informação (TI) colabora com usuários empresariais e “cientistas de dados” para identificar e implementar análises que ampliam a eficiência operacional e resolvem novos problemas empresariais.
Transferir a tomada de decisão dentro da empresa e permitir que as pessoas tomem decisões melhores, mais rápidas e em tempo real.

Análise de Big Data NÃO é...
Só tecnologia . No nível empresarial, refere-se a explorar as amplamente melhoradas fontes de dados para obter <i>insights</i> .
Somente volume . Também se refere à variedade e à velocidade. Mas, talvez mais importante, refere-se ao valor derivado dos dados.

Mais gerada ou utilizada somente por grandes empresas online, como Google ou Amazon. Embora as empresas de internet possam ter sido pioneiras no Big Data na escala web, **aplicativos chegam a todas as indústrias.**

Uso de bancos de dados relacionais tradicionais “tamanho único” criados com base em disco compartilhado e arquitetura de memória. A análise de Big Data usa uma rede de recursos de computação para processamento maciçamente paralelo (PMP).

Um substituto de bancos de dados relacionais ou centros de processamento de dados. Dados estruturados continuam a ser de importância crítica para as empresas. No entanto, sistemas tradicionais podem não ter capacidade de manipular as novas fontes e contextos do Big Data.

DIMENSÕES DO BIG DATA

Para analisar a viabilidade de implementação do Big Data em uma organização, a literatura citava inicialmente as **três dimensões do Big Data**, conhecidas como **3V** (**V**olume, **V**ariiedade e **V**elocidade); depois, o **4V** (incluindo a **V**eracidade) e o **5V** (incluindo o **V**alor).




Figura. 3 Dimensões (3 V's) do Big Data




Figura. Livro *Big Data: Técnicas e tecnologias para extração de valor dos dados*, por Rosângela Marquesone




Figura. 4 Dimensões (4 V's) do Big Data (DATASCIENCEACADEMY, 2022)

Vamos à descrição dessas **cinco dimensões – 5 V's – do Big Data**, que são de grande importância para a prova.



Figura. 5 V's do Big Data

Volume	O volume da informação refere-se ao fato de que certas coleções de dados atingem a faixa de gigabytes (bilhões de bytes), terabytes (trilhões), petabytes (milhares de trilhões) ou mesmo exabytes (milhões de trilhões). Assim, o Big Data deve possibilitar a análise de grandes volumes de dados . Além disso, a tecnologia do Big Data serve exatamente para lidar com esse volume de dados, guardando-os em diferentes localidades e juntando-os por meio de software .
Velocidade	Está relacionada à rapidez com a qual os dados são produzidos e tratados para atender à demanda , o que significa que não é possível armazená-los por completo, de modo que somos obrigados a escolher dados para guardar e outros para descartar. A tecnologia de Big Data agora nos permite analisar os dados no momento em que estes são gerados, sem a necessidade de inseri-los nos bancos de dados . Exemplos de uso envolvendo a tomada de decisão em tempo real: detecção de fraude em transação financeira; detecção de doença grave em <i>check-up</i> ; etc.
Variedade	O Big Data deve ser capaz de lidar com diferentes formatos de informação , como, por exemplo, arquivos de texto, <i>e-mails</i> , medidores e sensores de coleta de dados, vídeo, áudio, dados de ações do mercado ou transações financeiras. Dados são gerados em inúmeros formatos — desde estruturados (numéricos, em bancos de <i>dados</i> tradicionais) a não estruturados (documentos de texto, <i>e-mails</i> , vídeo, áudio, cotações da bolsa e transações financeiras, etc.).
Veracidade	Quanto à veracidade, Weber et al. (2009) ressaltou que as informações verdadeiras podem ser usadas pelos gestores para responder aos desafios estratégicos . A veracidade garantiria, então, a confiabilidade dos dados . Não adianta lidar com a combinação “volume + velocidade + variedade” se não houver dados confiáveis. É necessário que haja processos que garantam a consistência dos dados. A veracidade refere-se mais à proveniência ou à confiabilidade da fonte de dados , seu contexto e à sua utilidade para a análise com base nela.

Valor	Os dados do Big Data devem agregar valor ao negócio . O último V, valor, portanto, considera que informação é poder; informação é patrimônio. Com relação ao valor, Chen <i>et al.</i> (2014) afirmam que as análises críticas de dados podem ajudar as empresas a melhor entender seus negócios, trazendo benefícios. A combinação “volume + velocidade + variedade + veracidade”, além de todo e qualquer outro aspecto que caracteriza uma solução de <i>Big Data</i> , será inviável se o resultado não trazer benefícios significativos que compensem o investimento.
--------------	---

Fonte: <https://goo.gl/QacUvf>

DIRETO DO CONCURSO

003. (CEBRASPE (CESPE)/ANALISTA DA DEFENSORIA PÚBLICA (DPE RO)/ADMINISTRAÇÃO/2022)

O big data, inicialmente caracterizado por três Vs, em 2001, atualmente inclui mais dois Vs. Um dos Vs que caracteriza o big data é

- a) vulnerabilidade.
- b) varonil.
- c) variedade.
- d) vetor.
- e) volátil.



Para analisar a **viabilidade de implementação do Big Data em uma organização**, a literatura citava inicialmente os **3V (Volume, Variedade e Velocidade)**; depois, os **5V (incluindo a Veracidade e o Valor)**.



Figura. 5 V's do Big Data

Conforme visto, a letra C destaca a resposta correta.

Letra c.

004. (FCC/DPE-RS/ANALISTA/BANCO DE DADOS/2017) Os sistemas de Big Data costumam ser caracterizados pelos chamados 3 Vs, sendo que o V de

- a) Veracidade corresponde à rapidez na geração e obtenção de dados.
- b) Valor corresponde à grande quantidade de dados acumulada.
- c) Volume corresponde à rapidez na geração e obtenção de dados.
- d) Velocidade corresponde à confiança na geração e obtenção dos dados.
- e) Variedade corresponde ao grande número de tipos ou formas de dados.



Para analisar a **viabilidade de implementação do Big Data em uma organização**, a literatura citava inicialmente os **3 V's (Volume, Variedade e Velocidade)**; depois, os **5 V's** (incluindo a **Veracidade** e o **Valor**).




Figura. 3 dimensões (3 V's) do Big Data

Vamos à descrição dessas **cinco dimensões – 5 V's – do Big Data**:

Volume	Corresponde à grande quantidade de dados acumulada. Certas coleções de dados atingem a faixa de gigabytes (bilhões de bytes), terabytes (trilhões), petabytes (milhares de trilhões) ou mesmo exabytes (milhões de trilhões).
Variedade	Corresponde ao grande número de tipos ou formas de dados. Os dados de hoje aparecem em todos os tipos de formatos, como, por exemplo, arquivos de texto, e-mails, medidores e sensores de coleta de dados, vídeo, áudio, dados de ações do mercado ou transações financeiras.
Velocidade	Corresponde à rapidez na geração e obtenção de dados. Dessa forma, está relacionada à rapidez com que os dados são <u>produzidos</u> e <u>tratados</u> para atender à demanda, o que significa que não é possível armazená-los por completo, de modo que somos obrigados a escolher dados para guardar e outros para descartar.
Veracidade	Corresponde à confiança na geração e obtenção dos dados. Quanto à veracidade , Weber et al. (2009) ressaltou que as informações verdadeiras podem ser usadas pelos gestores para responder aos desafios estratégicos. A veracidade garantiria, então, a confiabilidade dos dados.

Valor	O último V, valor , considera que informação é poder, informação é patrimônio . Com relação ao valor , as análises críticas de dados podem ajudar as empresas a melhor entender seus negócios, trazendo benefícios. A combinação “volume + velocidade + variedade + veracidade”, além de todo e qualquer outro aspecto que caracteriza uma solução de <i>Big Data</i> , será inviável se o resultado não trouxer benefícios significativos que compensem o investimento.
--------------	---

Conforme visto, a letra E destaca a resposta correta.

Letra e.

A literatura já destaca os **7 V's do Big Data**, englobando os **5 V's (Volume, Velocidade, Variedade, Veracidade e Valor)**, a **Visualização** e a **Variabilidade**.

Visualização	Busca tornar os dados visíveis para os analistas de dados , por exemplo, permitindo que se obtenha a compreensão sobre os dados e comunique conceitos e ideias importantes. As atuais ferramentas de visualização de Big Data enfrentam desafios técnicos devido às limitações da tecnologia (memória, por exemplo) e à baixa escalabilidade, funcionalidade e tempo de resposta. Não se pode confiar em gráficos tradicionais ao tentar plotar um bilhão de pontos de dados; portanto, precisamos de diferentes formas de representar dados, como <i>clustering</i> de dados ou usando mapas de árvore, diagramas de rede circulares etc. Combine isso com a multiplicidade de variáveis resultantes da variedade e velocidade do Big Data e as relações complexas entre elas, e pode-se ver que o desenvolvimento de uma visualização significativa não é fácil.
Variabilidade	Pode aparecer de diversas formas, destacadas a seguir. Variação nas taxas de fluxo de dados (ou velocidade inconstante na carga dos dados) . Muitas vezes, a velocidade do Big Data não é consistente e os fluxos podem ser altamente inconsistentes, com picos periódicos. Todos os dias, picos de dados sazonais ou gerados por eventos particulares podem ser difíceis de gerenciar, ainda mais com dados não estruturados. - Multiplicidade de dimensões de dados resultantes de diferentes fontes de dados (complexidade refere-se ao fato de Big Data gerar ou receber informações através de uma multiplicidade de fontes). Isso impõe um desafio crucial: a necessidade de se conectar, integrar, limpar e transformar os dados recebidos de diferentes fontes. Número de inconsistências nos dados. Nota: A SAS (em https://www.sas.com/pt_br/insights/big-data/what-is-big-data.html) apresentou variabilidade (e complexidade) como duas dimensões <u>adicionais</u> para Big Data.

Mais recentemente, a IBM cita **sete dimensões** que devem ser consideradas ao avaliar a viabilidade de uma solução de *Big Data*.




Figura. Dimensões a serem consideradas ao avaliar a viabilidade de uma solução de big data. Fonte: <http://www.ibm.com/developerworks/br/library/bd-archpatterns2/>

São elas:

- **Volume** dos dados que são capturados;
- **Variedade** das fontes, tipos e formatos dos dados;
- **Velocidade** na qual os dados são gerados, a velocidade em que é preciso agir com relação a eles ou a taxa em que estão mudando;
- **Veracidade** dos dados, ou seja, a incerteza ou fidelidade dos dados;
- **Valor** de negócios do insight que pode ser obtido ao analisar os dados;
- **Pessoas** com aptidões relevantes disponíveis e compromisso de patrocinadores de negócios. Tais aptidões incluem conhecimento do segmento de mercado, domínio técnico sobre as ferramentas de Big Data e conhecimentos específicos de modelagem, estatística, matemática etc.;
- Considerações sobre **governança** para as novas fontes de dados e a maneira como os dados serão usados;

Conforme destaca <https://goo.gl/pr7ksF>, ao decidir pela implementação ou não de uma plataforma de *big data*, uma organização pode estar considerando novas fontes e novos

tipos de elementos de dados nos quais a propriedade do dia não está definida de forma clara. Alguns regulamentos do segmento de mercado regem os dados que são adquiridos e utilizados por uma organização. Por exemplo, no caso de assistência médica, é legal acessar dados de pacientes para obter *insights*? Além da **questão da governança de TI**, também **pode ser necessário redefinir ou modificar os processos de negócios de uma organização para que ela possa adquirir, armazenar e acessar dados externos.**

Veja a seguir **questões relacionadas à governança** (<https://goo.gl/pr7ksF>):

- **Segurança e privacidade** — Cumprindo os regulamentos locais, quais dados a solução pode acessar? Quais dados podem ser armazenados? Quais dados devem ser criptografados durante a movimentação? Quem pode ver os dados brutos e os *insights*?
- **Normalização dos dados** — Existem normas que regem os dados? Os dados estão em um formato proprietário? Parte dos dados está em um formato fora da norma?
- **Intervalo de tempo em que os dados estão disponíveis** — Os dados estão disponíveis em um intervalo de tempo que permita agir de forma rápida?
- **Propriedade dos dados** — Quem detém a posse dos dados? A solução tem acesso e permissão apropriados para usar os dados?
- **Usos permissíveis:** Como é permitido usar os dados?

Em <https://tdwi.org/articles/2017/02/08/10-vs-of-big-data.aspx>, o autor já referencia os **10 V's do Big Data**, que englobam os elementos:

1	Volume	Análise de grandes volumes de dados. Guarda os dados em diferentes localidades e junta-os através de software.
2	Velocidade	Está relacionada à rapidez com a qual os dados são produzidos e tratados para atender à demanda: analisar os dados no instante em que são criados, sem ter de armazená-los em bancos de dados.
3	Variedade	O Big Data deve ser capaz de lidar com diferentes formatos de informação , que são: fontes estruturadas, semiestruturadas e a grande maioria em fontes não estruturadas.
4	Veracidade	Informações verdadeiras podem ser usadas pelos gestores para responder aos desafios estratégicos. A veracidade garantiria, então, a confiabilidade dos dados .
5	Valor	Os dados do Big Data devem agregar valor ao negócio .
6	Visualização	Maneiras diferentes de representar dados.
7	Variabilidade	Variação nas taxas de fluxo de dados (ou velocidade inconstante na carga dos dados). Complexidade – refere-se ao fato de o Big Data gerar ou receber informações através de uma multiplicidade de fontes. Número de inconsistências nos dados.

8	Validade	Semelhante à veracidade, a validade refere-se à precisão e à correção dos dados para o uso pretendido . De acordo com a Forbes, estima-se que 60% do tempo de um cientista de dados é gasto na limpeza de seus dados antes de poder fazer qualquer análise. O benefício da análise de Big Data é tão bom quanto os dados subjacentes; portanto, é necessário adotar boas práticas de controle de dados para garantir a qualidade consistente dos dados, definições comuns e metadados (TDWI, 2017).
9	Vulnerabilidade	Big Data traz novas preocupações de segurança. Afinal, uma violação de dados com Big Data é uma grande preocupação . Alguém se lembra do site Ashley Madison hackeado em 2015? Infelizmente, muitas grandes violações de dados foram reportadas na mídia. Outro exemplo, conforme relatado pela CRN: em maio de 2016, “um hacker chamado Peace postou dados na dark web para vender, que supostamente incluíam informações sobre 167 milhões de contas do LinkedIn e 360 milhões de e-mails e senhas para usuários do MySpace”.
10	Volatilidade	Quantos anos seus dados precisam ter antes de serem considerados irrelevantes, históricos ou inúteis? Por quanto tempo os dados precisam ser mantidos? Devido à velocidade e ao volume de Big Data, no entanto, sua volatilidade precisa ser cuidadosamente considerada. É preciso estabelecer regras para o armazenamento e a garantia da disponibilidade de dados, além de permitir a rápida recuperação das informações quando necessário. Certifique-se de que estes estejam claramente vinculados às necessidades e aos processos comerciais – com Big Data, os custos e a complexidade de um processo de armazenamento e recuperação são ampliados.

PEGADINHA DA BANCA

As bancas examinadoras frequentemente cobram os “Vs” de Big Data, e é crucial que o aluno conheça os mais consensuais (Volume, Velocidade, Variedade, Veracidade e Valor), além de estar ciente de outros que podem aparecer. A inclusão do Valor como um dos principais “Vs” é fundamental, pois reflete a aplicação prática e estratégica do Big Data, um ponto de interesse crescente em questões de governança e gestão de TI.

INGESTÃO DE DADOS

“É o **processo de consumir os dados necessários de forma adequada, eficiente e metódica** (MACHADO, 2018).

Processo **composto** de:

- **Carga de lotes:** você acessa todos os tipos de dados de que precisa e dimensiona com eficiência o desempenho da carga de lotes nos repositórios de dados?

- **Captura de dados de mudanças:** você captura as alterações feitas nos dados dos sistemas de origem sem afetá-los?
- **Fluxo de dados:** você coleta dados de forma confiável em tempo real e os transmite nos repositórios de dados?
- **Arquivamento:** você arquiva e compacta dados que não são usados com frequência, garantindo fácil acesso aos dados arquivados, se necessário?" (MACHADO, 2018, p.310)

GERENCIAMENTO DE DADOS

É a governança de dados, com todas as políticas, processos e práticas necessárias para gerenciar adequadamente a eficácia, a precisão, a confiabilidade e a disponibilidade dos dados (MACHADO, 2018).

Algumas questões envolvidas (MACHADO, 2018):

- **Integração de dados:** você consegue preparar e consolidar várias estruturas e fontes em um conjunto de dados consistente para análise?
- **Qualidade de dados:** você consegue, de forma confiável, limpar os dados, duplicar e remover os erros?
- **Segurança de dados:** você descobre e protege os dados em todos os repositórios de dados, atribuindo para isso regras sobre uso, acesso e permissões?
- **Máquina virtual de dados:** você consegue criar uma camada de abstração para os dados que combinem vagamente o processamento de dados no ambiente de implantação subjacente?" (MACHADO, 2018, p.309)
- **Estrutura distribuída de dados:** você usa tecnologias como o Hadoop para dimensionar de forma econômica suas necessidades de armazenamento e processamento?
- **Data Warehouse (DW):** você possui uma tecnologia de DW que possa lidar com os requisitos de desempenho, uso e dimensionamento para análises e integrações de Big Data com infraestruturas Hadoop, por exemplo?

ENTREGA DE DADOS

É o *processo de envio dos dados necessários aos sistemas e aplicativos que precisam deles* (MACHADO, 2018, p.311).

Algumas questões envolvidas (MACHADO, 2018):

- **Carga de lotes:** você dimensiona com eficiência a carga de lotes de dados entre os sistemas de origem, análise e back-end operacionais?
- **Fluxo de dados em tempo real:** você oferece fluxo de dados em tempo real para sistemas de aplicativos, análises e back-end que precisam disso?

- **Hub de integração de dados:** você disponibiliza dados usando uma abordagem, como o modelo de publicação e assinatura, para evitar a proliferação de integrações ponto a ponto?
- **Visualização de dados:** você entrega dados dos seus sistemas sem sobrecarregá-los?
- **Processamento baseado em eventos:** você é capaz de detectar, “analisar e reagir a ameaças, oportunidades e outros eventos críticos de negócios em tempo real?” (MACHADO, 2018, p.312)

ANÁLISE DE DADOS

São *ferramentas e processos que transformam dados brutos em insights, padrões, previsões e cálculos sobre o domínio que você está analisando* (MACHADO, 2018).

Veja algumas questões relacionadas (MACHADO, 2018):

- **Visualização:** você consegue apresentar dados e resultados de maneira a facilitar a compreensão e o entendimento?
- **Análise avançada:** você consegue aplicar algoritmos analíticos avançados aos seus conjuntos de dados para fazer cálculos complexos? (MACHADO, 2018, p. 312)
- **Aprendizado de máquina:** você consegue aplicar sofisticados algoritmos de aprendizado de máquina para identificar padrões e fazer previsões em um nível para o qual não tem a largura de banda manual compatível? (MACHADO, 2018, p. 312).

ARQUITETURA DO BIG DATA

Uma **arquitetura de Big Data** foi projetada para lidar com a **ingestão**, o **processamento** e a **análise de dados grandes ou complexos** demais para sistemas de banco de dados tradicionais (TEJADA, 2020).

Conforme Tejada (2020), as **soluções de Big Data normalmente envolvem um ou mais dos seguintes tipos de carga de trabalho**, como, por exemplo:

- Processamento em lote (batch processing) de fontes Big Data em repouso;
- Processamento em tempo real de Big Data em movimento (por exemplo, o streaming processing);
- Exploração interativa de Big Data;
- Análise preditiva (a utilização de dados para prever eventos futuros probabilisticamente) e Machine Learning (Aprendizado de Máquina, que usa algoritmos que emulam o processo de aprendizado humano).

Considere o **uso das arquiteturas de Big Data** quando necessário (TEJADA, 2020) para:

- Armazenar e processar dados em volumes muito grandes para um banco de dados tradicional;
- Transformar dados não estruturados para análise e relatório;
- Capturar, processar e analisar fluxos **não** associados de dados em tempo real ou com baixa latência.

Tejada (2020) ilustra na figura a seguir os componentes lógicos que se inserem em uma **arquitetura de Big Data**. As soluções individuais podem **não** conter todos os itens desse diagrama.




Figura. Arquitetura de Big Data (TEJADA, 2020)

A maioria das **arquiteturas de Big Data** inclui alguns ou todos os seguintes componentes (TEJADA, 2020):

- **Fontes de dados (Data Sources)**. Todas as **soluções de Big Data começam com uma ou mais fontes de dados**. Exemplos: armazenamentos de dados de aplicativos, como bancos de dados relacionais; arquivos estáticos produzidos por aplicativos, como arquivos de log do servidor Web; fontes de dados em tempo real, como dispositivos IoT, etc.
- **Armazenamento de dados (Data Storage)**. Os dados de operações de processamento em lotes normalmente são armazenados em um repositório de arquivos distribuído, como Data Lakes, que pode conter amplos volumes de arquivos grandes em vários formatos.
- **Processamento em lotes (Batch Processing)**. Como os conjuntos de dados são muito grandes, geralmente, uma solução de Big Data precisa processar arquivos de dados usando trabalhos em lotes de execução longa para filtrar, agregar e, de outro modo, preparar os dados para análise. Normalmente, esses trabalhos envolvem ler arquivos de origem, processá-los e gravar a saída em novos arquivos.
- **Ingestão de mensagens em tempo real (Real-time Message Ingestion)**. Se a solução inclui fontes em tempo real, a arquitetura precisa incluir uma maneira de capturar e armazenar mensagens em tempo real para processamento de fluxo. Isso pode ser um armazenamento de dados simples, em que as mensagens de entrada são removidas para uma pasta para processamento. No entanto, muitas soluções precisam de um repositório de ingestão de mensagens para atuar como buffer de mensagens e dar

suporte a processamento de expansão, entrega confiável e outras semânticas de enfileiramento de mensagens. Essa parte de uma arquitetura de streaming geralmente é conhecida como buffer de fluxo.

- **Processamento de fluxo (Stream Processing).** Depois de capturar mensagens em tempo real, a solução precisa processá-las filtrando, agregando e preparando os dados para análise. Os dados de fluxo processados são gravados em um coletor de saída.
- **Armazenamento de dados analíticos (Analytical Data Store).** Muitas soluções de Big Data preparam dados para análise e, então, fornecem os dados processados em um formato estruturado que pode ser consultado com ferramentas analíticas.
- **Análise e relatórios (Analytics and Reporting).** A meta da maioria das soluções de Big Data é gerar insights sobre os dados por meio de análise e relatórios.
- **Orquestração (Orchestration).** A maioria das soluções de Big Data consiste em operações de processamento de dados repetidas, encapsuladas em fluxos de trabalho, que transformam dados de origem, movem dados entre várias origens e coletores, carregam os dados processados em um armazenamento de dados analíticos ou enviam os resultados por push diretamente para um relatório ou painel. Para automatizar esses fluxos de trabalho, você pode usar uma tecnologia de orquestração.

O diagrama a seguir destaca o modelo considerado ideal de arquitetura para Big Data, conforme Machado (2018, p. 315):



Figura. Arquitetura ideal de Big Data. Fonte: (MACHADO, 2018, p.315)

ARQUITETURA LAMBDA E ARQUITETURA KAPPA

Com o crescente volume de dados e a necessidade de analisá-los e obtê-los o mais rápido possível, é necessário definir novas arquiteturas para cobrir casos de uso diferentes daqueles utilizados até agora. Nesse contexto, merecem destaque a arquitetura Lambda e a arquitetura Kappa. A principal diferença entre as duas é o **fluxo de processamento de**

dados envolvido. Para isso, cabe diferenciar processamento em lote e processamento de *streaming* (TEJADA, 2020).

- Lote refere-se a um processo que envolve um conjunto de dados e tem um começo e um fim no tempo.
- Pelo contrário, dizemos que um processamento é do tipo streaming quando recebe e trata continuamente novas informações à medida que chegam, sem ter um fim em relação à seção temporária.

ARQUITETURA LAMBDA

A Arquitetura Lambda, representada pela letra grega, apareceu em **2012** e é atribuída a **Nathan Marz**.

Seu objetivo era ter um sistema **robusto e tolerante a falhas**, tanto de hardware quanto humano, linearmente escalável e que permitisse escrever e ler com **baixa latência**.

Nathan resolve esse problema criando uma arquitetura cujo diagrama de alto nível aparece na imagem a seguir:




Figura. Arquitetura Lambda. Fonte: (TEJADA, 2020)

Conforme visto, a **arquitetura Lambda cria dois caminhos para o fluxo de dados**, e todos os dados recebidos pelo sistema passam por esses **dois caminhos** (TEJADA, 2020):

- Uma camada de lote (**caminho frio**) armazena todos os dados de entrada em sua forma bruta e executa o processamento em lotes nos dados. O resultado desse processamento é armazenado como uma exibição de lote. A **camada de lote** alimenta uma camada de serviço que indexa a exibição de lote para uma consulta eficiente.
- Uma camada de velocidade (**caminho quente**) analisa os dados em tempo real. Essa camada foi projetada para baixa latência, em detrimento da precisão. A **camada de velocidade** atualiza a camada de serviço com atualizações incrementais de acordo com os dados mais recentes.

As características da arquitetura Lambda são (JUNIOR, 2019):

- As novas informações coletadas pelo sistema são enviadas para a camada de lote e a camada de **streaming** (referida como camada de velocidade na imagem anterior).
- Na **camada de lote**, as informações brutas são gerenciadas, ou seja, não modificadas. Novos dados são adicionados aos existentes. Em seguida, um tratamento é feito através de um processo em lote, cujo resultado serão as chamadas **Visualizações em Lote**, que serão usadas na camada que serve os dados para oferecer as informações já transformadas no exterior.
- A camada que serve os dados ou camada de **exibição indexa as visualizações** de lote geradas na etapa anterior para que possam ser consultadas com **baixa latência**.
- A camada de **streaming ou Speed Layer** compensa a **alta latência** das gravações que ocorrem na camada de veiculação e leva em consideração apenas os novos dados.
- Por fim, a resposta às consultas feitas é construída combinando os resultados das **Visualizações em Lote e as visualizações em tempo real**, que foram geradas na etapa anterior.

Em resumo, esse tipo de arquitetura é caracterizado pelo uso de diferentes camadas para processamento e streaming em lote.

Uma **desvantagem** da arquitetura de lambda é sua complexidade. A lógica de processamento aparece em dois lugares diferentes (os caminhos frio e crítico), utilizando estruturas distintas. Isso leva a uma lógica de cálculo duplicada e à complexidade de gerenciar a arquitetura para os dois caminhos.

ARQUITETURA KAPPA

A **arquitetura de Kappa** foi proposta em 2014 por Jay Kreps **como uma alternativa à arquitetura de Lambda**.

Ela tem as mesmas metas básicas da arquitetura de *Lambda*, mas com uma diferença importante: **todos os dados fluem por um único caminho, usando um sistema de processamento de fluxo**.




Figura. Arquitetura de Kappa Fonte: (TEJADA, 2020)

Há algumas semelhanças na camada de lote da arquitetura de Lambda, em que os dados do evento são imutáveis e todos eles são coletados, em vez de um subconjunto. Os dados são ingeridos como um fluxo de eventos em um *log* unificado, distribuído e tolerante a falhas. Esses eventos são ordenados, e o estado atual de um evento é alterado somente por um novo evento que está sendo acrescentado. Semelhante à camada de velocidade da arquitetura de *Lambda*, todo o processamento de eventos é feito no fluxo de entrada e persistido como uma exibição em tempo real (TEJADA, 2020).

Se você precisar recalcular todo o conjunto de dados (equivalente ao que a camada de lote faz no *Lambda*), basta reproduzir o fluxo, normalmente usando o paralelismo para concluir o cálculo em tempo hábil (TEJADA, 2020).

DIRETO DO CONCURSO

005. (FGV/ANALISTA DE TECNOLOGIA DA INFORMAÇÃO DA FAZENDA ESTADUAL (SEFAZ AM)/2022) Com relação às arquiteturas de big data, analise as afirmativas a seguir.

I – As arquiteturas de big data suportam um ou mais tipos de carga de trabalho, por exemplo, processamento em lote de fontes de big data em repouso; processamento em tempo real de big data em movimento; exploração interativa de big data e análise preditiva e aprendizado de máquina.

II – A arquitetura kappa aborda o problema da baixa latência criando dois caminhos para o fluxo de dados. Todos os dados que entram no sistema passam por dois caminhos: a camada de lote (caminho frio) que armazena os dados de entrada em sua forma bruta e executa o processamento os dados em lote, e a camada de velocidade (hot path) que analisa os dados em tempo real. Essa camada é projetada para ter baixa latência, em detrimento da precisão.

III – A arquitetura lambda, posterior à kappa, foi proposta para ser uma alternativa para mitigar os problemas da baixa latência. Lambda tem os mesmos objetivos da kappa, mas com uma distinção importante: todos os dados fluem por um único caminho, usando um sistema de processamento de fluxo de dados. Semelhante à camada de velocidade da arquitetura lambda, todo o processamento de eventos é realizado através de um fluxo único de entrada. Está correto o que se afirma em

- a) I, apenas.
- b) II, apenas.
- c) III, apenas.
- d) I e II, apenas.
- e) II e III, apenas.



I – Certa. Conforme visto, as soluções de Big Data normalmente envolvem um ou mais dos seguintes **tipos de carga de trabalho**:

- Processamento em lote de fontes Big Data em repouso.
- Processamento em tempo real de Big Data em movimento.
- Exploração interativa de Big Data.
- Análise preditiva e *machine learning*.

II – Errada. A **arquitetura Lambda é que cria dois caminhos para o fluxo de dados**. Todos os dados recebidos pelo sistema passam por esses dois caminhos:

- Uma camada de lote (caminho frio) armazena todos os dados de entrada em sua forma bruta e executa o processamento em lotes nos dados. O resultado desse processamento é armazenado como uma exibição de lote.
- Uma camada de velocidade (caminho quente) analisa os dados em tempo real. Essa camada foi projetada para baixa latência, em detrimento da precisão.




Figura. Arquitetura Lambda

III – Errada. Conceitos invertidos! A arquitetura de Kappa foi proposta por Jay Kreps como uma alternativa à arquitetura de Lambda.

Letra a.

CAMADAS LÓGICAS DE UMA SOLUÇÃO DE BIG DATA

Conforme destacam (MYSORE; KHUPAT; JAIN, 2014), as **camadas** proporcionam uma maneira de organizar componentes que realizam funções específicas. **Uma solução de Big Data possui camadas horizontais e verticais** (MYSORE; KHUPAT; JAIN, 2014):

Camada horizontal	Camada vertical
Camadas de “baixo” para “cima” na figura. São elas: Fontes de <i>Big Data</i> , Camada de Tratamento e Armazenamento de Dados, Camada de Análise, e Camada de consumo.	Lidam com aspectos que afetam todos os componentes das camadas lógicas (fontes de big data, tratamento e armazenamento de dados, análise e consumo). São elas: Integração de informações, Governança de <i>Big Data</i> , Gerenciamento de sistemas e Qualidade de serviço.

Vamos à descrição dessas camadas!

Camadas horizontais

Tabela: Camadas horizontais (MYSORE; KHUPAT; JAIN, 2014)

Camada horizontal	Descrição
Fontes de Big Data	Inclui todas as fontes de dados necessárias para proporcionar o insight necessário para solucionar o problema de negócios. Os dados são <u>estruturados</u>, <u>semiestruturados</u> e <u>não estruturados</u> e provêm de várias fontes: • sistemas corporativos legados; • sistemas de gerenciamento de dados; • armazenamentos de dados (incluem armazéns de dados corporativos e bancos de dados operacionais e transacionais); • dispositivos inteligentes (podem capturar, processar e comunicar informações na maioria dos protocolos e formatos mais usados. Por exemplo, smartphones, medidores e dispositivos de assistência médica); • outras fontes de dados, como: <i>informações geográficas; conteúdo gerado por seres humanos; mídia social, e-mail, blogs e informações online; dados de sensores etc.</i>
Camada horizontal	Descrição

Camada de tratamento e armazenamento de dados	Responsável por adquirir dados das fontes e, se necessário, convertê-los para um formato adequado à maneira como os dados devem ser analisados. Atividades: Aquisição de dados — Adquire dados de várias fontes e os envia ao componente de digestão de dados ou os armazena em locais específicos. Esse componente precisa ser inteligente o suficiente para decidir se deve armazenar os dados recebidos e onde armazená-los. Deve poder determinar se é necessário tratar os dados antes de armazená-los ou se é possível enviar os dados diretamente para a camada de análise de negócios. Compilação de dados — Responsável por tratar os dados no formato necessário para atingir o objetivo da análise. Esse componente pode ter lógica transformacional simples ou algoritmos estatísticos completos para converter os dados de origem. O mecanismo de análise determina os formatos específicos de dados que são necessários. O maior desafio é acomodar formatos de dados não estruturados, como imagens, áudio, vídeo etc. Armazenamento de dados distribuídos — responsável por armazenar os dados das fontes. Frequentemente, há várias opções de armazenamento de dados disponíveis nessa camada, como distributed file storage (DFS), nuvem, fontes de dados estruturados, NoSQL etc.
Camada horizontal	Descrição
Camada de Análise	Lê os dados digeridos pela camada de tratamento e armazenamento de dados. Em alguns casos, a camada de análise acessa os dados diretamente na fonte. É fundamental um planejamento cuidadoso para projetar a camada de análise. É necessário tomar decisões em relação a como gerenciar tarefas para: • produzir a análise desejada; • obter <i>insights</i> a partir dos dados; • localizar as entidades necessárias. • localizar as fontes de dados que fornecem dados para essas entidades; • entender quais algoritmos e ferramentas são necessários para realizar a análise.
Camada de consumo	Essa camada consome a saída fornecida pela camada de análise. Os consumidores podem ser aplicativos de visualização, seres humanos, processos de negócios ou serviços. Pode ser difícil visualizar a saída da camada de análise. Às vezes, é útil ver o que os concorrentes em mercados semelhantes estão fazendo.

Cada camada inclui vários tipos de componentes, conforme ilustrado a seguir.




Figura. Componentes por camada. Fonte: <http://www.ibm.com/developerworks/br/library/bd-archpatterns3/>

Camadas verticais

Camada vertical	Descrição
Integração de informações	Aplicativos de <i>Big Data</i> adquirem dados de várias origens, fornecedores e fontes. Essa camada vertical é usada por vários componentes (aquisição de dados, compilação de dados, gerenciamento de modelo e interceptor de transação, por exemplo) e é responsável por conectar várias fontes de dados . Também pode ser usada por componentes para armazenar informações em armazenamentos de big data e para recuperar informações desses armazenamentos para processamento. A maioria dos armazenamentos de big data possui serviços e APIs para armazenar e recuperar as informações.
Governança de <i>Big Data</i>	Ajuda a lidar com as complexidades, o volume e a variedade de dados dentro da empresa ou oriundos de fontes externas. São necessárias diretrizes e processos sólidos para monitorar, estruturar, armazenar e proteger os dados desde o momento em que entram na empresa, são processados, armazenados, analisados e removidos ou arquivados. A governança para big data inclui fatores, como: gerenciar grandes volumes de dados em diversos formatos; treinar e gerenciar continuamente os modelos estatísticos necessários para pré-processar dados não estruturados e analíticos (lembre-se de que essa etapa é importante ao lidar com dados não estruturados!); definir políticas e regulamentos de conformidade para retenção e uso de dados externos; definir políticas de arquivamento e remoção de dados; criar a política sobre a maneira como os dados podem ser replicados em vários sistemas; definir políticas de criptografia de dados.
Gerenciamento de sistemas	O gerenciamento de sistema é essencial para big data e inclui as seguintes ações: gerenciar os logs de sistemas, máquinas virtuais, aplicativos e outros dispositivos; correlacionar os vários logs e ajudar a investigar e monitorar a situação; monitorar alertas e notificações em tempo real; fazer referência a relatórios e análises detalhadas sobre o sistema; definir e cumprir os contratos de nível de serviço; arquivar e gerenciar a recuperação de arquivos; realizar a recuperação de sistema, etc.
Camada de qualidade de serviço	Responsável por definir a qualidade dos dados, políticas relacionadas à privacidade e segurança, frequência de dados, tamanho de busca e filtros de dados.

Tabela: Camadas verticais (MYSORE; KHUPAT; JAIN, 2014)

Conforme destaca o site <https://www.ibm.com/developerworks/br/library/bd-archpatterns4/index.html>, a IBM definiu uma série de **padrões** que nos ajudam a **definir a arquitetura da solução de Big Data**.

Esses padrões podem ser classificados em **atômicos (Atomic Patterns)**, **compostos (Composite Patterns)** e **de soluções (Solution Patterns)**.




Figura. Padrões

- Os **padrões atômicos** são os que fornecem as bases para a solução de *Big Data*.
- Os **padrões compostos e de solução** são mais abrangentes e variados, muitas vezes utilizando uma composição de padrões atômicos para definir a solução de Big Data.
- A IBM também destaca que **não** há sequência ou ordem recomendada em que os padrões de solução, compostos ou atômicos devem ser aplicados para chegar a uma solução.




Figura. Padrões Utilizados em Soluções de Big Data. Fonte: Quintão (2020)

CONCEITOS FUNDAMENTAIS E TERMINOLOGIA PARA CONCURSOS

Para aprofundar a compreensão do universo de Big Data e preparar-se para as nuances das provas de concurso, é essencial dominar alguns conceitos e terminologias específicas, destacados a seguir.

Esses termos são a base de muitas questões de Big Data, Arquitetura de Dados e Banco de Dados em concursos. A distinção clara entre SQL e NoSQL, ETL e ELT, OLTP e OLAP, além do entendimento de MDM e Qualidade de Dados, é frequentemente cobrada, tanto em questões conceituais quanto em cenários práticos.

NoSQL vs. SQL (Bancos de Dados Relacionais)

- **SQL (Structured Query Language) e Bancos de Dados Relacionais**
 - **Características:** Modelagem de dados baseada em tabelas, esquemas fixos (*schema-on-write*), transações ACID (Atomicidade, Consistência, Isolamento, Durabilidade) e forte consistência.
 - **Uso:** Sistemas OLTP (*Online Transaction Processing*), em que a integridade dos dados é crítica e o volume de transações é alto, mas a variedade e a velocidade dos dados são mais controladas.
 - **Exemplos:** MySQL, PostgreSQL, Oracle e SQL Server.
- **NoSQL (Not Only SQL) e Bancos de Dados Não Relacionais**
 - **Características:** Modelagem flexível (*schema-on-read*), escalabilidade horizontal, alta disponibilidade, consistência eventual (BASE – *Basically Available, Soft state, Eventually consistent*). Não impõem um esquema rígido.
 - **Uso:** Big Data, aplicações web em larga escala, dados não estruturados ou semiestruturados, em que a velocidade e a variedade são mais importantes que a consistência imediata.
 - **Tipos Comuns:**
 - **Documento:** Armazenam dados em documentos JSON, BSON ou XML (ex.: MongoDB, Couchbase).
 - **Chave-Valor:** Armazenam dados como um dicionário de chave-valor (ex.: Redis, DynamoDB).
 - **Colunar:** Armazenam dados em colunas, otimizados para agregação (ex.: Apache Cassandra, HBase).
 - **Grafo:** Armazenam dados como nós e arestas, otimizados para relações complexas (ex.: Neo4j).

ETL (Extract, Transform, Load) vs. ELT (Extract, Load, Transform)

Ambos são processos de integração de dados, mas com abordagens diferentes:

- **ETL (Extract, Transform, Load):**
 - **Processo:** os dados são **extraídos** da fonte, **transformados** (limpeza, padronização, agregação) em um servidor intermediário e, então, **carregados** no destino (geralmente um Data Warehouse).
 - **Uso:** ambientes com recursos de processamento limitados no destino, Data Warehouses tradicionais, em que a qualidade dos dados é garantida antes do carregamento.
- **ELT (Extract, Load, Transform):**
 - **Processo:** Os dados são **extraídos** da fonte, **carregados** diretamente no destino (geralmente um Data Lake ou Data Warehouse moderno) e, então, **transformados** dentro do próprio ambiente de destino.
 - **Uso:** Ambientes de Big Data com alta capacidade de processamento no destino (ex.: Spark, Data Warehouses em nuvem), permitindo armazenar dados brutos e transformá-los conforme a necessidade.

Data Mart vs. Data Warehouse

- **Data Warehouse (DW):**
 - **Definição:** Um repositório centralizado de dados integrados, orientados por assunto, não voláteis e variantes no tempo, projetado para suporte à decisão. Abrange toda a organização.
 - **Escopo:** Amplo, corporativo.
- **Data Mart (DM):**
 - **Definição:** Uma versão menor e mais focada de um Data Warehouse, projetada para atender às necessidades de um departamento ou área de negócio específica.
 - **Escopo:** Departamental, específico.

OLTP (Online Transaction Processing) vs. OLAP (Online Analytical Processing)

- **OLTP (Online Transaction Processing):**
- **Foco:** Processamento de transações diárias, como inserções, atualizações e exclusões de registros.
- **Características:** Alta concorrência, pequenas transações, dados atuais e normalização de dados para evitar redundância.
- **Uso:** Sistemas operacionais (bancos, e-commerce, ERP).
- **OLAP (Online Analytical Processing):**
- **Foco:** Análise de dados históricos e complexos para suporte à decisão.
- **Características:** Baixa concorrência, consultas complexas, dados históricos, desnormalização (esquema estrela/floco de neve) para otimizar consultas.
- **Uso:** Data Warehouses, Business Intelligence.

Master Data Management (MDM)

- **Definição:** Um conjunto de processos, governança, políticas, padrões e ferramentas que definem e gerenciam os dados mestres de uma organização (dados críticos e não transacionais, como clientes, produtos, fornecedores e localização).
- **Objetivo:** Criar uma “visão única da verdade” para os dados mais importantes, garantindo consistência, acurácia e integridade em todos os sistemas.

Dimensões da qualidade de dados

A qualidade dos dados é crucial para a confiabilidade das análises de Big Data. As principais dimensões incluem:

- **Acurácia (Accuracy):** Os dados refletem a realidade? Estão corretos?
- **Completeness (Completeness):** Todos os dados necessários estão presentes? Não há valores ausentes?
- **Consistência (Consistency):** Os dados são consistentes entre diferentes sistemas e ao longo do tempo? Não há contradições?
- **Validade (Validity):** Os dados estão em conformidade com as regras de negócio e formatos esperados?
- **Pontualidade (Timeliness):** Os dados estão disponíveis quando necessários e são suficientemente recentes para a finalidade?
- **Unicidade (Uniqueness):** Não há duplicatas nos dados?

APACHE HADOOP: O ECOSISTEMA PARA BIG DATA

- Quando nos referimos a *Big Data*, apenas um banco de dados do tipo **não** basta. É necessário também contar com **ferramentas** (ex.: **Hadoop** é a principal referência) **que permitam o tratamento correto do volume de dados.**
- **Hadoop:** **plataforma open source** desenvolvida especialmente para **processamento e análise de grandes volumes de dados, sejam eles estruturados ou não estruturados.**

Apache Hadoop é uma **estrutura de software de código aberto** para **armazenamento distribuído e processamento de grandes conjuntos de dados** em *clusters* de computadores, utilizando modelos de programação simples. É a base para muitas soluções de Big Data.

- **É utilizado em larga escala por grandes corporações**, como Facebook e Twitter, **em aplicações de Big Data.**
- Útil para aplicações que envolvam dados massivos para processamento paralelo (embora seja interessante para processamento de quaisquer dados), geralmente utilizando um *cluster* de computadores (Devmedia, 2016).
- Trata-se de um **projeto da Apache** de alto nível, que vem sendo construído por uma comunidade de colaboradores, utilizando em sua maior parte a linguagem de

programação Java, com algum código nativo em C e alguns **utilitários de linha de comando** escritos utilizando *scripts shell* (Wikipedia, 2016).

Obs.: O **Hadoop** é um **projeto Apache**, criado e mantido por uma comunidade de empresas e profissionais. Foi **inspirado no MapReduce e no GoogleFS**.




Figura. Pacote Apache Hadoop. O pacote de software Hadoop inclui uma série de componentes. Fonte: Intel Corporation (2013)

- Pode-se dizer que o projeto teve início em meados de 2003, quando o Google criou um **modelo de programação que distribui o processamento a ser realizado entre vários computadores para ajudar o seu mecanismo de busca a ficar mais rápido e livre das necessidades de servidores poderosos** (e caros). Esta tecnologia recebeu o nome de **MapReduce**.
- **Plataforma de software em Java, de computação distribuída**, voltada para **clusters** e processamento de grandes massas de dados, inspirada no **MapReduce** e no **GoogleFS (GFS)**.

DIRETO DO CONCURSO

006. (CEBRASPE (CESPE)/PROFISSIONAL PETROBRAS DE NÍVEL SUPERIOR (PETROBRAS)/CIÊNCIA DE DADOS/2022) Com referência aos conceitos de banco de dados e data warehouse, julgue o item seguinte.

O Hadoop Distributed File System (HDFS) é construído usando a linguagem Java, o que permite que sua arquitetura mestre/escravo seja implementada em uma ampla variedade de máquinas.



Conforme https://hadoop.apache.org/docs/r1.2.1/hdfs_design.html, o *Hadoop Distributed File System* (HDFS) é construído usando a **linguagem Java**; qualquer máquina que suporte Java pode executar o software **NameNode** ou **DataNode**. O uso da linguagem Java, altamente portátil, significa que o HDFS pode ser implementado em uma ampla variedade de máquinas.

Certo.

007. (ESAF/ANAC/ANALISTA ADMINISTRATIVO/2016) Para o processamento de grandes massas de dados, no contexto de Big Data, é muito utilizada uma plataforma de software em Java, de computação distribuída, voltada para clusters, inspirada no MapReduce e no GoogleFS. Esta plataforma é o(a)

- a) Yam Common.
- b) GoogleCrush.
- c) EMRx.
- d) Hadoop.
- e) MapFix.



Hadoop é uma **solução de código aberto (open source)**, inspirada no MapReduce e no GoogleFS, que permite a execução de aplicações de Big Data utilizando milhares de máquinas. Oferece recursos de armazenamento, gerenciamento e processamento distribuído de dados.

Letra d.

008. (ESAF/ESAF/GESTÃO E DESENVOLVIMENTO DE SISTEMAS/2015-ADAPTADA) O Hadoop, o mais conhecido e popular sistema para gestão de Big Data, foi criado pela IBM, a partir de sua ferramenta de Data Mining WEKA.



O **Hadoop** é um **projeto Apache**, criado e mantido por uma comunidade de empresas e profissionais. Foi **inspirado no MapReduce e no GoogleFS**, e não no Data Mining WEKA destacado na questão!

Errado.

Alguns conceitos importantes relacionados ao Hadoop:

- **MapReduce**: é um modelo de programação que permite processar grandes conjuntos de dados em paralelo em um *cluster* de servidores. O modelo MapReduce divide um problema em pequenas tarefas independentes que são distribuídas em diferentes servidores para serem processadas em paralelo.
- **HDFS**: é o **sistema de arquivos distribuídos do Hadoop**, projetado para armazenar grandes conjuntos de dados em *cluster* de servidores.
- **YARN**: é o **gerenciador de recursos do Hadoop**, que gerencia a alocação de recursos em um *cluster* de servidores.
- **Hive**: é uma plataforma de data warehouse construída no Hadoop, que permite executar consultas SQL em grandes conjuntos de dados armazenados no HDFS.
- **Pig**: é uma plataforma de análise de dados do Hadoop, que permite executar *scripts* em uma linguagem de programação própria, chamada Pig Latin.
 - A figura seguinte refere-se aos **Componentes do Hadoop**. Num **cluster** constituído por uma máquina mestre e várias máquinas escravas, esse ambiente pode ser visualizado através de uma máquina-cliente, dotada de uma interface web.




Figura. Componentes do Hadoop. Fonte: (UFSC, 2022)

Componentes principais do Hadoop

O ecossistema Hadoop é composto por vários módulos, sendo os mais centrais:

1. HDFS (Hadoop Distributed File System):

- **Definição**: Um sistema de arquivos distribuído, altamente tolerante a falhas, projetado para ser executado em hardware de baixo custo. Ele armazena dados em blocos grandes (geralmente 128 MB ou 256 MB) e os distribui por vários nós do cluster.

HDFS é o *sistema de arquivos distribuído do Hadoop*, projetado para armazenar grandes conjuntos de dados em *clusters* de servidores.

- **Arquitetura:**

- **NameNode (Master):** O nó mestre que gerencia o namespace do sistema de arquivos e regula o acesso dos clientes aos arquivos. Ele armazena os metadados do HDFS (estrutura de diretórios, permissões, localização dos blocos de dados). É um ponto crítico de falha, embora existam soluções para alta disponibilidade (HA).
- **DataNode (Slave):** Os nós escravos que armazenam os blocos de dados reais. Eles reportam periodicamente ao NameNode sobre os blocos que armazenam e seu status.
- **Secondary NameNode (Opcional):** Não é um substituto para o NameNode, mas ajuda a consolidar os logs de transações do NameNode para evitar que o arquivo de metadados se torne muito grande, auxiliando na recuperação em caso de falha do NameNode principal.

- **Replicação de Blocos:** Para garantir tolerância a falhas e alta disponibilidade, cada bloco de dados é replicado em vários DataNodes (o fator de replicação padrão é **3**). Se um DataNode falhar, os dados ainda estarão disponíveis em outras réplicas.
- **Rack Awareness:** O HDFS tenta armazenar réplicas de blocos em diferentes racks de servidores para proteger contra falhas de rack inteiro, otimizando a leitura de dados.

2. YARN (Yet Another Resource Negotiator):

- **Definição:** O framework de gerenciamento de recursos e agendamento de tarefas do Hadoop. Ele permite que diferentes motores de processamento (como MapReduce, Spark, Tez) compartilhem o mesmo cluster Hadoop.
- **Componentes:**
 - **ResourceManager (Global):** O componente mestre que gerencia os recursos de todo o cluster. Ele é responsável por alocar recursos (CPU, memória) para as aplicações.
 - **NodeManager (Por Nó):** Um agente que é executado em cada nó de trabalho e é responsável por gerenciar os recursos disponíveis nesse nó e monitorar o uso dos recursos pelos contêineres.
 - **ApplicationMaster (Por Aplicação):** Um processo que é executado para cada aplicação submetida ao YARN. Ele negocia recursos com o ResourceManager e trabalha com o NodeManager para executar e monitorar as tarefas da aplicação.

3. MapReduce:

- **Definição:** Um modelo de programação e um motor de execução para processar grandes conjuntos de dados em paralelo em um cluster distribuído.
- **Funcionamento:** Divide o problema em duas fases principais:

- **Map (Mapeamento):** Processa pares chave-valor de entrada para gerar um conjunto de pares chave-valor intermediários. Cada “mapper” trabalha independentemente em uma parte dos dados.
- **Shuffle & Sort (Embaralhamento e Ordenação):** Os pares chave-valor intermediários são agrupados por chave e ordenados. Essa fase prepara os dados para a fase Reduce, garantindo que todos os valores para uma mesma chave sejam enviados para o mesmo “reducer”.
- **Reduce (Redução):** Processa os pares chave-valor agrupados para gerar o resultado final. Cada “reducer” agrega os valores associados a uma chave específica.
- **Exemplo:** Contagem de palavras em um grande arquivo de texto. O Map contaria as palavras em cada linha, gerando (palavra, 1). O Shuffle & Sort agruparia todas as ocorrências da mesma palavra. O Reduce somaria os ‘1’s para cada palavra, resultando em (palavra, contagem_total).
- **Uma execução típica de uma aplicação Hadoop em um cluster utiliza *cinco processos diferentes*:**
 - NameNode,
 - DataNode,
 - SecondaryNameNode,
 - JobTracker, e
 - TaskTracker.

Os componentes NameNode, JobTracker e SecondaryNameNode são únicos para toda a aplicação, enquanto o DataNode e o TaskTracker são instanciados para cada máquina.

Vamos às descrições principais, conforme (UFSC, 2022):

NameNode	Tem a responsabilidade de gerenciar os arquivos armazenados no HDFS. Suas funções incluem mapear a localização, realizar a divisão dos arquivos em blocos, encaminhar os blocos aos nós escravos, obter os metadados dos arquivos e controlar a localização de suas réplicas. Como o NameNode é constantemente acessado, por questões de desempenho, ele mantém todas as suas informações em memória. Ele integra o sistema HDFS e fica localizado no nó mestre da aplicação, juntamente com o JobTracker.
DataNode	Enquanto o NameNode gerencia os blocos de arquivos, são os DataNodes que efetivamente realizam o armazenamento dos dados. Como o HDFS é um sistema de arquivos distribuído, é comum a existência de diversas instâncias do DataNode em uma aplicação Hadoop, para que possam distribuir os blocos de arquivos em diversas máquinas. Um DataNode poderá armazenar múltiplos blocos, inclusive de diferentes arquivos. Além de armazenar, eles precisam se reportar constantemente ao NameNode, informando quais blocos estão guardando, bem como todas as alterações realizadas localmente nesses blocos.

JobTracker	Assim como o NameNode, o JobTracker também possui uma função de gerenciamento; porém, nesse caso, o controle é realizado sobre o plano de execução das tarefas a serem processadas pelo MapReduce. Sua função, então, é designar diferentes nós para processar as tarefas de uma aplicação e monitorá-las enquanto estiverem em execução. Um dos objetivos do monitoramento é, em caso de falha, identificar e reiniciar uma tarefa no mesmo nó ou, em caso de necessidade, em um nó diferente.
TaskTracker	Processo responsável pela execução de tarefas MapReduce. Assim como os DataNodes, uma aplicação Hadoop é composta por diversas instâncias de TaskTracker, cada uma em um nó escravo. Um Task Tracker executa uma tarefa Map ou uma tarefa Reduce designada a ele. Como os TaskTrackers rodam sobre máquinas virtuais, é possível criar várias máquinas virtuais em uma mesma máquina física, de forma a explorar melhor os recursos computacionais.
Secondary Name Node	Utilizado para auxiliar o NameNode a manter seu serviço e ser uma alternativa de recuperação no caso de uma falha do NameNode. Sua única função é realizar pontos de checagem (<i>checkpointing</i>) do NameNode em intervalos predefinidos, de modo a garantir a sua recuperação e atenuar o seu tempo de reinicialização.

Como se resume a arquitetura do Hadoop Distributed File System (HDFS)?

Entre algumas opções, o **Apache Hadoop HDFS (Hadoop Distributed File System)** tem se mostrado a solução ideal para **gerenciar o armazenamento distribuído** em um **cluster** de computadores.

O HDFS é o software responsável pela gestão do *cluster* de computadores, definindo **como os arquivos serão distribuídos por meio do cluster**.

Com o HDFS, podemos construir um **Data Lake** que roda sobre um *cluster* de computadores e permite o armazenamento de grandes volumes de dados com *hardware commodity* (de baixo custo).

Isso permitiu que o Big Data fosse usado em larga escala!

Conforme HFSC (2022), o **Hadoop Distributed FileSystem (HDFS)** é implementado sobre a **arquitetura mestre/escravo**, possuindo, no lado mestre, uma instância do NameNode e, em cada escravo, uma instância do DataNode.

Em um cluster Hadoop, podemos ter centenas ou milhares de máquinas escravas, e, dessa forma, elas precisam estar dispostas em diversos armários (**racks**). (Armário: conjunto de máquinas alocadas em um mesmo espaço físico e interligadas por um comutador (*switch*)).




Figura. Racks de Exemplo (DATASCIENCEACADEMY, 2022)

Por questões estratégicas, **o HDFS organiza a armazenagem dos blocos dos arquivos e suas réplicas em diferentes máquinas e armários**. Assim, mesmo ocorrendo uma falha em um armário inteiro, os dados podem ser recuperados e a aplicação não precisaria ser interrompida.

O **NameNode é o componente central do HDFS**; assim, é recomendável que seja implantado em um nó exclusivo e, preferencialmente, no nó com melhor desempenho do aglomerado. Ainda por questões de desempenho, o NameNode mantém todas as suas informações em memória.

Em uma aplicação Hadoop, cada nó escravo contém um DataNode, que trabalha em conjunto com um TaskTracker, sendo o primeiro responsável pelo armazenamento e o segundo, pelo processamento dos dados.

Como funciona o Hadoop MapReduce?

O paradigma de programação **MapReduce** implementado pelo Hadoop inspira-se em duas funções simples (Map e Reduce) presentes em diversas linguagens de programação funcionais (UFSC, 2022).

- A **função Map** recebe uma lista como entrada e, aplicando uma função dada, gera uma nova lista como saída.
- A **função Reduce**, similarmente à função Map, recebe como entrada uma lista e, em geral, aplica uma função para que a entrada seja reduzida a um único valor na saída.

DIRETO DO CONCURSO

009. (FGV/AUDITOR FISCAL DA RECEITA ESTADUAL (SEF MG)/TECNOLOGIA DA INFORMAÇÃO/2023)

O HDFS foi projetado para armazenar arquivos grandes como uma sequência de blocos.

Em relação à replicação dos dados, assinale a afirmativa incorreta.

- a) A replicação de blocos de dados não ocorre quando o NameNode está no estado Safemode.
- b) O fator de replicação pode ser especificado no momento da criação de um arquivo e pode ser alterado posteriormente.
- c) Os arquivos no HDFS são de gravação única (write-once) com exceção para acréscimos e truncamentos, e têm estritamente um writer a qualquer momento.
- d) Um bloco é considerado replicado com segurança quando as três réplicas desse bloco de dados são verificadas com o NameNode.
- e) Como o NameNode não permite que os DataNodes tenham várias réplicas do mesmo bloco, o número máximo de réplicas criadas é o número total de DataNodes naquele momento.



Por padrão, o fator de replicação do HDFS é 3; no entanto, esse número pode variar conforme o ambiente de clusters, ou seja, pode ser alterado para os valores necessários de acordo com os requisitos da arquitetura, editando os arquivos de configuração (hdfs-site.xml).

```
dfs.replication (data replication value) = 1
(In the below given path /hadoop/ is the user name.
hadoopinfra/hdfs/namenode is the directory created by hdfs file system.)
namenode path = //home/hadoop/hadoopinfra/hdfs/namenode
(hadoopinfra/hdfs/datanode is the directory created by hdfs file system.)
datanode path = //home/hadoop/hadoopinfra/hdfs/datanode
```

Figura. HDFS-site. Xml (OEIRAS, 2020)

Letra d.

APACHE SPARK: PROCESSAMENTO RÁPIDO E VERSÁTIL

Apache Spark é um motor de processamento de dados unificado e de código aberto, projetado para análise de dados em larga escala. Ele é significativamente mais rápido que o MapReduce para muitas cargas de trabalho, especialmente para processamento iterativo e interativo, devido ao seu uso intensivo de memória (in-memory processing).

- Uma ferramenta Big Data que tem o objetivo de **processar grandes conjuntos de dados de forma paralela e distribuída**.

- Ela estende o modelo de programação MapReduce, popularizado pelo Apache Hadoop, **facilitando bastante o desenvolvimento de aplicações de processamento de grandes volumes de dados** (DEVMEDIA, 2020).
- **Todos os componentes funcionam integrados na própria ferramenta**, como o Spark Streaming, o Spark SQL e o GraphX, diferentemente do Hadoop, em que é necessário utilizar ferramentas que se integram a ele, mas que são distribuídas separadamente, como o Apache Hive.
- Permite a **programação** em três **linguagens: Java, Scala e Python**.
- Tem diversos componentes para diferentes tipos de processamento, todos construídos sobre o Spark Core, que é o componente que disponibiliza as funções básicas para o processamento, como as funções map, reduce, filter e collect. Entre estes, destacam-se:




Figura. Componentes do Apache Spark (DEVMEDIA, 2020).

- Spark Streaming, que possibilita o processamento de fluxos em tempo real;
- GraphX, que realiza o processamento sobre grafos;
- Spark SQL para a utilização de SQL na realização de consultas e processamento sobre os dados no Spark;
- MLlib, que é a biblioteca de aprendizado de máquina, com diferentes algoritmos para as mais diversas atividades, como clustering.

PRINCIPAIS PLATAFORMAS DE COMPUTAÇÃO EM NUVEM PARA BIG DATA

As empresas que oferecem esses serviços de computação são chamadas de **Cloud Providers** e normalmente **cobram pelos serviços de computação em nuvem com base no uso**.

Vamos, então, ao estudo das **plataformas de computação em nuvem que oferecem soluções de Big Data**, como **Amazon Web Services (AWS)**, **Microsoft Azure** e **Google Cloud Platform (GCP)**. Essas soluções ajudam as empresas a coletar, armazenar, processar e analisar grandes quantidades de dados.

Conforme visto na figura seguinte, **Amazon Web Services (AWS), Microsoft e Google** foram indicados como **líderes** no Quadrante Mágico da Gartner em infraestrutura de nuvem e serviços de plataforma de 2022.



Figura. Quadrante Mágico da Gartner em Infraestrutura de Nuvem e Serviços de Plataforma de 2022 (GARTNER, 2022)

Entretanto, outras plataformas de **computação em nuvem para Big Data** ainda podem ser utilizadas. Vamos, então, ao estudo das principais:

1) Amazon Web Services (AWS)




Figura. Amazon Web Services

Veja mais: <https://aws.amazon.com/pt/>

2) Microsoft Azure




Figura. Microsoft Azure

Veja mais: <https://azure.microsoft.com/pt-br/>

3) GCP – Google Cloud Platform

Veja mais: <https://cloud.google.com/>




Figura. Google Cloud Platform

4) IBM Cloud

Veja mais: <https://www.ibm.com/cloud>




Figura. IBM Cloud

5) Oracle Cloud Infrastructure (OCI)

Veja mais: <https://www.oracle.com/cloud/>




Figura. Oracle Cloud Infrastructure (OCI)

Assim como as plataformas em nuvem estão crescendo de forma acelerada, também percebemos uma **explosão na geração de dados** (DSAACADEMY, 2020).

As opções a seguir apresentam conjuntos de **ferramentas** diretamente relacionadas a soluções de Big Data, que envolvem principalmente armazenamento, processamento, análise e *streaming* de grandes quantidades de dados.




Figura. Exemplos de Ferramentas Voltados para Soluções de Big Data (QUINTÃO, 2025)

RESUMO




Figura. Big Data. Fonte: Quintão (2025)




Figura. Big Data. Fonte: Quintão (2025)




Figura. Exemplos de Ferramentas Voltados para Soluções de Big Data (QUINTÃO, 2025)




Figura. Data Lake (QUINTÃO, 2025)

Para o **DW**, normalmente utilizamos **ETL** (Extração, Transformação e Carga).

Para o **Data Lake**, normalmente usamos **ELT** (Extração, Carga e Transformação).




Figura. Data Store (QUINTÃO, 2025)




Figura. Padrões Utilizados em Soluções de Big Data. Fonte: Quintão (2025)




Figura. Tipos de Análises (QUINTÃO, 2025)




Figura. Pacote Apache Hadoop. O pacote de software Hadoop inclui uma série de componentes. Fonte: Intel Corporation (2013)

- **Uma execução típica de uma aplicação Hadoop em um cluster utiliza *cinco processos diferentes*:**
 - NameNode,
 - DataNode,
 - Secondary NameNode,
 - JobTracker, e
 - TaskTracker.

Os componentes NameNode, JobTracker e SecondaryNameNode são únicos para toda a aplicação, enquanto o **DataNode e o TaskTracker são instanciados para cada máquina.**

QUESTÕES COMENTADAS EM AULA

001. (QUADRIX/CREF-11ª REGIÃO/AGENTE DE ORIENTAÇÃO E FISCALIZAÇÃO/2014) Trata-se de uma infinidade de informações não estruturadas que, quando usadas com inteligência, se tornam uma arma poderosa para empresas tomarem decisões cada vez melhores. As soluções tecnológicas que trabalham com esse conceito permitem analisar um enorme volume de dados de forma rápida e ainda oferecem total controle ao gestor das informações. E as fontes de dados são as mais diversas possíveis: de textos e fotos em rede sociais, passando por imagens e vídeos, até jogadas específicas no esporte e até tratamentos na medicina. (<http://olhardigital.uol.com.br/pro/video/39376/39376>)

O conceito definido no texto é:

- a) Governança de TI
- b) QoS.
- c) Big Data
- d) Data Center.
- e) ITIL.

002. (CESPE/TCE-MG/2018) Uma empresa, ao implementar técnicas e softwares de big data, deu enfoque diferenciado à análise que tem como objetivo mostrar as consequências de determinado evento. Essa análise é do tipo

- a) preemptiva.
- b) perceptiva.
- c) prescritiva.
- d) preditiva.
- e) evolutiva.

003. (CEBRASPE (CESPE)/ANALISTA DA DEFENSORIA PÚBLICA (DPE RO)/ADMINISTRAÇÃO/2022) O big data, inicialmente caracterizado por três Vs, em 2001, atualmente inclui mais dois Vs. Um dos Vs que caracteriza o big data é

- a) vulnerabilidade.
- b) varonil.
- c) variedade.
- d) vetor.
- e) volátil.

004. (FCC/DPE-RS/ANALISTA/BANCO DE DADOS/2017) Os sistemas de Big Data costumam ser caracterizados pelos chamados 3 Vs, sendo que o V de

- a) Veracidade corresponde à rapidez na geração e obtenção de dados.
- b) Valor corresponde à grande quantidade de dados acumulada.
- c) Volume corresponde à rapidez na geração e obtenção de dados.
- d) Velocidade corresponde à confiança na geração e obtenção dos dados.
- e) Variedade corresponde ao grande número de tipos ou formas de dados.

005. (FGV/ANALISTA DE TECNOLOGIA DA INFORMAÇÃO DA FAZENDA ESTADUAL (SEFAZ AM)/2022) Com relação às arquiteturas de big data, analise as afirmativas a seguir.

I – As arquiteturas de big data suportam um ou mais tipos de carga de trabalho, por exemplo, processamento em lote de fontes de big data em repouso; processamento em tempo real de big data em movimento; exploração interativa de big data e análise preditiva e aprendizado de máquina.

II – A arquitetura kappa aborda o problema da baixa latência criando dois caminhos para o fluxo de dados. Todos os dados que entram no sistema passam por dois caminhos: a camada de lote (caminho frio) que armazena os dados de entrada em sua forma bruta e executa o processamento os dados em lote, e a camada de velocidade (hot path) que analisa os dados em tempo real. Essa camada é projetada para ter baixa latência, em detrimento da precisão.

III – A arquitetura lambda, posterior à kappa, foi proposta para ser uma alternativa para mitigar os problemas da baixa latência. Lambda tem os mesmos objetivos da kappa, mas com uma distinção importante: todos os dados fluem por um único caminho, usando um sistema de processamento de fluxo de dados. Semelhante à camada de velocidade da arquitetura lambda, todo o processamento de eventos é realizado através de um fluxo único de entrada.

Está correto o que se afirma em

- a) I, apenas.
- b) II, apenas.
- c) III, apenas.
- d) I e II, apenas.
- e) II e III, apenas.

006. (CEBRASPE (CESPE)/PROFISSIONAL PETROBRAS DE NÍVEL SUPERIOR (PETROBRAS)/CIÊNCIA DE DADOS/2022) Com referência aos conceitos de banco de dados e data warehouse, julgue o item seguinte.

O Hadoop Distributed File System (HDFS) é construído usando a linguagem Java, o que permite que sua arquitetura mestre/escravo seja implementada em uma ampla variedade de máquinas.

007. (ESAF/ANAC/ANALISTA ADMINISTRATIVO/2016) Para o processamento de grandes massas de dados, no contexto de Big Data, é muito utilizada uma plataforma de software em Java, de computação distribuída, voltada para clusters, inspirada no MapReduce e no GoogleFS. Esta plataforma é o(a)

- a) Yam Common.
- b) GoogleCrush.
- c) EMRx.
- d) Hadoop.
- e) MapFix.

008. (ESAF/ESAF/GESTÃO E DESENVOLVIMENTO DE SISTEMAS/2015/ADAPTADA) O Hadoop, o mais conhecido e popular sistema para gestão de Big Data, foi criado pela IBM, a partir de sua ferramenta de Data Mining WEKA.

009. (FGV/AUDITOR FISCAL DA RECEITA ESTADUAL (SEF MG)/TECNOLOGIA DA INFORMAÇÃO/2023) O HDFS foi projetado para armazenar arquivos grandes como uma sequência de blocos.

Em relação à replicação dos dados, assinale a afirmativa incorreta.

- a) A replicação de blocos de dados não ocorre quando o NameNode está no estado Safemode.
- b) O fator de replicação pode ser especificado no momento da criação de um arquivo e pode ser alterado posteriormente.
- c) Os arquivos no HDFS são de gravação única (write-once) com exceção para acréscimos e truncamentos, e têm estritamente um writer a qualquer momento.
- d) Um bloco é considerado replicado com segurança quando as três réplicas desse bloco de dados são verificadas com o NameNode.
- e) Como o NameNode não permite que os DataNodes tenham várias réplicas do mesmo bloco, o número máximo de réplicas criadas é o número total de DataNodes naquele momento.

EXERCÍCIOS

010. (SELECON/AUDITOR FISCAL DO MUNICÍPIO (PREF L DO RIO VERDE)/2025) Um grupo de auditoria de uma financeira precisa verificar e monitorar alguns padrões de pagamentos de clientes, de modo a analisá-los com relação ao histórico de atividades desses clientes, com o propósito de detectar fraudes em tempo real. Um recurso eficiente a ser utilizado nesse caso e revelar essas situações é fazer uso de:

- a) Big Datas
- b) Token Rins
- c) Internet das Coisas
- d) Redes Metropolitanas de Dados

011. (CEBRASPE (CESPE)/GESTOR DE APOIO ÀS ATIVIDADES POLICIAIS CIVIS (PC DF)/ANALISTA DE INFORMÁTICA/DESENVOLVIMENTO DE SISTEMAS/2025) A respeito de inteligência artificial, de tipos de análise de dados e de Big Data, julgue o item a seguir.

A veracidade em Big Data reflete o desafio de se assegurar a qualidade e precisão de dados frequentemente confusos, ruidosos e propensos a erros que comprometem sua confiabilidade.

012. (CEBRASPE (CESPE)/ANALISTA JUDICIÁRIO (TRF 6ª REGIÃO)/APOIO ESPECIALIZADO/ANÁLISE DE DADOS/2025) A respeito de Big Data, julgue o item a seguir.

Na etapa de ingestão de um pipeline de dados de Big Data, os dados de diversas fontes são coletados e transportados para um armazenamento centralizado.

013. (FGV/ANALISTA ADMINISTRATIVO (TCE-RR)/TECNOLOGIA DA INFORMAÇÃO/BANCO DE DADOS/2025) As organizações públicas podem se beneficiar do uso de Big Data para auditar grandes volumes de informações de maneira eficiente.

Sobre os 5Vs que caracterizam o Big Data, assinale a afirmativa correta.

- a) O “volume” refere-se à diversidade de fontes de dados utilizadas no Big Data.
- b) A “veracidade” refere-se à necessidade de adaptar sistemas para processar dados provenientes de fontes variadas.
- c) A “variedade” está associada à dificuldade em lidar com o grande volume de dados gerados em um curto período.
- d) Os 5Vs de Big Data são: volume, variedade, validade, valor e verificação.
- e) O “valor” de um conjunto de dados está diretamente ligado à capacidade de extrair informações úteis e significativas.

014. (CEBRASPE (CESPE)/ANALISTA JUDICIÁRIO (TRF 6ª REGIÃO)/APOIO ESPECIALIZADO/GOVERNANÇA E GESTÃO DE TECNOLOGIA DA INFORMAÇÃO/2025) No que se refere à ciência de dados, julgue o item a seguir.

Em big data, representações visuais, como gráficos e dashboards, permitem que padrões sejam rapidamente identificados.

015. (CEBRASPE (CESPE)/ANALISTA DE PLANEJAMENTO E ORÇAMENTO (SEPLAN RR)/TECNOLOGIA DA INFORMAÇÃO/2023) Julgue o próximo item com relação aos conceitos de big data.

Big data somente se aplica a dados não estruturados.

016. (CEBRASPE (CESPE)/ANALISTA DE PLANEJAMENTO E ORÇAMENTO (SEPLAN RR)/TECNOLOGIA DA INFORMAÇÃO/2023) Julgue o próximo item com relação aos conceitos de big data.

Variedade, em big data, refere-se à quantidade de fontes que geram os dados com potencial de serem altamente desestruturados.

017. (FGV/AUDITOR FISCAL DA RECEITA FEDERAL DO BRASIL/GERAL/2023) As principais plataformas de computação em nuvem, como Amazon Web Services (AWS), Microsoft Azure e Google Cloud Platform (GCP), oferecem soluções de Big Data para ajudar as empresas a coletar, armazenar, processar e analisar grandes quantidades de dados.

As opções a seguir apresentam conjuntos de serviços que estão diretamente relacionados a soluções de Big Data oferecidas pelas plataformas de computação em nuvem elencadas acima, à exceção de uma. Assinale-a.

- a) Armazenamento de dados: AWS S3, Azure Blob Storage e Google Cloud Storage.
- b) Processamento de dados: AWS EMR, Azure HDInsight e Google Cloud DataProc.
- c) Análise de Dados: AWS Athena, Azure Data Lake Analytics e Google BigQuery.
- d) Streaming de Dados: AWS Kinesis, Azure Stream Analytics e Google Cloud Pub/Sub.
- e) Aplicações: AWS Elastic Beanstalk, Azure App Service e Google App Engine.

018. (FGV/ANALISTA DE TECNOLOGIA DA INFORMAÇÃO DA FAZENDA ESTADUAL (SEFAZ AM)/2022) Leia o fragmento a seguir.

“Atualmente, no contexto do Big Data e Data Analytics, faz-se referência às características enunciadas por pesquisadores e produtores de soluções como sendo um conjunto de cinco Vs. Originalmente, a definição clássica de Big Data fez referência a três Vs fundamentais: _____, _____ e _____ de dados que demandam formas inovadoras e rentáveis de processamento da informação, para melhor percepção e tomada de decisão.”

Assinale a opção cujos itens completam corretamente as lacunas do fragmento acima, na ordem apresentada.

- a) valor – variância – veracidade.
- b) validade – velocidade – vocabulário.

- c) valor – variabilidade – viscosidade.
- d) variedade – velocidade – volume.
- e) valor – volatilidade – volume.

019. (IADES/REGULADOR DE SERVIÇOS PÚBLICOS (ADASA)/TECNOLOGIA DA INFORMAÇÃO E COMUNICAÇÃO/2022) Big Data caracteriza-se por dados com alta volumetria, velocidade e variedade. Por conta disso, nem sempre as informações são tratadas e armazenadas da mesma forma. Há situações em que os dados não são organizados seguindo um modelo de dados predeterminado e nem um esquema. Esses dados denominam-se

- a) não estruturados.
- b) estruturados.
- c) semiestruturados.
- d) ETL.
- e) ELT.

020. (INSTITUTO AOCP/MJSP/ENGENHEIRO DE DADOS/BIG DATA/2020) Assim como o Hadoop foi desenvolvido para possibilitar o processamento em lote de grande volume de dados, também surgiram tecnologias com suporte ao processamento em tempo real de Big Data, como o

- a) Hadoop RTime.
- b) Kubernetes.
- c) Elasticsearch.
- d) Spark.
- e) RealStorm.

021. (COMPERVE/TJ-RN/ANALISTA DE SUPORTE PLENO-BANCO DE DADOS/2020) Big Data surgiu a partir da necessidade de manipular um grande volume de dados e, com isso, novos conceitos foram introduzidos, como o Data Lake, que:

- a) pode ser considerado um repositório de dados relacionados, sendo, portanto, um armazém de dados orientado por assunto.
- b) pode ser considerado um conjunto de bancos de dados relacionais e com relacionamentos entre tabelas de diferentes esquemas de bancos de dados.
- c) é o resultado de sucessivas operações de mineração de dados, sendo um ambiente no qual é possível ter relatórios e dashboards de maneira amigável para os analistas de negócio.
- d) é projetado para armazenar dados de diversas fontes e formatos, não havendo a necessidade da definição de um esquema de dados para inserir novos itens.

022. (CESPE/POLÍCIA FEDERAL/PAPILOSCOPISTA/POLICIAL FEDERAL/2018) Julgue o item seguinte, a respeito de big data e tecnologias relacionadas a esse conceito.

De maneira geral, big data não se refere apenas aos dados, mas também às soluções tecnológicas criadas para lidar com dados em volume, variedade e velocidade significativos.

023. (CESPE/PF/AGENTE DA POLÍCIA FEDERAL/2018) Big data refere-se a uma nova geração de tecnologias e arquiteturas projetadas para processar volumes muito grandes e com grande variedade de dados, permitindo alta velocidade de captura, descoberta e análise.

024. (CESPE/TCE-PB/AUDITOR DE CONTAS PÚBLICAS/DEMAIS ÁREAS/2018) Com referência a big data, assinale a opção correta.

- a) A definição mais ampla de big data restringe o termo a duas partes — o volume absoluto e a velocidade —, o que facilita a extração das informações e dos insights de negócios.
- b) O sistema de arquivos distribuído Hadoop implementa o algoritmo Dijkstra modificado para busca irrestrita de dados em árvores aglomeradas em clusters com criptografia.
- c) Em big data, o sistema de arquivos HDFS é usado para armazenar arquivos muito grandes de forma distribuída, tendo como princípio o write-many, read-once.
- d) Para armazenar e recuperar grande volume de dados, o big data utiliza bancos SQL nativos, que são bancos de dados que podem estar configurados em quatro tipos diferentes de armazenamentos: valor chave, colunar, gráfico ou documento.
- e) O MapReduce é considerado um modelo de programação que permite o processamento de dados massivos em um algoritmo paralelo e distribuído.

025. (CESPE/EBSERH/ANALISTA DE TECNOLOGIA DA INFORMAÇÃO/2018) Com relação a banco de dados, julgue o item seguinte. As soluções de big data focalizam dados que já existem, descartam dados não estruturados e disponibilizam os dados estruturados.

026. (CESPE/TCM-BA/AUDITOR ESTADUAL DE CONTROLE EXTERNO/2018) Acerca de big data, assinale a opção correta.

- a) A utilização de big data nas organizações não é capaz de transformar os seus processos de gestão e cultura.
- b) Sistemas de recomendação são métodos baseados em computação distribuída, que proveem uma interface para programação de clusters, a fim de recomendar os tipos certos de dados e processar grandes volumes de dados.
- c) Pode-se recorrer a software conhecidos como scrapers para coletar automaticamente e visualizar dados que se encontram disponíveis em sítios de navegabilidade ruim ou em bancos de dados difíceis de manipular.

d) As ações inerentes ao processo de preparação de dados incluem detecção de anomalias, deduplicação, desambiguação de entradas e mineração de dados.

e) O termo big data se baseia em cinco Vs: velocidade, virtuosidade, volume, vantagem e valor.

027. (FCC/TCE-RS/ANÁLISE DE INFORMAÇÕES/2018) Um sistema de Big Data costuma ser caracterizado pelos chamados 3 Vs, ou seja, volume, variedade e velocidade. Por variedade entende-se que

a) há um grande número de tipos de dados suportados pelo sistema.

b) há um grande número de usuários distintos acessando o sistema.

c) os tempos de acesso ao sistema apresentam grande variação.

d) há um grande número de tipos de máquinas acessando o sistema.

e) os tamanhos das tabelas que compõem o sistema são muito variáveis.

028. (CESPE/TCE-PE/2017) O termo Big Data Analytics refere-se aos poderosos softwares que tratam dados estruturados e não estruturados para transformá-los em informações úteis às organizações, permitindo-lhes analisar dados, como registros de call center, postagens de redes sociais, de blogs, dados de CRM e demonstrativos de resultados.

029. (CESPE/TCE-PE/AUDITOR DE CONTROLE EXTERNO/AUDITORIA DE CONTAS PÚBLICAS/2017) Com relação a Big Data, julgue o item subsequente.

Além de estar relacionado à grande quantidade de informações a serem analisadas, o *Big Data* considera o volume, a velocidade e a variedade dos dados estruturados — dos quais se conhece a estrutura de armazenamento — bem como dos não estruturados, como imagens, vídeos, áudios e documentos.

030. (CESPE/FUNPRESP-JUD/ANALISTA/TECNOLOGIA DA INFORMAÇÃO/2016) A respeito de banco de dados, julgue o próximo item. Uma big data não engloba dados não estruturados, mas inclui um imenso volume de dados estruturados suportado por tecnologias como o DataMining e o DataWarehouse para a obtenção de conhecimento a partir da manipulação desses dados.

031. (ESAF/ANAC/ANALISTA ADMINISTRATIVO/2016) Big Data é:

a) volume + variedade + agilidade + efetividade, tudo agregando + valor + atualidade.

b) volume + oportunidade + segurança + veracidade, tudo agregando + valor.

c) dimensão + variedade + otimização + veracidade, tudo agregando + agilidade.

d) volume + variedade + velocidade + veracidade, tudo agregando + valor.

e) volume + disponibilidade + velocidade + portabilidade, tudo querendo – valor.

032. (FGV/TJ-SC/ANALISTA DE SISTEMAS/2015) Os termos Business Intelligence (BI) e Big Data confundem-se em certos aspectos. Uma conhecida abordagem para identificação dos pontos críticos de cada paradigma é conhecida como 3V, e destaca:

- a) variedade, visualização, volume;
- b) velocidade, virtualização, volume;
- c) variedade, velocidade, volume;
- d) virtualização, visualização, volume;
- e) variedade, visualização, virtualização.

033. (CESPE/TCU/AUDITOR FEDERAL DE CONTROLE EXTERNO – CONHECIMENTOS GERAIS/2015) No que concerne a data mining (mineração de dados) e big data, julgue o seguinte item. Devido à quantidade de informações manipuladas, a (cloud computing) computação em nuvem torna-se inviável para soluções de big data.

034. (FGV/AL-BA/TÉCNICO DE NÍVEL SUPERIOR/ECONOMIA/2014) A expressão Big Data é utilizada para descrever o contexto da informação contemporânea, caracterizada pelo volume, velocidade e variedade de dados disponíveis, em escala inédita. Com relação às características do Big Data, analise as afirmativas a seguir.

I – O volume da informação se refere ao fato de que certas coleções de dados atingem a faixa de gigabytes (bilhões de bytes), terabytes (trilhões), petabytes (milhares de trilhões) ou mesmo exabytes (milhões de trilhões).

II – A velocidade está relacionada à rapidez com a qual os dados são produzidos e tratados para atender à demanda, o que significa que não é possível armazená-los todos, de modo que somos obrigados a escolher dados para guardar e outros para descartar.

III – A variedade significa que os dados de hoje aparecem em todos os tipos de formatos, como, por exemplo, arquivos de texto, email, medidores e sensores de coleta de dados, vídeo, áudio, dados de ações do mercado ou transações financeiras.

Assinale:

- a) se somente a afirmativa I estiver correta.
- b) se somente a afirmativa II estiver correta.
- c) se somente a afirmativa III estiver correta.
- d) se somente as afirmativas I e II estiverem corretas.
- e) se todas as afirmativas estiverem corretas.

035. (CESPE/TJ-SE/ANALISTA JUDICIÁRIO/BANCO DE DADOS/2014) O processamento de consultas *ad hoc* em *Big Data*, devido às características de armazenamento dos dados, utiliza técnicas semelhantes àsquelas empregadas em consultas do mesmo tipo em bancos de dados tradicionais.

036. (CESPE/TJ-SE/ANALISTA JUDICIÁRIO/BANCO DE DADOS/2014) Ao utilizar armazenamento dos dados em nuvem, a localização do processamento de aplicações *Big Data* não influenciará os custos e o tempo de resposta, uma vez que os dados são acessíveis a partir de qualquer lugar.

037. (CESPE/TJ-SE/ANALISTA JUDICIÁRIO/BANCO DE DADOS/2014) Em soluções *Big Data*, a análise dos dados comumente precisa ser precedida de uma transformação de dados não estruturados em dados estruturados.

038. (CESPE/TJ-SE/ANALISTA JUDICIÁRIO/BANCO DE DADOS/ADAPTADA/2014) Julgue o item que se segue, no que se refere a *Big Data*.

Em soluções *Big Data*, a análise dos dados comumente precisa ser precedida de uma transformação de dados estruturados em dados não estruturados.

039. (CESPE/TRE-GO/TÉCNICO JUDICIÁRIO/ÁREA ADMINISTRATIVA/2013) A *Big Data* pode ser utilizada na EAD para se entender as preferências e necessidades de aprendizagem dos alunos e, assim, contribuir para soluções mais eficientes de educação mediada por tecnologia.

040. (INÉDITA/2023) Apache Hadoop é um software open source para armazenamento e processamento em larga escala de grandes conjuntos de dados (*Big Data*), em clusters de hardware de baixo custo.

041. (INÉDITA/2022) Julgue o item que se segue, no que se refere a *Big Data*.

Os sistemas de armazenamento de dados tradicionais são adequados para o big data.

042. (INÉDITA/2022) Para analisar a viabilidade de implementação do *Big Data* em uma organização, a literatura citava inicialmente três dimensões (conhecidas como 3V's), que são: Volume, Variedade e Veracidade.

043. (INÉDITA/2022) Data Mart é um termo utilizado para descrever grandes e complexos conjuntos de dados que são muito difíceis de capturar, processar, armazenar, buscar e analisar com os sistemas de base de dados convencionais.

044. (FGV/ANALISTA DE TECNOLOGIA DA INFORMAÇÃO DA FAZENDA ESTADUAL (SEFAZ AM)/2022) Com relação às características dos componentes do ecossistema Hadoop, analise as afirmativas a seguir.

I – Kafka é um gerenciador de armazenamento de dados do tipo colunar de código aberto de fácil integração com MapReduce e Spark, que utiliza o modelo de consistência forte, permite que o desenvolvedor escolha requisitos de consistência por solicitação, incluindo a opção de consistência estritamente serializável.

II – Impala, que tem forte integração com o Kudu, permite que o desenvolvedor de aplicações o utilize para inserir, consultar, atualizar e excluir dados no Kudu usando a sintaxe SQL do Impala. Adicionalmente, permite usar JDBC ou ODBC para conectar aplicativos novos ou pré-existentes escritos em qualquer linguagem, estrutura ou ferramenta de inteligência de negócios.

III – Kudu permite integrar seu próprio catálogo com o Hive Metastore (HMS). O HMS é o provedor de metadados e catálogo padrão no ecossistema Hadoop. Quando a integração está habilitada, as tabelas Kudu podem ser descobertas e usadas por ferramentas externas com reconhecimento de HMS, mesmo que elas não estejam integradas ao Kudu.

Está correto o que se afirma em

- a) I, apenas.
- b) II, apenas.
- c) III, apenas.
- d) I e II, apenas.
- e) II e III, apenas.

GABARITO

- | | |
|-------|-------|
| 1. c | 36. E |
| 2. c | 37. C |
| 3. c | 38. E |
| 4. e | 39. C |
| 5. a | 40. C |
| 6. C | 41. E |
| 7. d | 42. e |
| 8. E | 43. E |
| 9. d | 44. E |
| 10. a | |
| 11. C | |
| 12. C | |
| 13. e | |
| 14. C | |
| 15. E | |
| 16. C | |
| 17. e | |
| 18. d | |
| 19. a | |
| 20. d | |
| 21. d | |
| 22. C | |
| 23. C | |
| 24. e | |
| 25. E | |
| 26. c | |
| 27. a | |
| 28. C | |
| 29. C | |
| 30. E | |
| 31. d | |
| 32. c | |
| 33. E | |
| 34. e | |
| 35. E | |

GABARITO COMENTADO

010. (SELECON/AUDITOR FISCAL DO MUNICÍPIO (PREF L DO RIO VERDE)/2025) Um grupo de auditoria de uma financeira precisa verificar e monitorar alguns padrões de pagamentos de clientes, de modo a analisá-los com relação ao histórico de atividades desses clientes, com o propósito de detectar fraudes em tempo real. Um recurso eficiente a ser utilizado nesse caso e revelar essas situações é fazer uso de:

- a) Big Datas
- b) Token Rins
- c) Internet das Coisas
- d) Redes Metropolitanas de Dados



O grupo de auditoria necessita verificar e monitorar padrões de pagamentos, analisar o histórico de atividades dos clientes e detectar fraudes em tempo real.

Vamos à análise das alternativas:

a) Certa. Big Data:

- refere-se ao processamento de grandes volumes de dados estruturados e não estruturados;
- permite identificar padrões complexos por meio da análise de históricos extensos;
- técnicas como *machine learning* e análise preditiva detectam anomalias e comportamentos suspeitos;
- é eficiente para monitoramento em tempo real de transações;
- esse é exatamente o recurso necessário para comparar padrões atuais com o histórico de atividades.

b) Errada.

- “Token” é um mecanismo de autenticação/segurança.
- “Rins” não é um termo técnico consolidado em segurança da informação.
- Não se relaciona com a análise de padrões de comportamento.
- Não é apropriado para detectar fraudes por meio da análise de dados históricos.

c) Errada. Internet das Coisas (IoT):

- Trata-se da conexão de dispositivos físicos à internet.
- Não é um recurso adequado para a análise de padrões de pagamentos.
- Foca na coleta de dados de sensores, não na análise comportamental financeira.

d) Errada. Redes Metropolitanas de Dados (MAN):

- É uma infraestrutura de conectividade de rede.
- Não é uma ferramenta de análise de dados.
- Apenas possibilita a transmissão de dados, não a sua análise.

Letra a.

011. (CEBRASPE (CESPE)/GESTOR DE APOIO ÀS ATIVIDADES POLICIAIS CIVIS (PC DF)/ANALISTA DE INFORMÁTICA/DESENVOLVIMENTO DE SISTEMAS/2025) A respeito de inteligência artificial, de tipos de análise de dados e de Big Data, julgue o item a seguir.

A veracidade em Big Data reflete o desafio de se assegurar a qualidade e precisão de dados frequentemente confusos, ruidosos e propensos a erros que comprometem sua confiabilidade.



Veracidade é um dos principais desafios do Big Data. Significa garantir que os dados sejam **verdadeiros, precisos e confiáveis**.

Imagine uma empresa que coleta dados de **milhões de clientes**:

- **dados confusos**: informações vindas de fontes diferentes podem se contradizer. Ex.: cliente registrado como “João Silva” em um sistema e “J. Silva” em outro;
- **dados ruidosos**: existem informações incompletas ou incorretas. Ex.: um campo de CEP preenchido errado ou deixado em branco;
- **dados com erros**: falhas durante a captura ou transmissão. Ex.: um cliente com idade negativa por erro no sistema.

Por que isso é um desafio?

Se os dados são ruins, as análises ficam ruins e as decisões ficam ruins.

Exemplo prático:

- Um banco quer detectar fraudes analisando padrões de compra.
- Mas 30% dos dados das transações estão incorretos.
- O sistema pode deixar fraudes passarem ou bloquear clientes legítimos.

Quanto à veracidade, Weber et al. (2009) ressaltou que as **informações verdadeiras podem ser usadas pelos gestores para responder aos desafios estratégicos**. A veracidade garantiria, então, a **confiabilidade dos dados**. Ela refere-se mais à **proveniência ou à confiabilidade da fonte de dados**, seu contexto e sua utilidade para a análise com base nela.

Certo.

012. (CEBRASPE (CESPE)/ANALISTA JUDICIÁRIO (TRF 6ª REGIÃO)/APOIO ESPECIALIZADO/ANÁLISE DE DADOS/2025) A respeito de Big Data, julgue o item a seguir.

Na etapa de ingestão de um pipeline de dados de Big Data, os dados de diversas fontes são coletados e transportados para um armazenamento centralizado.



Um **pipeline de dados** é como um “caminho” que os dados seguem desde sua origem até se tornarem úteis. Ele possui várias etapas:

Ingestão → **Armazenamento** → **Processamento** → **Análise** → **Visualização**.

Na **etapa de ingestão**, os dados são:

- Coletados de várias fontes:
 - bancos de dados tradicionais;
 - APIs de sistemas externos;
 - *logs* de servidores;
 - redes sociais;
 - sensores IoT;
 - arquivos em nuvem, etc.
- Transportados para um lugar único:
 - Data Warehouse;
 - Data Lake;
 - Cluster de Big Data.

Exemplo prático: uma universidade quer analisar dados dos alunos:

- Fonte 1: Sistema de Matrículas.
- Fonte 2: Sistema Acadêmico.
- Fonte 3: Sistema de Biblioteca.
- Fonte 4: Plataforma de E-learning.

INGESTÃO:  Armazenamento centralizado (*Data Lake*).

Todos os dados chegam a um único lugar para serem processados juntos.

A frase descreve corretamente a etapa de ingestão:

- “Dados de diversas fontes” – Múltiplas origens de dados.
- “São coletados” – Captura dos dados.
- “Transportados” – Movimento dos dados.
- “Para um armazenamento centralizado” – Convergência em um local único.

Certo.

013. (FGV/ANALISTA ADMINISTRATIVO (TCE-RR)/TECNOLOGIA DA INFORMAÇÃO/BANCO DE DADOS/2025) As organizações públicas podem se beneficiar do uso de Big Data para auditar grandes volumes de informações de maneira eficiente.

Sobre os 5Vs que caracterizam o Big Data, assinale a afirmativa correta.

- a) O “volume” refere-se à diversidade de fontes de dados utilizadas no Big Data.
- b) A “veracidade” refere-se à necessidade de adaptar sistemas para processar dados provenientes de fontes variadas.
- c) A “variedade” está associada à dificuldade em lidar com o grande volume de dados gerados em um curto período.

- d) Os 5Vs de Big Data são: volume, variedade, validade, valor e verificação.
- e) O “valor” de um conjunto de dados está diretamente ligado à capacidade de extrair informações úteis e significativas.



Figura. 5 V's do Big Data

Os 5 Vs que caracterizam o Big Data são:

1. **Volume** – Grande quantidade de dados.
2. **Variedade** – Diferentes tipos e fontes de dados.
3. **Velocidade** – Rapidez na coleta e processamento.
4. **Veracidade** – Qualidade e precisão dos dados.
5. **Valor** – Utilidade dos insights gerados.

Analisando cada alternativa

- a) Errada. Confunde conceitos diferentes. **Volume** refere-se à **quantidade** de dados (terabytes, petabytes, exabytes). **Variedade** refere-se à **diversidade de fontes**.
- b) Errada. **Veracidade** = Qualidade, precisão e confiabilidade dos dados. O que descreve a assertiva está, na verdade, relacionado à **Variedade** (lidar com dados variados).
- c) Errada. **Variedade** = Diferentes tipos, formatos e fontes de dados.
- d) Errada. Os **5Vs de Big Data** são: **Volume, Variedade, Velocidade, Veracidade e Valor**. A alternativa lista: validade, verificação (incorretos) e, ainda, não inclui: velocidade, veracidade (corretos).
- e) Certa. **Valor** = **Capacidade de extrair informações úteis e significativas**. Utilidade prática dos dados; capacidade de gerar insights significativos e tomar decisões melhores.
- Exemplo prático:** uma organização coleta dados de auditoria (volume grande ✓, de várias fontes ✓, rapidamente ✓, com qualidade ✓); nesse caso, **o valor** está em conseguir identificar irregularidades, fraudes ou ineficiências que melhorem a gestão.

O “valor” de um conjunto de dados está diretamente ligado à capacidade de extrair informações úteis e significativas.

Letra e.

014. (CEBRASPE (CESPE)/ANALISTA JUDICIÁRIO (TRF 6ª REGIÃO)/APOIO ESPECIALIZADO/GOVERNANÇA E GESTÃO DE TECNOLOGIA DA INFORMAÇÃO/2025) No que se refere à ciência de dados, julgue o item a seguir.

Em big data, representações visuais, como gráficos e dashboards, permitem que padrões sejam rapidamente identificados.



Visualizações (gráficos e dashboards) são ferramentas essenciais em Big Data, exatamente porque permitem que padrões complexos em grandes volumes de dados sejam identificados **rapidamente**, facilitando análises e tomadas de decisão.

Gráficos: tornam padrões visuais e óbvios.

Dashboards: concentram múltiplas perspectivas em um só lugar.

Certo.

015. (CEBRASPE (CESPE)/ANALISTA DE PLANEJAMENTO E ORÇAMENTO (SEPLAN RR)/TECNOLOGIA DA INFORMAÇÃO/2023) Julgue o próximo item com relação aos conceitos de big data.

Big data somente se aplica a dados não estruturados.



Big Data é definido genericamente como a **captura**, **gerenciamento** e **análise** de grandes e complexos conjuntos de **dados – estruturados e não estruturados** – que impactam os negócios no dia a dia.

Assim, conforme visto, o conceito de Big Data se aplica tanto a dados estruturados, como os dados de transações comerciais, quanto a dados não estruturados, como mídias sociais, sensores IoT, imagens e vídeos. Esses dados não estruturados são mais complexos de capturar, armazenar, processar e consultar, exatamente pela sua falta de uma estrutura específica.

Errado.

016. (CEBRASPE (CESPE)/ANALISTA DE PLANEJAMENTO E ORÇAMENTO (SEPLAN RR)/TECNOLOGIA DA INFORMAÇÃO/2023) Julgue o próximo item com relação aos conceitos de big data.

Variedade, em big data, refere-se à quantidade de fontes que geram os dados com potencial de serem altamente desestruturados.



Big Data, normalmente, é dividido em três dimensões (os 3 V's):

Variedade	Significa que há um grande número de tipos de dados suportados pelo sistema . O termo variedade, em big data, refere-se, portanto, à quantidade de fontes que geram os dados com <u>potencial</u> de serem altamente desestruturados.
Velocidade	Está relacionada à rapidez com a qual os dados são produzidos e tratados para atender à demanda, o que significa que não é possível armazená-los por completo, de modo que somos obrigados a escolher dados para guardar e outros para descartar.
Volume	O volume da informação refere-se à grande quantidade de dados acumulados. Certas coleções de dados atingem a faixa de gigabytes (bilhões de bytes), terabytes (trilhões), petabytes (milhares de trilhões) ou mesmo exabytes (milhões de trilhões).

Certo.

017. (FGV/AUDITOR FISCAL DA RECEITA FEDERAL DO BRASIL/GERAL/2023) As principais plataformas de computação em nuvem, como Amazon Web Services (AWS), Microsoft Azure e Google Cloud Platform (GCP), oferecem soluções de Big Data para ajudar as empresas a coletar, armazenar, processar e analisar grandes quantidades de dados.

As opções a seguir apresentam conjuntos de serviços que estão diretamente relacionados a soluções de Big Data oferecidas pelas plataformas de computação em nuvem elencadas acima, à exceção de uma. Assinale-a.

- a) Armazenamento de dados: AWS S3, Azure Blob Storage e Google Cloud Storage.
- b) Processamento de dados: AWS EMR, Azure HDInsight e Google Cloud DataProc.
- c) Análise de Dados: AWS Athena, Azure Data Lake Analytics e Google BigQuery.
- d) Streaming de Dados: AWS Kinesis, Azure Stream Analytics e Google Cloud Pub/Sub.
- e) Aplicações: AWS Elastic Beanstalk, Azure App Service e Google App Engine.



- a) Certa. As **ferramentas de armazenamento de dados AWS S3, Azure Blob Storage e Google Cloud Storage** compartilham o propósito de fornecer armazenamento escalável, durável e altamente disponível para dados. Essas soluções de armazenamento em nuvem são amplamente utilizadas em arquiteturas de Big Data, permitindo o armazenamento e processamento de grandes quantidades de dados de maneira eficiente e escalável.
- b) Certa. As **ferramentas de processamento de dados AWS EMR, Azure HDInsight e Google Cloud DataProc** são projetadas para permitir o **processamento de grandes volumes de dados em escala, de maneira eficiente e escalável**. Todas essas ferramentas fornecem recursos de processamento distribuído, permitindo que grandes quantidades de dados sejam processadas de forma paralela através de *clusters* com serviços gerenciados de Hadoop e Spark, principais ferramentas de processamento de Big Data.
- c) Certa. As **ferramentas de Análise de Dados AWS Athena, Azure Data Lake Analytics e Google BigQuery** possuem o mesmo propósito de **permitir a execução de consultas SQL**

em larga escala em dados armazenados em plataformas de armazenamento em nuvem.

Além disso, todas as ferramentas oferecem escalabilidade e flexibilidade, permitindo que grandes volumes de dados sejam processados de maneira eficiente. Na arquitetura de Big Data, **essas ferramentas são comumente utilizadas para análises exploratórias e consultas ad-hoc em grandes volumes de dados**, fornecendo informações valiosas para a tomada de decisões estratégicas.

d) Certa. As **ferramentas de streaming de dados AWS Kinesis, Azure Stream Analytics e Google Cloud Pub/Sub** compartilham o **propósito de coletar, processar e analisar dados em tempo real em arquiteturas de Big Data**. Todas essas ferramentas permitem que os usuários criem *pipelines* de *streaming* de dados para extrair *insights* em tempo real a partir de fluxos de dados em alta velocidade.

e) Errada. Embora esses serviços possam ser usados para hospedar aplicativos que fazem uso de soluções de Big Data, eles não estão diretamente relacionados às soluções de Big Data em si, que envolvem principalmente armazenamento, processamento, análise e *streaming* de grandes quantidades de dados.




Figura. Exemplos de Ferramentas Voltados para Soluções de Big Data (QUINTÃO, 2023)

Letra e.

018. (FGV/ANALISTA DE TECNOLOGIA DA INFORMAÇÃO DA FAZENDA ESTADUAL (SEFAZ AM)/2022) Leia o fragmento a seguir.

“Atualmente, no contexto do Big Data e Data Analytics, faz-se referência às características enunciadas por pesquisadores e produtores de soluções como sendo um conjunto de cinco Vs. Originalmente, a definição clássica de Big Data fez referência a três Vs fundamentais: _____, _____ e _____ de dados que demandam formas inovadoras e rentáveis de processamento da informação, para melhor percepção e tomada de decisão.”

Assinale a opção cujos itens completam corretamente as lacunas do fragmento acima, na ordem apresentada.

- a) valor – variância – veracidade.
- b) validade – velocidade – vocabulário.
- c) valor – variabilidade – viscosidade.
- d) variedade – velocidade – volume.
- e) valor – volatilidade – volume.



Big Data, normalmente, é dividido em três dimensões (os 3 V's):

Variedade	Significa que os dados de hoje aparecem em todos os tipos de formatos , como, por exemplo, arquivos de texto, <i>e-mails</i> , medidores e sensores de coleta de dados, vídeos, áudios, dados de ações do mercado ou transações financeiras. Por variedade, entende-se que há um grande número de tipos de dados suportados pelo sistema .
Velocidade	Está relacionada à rapidez com a qual os dados são produzidos e tratados para atender à demanda, o que significa que não é possível armazená-los por completo, de modo que somos obrigados a escolher dados para guardar e outros para descartar. A tecnologia de Big Data agora nos permite analisar os dados no momento em que estes são gerados , sem a necessidade de inseri-los nos bancos de dados.
Volume	O volume da informação refere-se à grande quantidade de dados acumulados. Certas coleções de dados atingem a faixa de gigabytes (bilhões de bytes), terabytes (trilhões), petabytes (milhares de trilhões) ou mesmo exabytes (milhões de trilhões).




Figura. 3 V's do Big Data

Letra d.

019. (IADES/REGULADOR DE SERVIÇOS PÚBLICOS (ADASA)/TECNOLOGIA DA INFORMAÇÃO E COMUNICAÇÃO/2022) Big Data caracteriza-se por dados com alta volumetria, velocidade e variedade. Por conta disso, nem sempre as informações são tratadas e armazenadas da mesma forma. Há situações em que os dados não são organizados seguindo um modelo de dados predeterminado e nem um esquema. Esses dados denominam-se

- a) não estruturados.
- b) estruturados.
- c) semiestruturados.
- d) ETL.
- e) ELT.



O termo *Big Data* faz referência a um conjunto de técnicas utilizadas para lidar com um grande volume de dados.

Nos tempos atuais, somos bombardeados por um enorme fluxo de informações.

Esses dados podem vir de fontes diferentes e ser de tipos diversos:

- **Dados não estruturados:** são aqueles que **existem em seu estado original (bruto), ou seja, no formato em que foram coletados**. Portanto, **estão em um formato que não possibilita o processamento que produz informações**.

Como exemplos de dados desse tipo, podemos citar textos, imagens, vídeos e documentos, entre outros. Ao contrário dos dados estruturados, os dados não estruturados **não possuem**

uma estrutura definida (não são organizados seguindo um modelo de dados predeterminado nem um esquema).

- **Dados estruturados:** são o **resultado da obtenção de dados não estruturados e de sua formatação (estruturação)** visando facilitar o armazenamento, a utilização e a geração de informações. A estrutura (formato) é aplicada com base no tipo de processamento que se deseja executar nos dados.

Os dados estruturados que **descrevem** e permitem **encontrar, gerenciar, compreender** e (ou) **preservar** documentos arquivísticos ao longo do tempo são conhecidos como **metadados**.

- **Dados semiestruturados:** são aqueles que **já foram parcialmente processados**. Como o nome pode indicar, são dados que contêm **parte de sua estrutura rígida e outra parte não rígida**. Possuem uma **representação estrutural heterogênea**, não sendo nem completamente não estruturados nem estritamente tipados. Por exemplo, olhando-se uma página comum da web, os dados são apresentados em um formato pré-organizado para transmitir alguma informação.

ETL é a sigla para **Extração** (Extraction), **Transformação** (Transformation) e **Carga** (Load). De forma direta, consiste em extrair dados de uma base de origem, realizar transformações (limpezas, padronizações etc.) e, posteriormente, **carregar** os dados alterados em uma nova base.

Ao contrário do ETL, o **ELT** é um processo mais ágil para o carregamento e o processamento de dados, pois inverte a ordem das etapas de transformação de dados da abordagem tradicional de ETL. No processo de **ELT**, as fases seguem a seguinte ordem:

- **extração:** coleta e extração de dados brutos de uma ou diversas fontes para posterior integração em um repositório de dados único.
- **carregamento:** carregamento dos dados coletados em um data warehouse ou repositório de dados.
- **transformação:** transformação dos dados brutos em dados modelados dentro de um *data warehouse* para a aplicação de *business intelligence*, análise de dados e *advanced analytics*.

Na abordagem de **ELT**, ao contrário da abordagem de **ETL**, a transformação de dados ocorre logo após a coleta e o carregamento das informações em um repositório de dados centralizado, e não antes.




Figura. (DATASCIENCEACADEMY, 2022)

Conforme visto, a letra A é a resposta!

Letra a.

020. (INSTITUTO AOCP/MJSP/ENGENHEIRO DE DADOS/BIG DATA/2020) Assim como o Hadoop foi desenvolvido para possibilitar o processamento em lote de grande volume de dados, também surgiram tecnologias com suporte ao processamento em tempo real de Big Data, como o

- a) Hadoop RTime.
- b) Kubernetes.
- c) Elasticsearch.
- d) Spark.
- e) RealStorm.



a) Errada. **Hadoop** é uma **plataforma open source** desenvolvida especialmente para processamento e análise de grandes volumes de dados, sejam eles estruturados ou não estruturados. No entanto, não realiza processamento em tempo real, e não se tem a tal ramificação RTime.

b) Errada. **Kubernetes** é uma solução de orquestração (utilizada para automatizar a implantação, o dimensionamento e o gerenciamento de aplicativos) em containers de código aberto no DevOps. Veja mais em  <https://kubernetes.io/pt-br/>. No entanto, não realiza processamento em tempo real de Big Data.

c) Errada. Elasticsearch é uma engine de busca e análise de dados, componente que irá armazenar os dados e processar as consultas aos mesmos.

d) Certa. Conforme DevMedia (2020),

“o Apache Spark é uma ferramenta Big Data que tem o objetivo de processar grandes conjuntos de dados de forma paralela e distribuída. Ela estende o modelo de programação MapReduce popularizado pelo Apache Hadoop, facilitando bastante o desenvolvimento de aplicações de processamento de grandes volumes de dados. Além do modelo de programação estendido, o Spark também apresenta uma performance muito superior ao Hadoop, chegando em alguns casos a apresentar uma performance quase 100x maior”.

e) Errada. *Apache Storm* é um sistema de processamento de dados em tempo real. *Real Storm* não está localizado na literatura.

Letra d.

021. (COMPERVE/TJ-RN/ANALISTA DE SUPORTE PLENO-BANCO DE DADOS/2020) Big Data surgiu a partir da necessidade de manipular um grande volume de dados e, com isso, novos conceitos foram introduzidos, como o Data Lake, que:

- a) pode ser considerado um repositório de dados relacionados, sendo, portanto, um armazém de dados orientado por assunto.
- b) pode ser considerado um conjunto de bancos de dados relacionais e com relacionamentos entre tabelas de diferentes esquemas de bancos de dados.
- c) é o resultado de sucessivas operações de mineração de dados, sendo um ambiente no qual é possível ter relatórios e dashboards de maneira amigável para os analistas de negócio.
- d) é projetado para armazenar dados de diversas fontes e formatos, não havendo a necessidade da definição de um esquema de dados para inserir novos itens.



a) Errada. Os dados não precisam estar relacionados e também não são orientados por assunto. O Data Warehouse (DW) é **organizado conforme diferentes visões de negócio**, ou seja, armazena informações sobre temas específicos importantes para o negócio da empresa, como Vendas, Compras etc.



Figura. Visões de Negócio

b) Errada. *Data Lake* **não** é considerado um conjunto de dados relacionais e não precisa haver relacionamentos entre tabelas de diferentes esquemas – os dados são de diversos formatos (armazenam dados estruturados, semiestruturados e não estruturados) e de diversas fontes.

Data Lake: único repositório dentro de uma empresa com todos os dados brutos.

c) Errada. Não é o resultado de operações de mineração de dados. Data Lakes são armazenados da maneira como foram capturados – brutos, **sem nenhum tratamento**.

d) Certa. *Data Lake* é projetado para armazenar dados de diversas fontes e formatos, não havendo a necessidade da definição de um esquema de dados para inserir novos itens.




Figura. Características do Data Warehouse. Fonte: Quintão (2022)

Letra d.

022. (CESPE/POLÍCIA FEDERAL/PAPILOSCOPISTA/POLICIAL FEDERAL/2018) Julgue o item seguinte, a respeito de big data e tecnologias relacionadas a esse conceito.

De maneira geral, big data não se refere apenas aos dados, mas também às soluções tecnológicas criadas para lidar com dados em volume, variedade e velocidade significativos.



Big Data é um termo amplamente utilizado na atualidade para nomear **conjuntos de dados que podem ser estruturados e não estruturados** (como vídeo digital, imagens, dados de sensores, arquivos de *logs* e qualquer tipo de dados não contidos em registros típicos com campos que podem ser pesquisados) **muito grandes ou complexos**, mas também pode se referir ao Big Data Analytics (soluções tecnológicas criadas para lidar com dados em volume, variedade e velocidade significativos).

Certo.

023. (CESPE/PF/AGENTE DA POLÍCIA FEDERAL/2018) Big data refere-se a uma nova geração de tecnologias e arquiteturas projetadas para processar volumes muito grandes e com grande variedade de dados, permitindo alta velocidade de captura, descoberta e análise.



Big Data é definido genericamente como a **captura, gerenciamento e análise** de grandes e complexos conjuntos de **dados – estruturados e não estruturados** – que impactam os negócios no dia a dia.

Certo.

024. (CESPE/TCE-PB/AUDITOR DE CONTAS PÚBLICAS/DEMAIS ÁREAS/2018) Com referência a big data, assinale a opção correta.

- a) A definição mais ampla de big data restringe o termo a duas partes — o volume absoluto e a velocidade —, o que facilita a extração das informações e dos insights de negócios.
- b) O sistema de arquivos distribuído Hadoop implementa o algoritmo Dijkstra modificado para busca irrestrita de dados em árvores aglomeradas em clusters com criptografia.
- c) Em big data, o sistema de arquivos HDFS é usado para armazenar arquivos muito grandes de forma distribuída, tendo como princípio o write-many, read-once.
- d) Para armazenar e recuperar grande volume de dados, o big data utiliza bancos SQL nativos, que são bancos de dados que podem estar configurados em quatro tipos diferentes de armazenamentos: valor chave, colunar, gráfico ou documento.
- e) O MapReduce é considerado um modelo de programação que permite o processamento de dados massivos em um algoritmo paralelo e distribuído.




Veja mais: <https://www.devmedia.com.br/hadoop-mapreduce-introducao-a-big-data/30034>

a) Errada. Big Data não se refere apenas aos dados, mas também às soluções tecnológicas criadas para lidar com esses dados em quantidade, variedade e velocidade bastante significativas. Para analisar a viabilidade de implementação do Big Data em uma organização, citava-se inicialmente as três dimensões (conhecidas como 3V's), que são: **Volume, Variedade e Velocidade**.

A literatura destacou, em seguida, o **4V** (incluindo a **Veracidade**); depois, o **5V** (incluindo **Veracidade e Valor**); atualmente, a IBM cita **7 dimensões (Volume, Variedade, Velocidade, Veracidade, Valor, Governança e Pessoas)** a serem consideradas ao avaliar a viabilidade de uma solução de Big Data.

b) Errada. **Hadoop** é um sistema de armazenamento compartilhado, distribuído e altamente confiável para processamento de grandes volumes de dados através de clusters de computadores. Em outras palavras, Hadoop é um framework que facilita o funcionamento de diversos computadores, com o objetivo de analisar grandes volumes de dados. Não se pode afirmar que a busca ocorrerá de maneira irrestrita, principalmente se os dados estiverem criptografados (protegidos). A proteção pode restringir o acesso ao conteúdo dos dados. O projeto Apache Hadoop é composto por três módulos principais:

- Hadoop Distributed File System (HDFS)
- Hadoop YARN
- Hadoop MapReduce



<http://hadoop.apache.org>

c) Errada. O **HDFS** é um sistema de arquivos criado para armazenar arquivos muito grandes de forma distribuída.

- O conceito sobre o qual o HDFS foi construído é o chamado **write-once, read-many-times**, ou seja, **escreva uma vez, leia muitas vezes**.
- Esse tipo de construção é essencial para o Hadoop, uma vez que os dados serão processados inúmeras vezes, dependendo da aplicação, embora, normalmente, sejam escritos apenas uma vez.

d) Errada. O conceito de NoSQL é geralmente associado ao Big Data. “Bancos de dados NoSQL usam diversos modelos de dados, incluindo documentos, gráficos, chave-valor e colunares. Big Data pode utilizar bases de dados não relacionadas a modelos relacionais.

<Fonte: <https://www.devmedia.com.br/introducao-aos-bancos-de-dados-nosql/26044>>

e) Certa. **MapReduce** é um modelo de programação e framework introduzido pelo Google para suportar computações paralelas em grandes coleções de dados em clusters de computadores. Agora, MapReduce é considerado um novo modelo computacional distribuído, inspirado pelas funções map e reduce, usadas comumente em programação funcional.

Letra e.

025. (CESPE/EBSERH/ANALISTA DE TECNOLOGIA DA INFORMAÇÃO/2018) Com relação a banco de dados, julgue o item seguinte. As soluções de big data focalizam dados que já existem, descartam dados não estruturados e disponibilizam os dados estruturados.



Além de estar relacionado à grande quantidade de informações a serem analisadas, o **Big Data considera** o volume, a velocidade e a variedade **dos dados estruturados** — dos quais se conhece a estrutura de armazenamento — bem como dos **não estruturados**, como imagens, vídeos, áudios e documentos. Em soluções de *Big Data*, a análise dos dados comumente precisa ser precedida de uma transformação de dados não estruturados em dados estruturados.

Errado.

026. (CESPE/TCM-BA/AUDITOR ESTADUAL DE CONTROLE EXTERNO/2018) Acerca de big data, assinale a opção correta.

- a) A utilização de big data nas organizações não é capaz de transformar os seus processos de gestão e cultura.
- b) Sistemas de recomendação são métodos baseados em computação distribuída, que proveem uma interface para programação de clusters, a fim de recomendar os tipos certos de dados e processar grandes volumes de dados.
- c) Pode-se recorrer a software conhecidos como scrapers para coletar automaticamente e visualizar dados que se encontram disponíveis em sítios de navegabilidade ruim ou em bancos de dados difíceis de manipular.
- d) As ações inerentes ao processo de preparação de dados incluem detecção de anomalias, deduplicação, desambiguação de entradas e mineração de dados.
- e) O termo big data se baseia em cinco Vs: velocidade, virtuosidade, volume, vantagem e valor.



- a) Errada. A utilização de big data nas organizações será capaz de transformar os seus processos de gestão e cultura.
- b) Errada. Um **Sistema de Recomendação** combina várias técnicas computacionais para selecionar itens personalizados com base nos interesses dos usuários e conforme o contexto no qual estão inseridos. Tais itens podem assumir formas bem variadas, como, por exemplo, livros, filmes, notícias, música, vídeos, anúncios, links patrocinados, páginas de internet, produtos de uma loja virtual etc. Empresas como Amazon, Netflix e Google são reconhecidas pelo uso intensivo de sistemas de recomendação, com os quais obtêm grande vantagem competitiva.
- c) Certa. De acordo com Wikipedia (2017), **Data Scraping** (ou **raspagem de dados**) é uma técnica na qual um programa de computador extrai dados de saída legível para humanos, proveniente de um outro programa, e disponibiliza esses dados de modo que se tornem legíveis para outros programas de computador.

Scraping é a atividade de extrair dados de sites e transportá-los para um formato mais simples e maleável, para que possam ser analisados e cruzados com mais facilidade. Muitas vezes, a informação necessária para reforçar uma história está disponível, mas em sites de navegabilidade ruim ou em bancos de dados difíceis de manipular.

Para que se possa coletar automaticamente e visualizar essas informações, recorre-se a softwares conhecidos como **scrapers** (Andriolo, 2012).

<http://sinfisco.org.br/wp-content/uploads/2017/12/...>

- d) Errada. **Preparação de dados** é o **processo de coletar, limpar, normalizar, combinar, estruturar e organizar dados para análise**. Ele é o passo inicial (e fundamental) para que o trabalho com Big Data, uma vez que aumenta a qualidade dos dados – e, conseqüentemente, dos resultados com mineração de dados. Dados “pobres”, de qualidade ruim, geram resultados incorretos e não confiáveis ao fim do processo.

Deduplicação é o processo de analisar, identificar e remover duplicidades nos dados, diminuindo assim a quantidade de informações a ser manipulada e armazenada.

Minerar dados consiste no uso de um conjunto de tecnologias e técnicas que permitem automatizar a busca em grandes volumes de dados por padrões e tendências que não são detectáveis por análises mais simples. Este tipo de análise fornece aos gestores embasamento de alto valor para a tomada de decisões estratégicas, permitindo detectar de forma precoce a ocorrência de tendências do mercado e antecipar suas ações para responder a novos cenários.

- e) Errada. As **5 Dimensões (5 V's) do Big Data** são: Volume, Variedade, Velocidade, Veracidade, Valor.

Referências:

https://www.gta.ufrj.br/grad/15_1/bigdata/vs.html

https://pt.wikipedia.org/wiki/Sistema_de_recomendação

Letra c.

027. (FCC/TCE-RS/ANÁLISE DE INFORMAÇÕES/2018) Um sistema de Big Data costuma ser caracterizado pelos chamados 3 Vs, ou seja, volume, variedade e velocidade. Por variedade entende-se que

- a) há um grande número de tipos de dados suportados pelo sistema.
- b) há um grande número de usuários distintos acessando o sistema.
- c) os tempos de acesso ao sistema apresentam grande variação.
- d) há um grande número de tipos de máquinas acessando o sistema.
- e) os tamanhos das tabelas que compõem o sistema são muito variáveis.



Obs.: O **objetivo do Big Data** é propiciar dados e informações que possam ser analisados, visando subsidiar a tomada de decisão.

A tomada de decisão é possível em função não somente do **volume** de dados, da **velocidade** de captura dessas informações, das **fontes variadas de dados** e de **novos softwares para fins de modelagem dessas informações**.

Big Data, normalmente, é dividido em três dimensões (3 V's):

Volume	O volume da informação refere-se à grande quantidade de dados acumulados. Certas coleções de dados atingem a faixa de gigabytes (bilhões de bytes), terabytes (trilhões), petabytes (milhares de trilhões) ou mesmo exabytes (milhões de trilhões).
Variedade	Significa que os dados de hoje aparecem em todos os tipos de formatos , como, por exemplo, arquivos de texto, <i>e-mails</i> , medidores e sensores de coleta de dados, vídeo, áudio, dados de ações do mercado ou transações financeiras. Por variedade, entende-se que há um grande número de tipos de dados suportados pelo sistema .
Velocidade	Está relacionada à rapidez com a qual os dados são produzidos e tratados para atender à demanda, o que significa que não é possível armazená-los por completo, de modo que somos obrigados a escolher dados para guardar e outros para descartar. A tecnologia de Big Data agora nos permite analisar os dados no momento em que estes são gerados , sem a necessidade de inseri-los nos bancos de dados.




Figura. 3 V's do Big Data

Letra a.

028. (CESPE/TCE-PE/2017) O termo Big Data Analytics refere-se aos poderosos softwares que tratam dados estruturados e não estruturados para transformá-los em informações úteis às organizações, permitindo-lhes analisar dados, como registros de call center, postagens de redes sociais, de blogs, dados de CRM e demonstrativos de resultados.



Big Data Analytics é o trabalho analítico e inteligente de grandes volumes de dados, **estruturados ou não estruturados**, que são coletados, armazenados e interpretados por softwares de altíssimo desempenho.

Trata-se do cruzamento de uma infinidade de dados do **ambiente interno e externo**, gerando uma espécie de **"bússola gerencial"** para **tomadores de decisão**. Tudo isso, é claro, em um tempo de processamento extremamente reduzido.

Certo.

029. (CESPE/TCE-PE/AUDITOR DE CONTROLE EXTERNO/AUDITORIA DE CONTAS PÚBLICAS/2017) Com relação a Big Data, julgue o item subsequente.

Além de estar relacionado à grande quantidade de informações a serem analisadas, o *Big Data* considera o volume, a velocidade e a variedade dos dados estruturados — dos quais se conhece a estrutura de armazenamento — bem como dos não estruturados, como imagens, vídeos, áudios e documentos.



Big Data é um termo que descreve o grande volume de dados — estruturados e não estruturados — que impactam as empresas diariamente.

Para analisar a viabilidade de implementação do Big Data em uma organização, citavam-se inicialmente as três dimensões (conhecidas como 3V), que são: **Volume, Variedade e Velocidade**. A literatura destacou, em seguida, o **4V** (incluindo a **Veracidade**); depois, o **5V** (incluindo **Veracidade e Valor**); atualmente, a IBM cita **7 dimensões (Volume, Variedade, Velocidade, Veracidade, Valor, Governança e Pessoas)** a serem consideradas ao avaliar a viabilidade de uma solução de Big Data.

Certo.

030. (CESPE/FUNPRESP-JUD/ANALISTA/TECNOLOGIA DA INFORMAÇÃO/2016) A respeito de banco de dados, julgue o próximo item. Uma big data não engloba dados não estruturados, mas inclui um imenso volume de dados estruturados suportado por tecnologias como o DataMining e o DataWarehouse para a obtenção de conhecimento a partir da manipulação desses dados.



Big Data é

“definido genericamente como a **captura, gerenciamento e a análise de dados que vão além dos dados tipicamente estruturados**, que podem ser consultados e pesquisados através de bancos de dados relacionais.

Frequentemente são **dados obtidos de arquivos não estruturados como vídeo digital, imagens, dados de sensores, arquivos de logs e de qualquer tipo de dados não contidos em registros típicos com campos que podem ser pesquisados**”.

- **Dados estruturados:** são armazenados em bancos de dados, sequenciados em tabelas;
- **Dados semiestruturados:** acompanham padrões heterogêneos, sendo mais difíceis de serem identificados, pois podem seguir diversos padrões;
- **Dados não estruturados:** são uma mistura de dados provenientes de fontes diversificadas, como imagens, áudios e documentos online.

Fonte: https://www.gta.ufrj.br/grad/15_1/bigdata/vs.html

Errado.

031. (ESAF/ANAC/ANALISTA ADMINISTRATIVO/2016) Big Data é:

- a) volume + variedade + agilidade + efetividade, tudo agregando + valor + atualidade.
- b) volume + oportunidade + segurança + veracidade, tudo agregando + valor.
- c) dimensão + variedade + otimização + veracidade, tudo agregando + agilidade.

- d) volume + variedade + velocidade + veracidade, tudo agregando + valor.
e) volume + disponibilidade + velocidade + portabilidade, tudo requerendo – valor.



As 5 Dimensões (5 Vs) do Big Data são: volume, variedade, velocidade, veracidade e valor.

Vamos à descrição dessas **cinco dimensões – 5 Vs – do Big Data**, que são de grande importância para a prova.

Volume

O **volume** da informação refere-se ao fato de que certas coleções de dados atingem a faixa de gigabytes (bilhões de bytes), terabytes (trilhões), petabytes (milhares de trilhões) ou mesmo exabytes (milhões de trilhões).

Variedade

A **variedade** significa que os dados de hoje aparecem em todos os tipos de formatos, como, por exemplo, arquivos de texto, e-mails, medidores e sensores de coleta de dados, vídeos, áudios, dados de ações do mercado ou transações financeiras.

Velocidade

A **velocidade** está relacionada à **rapidez** com que os dados são produzidos e tratados para atender à demanda, o que significa que não é possível armazená-los por completo, de modo que somos obrigados a escolher quais dados guardar e quais descartar. A tecnologia de Big Data agora nos permite analisar os dados **no momento em que são gerados**, sem a necessidade de inseri-los nos bancos de dados.

Veracidade

Quanto à **veracidade**, Weber et al. (2009) ressaltaram que as informações verdadeiras podem ser usadas pelos gestores para responder aos desafios estratégicos. A veracidade garantiria, então, a confiabilidade dos dados.

Valor

Com relação ao **valor**, Chen et al. (2014) afirmam que as análises críticas de dados podem ajudar as empresas a entender melhor seus negócios, trazendo benefícios.

A combinação “volume + velocidade + variedade + veracidade”, além de todo e qualquer outro aspecto que caracteriza uma solução de Big Data, mostrará ser inviável se o resultado não trazer benefícios significativos que compensem o investimento. Este é o ponto de vista do **valor** (*value*), conforme destaca <http://www.infowester.com/big-data.php>.


Letra d.

032. (FGV/TJ-SC/ANALISTA DE SISTEMAS/2015) Os termos Business Intelligence (BI) e Big Data confundem-se em certos aspectos. Uma conhecida abordagem para identificação dos pontos críticos de cada paradigma é conhecida como 3V, e destaca:

- a) variedade, visualização, volume;
- b) velocidade, virtualização, volume;
- c) variedade, velocidade, volume;
- d) virtualização, visualização, volume;
- e) variedade, visualização, virtualização.



A abordagem **3V** destaca o **V**olume, a **V**ariiedade e a **V**elocidade.



Fonte: <http://pt.slideshare.net/RioInfo2009/big-data-tendncias-e-oportunidades-palestrante-srgio-mafra>

São eles:

- O **volume** da informação se refere ao fato de que certas coleções de dados atingem a faixa de gigabytes (bilhões de bytes), terabytes (trilhões), petabytes (milhares de trilhões) ou mesmo exabytes (milhões de trilhões).
- A **velocidade** está relacionada à rapidez com que os dados são produzidos e tratados para atender à demanda, o que significa que não é possível armazená-los todos, de modo que somos obrigados a escolher dados para guardar e outros para descartar.
- A **variedade** significa que os dados de hoje aparecem em todos os tipos de formatos, como, por exemplo, arquivos de texto, e-mails, medidores e sensores de coleta de dados, vídeos, áudios, dados de ações do mercado ou transações financeiras.

Letra c.

033. (CESPE/TCU/AUDITOR FEDERAL DE CONTROLE EXTERNO – CONHECIMENTOS GERAIS/2015) No que concerne a data mining (mineração de dados) e big data, julgue o seguinte item. Devido à quantidade de informações manipuladas, a (cloud computing) computação em nuvem torna-se inviável para soluções de big data.



Para processar grandes volumes de dados em tempo real, as empresas deverão usar a infraestrutura de Cloud Computing para colocar projetos de Big Data em ação, é o que destaca <https://cloud21.com.br/computacao-em-nuvem/cloud-computing-e-o-motor-do-big-data/>.

A Cloud Computing (Computação em Nuvem) é a infraestrutura que suportará as iniciativas pela sua capacidade de processar grandes volumes de dados em tempo real, requisito do Big Data. Stefanini (em <https://stefanini.com/br/2015/01/relacao-entre-big-data-cloud-computing/>) também destaca que *Big Data* e *Cloud Computing* são praticamente indissociáveis quando o assunto é gerar vantagens competitivas para uma organização a partir das informações que ela possui disponíveis, seja internamente ou no mercado. Segundo o autor, a grande vantagem de associar Big Data à Cloud Computing é a redução dos custos de uma infraestrutura de TI para armazenar e processar os dados. Empresas como a Amazon fornecem serviços para que você possa estruturar toda a sua capacidade de BI fora da sua empresa.

Errado.

034. (FGV/AL-BA/TÉCNICO DE NÍVEL SUPERIOR/ECONOMIA/2014) A expressão Big Data é utilizada para descrever o contexto da informação contemporânea, caracterizada pelo volume, velocidade e variedade de dados disponíveis, em escala inédita. Com relação às características do Big Data, analise as afirmativas a seguir.

I – O volume da informação se refere ao fato de que certas coleções de dados atingem a faixa de gigabytes (bilhões de bytes), terabytes (trilhões), petabytes (milhares de trilhões) ou mesmo exabytes (milhões de trilhões).

II – A velocidade está relacionada à rapidez com a qual os dados são produzidos e tratados para atender à demanda, o que significa que não é possível armazená-los todos, de modo que somos obrigados a escolher dados para guardar e outros para descartar.

III – A variedade significa que os dados de hoje aparecem em todos os tipos de formatos, como, por exemplo, arquivos de texto, email, medidores e sensores de coleta de dados, vídeo, áudio, dados de ações do mercado ou transações financeiras.

Assinale:

- a) se somente a afirmativa I estiver correta.
- b) se somente a afirmativa II estiver correta.
- c) se somente a afirmativa III estiver correta.

d) se somente as afirmativas I e II estiverem corretas.

e) se todas as afirmativas estiverem corretas.



Todas as afirmativas estão corretas!

- **Volume** – refere-se à quantidade de dados a ser capturada, armazenada e manipulada. Estamos falando de petabytes ou terabytes de dados, tendendo a aumentar!
- **Velocidade** – refere-se à velocidade de produção dos novos dados, à velocidade em que é preciso agir com relação a eles ou à taxa em que esses dados estão mudando. A depender da velocidade, pode ser necessário escolher dados para guardar e outros para descartar;
- **Variedade** – significa que os dados de hoje aparecem em todos os tipos de formatos, envolvendo, por exemplo, dados de redes sociais, vídeos, áudios etc. Já não é mais possível antecipar o conteúdo e a estrutura dos mesmos!

Letra e.

035. (CESPE/TJ-SE/ANALISTA JUDICIÁRIO/BANCO DE DADOS/2014) O processamento de consultas *ad hoc* em *Big Data*, devido às características de armazenamento dos dados, utiliza técnicas semelhantes às aquelas empregadas em consultas do mesmo tipo em bancos de dados tradicionais.



O processamento de **consultas ad hoc** no *Big Data* traz desafios diferentes daqueles incorridos ao realizar consultas *ad hoc* em dados estruturados, pelo fato de as fontes e formatos dos dados não serem fixos e exigirem mecanismos distintos para recuperá-los e processá-los. Embora as **consultas ad hoc** simples possam ser resolvidas pelos provedores de *Big Data*, na maioria dos casos, elas são complexas porque os dados, algoritmos, formatos e resoluções da entidade devem ser descobertos dinamicamente.

Referência: <http://www.ibm.com/developerworks/br/library/bd-archpatterns4/>

Errado.

036. (CESPE/TJ-SE/ANALISTA JUDICIÁRIO/BANCO DE DADOS/2014) Ao utilizar armazenamento dos dados em nuvem, a localização do processamento de aplicações *Big Data* não influenciará os custos e o tempo de resposta, uma vez que os dados são acessíveis a partir de qualquer lugar.



A localização do processamento de aplicações de *Big Data* influenciará os custos e o tempo de resposta.

Errado.

037. (CESPE/TJ-SE/ANALISTA JUDICIÁRIO/BANCO DE DADOS/2014) Em soluções *Big Data*, a análise dos dados comumente precisa ser precedida de uma transformação de dados não estruturados em dados estruturados.



Conforme destaca <http://www.ibm.com/developerworks/br/library/bd-archpatterns4/>, para executar a análise de quaisquer dados, eles devem estar em algum tipo de formato **estruturado**. Os dados não estruturados acessados de várias fontes podem ser armazenados como estão e, em seguida, transformados em dados estruturados e novamente armazenados nos sistemas de armazenamento de big data. O texto não estruturado pode ser convertido em dados estruturados ou semiestruturados. Da mesma forma, os dados de imagem, áudio e vídeo precisam ser convertidos para formatos que possam ser usados para análise.

Certo.

038. (CESPE/TJ-SE/ANALISTA JUDICIÁRIO/BANCO DE DADOS/ADAPTADA/2014) Julgue o item que se segue, no que se refere a *Big Data*.

Em soluções *Big Data*, a análise dos dados comumente precisa ser precedida de uma transformação de dados estruturados em dados não estruturados.



Em soluções de *Big Data*, a análise dos dados comumente precisa ser precedida de uma transformação de dados não estruturados em dados estruturados.

Conforme destaca <http://www.ibm.com/developerworks/br/library/bd-archpatterns4/>, para executar a análise em quaisquer dados, eles devem estar em algum tipo de formato **estruturado**. Os dados não estruturados acessados de várias fontes podem ser armazenados como estão e, em seguida, transformados em dados estruturados e novamente armazenados nos sistemas de armazenamento de Big Data. O texto não estruturado pode ser convertido em dados estruturados ou semiestruturados. Da mesma forma, os dados de imagem, áudio e vídeo precisam ser convertidos em formatos que podem ser usados para análise.

Errado.

039. (CESPE/TRE-GO/TÉCNICO JUDICIÁRIO/ÁREA ADMINISTRATIVA/2013) A Big Data pode ser utilizada na EAD para se entender as preferências e necessidades de aprendizagem dos alunos e, assim, contribuir para soluções mais eficientes de educação mediada por tecnologia.



Isso mesmo! Ferramentas do tipo Big Data têm permitido um conhecimento muito maior e melhor do perfil e comportamento dos alunos de EAD, fazendo com que os novos cursos sejam cada vez mais eficazes.

Certo.

040. (INÉDITA/2023) Apache Hadoop é um software open source para armazenamento e processamento em larga escala de grandes conjuntos de dados (Big Data), em clusters de hardware de baixo custo.



Hadoop é um sistema de armazenamento compartilhado, distribuído e altamente confiável para o processamento de grandes volumes de dados através de clusters de computadores. Em outras palavras, Hadoop é um framework que facilita o funcionamento de diversos computadores com o objetivo de analisar grandes volumes de dados.

O **projeto Apache Hadoop** é composto por três módulos principais:

- Hadoop Distributed File System (HDFS)
- Hadoop YARN
- Hadoop MapReduce



<http://hadoop.apache.org>

Certo.

041. (INÉDITA/2022) Julgue o item que se segue, no que se refere a *Big Data*.

Os sistemas de armazenamento de dados tradicionais são adequados para o big data.



O **armazenamento de dados tradicional não é a melhor opção para armazenar big data**, mas, nos casos em que as empresas estão realizando a exploração inicial de dados, elas podem optar por usar o *Data Warehouse*, o sistema RDBMS (sistemas relacionais) e outros armazenamentos de conteúdo existentes. Esses sistemas de armazenamento podem ser usados para armazenar os dados que são compilados e filtrados usando a plataforma de big data. **Não** considere os sistemas de armazenamento de dados tradicionais como adequados para o Big Data.

Referência: <http://www.ibm.com/developerworks/br/library/bd-archpatterns4/>

Errado.

042. (INÉDITA/2022) Para analisar a viabilidade de implementação do Big Data em uma organização, a literatura citava inicialmente três dimensões (conhecidas como 3V's), que são: Volume, Variedade e Veracidade.



Para analisar a viabilidade de implementação do Big Data em uma organização, citavam-se inicialmente as três dimensões (conhecidas como 3V), que são: **Volume, Variedade e Velocidade**. A literatura destacou, em seguida, o **4V** (incluindo a **Veracidade**); depois, o **5V** (incluindo **Veracidade** e **Valor**); atualmente, a IBM cita **7 dimensões (Volume, Variedade, Velocidade, Veracidade, Valor, Governança e Pessoas)** a serem consideradas ao avaliar a viabilidade de uma solução de Big Data.




Figura. 3 dimensões (3 V's) do Big Data



Figura. 4 dimensões (4 V's) do Big Data

Errado.

043. (INÉDITA/2022) Data Mart é um termo utilizado para descrever grandes e complexos conjuntos de dados que são muito difíceis de capturar, processar, armazenar, buscar e analisar com os sistemas de base de dados convencionais.



Esse é o conceito de **Big Data**!

Siewert (2013) destaca que o termo ***Big Data*** é

*“definido genericamente como a **captura**, **gerenciamento** e a **análise de dados que vão além dos dados tipicamente estruturados**, que podem ser consultados e pesquisados através de bancos de dados relacionais. Frequentemente são **dados obtidos de arquivos não estruturados** como **vídeo digital, imagens, dados de sensores, arquivos de logs e de qualquer tipo de dados não contidos em registros típicos com campos que podem ser pesquisados**”.*

De acordo com Landim (2015), trata-se de um termo usado para descrever **grandes e complexos conjuntos de dados** que são muito difíceis de capturar, processar, armazenar, buscar e analisar com os sistemas de bancos de dados convencionais.

As 5 Dimensões (5 Vs) do Big Data: volume, velocidade, variedade, valor e veracidade.

Uma solução de big data possui camadas horizontais e verticais:

- **As camadas horizontais**, de “baixo” para “cima”, são: **Fontes de Big Data, Camada de Tratamento e Armazenamento, Camada de Análise e Camada de Consumo.**
- **As camadas verticais** são: Integração de informações, Governança de Big Data, Gerenciamento de sistemas e Qualidade de serviço.

Errado.

044. (FGV/ANALISTA DE TECNOLOGIA DA INFORMAÇÃO DA FAZENDA ESTADUAL (SEFAZ AM)/2022) Com relação às características dos componentes do ecossistema Hadoop, analise as afirmativas a seguir.

I – Kafka é um gerenciador de armazenamento de dados do tipo colunar de código aberto de fácil integração com MapReduce e Spark, que utiliza o modelo de consistência forte, permite que o desenvolvedor escolha requisitos de consistência por solicitação, incluindo a opção de consistência estritamente serializável.

II – Impala, que tem forte integração com o Kudu, permite que o desenvolvedor de aplicações o utilize para inserir, consultar, atualizar e excluir dados no Kudu usando a sintaxe SQL do Impala. Adicionalmente, permite usar JDBC ou ODBC para conectar aplicativos novos ou pré-existentes escritos em qualquer linguagem, estrutura ou ferramenta de inteligência de negócios.

III – Kudu permite integrar seu próprio catálogo com o Hive Metastore (HMS). O HMS é o provedor de metadados e catálogo padrão no ecossistema Hadoop. Quando a integração está habilitada, as tabelas Kudu podem ser descobertas e usadas por ferramentas externas com reconhecimento de HMS, mesmo que elas não estejam integradas ao Kudu.

Está correto o que se afirma em

- a) I, apenas.
- b) II, apenas.
- c) III, apenas.

d) I e II, apenas.

e) II e III, apenas.




Figura. <https://cazena.com/streaming-data-analytics-kafka-spark-kudu-tutorial/>

- **Apache Kafka:** plataforma de fila de mensagens que transmite dados para Spark;
- **Spark Streaming:** lida com a ingestão e transformação de dados;
- **Apache Kudu:** camada de armazenamento;
- **Impala:** consulta à tabela Kudu.

I – Errada. Kafka **não** é um gerenciador de armazenamento de dados, apesar de realizar alguns tratamentos iniciais nos dados (organizando-os em tópicos). **Apache Kafka é uma plataforma de processamento de fluxo de código aberto amplamente usada.** Trata-se de uma plataforma distribuída de transmissão de dados que é capaz de publicar, subscrever, armazenar e processar fluxos de registro em tempo real. Essa plataforma foi desenvolvida para processar fluxos de dados provenientes de diversas fontes e entregá-los a vários clientes.

II – Certa. **Impala, que tem forte integração com o Kudu, permite que o desenvolvedor de aplicações o utilize para inserir, consultar, atualizar e excluir dados no Kudu usando a sintaxe SQL do Impala.** Adicionalmente, permite usar JDBC ou ODBC para conectar aplicativos novos ou pré-existentes escritos em qualquer linguagem, estrutura ou ferramenta de inteligência de negócios.

III – Certa. Kudu permite integrar seu próprio catálogo com o Hive Metastore (HMS). **O HMS é o provedor de metadados e catálogo padrão no ecossistema Hadoop.** Quando a integração está habilitada, as tabelas Kudu podem ser descobertas e usadas por ferramentas externas com reconhecimento de HMS, mesmo que não estejam integradas ao Kudu.

Veja mais:

<https://www.redhat.com/pt-br/topics/integration/what-is-apache-kafka> <https://kafka.apache.org/>

<https://cazena.com/streaming-data-analytics-kafka-spark-kudu-tutorial/>

Itens II e III estão corretos.

Letra e.

REFERÊNCIAS

ALECRIM, E. **O que é Big Data?** 2013. Disponível em: <<http://www.infowester.com/big-data.php>>. Acesso em: 05 jul. 2020.

BIG DATA BUSINESS. **Big Data Analytics: você sabe o que é?** Disponível em: <<http://www.bigdatabusiness.com.br/voce-sabe-o-que-e-big-data-analytics/>> Acesso em: 10 mar. 2019.

_____. **Tipos de análise de Big Data: você conhece todos os 4?** Disponível em: <<http://www.bigdatabusiness.com.br/conheca-os-4-tipos-de-analises-de-big-data-analytics/>>. Acesso em: 10 mar. 2019.

BRITO, S. H. B. **Afinal, o que é Big Data?** 2013. Disponível em: <<http://labcisco.blogspot.com.br/2013/08/afinal-o-que-e-big-data.html>>.

CIENCIA E DADOS. **Data Lake, a fonte do Big Data.** Disponível em: <<http://www.cienciaedados.com>>. Acesso em: 14 jan. 2023.

DATASCIENCEACADEMY. 2022. Disponível em: <<https://www.datascienceacademy.com.br>>. Acesso em: 05 jan. 2023.

DEV MEDIA. **Introdução ao Apache Spark.** 2020. Disponível em: <<https://www.devmedia.com.br/introducao-ao-apache-spark/34178#:~:text=O%20Apache%20Spark%20%C3%A9%20uma,de%20grandes%20volumes%20de%20dados>>. Acesso em: 15 jan. 2023.

FERNANDES, A. A.; DE ABREU, V. F. **Implantando a Governança de TI: Da estratégia à Gestão de Processos e Serviços.** Brasport, 2014.

GARTNER IT GLOSSARY. Disponível em: <<https://www.gartner.com/en/information-technology/glossary/big-data>> Acesso em: 15 nov. 2012.

GEORGE G., HAAS, M. & PENTLAND A., **Big Data and Management.** Academy of Management Journal, 2014, Vol. 57, No. 2, 321–326. Disponível em: <http://dx.doi.org/10.5465/amj.2014.4002> Acesso em: 25 abr. 2014.

GOLDMAN, Alfredo et al. **Apache Hadoop: conceitos teóricos e práticos, evolução e novas possibilidades.** XXXI Jornadas de atualizações em informatica, p. 88–136, 2012.

HANSON, J. **Uma Introdução ao Hadoop Distributed File System.** Disponível em: <<https://www.ibm.com/developerworks/br/library/wa-introhdfs/index.html>> Acesso em: 19 mar. 2018.

INTEL IT CENTER. **Guia de Planejamento Saiba mais sobre Big Data Medidas que Gerentes de TI Podem Tomar para Avançar com o Software Apache Hadoop.** 2013.

IBM. **Como saber se uma solução de big data é ideal para sua organização.** Disponível em: <<https://www.ibm.com/developerworks/br/library/bd-archpatterns2/index.html>> Acesso em: 25 dez. 2017.

JUNIOR, J. R. F. **Lambda x Kappa.** 2019. Disponível em: <<https://www.linkedin.com/pulse/lambda-vs-kappa-jose-r-f-junior/?originalSubdomain=pt>>. Acesso em: 17 jan. 2023.

MAÇADA, A. C. G.; Vivian Passos Canary. **A Tomada de decisão no contexto do Big Data: Estudo de caso único.** 2014. Disponível em: <http://www.anpad.org.br/admin/pdf/2014_EnANPAD_ADI1088.pdf>.

McAFEE, A.; BRYNJOLFSSON, E. **Big Data: The Management Revolution.** Harvard Business Review, October, 2012. p. 1-9.

MACHADO, Henrique. **Hadoop MapReduce: Introdução a Big Data.** Disponível em: <<https://www.devmedia.com.br/hadoop-mapreduce-introducao-a-big-data/30034>>. Acesso em: 25 abr. 2018.

MACHADO, F. N. R. **Big Data.** São Paulo: Saraiva, 2018. *E-book*.

MAFRA, S. Big data: tendências e oportunidades. 2013. Disponível em: <<http://pt.slideshare.net/RioInfo2009/big-data-tendencias-e-oportunidades-palestrante-srgio-mafra>>. Acesso em: 05 jul. 2020.

MARQUESONE, R. **O novo desafio das empresas e profissionais do mercado.** <http://paineira.usp.br/lassu/wp-content/uploads/2017/01/2017.02.07-palestra_rosangela_bigdata.pdf>. Acesso em: 25 ago. 2020.

MYSORE, D., KHUPAT, S., JAIN, S. **Entendendo as camadas de arquitetura de uma solução de big data.** 2014. Disponível em: <<http://www.ibm.com/developerworks/br/library/bd-archpatterns3/>>. Acesso em: 10 jul. 2020.

_____. **Entendendo padrões atômicos e compostos de soluções de big data.** 2014. Disponível em: <<http://www.ibm.com/developerworks/br/library/bd-archpatterns4/>>. Acesso em: 10 jul. 2020.

Intel Corporation. **Guia de Planejamento. Saiba mais sobre Big Data.** 2013. Disponível em: <<https://www.intel.com.br/content/dam/www/public/lar/br/pt/documents/articles/90318386-1-por.pdf>>. Acesso em: 25 ago. 2020.

OEIRAS, A. **Uma Breve Introdução do HADOOP HDFS — Hadoop Distributed File System.** 2020. Disponível em: <<https://medium.com/@cm.oeiras01/uma-breve->

introdu%C3%A7%C3%A3o-do-hadoop-hdfs-hadoop-distributed-file-system-2-2-7694055a7917>. Acesso em: 17 jan. de 2023.

SANTANA, R. **Coleta e Análise de Dados Matérias-primas de Big Data Analytics**. 2018. Disponível em: <<http://rubenssantana.com/coleta-e-analise-de-dados/>>. Acesso em: 20 ago. 2020.

SIEWERT, Sam B. **Big data in the cloud: data velocity, volume, variety veracity**. IBM developersWorks. July 2013.

TAURION, C. **Big Data**. São Paulo: Brasport, 2013.

TEJADA, Z. **Arquiteturas de Big Data**. 2020. Disponível em: <<https://learn.microsoft.com/pt-br/azure/architecture/data-guide/big-data/>>. Acesso em: jan. 2023.

TURBAM, E. et al. **Business Intelligence: um Enfoque Gerencial para a Inteligência do Negócio**. Bookman, 2009.

WEBER, K.et. al.. 2009. **One size does not fit all—a contingency approach to data governance**. Journal of Data and Information Quality, Volume 1, Issue 1, Article 4, June 2009, 27 p.

WIKERSON, L. **De que maneira o Big Data melhora nossa vida diária?** 2015. Disponível em: <<http://www.tecmundo.com.br/tecnologia-da-informacao/80027-maneira-big-data-melhora-nossa-vida-diaria-infografico.htm>>. Acesso em: 04 jul. 2020.

VORHIES, W. **Prescriptive versus predictive analytics – a distinction without a difference?** 2014. Disponível em: <<https://www.datasciencecentral.com/profiles/blogs/prescriptive-versus-predictive-analytics-a-distinction-without-a>>. Acesso em: 20 ago. 2020.

UFSC. **Questionário sobre HADOOP**. 2022. Disponível em: <http://www.inf.ufsc.br/~bosco.sobral/ensino/ine5645/QUESTIONARIO_SOBRE_HADOOP.pdf> Acesso em: 17 de jan. de 2023.

Abra



caminhos



crie

futuros

gran.com.br

